SKRIPSI

Judul:

Klasifikasi Status Tumbuh Kembang dan Gizi Balita Menggunakan LightGBM dan XGBoost

Disusun oleh:

PUSPA INDAH

NIM. 535220035

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS TEKNOLOGI INFORMASI

UNIVERSITAS TARUMANAGARA

2026

Pengesahan

Nama	:	PUSPA INDAH
NIM	:	535220035
Program Studi	:	TEKNIK INFORMATIKA
Judul Skripsi	:	Klasifikasi Status Tumbuh Kembang dan Gizi Balita Menggunakan LightGBM dan XGBoost
Title	:	Classification of Toddler Growth, Development, and Nutritional Status Using LightGBM and XGBoost

Skripsi ini telah dipertahankan di hadapan Dewan Penguji Program Studi TEKNIK INFORMATIKA Fakultas Teknologi Informasi Universitas Tarumanagara pada tanggal 09-Juni-2026.

Tim Penguji:
1. LELY HIRYANTO, ST., M.Sc.,Ph.D.
2. JEANNY PRAGANTHA, Ir., M.Eng

Yang bersangkutan dinyatakan: **LULUS.**

Pembimbing:
TENY HANDHAYANI, S.Kom., M.Kom., Ph.D.
NIK/NIP: 10813002

Teny Handhayani 70ff6fd7-d83e-4e1f-aa79-4119beabc33a FTI Untar 2026.06.27 17:07:07+07'00'

Pembimbing Pendamping:
MEIRISTA WULANDARI, S.T., M.Eng. Dr.
NIK/NIP: 10316003

Jakarta, 09-Juni-2026
Ketua Program Studi

Digitally signed by Lely Hiryanto
Date: 2026.06.28 06:24:02 +07'00'

LELY HIRYANTO, ST., M.Sc.,Ph.D.

Persetujuan

Nama	:	PUSPA INDAH
NIM	:	535220035
Program Studi	:	TEKNIK INFORMATIKA
Judul	:	Klasifikasi Status Tumbuh Kembang dan Gizi Balita Menggunakan LightGBM dan XGBoost

Skripsi ini disetujui untuk diuji

Jakarta, 22-Mei-2026

Pembimbing:
TENY HANDHAYANI, S.Kom., M.Kom., Ph.D.
NIK/NIP: 10813002

Teny Handhayani
70ff6fd7-d83e-4e1f-aa79-4119beabc33a
FTI Untar
2026.05.25 14:30:36+07'00'

Pembimbing Pendamping:
MEIRISTA WULANDARI, S.T., M.Eng. Dr.
NIK/NIP: 10316003

Pernyataan

Nama	:	PUSPA INDAH
NIM	:	535220035
Program Studi	:	TEKNIK INFORMATIKA
Judul	:	Klasifikasi Status Tumbuh Kembang dan Gizi Balita Menggunakan LightGBM dan XGBoost

Dengan ini menyatakan bahwa skripsi ini merupakan hasil kerja saya sendiri di bawah bimbingan Tim Pembimbing dan bukan hasil plagiasi dan/atau kegiatan curang lainnya.

Jika saya melanggar pernyataan ini, maka saya bersedia dikenakan sanksi sesuai aturan yang berlaku di Universitas Tarumanagara.

Demikian pernyataan ini saya buat dengan sebenarnya, untuk dipergunakan sebagaimana mestinya.

Jakarta, 22-Mei-2026
Yang menyatakan



PUSPA INDAH
NIM. 535220035

Dipindai dengan CamScanner

ABSTRAK

Puspa Indah, NPM: 535220035. Klasifikasi Status Tumbuh Kembang dan Gizi Balita Menggunakan LightGBM dan XGBoost. Skripsi, Jakarta: Program Studi Teknik Informatika, Fakultas Teknologi Informasi, Universitas Tarumanagara, Juni 2026.

Status tumbuh kembang anak dan gizi balita merupakan aspek penting dalam bidang kesehatan. Kondisi tersebut dapat memengaruhi pertumbuhan fisik, perkembangan, serta kualitas kesehatan anak pada masa berikutnya. Pemantauan status balita umumnya dilakukan melalui pengukuran antropometri, seperti usia, berat badan, dan tinggi badan. Penelitian ini bertujuan untuk mengembangkan aplikasi klasifikasi status tumbuh kembang dan gizi balita berbasis *machine learning* dengan menggunakan algoritma *Light Gradient Boosting Machine* (*LightGBM*) dan *Extreme Gradient Boosting* (*XGBoost*). Penelitian ini menggunakan dataset *Stunting and Nutritional Status of Toddler from Jeneponto Regency, South Sulawesi, Indonesia* yang tersedia pada repositori Mendeley Data. Dataset awal memiliki 40.071 baris dan 17 kolom. Penelitian ini melakukan tahap pra-pemrosesan data melalui penghapusan 8.970 data duplikat, pembersihan *missing value*, dan seleksi variabel. Setelah tahap tersebut dilakukan, dataset akhir yang digunakan berjumlah 14.326 baris dan 9 kolom. Variabel masukan pada penelitian ini terdiri atas jenis kelamin, tanggal lahir, tanggal pengukuran, usia dalam bulan, berat badan (kg), dan tinggi badan (cm). Penelitian ini membagi keluaran klasifikasi ke dalam tiga indikator antropometri, yaitu *Weight-for-Age* (W/A), *Height-for-Age* (H/A), dan *Weight-for-Height* (W/H). Setiap indikator memiliki kategori kelas yang berbeda, sehingga penelitian ini melatih model secara terpisah pada masing-masing target. Evaluasi model dilakukan menggunakan metrik *accuracy*, *precision*, *recall*, *F1-score*, *confusion matrix*, dan *5-Fold Cross Validation*. Hasil pengujian menunjukkan bahwa model *LightGBM* memberikan performa terbaik pada seluruh target klasifikasi. Pada target *Height-for-Age*, model *LightGBM* memperoleh nilai *accuracy* sebesar 0,9909 dan *F1 macro* sebesar 0,9882. Pada target *Weight-for-Age*, model *LightGBM* memperoleh nilai *accuracy* sebesar 0,9374 dan *F1 macro* sebesar 0,8349. Pada target *Weight-for-Height*, model *LightGBM* memperoleh nilai *accuracy* sebesar 0,9669 dan *F1 macro* sebesar 0,8522. Berdasarkan hasil tersebut, model *LightGBM* dapat digunakan sebagai model utama pada aplikasi *GrowSmart Health*. Aplikasi ini menampilkan hasil klasifikasi status tumbuh kembang dan gizi balita serta informasi pendukung yang dapat membantu proses skrining awal. Dengan demikian, aplikasi *GrowSmart Health* dapat membantu pemantauan balita secara lebih praktis. Namun, hasil analisis dari aplikasi tetap perlu dikonfirmasi oleh tenaga kesehatan.

Kata Kunci: Antropometri, Klasifikasi, LightGBM, Status Gizi Balita, Tumbuh Kembang Anak, XGBoost

KATA PENGANTAR

Puji syukur penulis panjatkan kepada Tuhan Yang Maha Esa atas berkat, rahmat, dan penyertaan-Nya, sehingga penulis dapat menyelesaikan skripsi yang berjudul "Klasifikasi Status Tumbuh Kembang dan Gizi Balita Menggunakan LightGBM dan XGBoost". Penulis menyusun skripsi ini sebagai salah satu syarat untuk memperoleh gelar Sarjana Komputer pada Program Studi Teknik Informatika, Fakultas Teknologi Informasi, Universitas Tarumanagara.

Dalam proses penyusunan skripsi ini, penulis memperoleh banyak bantuan, arahan, dukungan, dan motivasi dari berbagai pihak. Bantuan tersebut sangat berarti bagi penulis dalam menyelesaikan penelitian dan mengembangkan aplikasi GrowSmart Health sebagai alat bantu skrining awal status pertumbuhan dan gizi balita. Oleh karena itu, penulis ingin menyampaikan rasa terima kasih yang tulus kepada:

1. Prof. Lina, S.T., M.Kom., Ph.D., selaku Dekan Fakultas Teknologi Informasi Universitas Tarumanagara, yang telah memberikan kesempatan dan dukungan kepada penulis selama menjalani pendidikan di Fakultas Teknologi Informasi.
2. Ibu Lely Hiryanto, S.T., M.Sc., Ph.D., selaku Ketua Program Studi Sarjana Teknik Informatika Universitas Tarumanagara, yang telah memberikan arahan dan dukungan akademik selama penulis menempuh perkuliahan.
3. Ibu Jeanny Pragantha, Ir., M.Eng., selaku koordinator skripsi, yang telah membantu penulis melalui arahan dan koordinasi selama proses

pelaksanaan skripsi.

4. Ibu Teny Handhayani, S.Kom., M.Kom., Ph.D., selaku dosen pembimbing utama, yang telah meluangkan waktu untuk memberikan bimbingan, masukan, koreksi, dan dorongan kepada penulis dalam menyusun penelitian serta mengembangkan aplikasi ini.
5. Dr. Ir. Meirista Wulandari, S.T., M.Eng., selaku dosen pembimbing pendamping, yang yang telah meluangkan waktu untuk memberikan bimbingan, saran, dan perhatian kepada penulis selama proses penyusunan skripsi hingga penelitian ini dapat diselesaikan dengan baik.
6. Dr. dr. Wiyarni Pambudi, Sp.A., IBCLC, selaku dokter spesialis anak dan Dosen Departemen Ilmu Kesehatan Anak Fakultas Kedokteran Universitas Tarumanagara, yang telah memberikan penilaian, masukan, dan arahan dalam proses validasi aplikasi.
7. Ibu Syukriah Usman, S.Gz., RD, selaku dietisien di Rumah Sakit Islam Jakarta Cempaka Putih, yang telah memberikan penilaian dan saran dalam proses validasi aplikasi, khususnya terkait informasi status gizi dan kejelasan hasil yang ditampilkan.
8. Bidan Mercu Tiana, Am. Keb., yang telah memberikan masukan dan pandangan mengenai kebutuhan pemantauan tumbuh kembang serta gizi balita sebagai bahan pendukung dalam penelitian ini.
9. Rumah Sakit Islam Jakarta Cempaka Putih, yang telah memberikan dukungan dan kesempatan kepada penulis dalam pelaksanaan proses

validasi yang berkaitan dengan pengembangan aplikasi.

10. Orang tua dan keluarga penulis, yang senantiasa memberikan doa, kasih sayang, dukungan moral, dukungan materi, perhatian, nasihat, serta semangat kepada penulis selama menjalani masa perkuliahan hingga proses penyusunan skripsi ini dapat diselesaikan.
11. Rakha Naufal Sujana, selaku teman pendamping penulis, yang telah memberikan dukungan, semangat, perhatian, serta bantuan selama proses perkuliahan dan penyusunan skripsi ini. Kehadiran dan dukungan yang diberikan sangat berarti bagi penulis dalam menghadapi berbagai proses hingga skripsi ini dapat diselesaikan.
12. Theresa Patricia, yang telah menjadi sosok kakak bagi penulis selama berada di lingkungan kampus. Terima kasih atas perhatian, arahan, bantuan, dan dukungan yang telah diberikan kepada penulis selama menjalani masa perkuliahan.
13. Khansa Maritza, Nafisya Sefa Nur vinta, Maulitha Fuji Astuti, Nabilah Bertha, serta teman-teman dalam grup “Tadinya Mesra” termasuk Rafi Cahya, yang telah memberikan dukungan, bantuan, kebersamaan, canda tawa, dan semangat kepada penulis selama proses perkuliahan hingga penyusunan skripsi ini. Kehadiran mereka memberikan warna tersendiri dalam perjalanan akademik penulis.
14. Sahabat dan teman-teman penulis lainnya, yang telah memberikan dukungan, bantuan, kebersamaan, serta semangat selama proses

perkuliahan dan penyusunan skripsi.

15. Seluruh pihak yang tidak dapat penulis sebutkan satu per satu, yang telah memberikan bantuan secara langsung maupun tidak langsung dalam proses penyelesaian skripsi ini.

Penulis menyadari bahwa skripsi ini masih memiliki kekurangan dan keterbatasan. Oleh karena itu, penulis menerima kritik dan saran yang membangun sebagai bahan perbaikan untuk pengembangan penelitian selanjutnya. Penulis berharap penelitian ini dapat memberikan manfaat bagi pembaca serta menjadi salah satu referensi dalam pengembangan teknologi yang mendukung pemantauan awal status pertumbuhan dan gizi balita.

Jakarta, 24 Mei 2026

Penulis,



Puspa Indah

DAFTAR ISI

Halaman

HALAMAN JUDUL i

LEMBAR PENGESAHAN SKRIPSI ii

LEMBAR PERSETUJUAN SKRIPSI iii

LEMBAR PERNYATAAN iv

ABSTRAK v

KATA PENGANTAR vi

DAFTAR ISI x

DAFTAR TABEL xvi

DAFTAR GAMBAR xxi

DAFTAR LAMPIRAN xxvii

BAB I PENDAHULUAN 1

1.1 Latar Belakang 1

1.2 Rumusan Rancangan 4

1.3 Komponen Rancangan 6

1.4 Spesifikasi Rancangan 9

1.5 Kegunaan Rancangan 14

1.6 Rancangan yang Sudah Dibuat 15

1.7 Sustainaible Development Goals (SDGs) 20

BAB II LANDASAN TEORETIK 23

2.1 Sistem yang Dirancang 23

2.2 Landasan Teori 27

2.2.1 Balita 27

2.2.2 Tumbuh Kembang Balita 28

2.2.3 Gizi Balita 30

2.2.4 Status Tumbuh Kembang dan Gizi Balita 32

2.2.5 Machine Learning 42

2.2.6 Klasifikasi 43

2.2.7 Light Gradient Boosting Machine (LightGBM) 44

2.2.8 Extreme Gradient Boosting (XGBoost) 53

2.2.9 Python 58

2.2.10 Google Colab 59

2.2.11 React Native 60

2.2.12 Pandas 61

2.2.13 Heatmap 61

2.2.14 Expo Go 62

2.2.15 Seaborn 62

2.2.16 Joblib 63

2.2.17 MySQL 63

2.2.18 Visual Studio Code 64

2.2.19 Scikit-learn 65

2.2.20 Matplotlib 66

2.2.21 Evaluasi Model Klasifikasi 67

2.2.22 K – Fold Cross Validation 70

2.2.23 User Acceptance Test (UAT) 71

BAB III RANCANGAN DAN PEMBUATAN 73

3.1 Rancangan Sistem 73

3.1.1 Perencanaan Sistem 75

3.1.2 Analisis Sistem 78

3.1.3 Perancangan Sistem 79

3.1.3.1 Skema Rancangan Sistem 79

3.1.3.2 Skema Rancangan Tahap Pelatihan 80

3.1.3.3 Rancangan Antarmuka 84

3.2 Dataset 89

3.3 Modul Pra-pemrosesan Data 92

3.4 Pembuatan Model Klasifikasi 106

3.4.1 Persiapan Fitur dan Target 106

3.4.2 Pembuatan Model LightGBM 108

3.4.3 Pembuatan Model XGBoost..... 110

3.4.4 Setup Evaluasi Model..... 113

3.4.5 Split Data 80% dan 20%..... 115

3.5 Tampilan Antarmuka Sistem..... 116

BAB IV PENGUJIAN 143

4.1 Cara Pengujian 143

4.1.1 Cara pengujian persiapan fitur dan target (Distribusi Target) 143

4.1.2 Cara Pengujian Heatmap Korelasi 145

4.1.3 Cara pengujian model Evaluasi detail dan Confusion Matrix 147

4.1.4 Cara Pengujian Fungsi Eksperimen 5-Fold Cross Validation..... 151

4.1.5 Cara pengujian Evaluasi K fold Cross Validation..... 159

4.1.6 Cara Pengujian Ringkasan Eksperimen..... 162

4.1.7 Cara Pengujian Boxplot Perbandingan Algoritma 164

4.1.8 Cara Pengujian Boxplot Waktu Komputasi..... 167

4.1.9 Pilih Model Terbaik..... 168

4.1.10 Cara Pengujian Latih Ulang dan Simpan Model Terbaik 170

4.2 Hasil Pengujian 184

4.2.1 Hasil Pengujian Persiapan Fitur dan Target (Distribusi Target) 184

4.2.2 Hasil Pengujian Heatmap Korelasi 186

4.2.3 Hasil Pengujian Model Evaluasi Detail dan Confusion Matrix 189

4.2.4 Hasil Pengujian Fungsi Eksperimen 5-Fold Cross Validation 204

4.2.5 Hasil Pengujian Evaluasi Detail K-Fold Cross Validation 209

4.2.6 Hasil Ringkasan Eksperimen 235

4.2.7 Hasil Pengujian Boxplot Perbandingan Algoritma 238

4.2.8 Hasil Pengujian Boxplot Waktu Komputasi 241

4.2.9 Hasil Pemilihan Model Terbaik 244

4.2.10 Hasil Pengujian Latih Ulang dan Simpan Model Terbaik 246

4.2.11 Hasil BlackBox Tesing 247

4.2.12 Validasi Ahli 248

4.2.13 Hasil Kuesioner 251

4.3 Pembahasan 259

4.3.1 Pembahasan Distribusi Kelas dan Korelasi Data 259

4.3.2 Pembahasan Hasil Evaluasi Model 261

4.3.3 Pembahasan Hasil 5-Fold Cross Validation 265

4.3.4 Pembahasan Pemilihan Model Terbaik 269

4.3.5 Pembahasan Black Box Testing 272

4.3.6 Pembahasan Validasi Ahli 273

4.3.7 Pembahasan Hasil Kuesioner Responden 276

BAB V KESIMPULAN DAN SARAN 283

5.1 Kesimpulan 283

5.2 Saran 285

DAFTAR PUSTAKA 288

LAMPIRAN 300

Daftar Riwayat Hidup 472

DAFTAR TABEL

Halaman

Tabel 1. 1 Penelitian Rancangan yang Sudah Dibuat serta relevansi dengan sistem yang dirancang 15

Tabel 2. 1 Kategori Status Pertumbuhan dan Gizi Balita Berdasarkan WHO dan SDIDTK [79] 36

Tabel 2. 2 Referensi Ringkas Berat Badan dan Tinggi Badan Normal Balita Berdasarkan WHO [79] 39

Tabel 3. 1 Dataset Stunting 90

Tabel 3. 2 Mapping Encoder Target 103

Tabel 4. 1 Pertanyaan BlackBox Testing 173

Tabel 4. 2 Skala Penilaian Kuesioner Pengguna 180

Tabel 4. 3 Daftar Pertanyaan Kuesioner Pengguna 180

Tabel 4. 4 Pernyataan Negatif 183

Tabel 4. 5 Konversi Skor Pernyataan Negatif 184

Tabel 4. 6 Hasil Evaluasi Model pada Seluruh Target Klasifikasi 190

Tabel 4. 7 Hasil Evaluasi Model Algoritma LightGBM Weight For Age 192

Tabel 4. 8 Hasil Evaluasi Model XGBoost Weight For Age 194

Tabel 4. 9 Evaluasi Model LightGBM Height For Age 195

Tabel 4. 10 Evaluasi Model XGBoost Height For Age 196

Tabel 4. 11 Evaluasi Model LightGBM Weight For Height 197

Tabel 4. 12 Evaluasi Model XGBoost Weight For Height 199

Tabel 4. 13 Hasil Pengujian 5-Fold Cross Validation per Fold 205

Tabel 4. 14 Ringkasan Jumlah Hasil Pengujian 5-Fold Cross Validation 208

Tabel 4. 15 Hasil Pengujian 5 K-Fold Cross Validation Weight For Age 210

Tabel 4. 16 Hasil Pengujian 5 K-Fold Cross Validation Height For Age 212

Tabel 4. 17 Hasil 5-Fold Cross Validation Target Weight for Height 215

Tabel 4. 18 Hasil Pengujian Model LightGBM 5 K-Fold Cross Validation Weight For Age 217

Tabel 4. 19 Hasil Pengujian Model XGBoost 5 K-Fold Cross Validation Weight For Age 220

Tabel 4. 20 Hasil Pengujian Model LightGBM 5 K-Fold Cross Validation Height For Age 222

Tabel 4. 21 Hasil Pengujian Model XGBoost 5 K-Fold Cross Validation Height For Age 224

Tabel 4. 22 Hasil Pengujian Model LightGBM 5 K-Fold Cross Validation Weight For Height 226

Tabel 4. 23 Hasil Pengujian Model XGboost 5 K-Fold Cross Validation Weight For Height 229

Tabel 4. 24 Hasil Ringkasan Eksperimen 235

Tabel 4. 25 Hasil Model Terbaik 245

Tabel 4. 26 Hasil Pengujian Latih Ulang dan Simpan Model 247

Tabel 4. 27 Distribusi Data Balita Berdasarkan Jenis Kelamin 252

Tabel 4. 28 Distribusi Data Balita Berdasarkan Kelompok Usia 253

Tabel 4. 29 Hasil Penilaian Pengalaman Menggunakan Aplikasi 254

Tabel 4. 30 Hasil Penilaian Relevansi Output Aplikasi 256

Tabel 4. 31 Ringkasan Hasil Pengujian Kuesioner Responden 259

Tabel L1. 1 Label encoding Perhitungan LightGBM weight for height 301

Tabel L1. 2 Data Latih Perhitungan LightGBM Weight For Height 302

Tabel L1. 3 Data Uji Weight For Height 303

Tabel L1. 4 Tabel kumulatif jumlah kelas di sisi Kiri Weight For Height 305

Tabel L1. 5 Tabel hasil prediksi TEST Weight For Height 320

Tabel L1. 6 Hasil Perhitungan Confusion Matrix Weight For Height 322

Tabel L1. 7 Ringkasan metrik perkelas Weight For Height 326

Tabel L1. 8 Perhitungan Manual LightGBM Weight for Age 330

Tabel L1. 9 Distribusi Data Latih Weight For Age 332

Tabel L1. 10 Ringkasan Perhitungan Data Latih 335

Tabel L1. 11 hasil prediksi seluruh data uji 341

Tabel L1. 12 Data latih Height For Age 344
Tabel L1. 13 Data Uji Height For Age 345
Tabel L1. 14 prediksi seluruh data uji 351
Tabel L2. 1 TRAIN = 20 (data latih) Weight For Height 354
Tabel L2. 2 TEST = 7 (data uji) 355
Tabel L2. 3 Indikator 356
Tabel L2. 4 Gradient 20 Data 358
Tabel L2. 5 kumulatif jumlah kelas di sisi Left 360
Tabel L10. 1 Skor Pernyataan Positif 429
Tabel L10. 2 Konversi Skor Pernyataan Negatif 430
Tabel L10. 3 Data Jenis Kelamin dan Usia Balita Responden 431
Tabel L10. 4 Perhitungan Distribusi Jenis Kelamin Balita 433
Tabel L10. 5 Perhitungan Distribusi Kelompok Usia Balita 434
Tabel L10. 6 Daftar Pernyataan Pengalaman Menggunakan Aplikasi 434
Tabel L10. 7 Perhitungan Pernyataan Nomor 1 435
Tabel L10. 8 Perhitungan Pernyataan Nomor 2 437
Tabel L10. 9 Hasil Perhitungan Skor Pengalaman Menggunakan Aplikasi 438
Tabel L10. 10 Skor Pengalaman Menggunakan Aplikasi per Responden 439
Tabel L10. 11 Perhitungan Pernyataan Nomor 6 pada Relevansi Output Aplikasi 442

Tabel L10. 12 Skor Relevansi Output Aplikasi per Responden 443

Tabel L10. 13 Ringkasan Perhitungan Hasil Kuesioner Responden 445

DAFTAR GAMBAR

Halaman

Gambar 1. 1 Agenda Sustainable Development Goals (SDGs) [15] 21

Gambar 2. 1 Alur Perancangan Sistem 24

Gambar 2. 2 Balita [2] 27

Gambar 2. 3 Alur Kerja Machine Learning [33]..... 43

Gambar 2. 4 Leaf-wise tree growth in LGBM [38] 46

Gambar 2. 5 Leaf-wise tree growth in LGBM [38] 46

Gambar 2. 6 5 - Fold Validation..... 71

Gambar 3. 1 Skema Rancangan Sistem..... 80

Gambar 3. 2 Skema Rancangan Tahap Pelatihan 83

Gambar 3. 3 Tampilan Beranda 85

Gambar 3. 4 Input Data Balita..... 86

Gambar 3. 5 Hasil Analisis 87

Gambar 3. 6 Panduan Gizi..... 88

Gambar 3. 7 Riwayat Pemeriksaan 89

Gambar 3. 8 Load Dataset..... 93

Gambar 3. 9 Pilih Variabel Penelitian 95

Gambar 3. 10 Cek duplikat..... 96

Gambar 3. 11 Hapus Duplikat 97

Gambar 3. 12 Cek Missing Value Sebelum Cleaning..... 97

Gambar 3. 13 Konversi Numerik dan Hapus Missing..... 99

Gambar 3. 14 Cek Missing Value Sesudah Cleaning 100

Gambar 3. 15 Target Encoder 101

Gambar 3. 16 Dataset Final Setelah Preprocessing 104

Gambar 3. 17 Output Dataset Final Setelah Preprocessing..... 105

Gambar 3. 18 Siapkan Fitur dan Target 107

Gambar 3. 19 Pembuatan Model LightGBM..... 110

Gambar 3. 20 Pembuatan Model XGBoost..... 112

Gambar 3. 21 Setup Evaluasi Model 114

Gambar 3. 22 Split Data 80% dan 20%..... 116

Gambar 3. 23 Tampilan Login 118

Gambar 3. 24 Tampilan Register..... 119

Gambar 3. 25 Tampilan Home 120

Gambar 3. 26 Tampilan Input Data Balita..... 121

Gambar 3. 27 Tampilan Input Data Balita Terisi 123

Gambar 3. 28 Tampilan Hasil Analisis 125

Gambar 3. 29 Tampilan Riwayat Pemeriksaan 129

Gambar 3. 30 Tampilan Hapus Semua di Riwayat Pemeriksaan 130

Gambar 3. 31 Halaman Panduan Gizi 132

Gambar 3. 32 Tentang Aplikasi 137

Gambar 3. 33 Tampilan Logout..... 141

Gambar 3. 34 Tampilan kotak dialog konfirmasi logout..... 142

Gambar 4. 1 Cara pengujian persiapan fitur dan target (Distribusi Target) 145
Gambar 4. 2 Cara Pengujian Heatmap 147
Gambar 4. 3 Cara pengujian model Evaluasi detail dan Confusion Matrix 148
Gambar 4. 4 Cara Pengujian Fungsi Eksperimen 5-Fold Cross Validation 153
Gambar 4. 5 Cara pengujian Evaluasi K fold Cross Validation 160
Gambar 4. 6 Cara Pengujian Ringkasan Eksperimen 163
Gambar 4. 7 Cara Pengujian Boxplot Perbandingan Algoritma 165
Gambar 4. 8 Cara Pengujian Boxplot Waktu Komputasi 168
Gambar 4. 9 Pilih Model Terbaik 170
Gambar 4. 10 Cara Pengujian Latih Ulang dan Simpan Model Terbaik 171
Gambar 4. 11 Hasil Pengujian Persiapan Fitur dan Target (Distribusi Target) 186
Gambar 4. 12 Hasil Pengujian Heatmap Korelasi 188
Gambar 4. 13 Hasil Confusion Matrix Train - Test Weight For Age 201
Gambar 4. 14 Confusion Matrix Train - Test Height For Age 202
Gambar 4. 15 Confusion Matrix Train - Test - Weight For Height 204
Gambar 4. 16 Confusion Matrix 5 Fold - Weight For Age 231
Gambar 4. 17 Confusion Matrix 5 Fold - Height For Age 233

Gambar 4. 18 Confusion Matrix 5 Fold - Weight For Height 235
Gambar 4. 19 Boxplot Algoritma Weight For Age 239
Gambar 4. 20 Boxplot Algoritma Height For Age..... 239
Gambar 4. 21 Boxplot Algoritma Weight for Height..... 240
Gambar 4. 22 Boxplot Waktu Komputasi Weight For Age 242
Gambar 4. 23 Boxplot Waktu Komputasi Height For Age..... 242
Gambar 4. 24 Boxplot Waktu Komputasi Weight For Height 243
Gambar 4. 25 Grafik Data Balita Berdasarkan Jenis Kelamin..... 277
Gambar 4. 26 Grafik Data Balita Berdasarkan Kelompok Usia 278
Gambar L3. 1 Bukti konsultasi bersama Bidan Mercu
Tiana, Am. Keb..... 406
Gambar L4 1 Dokumentasi bersama Ibu Syukriah Usman, S.Gz, RD 407
Gambar L5 1 Curriculum Vitae (CV) Ibu Syukriah
Usman, S.Gz, RD 408
Gambar L6 1 Dokumentasi bersama Dr. dr. Wiyarni
Pambudi, Sp.A, IBCLC 409
Gambar L7 1 Curiculum Vitae (CV) Dokter Spesialis Anak..... 410
Gambar L8. 1 Dokumentasi Bukti UAT bersama Dr. dr. Wiyarni
Pambudi, Sp.A, IBCLC 417
Gambar L8. 2 Dokumentasi Bukti UAT bersama Ibu Syukriah
Usman, S.Gz, RD 418
Gambar L9. 1 Hasil Lembar UAT Bersama Dokter Anak 419

Gambar L9. 2 Hasil Lembar UAT Bersama Ahli Gizi 424
Gambar L9. 3 Hasil Bukti Penelitian Ke RS Islam Cempaka Putih 428
Gambar L11. 1 Surat Pernyataan Kesediaan Kerja Sama kepada
RT Setempat..... 448
Gambar L11. 2 Dokumentasi Bersama RT..... 449
Gambar L11. 3 Dokumentasi Bersama Responden 1..... 450
Gambar L11. 4 Dokumentasi Bersama Responden 2..... 451
Gambar L11. 5 Dokumentasi Bersama Responden 3..... 452
Gambar L11. 6 Dokumentasi Bersama Responden 4..... 453
Gambar L11. 7 Dokumentasi Bersama Responden 5..... 454
Gambar L11. 8 Dokumentasi Bersama Responden 6..... 455
Gambar L11. 9 Dokumentasi Bersama Responden 7..... 456
Gambar L11. 10 Dokumentasi Bersama Responden 8..... 457
Gambar L11. 11 Dokumentasi Bersama Responden 9..... 458
Gambar L11. 12 Dokumentasi Bersama Responden 10 459
Gambar L11. 13 Dokumentasi Bersama Responden 11 460
Gambar L11. 14 Dokumentasi Bersama Responden 12 461
Gambar L11. 15 Dokumentasi Bersama Responden 13 462
Gambar L11. 16 Dokumentasi Bersama Responden 14 463
Gambar L11. 17 Dokumentasi Bersama Responden 15 463
Gambar L12. 1 Hasil Black Box Testing 464
Gambar L13. 1 Hasil Cek Plagiasi Turnitin..... 471

Gambar L14. 1 Tampilan Github 472

DAFTAR LAMPIRAN

Halaman

Lampiran 1 Contoh Perhitungan Lightgbm 300

Lampiran 2 Perhitungan Manual XGBOOST 353

Lampiran 3 Bukti konsultasi ahli bersama Bidan 406

Lampiran 4 Dokumentasi Bersama Ketua Ahli Gizi 407

Lampiran 5 Curriculum Vitae Ahli Gizi 408

Lampiran 6 Dokumentasi Bersama Dokter Spesialis Anak 409

Lampiran 7 Curiculum Vitae Dokter Spesialis Anak 410

Lampiran 8 Bukti Validasi Bersama Para Ahli 417

Lampiran 9 Hasil Lembar UAT Para Ahli 419

Lampiran 10 Perhitungan Manual Hasil Kuesioner Responden 429

Lampiran 11 Dokumentasi Bersama Responden 448

Lampiran 12 Black Box Testing 464

Lampiran 13 Turnitin 471

Lampiran 14 Github 472

BAB I

PENDAHULUAN

1.1 Latar Belakang

Status pertumbuhan anak dan gizi balita masih menjadi perhatian penting dalam bidang kesehatan masyarakat, terutama pada masa balita [1]. Pada tahap ini, anak mengalami pertumbuhan fisik yang sangat cepat, sehingga kondisi gizinya perlu dipantau dengan baik. Gangguan pada pertumbuhan dan status gizi tidak hanya memengaruhi kondisi fisik anak, tetapi juga dapat berdampak pada perkembangan, daya tahan tubuh, serta kualitas hidupnya pada tahap berikutnya [1], [2]. Oleh karena itu, pemantauan kondisi pertumbuhan dan gizi balita perlu dilakukan sejak dini agar upaya pencegahan dan penanganan dapat diberikan lebih cepat dan tepat.

Di Indonesia, upaya peningkatan status gizi anak dan pencegahan masalah pertumbuhan telah menjadi salah satu fokus penting dalam bidang kesehatan [2], [3]. Namun, pada praktiknya, penilaian kondisi balita di fasilitas layanan kesehatan masih banyak dilakukan melalui pengukuran antropometri dan pencatatan secara manual. Antropometri merupakan metode pengukuran ukuran tubuh manusia yang digunakan untuk menilai kondisi pertumbuhan dan status gizi, misalnya melalui usia, berat badan, dan tinggi badan. Cara ini tetap memiliki peran penting, tetapi dapat menimbulkan kendala ketika jumlah data yang harus ditangani semakin banyak dan hasil penilaian dibutuhkan secara cepat

serta konsisten [1], [3]. Kondisi tersebut menunjukkan bahwa pemanfaatan teknologi berbasis data dapat menjadi salah satu solusi untuk membantu proses pemantauan dan klasifikasi status tumbuh kembang anak dan gizi balita secara lebih efektif.

Perkembangan teknologi informasi, khususnya *machine learning*, membuka peluang dalam mengolah data kesehatan dalam jumlah besar dan menemukan pola yang sulit dikenali secara manual. Sejumlah penelitian terdahulu telah menerapkan metode seperti *Decision Tree*, *Random Forest*, dan *Support Vector Machine* (SVM) untuk mengklasifikasikan kondisi stunting maupun status gizi anak, serta menunjukkan hasil yang cukup baik [4], [5]. Selain itu, algoritma boosting seperti *Extreme Gradient Boosting* (XGBoost) juga banyak digunakan karena dinilai mampu menangani data tabular yang kompleks dengan performa yang kompetitif [6]. Namun, penelitian yang mengkaji penggunaan *Light Gradient Boosting Machine* (LightGBM) serta XGBoost pada klasifikasi status pertumbuhan anak dan gizi balita masih belum banyak dilakukan.

Light Gradient Boosting Machine (LightGBM) merupakan salah satu algoritma boosting yang dikenal efisien dan mampu memberikan kinerja yang baik pada tugas klasifikasi data tabular [7]. LightGBM dirancang agar proses pelatihan model dapat berjalan lebih cepat dan stabil, terutama ketika digunakan pada dataset berukuran besar. Walaupun demikian, kajian yang memfokuskan LightGBM sebagai metode utama pada klasifikasi status pertumbuhan anak dan gizi balita dalam konteks Indonesia masih relatif terbatas. Hal ini menunjukkan

bahwa penggunaan LightGBM dalam penelitian ini masih relevan untuk dikaji lebih lanjut.

Data yang digunakan dalam penelitian ini berasal dari dataset *Stunting and Nutritional Status of Toddler from Jeneponto Regency, South Sulawesi, Indonesia* yang tersedia pada repositori daring [9]. Penggunaan dataset tersebut memberikan konteks penelitian pada data balita yang berasal dari Kabupaten Jeneponto, Sulawesi Selatan. Selain itu, penelitian Devi dkk. menunjukkan bahwa permasalahan stunting di Kabupaten Jeneponto masih memerlukan perhatian, sehingga penggunaan dataset dari wilayah tersebut dinilai relevan untuk mendukung analisis kondisi pertumbuhan dan status gizi balita [8]. Selain membangun model klasifikasi, penelitian ini juga menekankan pentingnya validasi agar rancangan sistem yang dikembangkan sesuai dengan kebutuhan praktik di lapangan.

Berdasarkan uraian tersebut, penelitian ini berfokus pada pengembangan model klasifikasi status pertumbuhan anak dan gizi balita menggunakan algoritma LightGBM dan XGBoost. Proses klasifikasi dilakukan pada tiga kelompok indikator antropometri, yaitu *Weight-for-Age* (WA), *Height-for-Age* (HA), dan *Weight-for-Height* (WH), sehingga keluaran sistem berupa kategori untuk masing-masing kelompok indikator tersebut. Kinerja model akan dievaluasi menggunakan metrik akurasi, presisi, *recall*, dan *F1-score*, serta dilengkapi dengan analisis *feature importance* untuk mengetahui variabel yang paling berpengaruh terhadap hasil klasifikasi. Dengan demikian, penelitian ini

diharapkan dapat memberikan kontribusi dalam penerapan *machine learning* pada bidang kesehatan masyarakat dan membantu proses pemantauan status pertumbuhan anak dan gizi balita secara lebih efektif.

1.2 Rumusan Rancangan

Rumusan Rancangan pada Penelitian ini mengembangkan sistem klasifikasi status tumbuh kembang dan gizi balita berbasis *machine learning* yang akurat, efisien, dan mudah digunakan oleh tenaga kesehatan. Sistem ini membantu tenaga kesehatan memantau kondisi tumbuh kembang dan gizi balita yang sebelumnya masih banyak dinilai secara manual. Melalui sistem berbasis data, tenaga kesehatan dapat memperoleh hasil klasifikasi secara lebih cepat dan konsisten sebagai informasi pendukung dalam proses pemantauan di layanan kesehatan.

Penelitian ini menggunakan algoritma *Light Gradient Boosting Machine* (LightGBM) dan *Extreme Gradient Boosting* (XGBoost) untuk membangun serta membandingkan model klasifikasi. Model mengolah enam variabel masukan, yaitu jenis kelamin, tanggal lahir, tanggal pengukuran, usia dalam bulan, berat badan, dan tinggi badan. Sebelum melatih model, penelitian ini memproses dataset melalui beberapa tahap, yaitu pemeriksaan data duplikat, pemeriksaan nilai kosong (*missing value*), pembersihan data yang tidak lengkap, seleksi variabel, penyesuaian format tanggal, serta pengkodean variabel jenis kelamin dan target klasifikasi ke dalam bentuk numerik.

Dataset awal memiliki 40.071 baris data. Proses pemeriksaan menemukan 8.970 data duplikat, kemudian penelitian ini menghapus data tersebut sehingga jumlah data menjadi 31.101 baris. Proses pemeriksaan juga menemukan 2 nilai kosong pada variabel *age_month* dan 5 nilai kosong pada variabel *weight_for_height*. Penelitian ini menghapus data yang memiliki nilai kosong tersebut agar seluruh variabel penelitian memiliki data yang lengkap. Setelah menyelesaikan tahap pra-pemrosesan dan seleksi variabel, penelitian ini menggunakan dataset akhir yang berjumlah 14.326 baris dengan 9 variabel penelitian. Dalam proses pemodelan, penelitian ini menggunakan fitur *gender_enc*, *date_of_birth*, *date_of_measurement*, *age_month*, *weight*, dan *height*.

Sistem menghasilkan klasifikasi pada tiga indikator antropometri, yaitu *Weight-for-Age* (W/A), *Height-for-Age* (H/A), dan *Weight-for-Height* (W/H). Pada indikator W/A, sistem menampilkan kategori *Normal*, *Underfed*, *Malnutrition*, dan *Overnutrition*. Pada indikator H/A, sistem menampilkan kategori *Stunted* dan *Not Stunted*. Pada indikator W/H, sistem menampilkan kategori *Very Thin*, *Thin*, *Normal*, dan *Obese*. Setiap indikator memiliki kategori target yang berbeda, sehingga penelitian ini melatih model W/A, model H/A, dan model W/H secara terpisah.

Selain menghasilkan klasifikasi, sistem menampilkan analisis *feature importance* untuk menunjukkan variabel yang paling berpengaruh terhadap hasil prediksi. Penelitian ini mengintegrasikan model terbaik ke dalam aplikasi *mobile*

GrowSmart Health. Melalui aplikasi tersebut, pengguna dapat memasukkan data balita dan memperoleh hasil klasifikasi pada setiap indikator secara otomatis. Aplikasi ini berperan sebagai alat bantu skrining awal dalam pemantauan status tumbuh kembang dan gizi balita.

Untuk memastikan sistem yang dibangun sesuai dengan kebutuhan praktik di tenaga kesehatan, perancangan ini juga mencakup tahap validasi melalui *User Acceptance Test* (UAT). Validasi sistem dilakukan bersama ahli gizi, yaitu Ibu Syukriah Usman, S.Gz., RD, yang bertugas di Rumah Sakit Islam Jakarta Cempaka Putih, beralamat di Jl. Cempaka Putih Tengah I No. 1, RT 11/RW 5, Cempaka Putih Timur, Kecamatan Cempaka Putih, Kota Jakarta Pusat, Daerah Khusus Ibukota Jakarta 10510. Selain itu, validasi juga dilakukan bersama dokter spesialis anak, yaitu Dr. dr. Wiyarni Pambudi, Sp.A., IBCLC, dari Fakultas Kedokteran Universitas Tarumanagara. Umpan balik dari proses validasi tersebut diharapkan dapat digunakan untuk menilai kelayakan sistem, kemudahan penggunaan, serta relevansi keluaran sistem sebagai alat bantu pemantauan kondisi balita. Di samping itu, penyusunan rancangan ini juga didukung oleh hasil konsultasi dengan Bidan Mercu Tiana, Am. Keb, yang beralamat di Jl. Kali Anyar V No. 38 RT 11 RW 03, Kelurahan Kali Anyar, Kecamatan Tambora, Jakarta Barat.

1.3 Komponen Rancangan

Rancangan sistem klasifikasi status tumbuh kembang anak dan gizi balita dalam penelitian ini terdiri atas beberapa komponen utama yang saling

terhubung. Setiap komponen mendukung sistem agar dapat menghasilkan klasifikasi secara akurat dan mudah digunakan, terutama oleh tenaga kesehatan. Komponen pertama mencakup proses pengumpulan dan penyusunan dataset. Penelitian ini menggunakan dataset sekunder *Stunting and Nutritional Status of Toddler from Jeneponto Regency, South Sulawesi, Indonesia* yang diperoleh dari repositori Mendeley Data. Dataset tersebut memuat informasi balita, data antropometri, serta status pertumbuhan dan gizi yang menjadi dasar dalam proses pemodelan [9].

Setelah memperoleh dataset, penelitian ini melakukan tahap pra-pemrosesan data untuk menyiapkan data sebelum proses analisis dan pelatihan model. Penelitian ini memeriksa data duplikat, nilai kosong (*missing value*), serta kelengkapan variabel yang digunakan. Pada dataset awal, penelitian ini menemukan 8.970 data duplikat, kemudian menghapus data tersebut. Penelitian ini juga menemukan 2 nilai kosong pada variabel *age_month* dan 5 nilai kosong pada variabel *weight_for_height*, kemudian menghapus data yang tidak lengkap agar dataset tidak lagi mengandung *missing value*. Selanjutnya, penelitian ini menyeleksi variabel, mengubah usia, berat badan, dan tinggi badan ke dalam bentuk numerik, mengubah tanggal lahir dan tanggal pengukuran ke dalam format angka, serta mengodekan jenis kelamin dan label target agar dapat diproses oleh model. Tahap ini menjaga kualitas data agar model dapat mempelajari pola data secara lebih baik.

Komponen berikutnya mencakup pembangunan model klasifikasi menggunakan metode *machine learning*. Penelitian ini menggunakan algoritma *Light Gradient Boosting Machine* (LightGBM) dan *Extreme Gradient Boosting* (XGBoost) sebagai metode klasifikasi. Penelitian ini melatih model menggunakan enam variabel masukan, yaitu jenis kelamin, tanggal lahir, tanggal pengukuran, usia dalam bulan, berat badan, dan tinggi badan. Dalam proses pemodelan, sistem menggunakan fitur *gender_enc*, *date_of_birth*, *date_of_measurement*, *age_month*, *weight*, dan *height*. Adapun target klasifikasi terdiri atas tiga indikator antropometri, yaitu *Weight-for-Age* (W/A), *Height-for-Age* (H/A), dan *Weight-for-Height* (W/H). Setiap indikator memiliki kategori kelas yang berbeda, sehingga penelitian ini melatih model W/A, model H/A, dan model W/H secara terpisah. Selanjutnya, penelitian ini membandingkan kinerja LightGBM dan XGBoost untuk menentukan model yang memberikan performa terbaik pada setiap target.

Komponen selanjutnya mencakup evaluasi kinerja model untuk menilai kualitas hasil prediksi. Penelitian ini mengevaluasi setiap model menggunakan metrik *accuracy*, *precision*, *recall*, dan *F1-score*. Penelitian ini juga menggunakan *confusion matrix* untuk melihat distribusi prediksi benar dan salah pada setiap kelas. Selain itu, penelitian ini menggunakan analisis *feature importance* untuk mengetahui variabel yang paling berpengaruh terhadap hasil prediksi. Melalui proses evaluasi tersebut, penelitian ini dapat menjelaskan performa model dan memilih model terbaik untuk diterapkan ke dalam aplikasi.

Komponen terakhir adalah integrasi hasil model ke dalam sistem *mobile* serta validasi pengguna. Sistem dirancang agar pengguna dapat memasukkan data balita, lalu memperoleh hasil klasifikasi untuk setiap kelompok indikator antropometri secara langsung. Untuk memastikan sistem yang dikembangkan sesuai dengan kebutuhan praktik di lapangan, penelitian ini merencanakan *User Acceptance Test* (UAT). Validasi/UAT dilakukan bersama ahli gizi, yaitu Ibu Syukriah Usman, S.Gz., RD, yang bertugas di Rumah Sakit Islam Jakarta Cempaka Putih, beralamat di Jl. Cempaka Putih Tengah I No. 1, RT 11/RW 5, Cempaka Putih Timur, Kecamatan Cempaka Putih, Kota Jakarta Pusat, Daerah Khusus Ibukota Jakarta 10510. Selain itu, validasi juga dilakukan bersama dokter spesialis anak, yaitu Dr. dr. Wiyarni Pambudi, Sp.A., IBCLC, dari Fakultas Kedokteran Universitas Tarumanagara. Sebagai bahan pertimbangan tambahan, penyusunan rancangan ini juga didukung oleh hasil konsultasi dengan Bidan Mercu Tiana, Am. Keb, yang beralamat di Jl. Kali Anyar V No. 38 RT 11 RW 03, Kelurahan Kali Anyar, Kecamatan Tambora, Jakarta Barat. Umpan balik dari proses ini diharapkan dapat menjadi dasar untuk menyempurnakan sistem sebelum diterapkan lebih lanjut.

1.4 Spesifikasi Rancangan

Rancangan sistem klasifikasi status tumbuh kembang anak dan gizi balita ini diarahkan untuk menjawab kebutuhan identifikasi kondisi balita secara lebih cepat dan konsisten dengan memanfaatkan data antropometri, sehingga dapat membantu proses pemantauan dan deteksi dini di fasilitas pelayanan kesehatan.

Spesifikasi rancangan sistem ini kemudian disusun ke dalam beberapa modul utama sebagai berikut.

1. Modul Pemasukan Data.

   Modul pemasukan data disediakan sebagai antarmuka untuk memasukkan identitas dan data balita yang akan dianalisis oleh sistem. Data yang diisi oleh pengguna meliputi nama balita, jenis kelamin, tanggal lahir, tanggal pengukuran, usia dalam bulan, berat badan dalam kilogram, dan tinggi badan dalam sentimeter. Nama balita digunakan sebagai identitas pemeriksaan, sedangkan variabel yang digunakan sebagai masukan dalam proses klasifikasi terdiri atas jenis kelamin, tanggal lahir, tanggal pengukuran, usia, berat badan, dan tinggi badan. Pada tahap pengolahan data, jenis kelamin dikonversi menjadi bentuk numerik melalui variabel *gender_enc*, sedangkan tanggal lahir dan tanggal pengukuran disesuaikan ke dalam format yang dapat diproses oleh model. Seluruh data tersebut dimasukkan melalui formulir pada aplikasi berbasis mobile, kemudian diproses oleh model untuk menghasilkan klasifikasi status tumbuh kembang dan gizi balita berdasarkan indikator *Weight-for-Age* (W/A), *Height-for-Age* (H/A), dan *Weight-for-Height* (W/H).

2. Modul Dataset dan Penyimpanan Data.

   Modul ini berfungsi untuk menyimpan serta mengelola dataset yang digunakan selama penelitian. Data berasal dari dataset sekunder yang dipublikasikan melalui repositori ilmiah dengan jumlah sampel puluhan ribu

data balita. Meskipun dataset awal memuat banyak variabel, penelitian ini memanfaatkan variabel jenis kelamin, tanggal lahir, tanggal pengukuran, usia, berat badan, tinggi badan, serta label kelas untuk masing-masing kelompok indikator antropometri sesuai skenario perancangan. Data disimpan dalam format tabular seperti CSV atau *DataFrame* agar memudahkan pengolahan pada tahap pra-pemrosesan dan pelatihan model.

3. Modul Pra-Pemrosesan Data.

   Modul pra-pemrosesan data dirancang untuk menyiapkan dataset agar siap digunakan dalam proses pemodelan. Pada tahap ini, data terlebih dahulu diperiksa untuk mengetahui keberadaan data duplikat yang dapat memengaruhi hasil analisis. Selanjutnya, pengecekan terhadap nilai kosong (*missing value*) pada setiap variabel dilakukan untuk memastikan kelengkapan data. Data yang tidak lengkap atau tidak valid kemudian dibersihkan agar kualitas dataset tetap terjaga. Setelah itu, seleksi variabel dilakukan untuk menentukan atribut yang digunakan sesuai dengan kebutuhan model. Variabel tanggal lahir dan tanggal pengukuran disesuaikan formatnya, sedangkan variabel jenis kelamin serta label target dikonversi ke dalam bentuk numerik agar dapat diproses oleh model. Setelah seluruh tahap pra-pemrosesan selesai, dataset dibagi menjadi data latih dan data uji agar proses pelatihan serta evaluasi model dapat dilakukan.

4. Modul Pelatihan Model.

Modul pelatihan model digunakan untuk membentuk model klasifikasi pada setiap kelompok indikator antropometri balita. Perancangan ini menerapkan Light Gradient Boosting Machine (LightGBM) dan Extreme Gradient Boosting (XGBoost) sebagai metode klasifikasi. Proses pelatihan mencakup penyetelan parameter penting seperti jumlah pohon (n_estimators), learning rate, dan kedalaman pohon (max_depth) untuk memperoleh hasil prediksi yang optimal. Keluaran dari tahap ini adalah model terlatih yang siap digunakan untuk memprediksi data baru.

5. Modul Prediksi dan Klasifikasi.

   Modul prediksi dan klasifikasi bertugas menghasilkan keluaran berdasarkan data yang dimasukkan oleh pengguna. Setelah pengguna menginput usia, berat badan, dan tinggi badan, sistem menjalankan model terlatih yang sesuai untuk menentukan kelas pada setiap indikator antropometri. Hasil prediksi yang ditampilkan meliputi kategori Weight for Age (W/A), Height for Age (H/A), dan Weight for Height (W/H). Melalui hasil tersebut, pengguna dapat memperoleh gambaran awal mengenai status pertumbuhan dan gizi balita berdasarkan indikator yang digunakan dalam sistem.

6. Modul Evaluasi Model.

   Modul evaluasi disusun untuk mengukur kualitas model yang telah dibangun. Penilaian performa dilakukan menggunakan metrik accuracy, precision, recall, dan F1-score, serta dilengkapi dengan confusion matrix untuk melihat sebaran hasil prediksi yang benar dan salah pada setiap kelas.

Selain itu, sistem menerapkan metode 5-Fold Cross Validation untuk mengevaluasi kestabilan performa model pada beberapa pembagian data. Evaluasi dilakukan pada masing-masing model untuk kelompok Weight for Age (W/A), Height for Age (H/A), dan Weight for Height (W/H), sehingga performa serta konsistensi model pada setiap kelompok target dapat dianalisis secara lebih jelas.

7. Modul Antarmuka Aplikasi.

   Modul antarmuka aplikasi dikembangkan agar sistem dapat digunakan secara praktis. Antarmuka berbasis mobile menyediakan formulir input, tombol untuk menjalankan prediksi, serta halaman hasil klasifikasi. Pada bagian keluaran, sistem menampilkan status prediksi pada setiap indikator antropometri, yaitu Weight for Age (W/A), Height for Age (H/A), dan Weight for Height (W/H), disertai informasi pendukung untuk membantu pengguna memahami hasil yang diperoleh. Antarmuka dibuat sederhana agar mudah dipahami dan dapat digunakan oleh pengguna non-teknis, termasuk tenaga kesehatan.

8. Modul Pengujian dan Validasi Pengguna.

   Modul pengujian dan validasi bertujuan untuk memastikan bahwa sistem dapat berfungsi sesuai rancangan dan layak digunakan. Pengujian fungsional dilakukan melalui beberapa skenario penggunaan, mulai dari proses memasukkan data, menjalankan prediksi, hingga menampilkan hasil klasifikasi. Selanjutnya, validasi dilakukan melalui User Acceptance Test

(UAT) dengan melibatkan tenaga ahli di bidang gizi, yaitu Ibu Syukriah Usman, S.Gz., RD dari Rumah Sakit Islam Jakarta Cempaka Putih, serta dokter spesialis anak, yaitu Dr. dr. Wiyarni Pambudi, Sp.A., IBCLC dari Fakultas Kedokteran Universitas Tarumanagara. Penilaian difokuskan pada kemudahan penggunaan sistem, kejelasan informasi yang ditampilkan, serta kesesuaian hasil prediksi dengan kebutuhan pemantauan kondisi balita. Dengan demikian, masukan dari pengguna dapat dimanfaatkan sebagai dasar untuk menyempurnakan sistem.

1.5 Kegunaan Rancangan

Kegunaan rancangan sistem klasifikasi pertumbuhan balita adalah sebagai berikut:

1. Menyajikan hasil klasifikasi yang dilengkapi dengan evaluasi performa model menggunakan metrik akurasi, presisi, recall, dan F1-score, serta confusion matrix untuk menggambarkan hasil prediksi pada setiap kelas.
2. Menghasilkan aplikasi *mobile* yang dapat memprediksi status tumbuh kembang dan gizi balita berdasarkan input jenis kelamin, tanggal lahir, tanggal pengukuran, usia (bulan), berat badan (kg), dan tinggi badan (cm), serta menampilkan keluaran klasifikasi pada indikator *Weight-for-Age* (W/A), *Height-for-Age* (H/A), dan *Weight-for-Height* (W/H).

3. Mendukung proses skrining dan deteksi dini tumbuh kembang dan gizi balita di fasilitas pelayanan kesehatan melalui penyajian hasil prediksi yang jelas, informatif, dan mudah dipahami oleh tenaga kesehatan.

1.6 Rancangan yang Sudah Dibuat

Beberapa penelitian sebelumnya yang relevan dengan pengembangan sistem klasifikasi stunting telah dilakukan oleh berbagai peneliti. Penelitian-penelitian tersebut memiliki fokus, metode, dan hasil evaluasi yang berbeda, namun tetap memberikan kontribusi sebagai referensi dalam perancangan sistem pada penelitian ini. Perbandingan penelitian yang telah dilakukan dirangkum pada Tabel 1.1.

Tabel 1. 1 Penelitian Rancangan yang Sudah Dibuat serta relevansi dengan sistem yang dirancang

No	Judul	Peneliti	Hasil	Relevan sistem dirancang
1	Model Klasifikasi Risiko Stunting Pada Balita Menggunakan Algoritma CatBoost Classifier [10].	Omar Pahlevi, Dian Ayu Nur Wulandari, Lilis Kurnia Rahayu, Henny Leidiyana, dan Yogi Handrianto (2024)	Algoritma CatBoost menghasilkan akurasi sebesar 98,47% serta nilai ROC-AUC sebesar 1,00 pada proses evaluasi model.	Penelitian ini relevan karena membahas klasifikasi stunting berbasis machine learning. Perbedaannya terletak pada metode yang digunakan, yaitu CatBoost, sedangkan penelitian ini menerapkan Light

Tabel 1.1 (Lanjutan)

No	Judul	Peneliti	Hasil	Relevan sistem dirancang
				Gradient Boosting Machine (LightGBM) dan Extreme Gradient Boosting (XGBoost) sebagai metode klasifikasi.
2	Klasifikasi Stunting Pada Balita Berdasarkan Status Gizi Menggunakan Pendekatan Support Vector Machine (SVM) [5].	Adi Candra, Muhammad Erkamim, Muhammad Muharrom, dan Eko Prayitno (2024	Model SVM memperoleh akurasi keseluruhan sebesar 98,37% serta dievaluasi menggunakan metrik precision, recall, dan F1-score pada masing-masing kelas.	Penelitian ini memiliki kesamaan dalam penggunaan metrik evaluasi klasifikasi. Namun, penelitian tersebut menggunakan metode SVM, sedangkan penelitian ini menerapkan algoritma boosting modern, yaitu LightGBM dan XGBoost, yang dinilai lebih efektif pada data tabular berskala besar.
3	Analisis Komparatif	Yudhi Fajar Saputra,	Random Forest	Penelitian ini relevan karena

Tabel 1.1 (Lanjutan)

No	Judul	Peneliti	Hasil	Relevan sistem dirancang
	Klasifikasi Machine Learning untuk Memprediksi Stunting pada Anak Usia di Bawah Lima Tahun 2025 [11].	Mohammad Al-Khasawneh, Milkhatun, Ni Wayan Widhiasthini Asthiningsih, dan Siti Rahmah (2025)	memperoleh Classification Accuracy sebesar 71% dengan AUC 0,74, sedangkan Decision Tree memperoleh Classification Accuracy sebesar 67% dengan AUC 0,68.	membandingkan performa beberapa algoritma dalam prediksi stunting. Perbedaannya terletak pada jenis algoritma yang digunakan, yaitu metode pohon keputusan konvensional, sedangkan penelitian ini berfokus pada algoritma boosting modern dan analisis variabel yang memengaruhi hasil klasifikasi.
4	Klasifikasi Tweet Cyberbullying dengan Menggunakan Algoritma	Felix Fernando (2025)	XGBoost sedikit lebih unggul disbanding SVM, pada hasil eksperimen	Menjadi rujukan pemilihan algoritma pembanding pada penelitian ini, khususnya penggunaan XGBoost sebagai model yang

Tabel 1.1 (Lanjutan)

No	Judul	Peneliti	Hasil	Relevan sistem dirancang
	SVM dan XGBoost [12].		dilaporkan akurasi SVM 82,65% dan XGBoost 83,24%	kompetitif untuk tugas klasifikasi. Pada penelitian skripsi ini, menerapkan Light Gradient Boosting Machine (LightGBM) dan Extreme Gradient Boosting (XGBoost) sebagai metode klasifikasi
5	Application of ADASYN and Optuna in the XGBoost Algorithm for Stunting Detection (2026) [13].	Fastabyq Putra Sadewa dan Defri Kurniawan (2026)	Model XGBoost + ADASYN + Optuna mencapai akurasi 81,98%, recall 91,50%, dan F1-score 89,14%.	Relevan karena membahas deteksi stunting dengan XGBoost serta peningkatan performa melalui penanganan ketidakseimbangan kelas dan optimasi hiperparameter.
6	Prediction models for stunting at 2-years-old from Indonesian	Devi Azriani, Dwi Agustian, Yenni Zuhairini, Intan Nurma Yulita, dan	Model terbaik adalah KNN dengan F1 = 84,5%, dibanding	Relevan karena sama-sama mengembangkan model prediksi stunting dan

Tabel 1.1 (Lanjutan)

No	Judul	Peneliti	Hasil	Relevan sistem dirancang
	newborn population (2025)[14].	Meita Dhamayanti (2025)	Random Forest (80,5%), Neural Network (71,2%), Decision Tree (68,7%), dan Naïve Bayes (65,8%).	menggunakan metrik evaluasi (F1, AUC, dll.). Perbedaannya, penelitian ini memanfaatkan data IFLS dan membandingkan beberapa algoritma non-boosting, sedangkan penelitianmu fokus pada boosting (LightGBM/XGBoost).
7	Data Analysis and Explainable Machine Learning for Stunting Prediction	Ardy Wicaksono, Deny Prasetyo, Yulaikha Mar'atullatifah, Dwi Utari Iswavigra, Himmatunnisa Mahmudah, dan Ayun Hapsari (2025)	Model terbaik adalah XGBoost dengan F1-score 96,97% dan akurasi 97,57%. SHAP menunjukkan tinggi badan sebagai fitur paling berpengaruh.	Relevan karena sama-sama menggunakan data antropometri untuk klasifikasi stunting. Perbedaannya, penelitian ini menggunakan XGBoost dan SHAP, sedangkan penelitianmu membandingkan

Tabel 1.1 (Lanjutan)

No	Judul	Peneliti	Hasil	Relevan sistem dirancang
				LightGBM dan XGBoost untuk klasifikasi W/A, H/A, dan W/H.

1.7 Sustainaible Development Goals (SDGs)

Sustainable Development Goals (SDGs) merupakan agenda pembangunan global yang terdiri dari 17 tujuan utama untuk mengatasi kemiskinan, menekan ketimpangan, serta menjaga keberlanjutan lingkungan. Agenda ini ditetapkan oleh Perserikatan Bangsa-Bangsa sebagai kerangka kerja bersama yang ditujukan untuk mewujudkan masa depan yang lebih baik dan berkelanjutan bagi semua hingga tahun 2030. Setiap tujuan SDGs saling berhubungan dan mencakup berbagai aspek kehidupan, mulai dari kesehatan, pendidikan, hingga pembangunan ekonomi dan kesejahteraan social [15]. Ilustrasi mengenai 17 tujuan SDGs dapat dilihat pada Gambar 1.1.



Gambar 1. 1 Agenda Sustainable Development Goals (SDGs) [15]

Penelitian ini memiliki keterkaitan yang kuat dengan beberapa tujuan SDGs, khususnya pada aspek peningkatan kesehatan dan status gizi anak di Indonesia. Keterkaitan yang paling dekat adalah dengan SDG 2 (Tanpa Kelaparan atau Zero Hunger). Tujuan ini tidak hanya berfokus pada penghapusan kelaparan, tetapi juga menekankan pentingnya perbaikan gizi serta penanggulangan berbagai bentuk malnutrisi pada balita. Pengembangan sistem klasifikasi status tumbuh kembang anak dan gizi balita berbasis *machine learning* dalam penelitian ini diharapkan dapat membantu deteksi dini masalah gizi, sehingga intervensi yang diperlukan dapat dilakukan lebih cepat dan lebih tepat sasaran.

Selain itu, penelitian ini juga sejalan dengan SDG 3 (*Kehidupan Sehat dan Sejahtera* atau *Good Health and Well-Being*). Kondisi pertumbuhan dan status gizi anak merupakan bagian penting dari kesehatan anak yang dapat berdampak jangka panjang terhadap pertumbuhan fisik, perkembangan, serta kualitas

hidupnya di masa mendatang. Sistem klasifikasi yang dirancang untuk memprediksi status pertumbuhan anak dan gizi balita berdasarkan data antropometri diharapkan dapat membantu memperkuat proses skrining, pemantauan pertumbuhan, serta pencegahan gangguan pertumbuhan pada anak di fasilitas pelayanan kesehatan.

Lebih lanjut, Penelitian ini juga berkaitan dengan SDG 10 (Berkurangnya Kesenjangan atau Reduced Inequalities). Permasalahan pertumbuhan dan gizi pada balita cenderung lebih banyak ditemukan di wilayah yang memiliki keterbatasan akses layanan kesehatan dan kondisi sosial ekonomi tertentu, termasuk daerah yang masih menghadapi berbagai tantangan pembangunan. Melalui analisis berbasis data yang lebih terarah, hasil penelitian ini diharapkan dapat memberikan masukan dalam penyusunan kebijakan dan program intervensi yang lebih sesuai dengan kebutuhan di tenaga kesehatan, sehingga dapat membantu mengurangi kesenjangan kesehatan antarwilayah.

Dengan demikian, penelitian ini tidak hanya memberikan kontribusi ilmiah dalam penerapan *machine learning* untuk klasifikasi status tumbuh kembang anak dan gizi balita, tetapi juga berpotensi mendukung pencapaian SDGs melalui penguatan deteksi dini, pemantauan, dan penanganan masalah pertumbuhan dan gizi pada balita di Indonesia.

BAB II

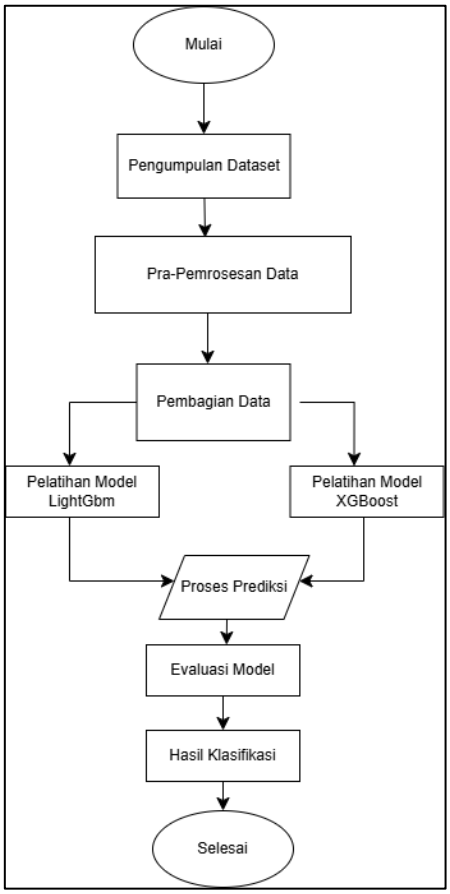
LANDASAN TEORETIK

2.1 Sistem yang Dirancang

Sistem klasifikasi yang dikembangkan dalam penelitian ini dirancang untuk membantu proses skrining awal kondisi tumbuh kembang anak dan gizi balita berdasarkan data balita dan pengukuran antropometri. Sistem ini menerapkan pendekatan *machine learning* dengan algoritma *Light Gradient Boosting Machine* (LightGBM) dan *Extreme Gradient Boosting* (XGBoost) sebagai metode klasifikasi. Penelitian ini membangun dan membandingkan kedua model tersebut untuk memperoleh model dengan kinerja klasifikasi yang optimal. Melalui pendekatan ini, sistem diharapkan dapat membantu tenaga kesehatan memperoleh hasil klasifikasi status tumbuh kembang dan gizi balita secara lebih cepat, objektif, dan konsisten sebagai pendukung pemantauan awal.

Alur perancangan sistem yang ditampilkan pada Gambar 2.1 dimulai dari tahap pengumpulan data yang bersumber dari dataset status pertumbuhan dan gizi balita. Dataset tersebut memuat informasi balita berupa jenis kelamin, tanggal lahir, tanggal pengukuran, usia dalam bulan, berat badan, dan tinggi badan yang digunakan sebagai variabel masukan dalam proses klasifikasi. Dalam proses pemodelan, penelitian ini mengodekan variabel jenis kelamin menjadi *gender_enc* serta menyesuaikan variabel tanggal lahir dan tanggal pengukuran agar dapat diproses oleh model.

Selain variabel masukan, dataset juga memuat label keluaran yang menjadi target pembelajaran model, yaitu indikator antropometri *Weight-for-Age* (W/A), *Height-for-Age* (H/A), dan *Weight-for-Height* (W/H). Pada indikator W/A, sistem menghasilkan kategori *Normal*, *Underfed*, *Malnutrition*, dan *Overnutrition*. Pada indikator H/A, sistem menghasilkan kategori *Stunted* dan *Not Stunted*. Sementara itu, pada indikator W/H, sistem menghasilkan kategori *Normal*, *Thin*, *Very Thin*, dan *Obese*. Karena setiap indikator memiliki kategori keluaran yang berbeda, penelitian ini membangun model klasifikasi secara terpisah untuk masing-masing indikator sesuai dengan dasar penilaian antropometri yang digunakan.



Gambar 2. 1 Alur Perancangan Sistem

Tahap berikutnya adalah pengolahan data awal (*preprocessing*). Pada tahap ini dilakukan pembersihan data dari duplikasi, pemeriksaan nilai kosong (*missing value*), serta penghapusan data tidak valid. Proses ini bertujuan memastikan kualitas dataset sebelum digunakan dalam pelatihan model. Setelah data dinyatakan valid, dataset kemudian dibagi menjadi data latih dan data uji sehingga proses evaluasi model dapat dilakukan secara objektif serta menghindari terjadinya *overfitting*.

Setelah tahap persiapan data selesai, sistem melakukan pelatihan model menggunakan algoritma LightGBM. Algoritma ini membangun model secara bertahap dengan memperbaiki kesalahan prediksi sebelumnya melalui pendekatan *gradient boosting decision tree*. Untuk memperoleh gambaran performa yang lebih komprehensif dilakukan pula pelatihan model menggunakan algoritma XGBoost. Hasil dari kedua model kemudian dianalisis untuk menentukan model yang memiliki kemampuan klasifikasi terbaik.

Model yang telah dilatih selanjutnya digunakan untuk melakukan prediksi terhadap data baru. Pengguna memasukkan data balita berupa usia, berat badan, dan tinggi badan melalui sistem. Berdasarkan data tersebut, model akan menentukan kategori status tumbuh kembang anak dan gizi balita ke dalam beberapa kategori sesuai indikator antropometri. Hasil klasifikasi ini diharapkan dapat membantu tenaga kesehatan dalam melakukan skrining awal kondisi balita secara lebih cepat.

Tahap selanjutnya adalah evaluasi performa sistem. Untuk mengukur kualitas klasifikasi, model dievaluasi menggunakan metrik *Accuracy*, *Precision*, *Recall*, dan *F1-Score*. Evaluasi ini dilakukan untuk mengetahui tingkat ketepatan model dalam mengklasifikasikan data serta keseimbangan model dalam mengenali setiap kelas.

Selain pengujian model, penelitian ini juga melibatkan proses validasi oleh tenaga kesehatan. Validasi dilakukan oleh ahli gizi di Rumah Sakit Islam Jakarta Cempaka Putih untuk memastikan hasil klasifikasi dapat dipahami dan relevan dengan praktik skrining di rumah sakit. Selain itu, validasi juga dilakukan bersama dokter spesialis anak dari Fakultas Kedokteran Universitas Tarumanagara. Masukan dari tenaga kesehatan digunakan sebagai bahan penyempurnaan sistem agar lebih sesuai dengan kebutuhan pengguna.

Secara umum, rancangan sistem ini membentuk alur kerja yang saling terhubung, dimulai dari data mentah hingga menghasilkan keluaran akhir berupa klasifikasi status tumbuh kembang anak dan gizi balita. Sistem yang dirancang tidak hanya digunakan sebagai alat klasifikasi, tetapi juga dapat membantu memberikan gambaran awal dalam proses pemantauan kondisi balita. Melalui pendekatan ini, sistem diharapkan dapat mendukung identifikasi kondisi pertumbuhan dan gizi balita secara lebih terarah, konsisten, dan berbasis data. Selain itu, rancangan ini juga masih terbuka untuk dikembangkan lebih lanjut pada penelitian berikutnya, misalnya dengan menambahkan variabel kesehatan lain atau memperluas penerapannya pada layanan kesehatan yang lebih luas.

2.2 Landasan Teori

Landasan Teori berisi pembahasan mengenai konsep-konsep yang mendasari perancangan, meliputi teori serta metode yang digunakan. Bagian ini bertujuan memberikan pemahaman yang lebih jelas terhadap perancangan yang akan dilaksanakan.

2.2.1 Balita

Balita merupakan anak yang berada pada kelompok usia di bawah lima tahun. Dalam pengelompokan usia anak, balita umumnya mencakup anak usia 12–59 bulan, yaitu setelah melewati masa bayi hingga sebelum mencapai usia lima tahun. Pada tahap ini, anak berada pada masa pertumbuhan dan perkembangan yang berlangsung sangat cepat, sehingga kondisi kesehatannya perlu mendapat perhatian khusus [17]. Gambaran anak pada masa balita dapat dilihat pada Gambar 2.2.



Gambar 2. 2 Balita [2]

Masa balita sering dipandang sebagai periode penting karena pada fase ini terjadi banyak perubahan pada anak, baik dari sisi fisik maupun kemampuan dasarnya. Balita mulai mengalami peningkatan kemampuan bergerak, berinteraksi, berkomunikasi, dan beradaptasi dengan lingkungan sekitarnya. Karena itu, masa balita tidak hanya menjadi fase pertumbuhan tubuh, tetapi juga fase pembentukan dasar perkembangan anak pada tahap berikutnya [18], [19].

Selain itu, balita juga termasuk kelompok usia yang masih rentan terhadap berbagai masalah kesehatan, pertumbuhan, dan gizi. Kondisi tubuh anak pada usia ini belum berkembang secara optimal seperti pada anak yang lebih besar, sehingga balita masih sangat membutuhkan pengasuhan, pemantauan, dan perhatian dari orang tua maupun tenaga kesehatan. Pemantauan yang dilakukan secara rutin penting agar setiap perubahan kondisi anak dapat dikenali lebih awal dan penanganan yang sesuai dapat segera diberikan [18], [20].

2.2.2 Tumbuh Kembang Balita

Tumbuh kembang balita merupakan proses yang mencakup pertumbuhan fisik dan perkembangan kemampuan anak pada usia balita. Masa ini sering disebut sebagai masa emas karena pada periode tersebut terjadi pertumbuhan yang sangat cepat dan pembentukan kecerdasan anak berlangsung secara intensif. Pada tahap ini, anak tidak hanya mengalami pertambahan ukuran tubuh, tetapi juga perkembangan kemampuan motorik, bahasa, sosial, emosional, dan kognitif [21].

Pertumbuhan mengacu pada perubahan fisik yang dapat diukur, seperti bertambahnya tinggi badan, berat badan, jumlah sel, dan ukuran tubuh lainnya. Sementara itu, perkembangan mengarah pada perubahan kemampuan dan fungsi anak yang terjadi secara bertahap, seperti meningkatnya kemampuan bergerak, berbicara, memahami lingkungan, mengekspresikan emosi, dan berinteraksi dengan orang lain. Dengan demikian, pertumbuhan lebih bersifat kuantitatif karena dapat diukur secara fisik, sedangkan perkembangan lebih bersifat kualitatif karena berkaitan dengan kematangan fungsi tubuh dan kemampuan anak [21].

Tumbuh kembang balita dipengaruhi oleh berbagai faktor, salah satunya adalah asupan nutrisi. Kecukupan zat gizi sangat penting karena pada masa balita anak mengalami pertumbuhan fisik yang cepat dan perkembangan otak yang pesat. Apabila anak tidak mendapatkan asupan gizi yang cukup, kondisi tersebut dapat mengganggu proses tumbuh kembang dan meningkatkan risiko terjadinya malnutrisi [21]. Selain faktor gizi, tumbuh kembang balita juga dipengaruhi oleh stimulasi, pola asuh, kondisi kesehatan, dan lingkungan tempat anak tumbuh [22].

Karena berada pada masa yang sangat menentukan, pemantauan tumbuh kembang balita perlu dilakukan secara rutin agar setiap perubahan kondisi anak dapat dikenali sejak dini. Melalui pemantauan yang baik, kesesuaian pertumbuhan dan perkembangan anak dengan tahap usianya dapat diketahui oleh orang tua maupun tenaga kesehatan, sehingga apabila gangguan ditemukan, intervensi yang sesuai dapat segera diberikan [23].

2.2.3 Gizi Balita

Gizi balita didefinisikan sebagai kondisi yang menggambarkan terpenuhi atau tidaknya kebutuhan zat gizi pada anak usia balita. Pada masa ini, pemenuhan gizi perlu diperhatikan secara khusus karena balita berada pada tahap pertumbuhan yang berlangsung sangat cepat dan membutuhkan asupan yang memadai untuk mendukung kesehatan serta aktivitas sehari-hari.

Menurut WHO, praktik pemberian makan pada bayi dan anak usia dini dijelaskan memiliki peran yang sangat penting dalam menunjang pertumbuhan yang sehat, perkembangan yang optimal, serta dalam mengurangi risiko kesakitan dan kematian pada anak. Selain itu, ditegaskan pula bahwa dua tahun pertama kehidupan merupakan periode yang sangat krusial, karena kualitas gizi pada masa tersebut akan memengaruhi kondisi anak pada tahap perkembangan berikutnya [24], [25].

Peran gizi pada balita tidak hanya berkaitan dengan pemenuhan energi, tetapi juga berpengaruh terhadap pertumbuhan dan perkembangan anak secara keseluruhan. Asupan gizi yang cukup membantu pembentukan jaringan tubuh, mendukung perkembangan otak, menjaga sistem kekebalan tubuh, serta menunjang aktivitas dan kemampuan belajar anak. Penelitian di tingkat nasional juga menunjukkan bahwa status gizi anak usia 3–5 tahun yang diukur menggunakan indikator antropometri memiliki hubungan dengan perkembangan anak. Hal ini menunjukkan bahwa gizi yang baik tidak hanya penting untuk

menjaga kesehatan fisik, tetapi juga berperan dalam mendukung perkembangan anak pada tahap selanjutnya [26].

Permasalahan gizi pada balita dapat terjadi dalam berbagai bentuk, baik berupa kekurangan maupun kelebihan gizi. WHO menjelaskan bahwa malnutrisi pada anak dapat muncul dalam bentuk stunting, wasting, underweight, maupun overweight. Kondisi ini menunjukkan bahwa status gizi balita perlu dipahami secara menyeluruh, karena setiap bentuk masalah gizi dapat memberikan dampak yang berbeda terhadap kesehatan anak. WHO juga menyebutkan bahwa hampir setengah dari kematian anak usia di bawah lima tahun berkaitan dengan undernutrition. Oleh karena itu, perhatian terhadap status gizi balita menjadi hal yang sangat penting dalam upaya meningkatkan kesehatan masyarakat [27].

Status gizi balita dipengaruhi oleh berbagai faktor yang saling berhubungan. Faktor-faktor tersebut mencakup kualitas dan kecukupan asupan makanan, pola pemberian makan, penyakit infeksi, kondisi rumah tangga, tingkat pengetahuan ibu, serta lingkungan tempat anak tumbuh dan berkembang. Artikel dalam Media Kesehatan Masyarakat Indonesia menunjukkan bahwa penilaian status gizi anak dapat dilakukan melalui indikator BB/U, TB/U, dan BB/TB, serta dipengaruhi oleh faktor-faktor seperti pendidikan ibu, pekerjaan ibu, pendapatan keluarga, pengetahuan ibu, penyakit infeksi, dan paparan asap rokok. Dengan demikian, status gizi balita tidak hanya dipengaruhi oleh makanan yang dikonsumsi, tetapi juga oleh kondisi keluarga dan lingkungan secara keseluruhan [28].

Berdasarkan uraian tersebut, gizi balita merupakan aspek yang sangat penting karena berhubungan erat dengan kesehatan, pertumbuhan, dan perkembangan anak. Pemantauan status gizi perlu dilakukan secara rutin agar kondisi anak dapat diketahui sejak dini dan intervensi yang tepat dapat segera diberikan. Melalui pemantauan yang baik, masalah gizi pada balita dapat dideteksi lebih awal sehingga upaya perbaikan gizi dapat dilakukan secara lebih terarah [1], [27], [28].

2.2.4 Status Tumbuh Kembang dan Gizi Balita

Status tumbuh kembang dan gizi balita menggambarkan keadaan anak pada masa balita dilihat dari pertumbuhan fisik, perkembangan umum, dan kecukupan gizinya. Penilaian kondisi ini penting karena masa balita merupakan periode ketika perubahan fisik berlangsung cepat dan perlu dipantau secara teratur. WHO menempatkan pertumbuhan anak sebagai indikator penting untuk menilai status gizi dan kesehatan anak, sedangkan standar pertumbuhan anak digunakan untuk melihat kondisi pertumbuhan fisik berlangsung sesuai acuan yang berlaku [29], [30].

Salah satu cara yang paling banyak digunakan untuk menilai status tersebut adalah pengukuran antropometri. Pada balita, pengukuran antropometri umumnya menggunakan usia dalam bulan, berat badan dalam kilogram, serta panjang atau tinggi badan dalam sentimeter. WHO *Child Growth Standards* menggunakan indikator panjang atau tinggi badan menurut umur, berat badan

menurut umur, dan berat badan menurut panjang atau tinggi badan sebagai dasar penilaian status balita [29], [31], [32]. Penentuan kategori pada indikator antropometri dilakukan dengan membandingkan hasil pengukuran anak terhadap standar pertumbuhan WHO atau standar antropometri yang diadopsi secara nasional. Secara umum, hasil pengukuran dinyatakan dalam nilai *z-score*, kemudian dibandingkan dengan batas standar, misalnya di bawah -3 SD, di bawah -2 SD, median, atau di atas +2 SD. Dengan cara ini, setiap anak dapat dikelompokkan ke dalam kategori status tertentu sesuai indikator yang digunakan [29], [30].

Pada indikator *Height-for-Age* (H/A) atau tinggi badan menurut umur, penilaian digunakan untuk melihat kesesuaian tinggi badan anak dengan usianya. Penilaian stunting diterapkan pada balita usia 0 sampai 5 tahun. Apabila tinggi badan anak berada di bawah standar pertumbuhan untuk usianya, maka kondisi tersebut dikategorikan sebagai stunted. Sebaliknya, apabila tinggi badan anak masih sesuai dengan pertumbuhan menurut usianya, maka kondisi tersebut dikategorikan sebagai not stunted. Dalam klasifikasi yang digunakan, keluaran indikator H/A dibagi menjadi dua kelas, yaitu Not Stunted dan Stunted, agar hasil penilaian dapat disajikan secara lebih sederhana dan mudah dipahami. Secara umum, kategori Not Stunted menunjukkan bahwa tinggi badan anak masih sesuai dengan usianya dan berada pada jalur pertumbuhan normal, sedangkan kategori Stunted menunjukkan adanya hambatan pertumbuhan linier yang sering dikaitkan

dengan kekurangan gizi jangka panjang, infeksi berulang, serta faktor pengasuhan dan lingkungan. [30].

Pada indikator *Weight-for-Age* (W/A) atau berat badan menurut umur, penilaian dilakukan untuk melihat kesesuaian berat badan balita dengan usianya. Penilaian ini diterapkan pada balita usia 0 sampai 5 tahun. Apabila berat badan anak masih sesuai dengan kelompok umurnya, maka kondisi tersebut dikategorikan sebagai Normal. Apabila berat badan anak berada di bawah kondisi yang seharusnya untuk usianya, maka kondisi tersebut dikategorikan sebagai Underfed. Sementara itu, apabila berat badan anak berada jauh di bawah kondisi yang seharusnya, maka kondisi tersebut dikategorikan sebagai Malnutrition. Dengan demikian, indikator ini digunakan untuk menggambarkan tingkat kecukupan berat badan anak berdasarkan umur.

Dalam praktiknya, indikator BB/U sering digunakan sebagai skrining awal status gizi karena perubahan berat badan umumnya lebih cepat terlihat dibandingkan tinggi badan, sehingga pengaruh asupan makan maupun kondisi kesehatan atau infeksi yang sedang atau berulang dapat tercermin. Perbedaan antara Underfed dan Malnutrition ditunjukkan pada tingkat keparahan kekurangan berat badan, di mana kondisi Malnutrition dikategorikan sebagai tingkat yang lebih berat dan memerlukan perhatian yang lebih intensif [30], [32].

Pada indikator *Weight-for-Height* (W/H) atau berat badan menurut tinggi badan, penilaian dilakukan untuk melihat proporsi berat badan terhadap tinggi

badan anak. Melalui indikator ini, kondisi berat badan anak terlalu rendah, sesuai, atau melebihi proporsi tinggi badannya dapat diketahui.

Indikator BB/TB digunakan untuk menggambarkan kondisi gizi jangka pendek atau akut karena sangat dipengaruhi oleh keadaan terkini, seperti pola makan harian, nafsu makan, serta adanya penyakit infeksi yang baru dialami. Oleh karena itu, indikator W/H sering dimanfaatkan untuk mengenali kondisi wasting maupun berat badan berlebih pada balita [30], [31]. Dalam klasifikasi yang digunakan, kategori Very Thin menunjukkan kondisi berat badan yang sangat rendah dibandingkan tinggi badan, Thin menunjukkan kondisi berat badan yang rendah, Normal menunjukkan kondisi berat badan yang proporsional, dan Obese menunjukkan kondisi berat badan yang berada di atas rentang normal. Perubahan nilai W/H cenderung terjadi lebih cepat dibandingkan indikator tinggi badan menurut umur, sehingga indikator ini penting untuk melihat keseimbangan antara berat badan dan tinggi badan anak [30], [31].

Penilaian status pertumbuhan dan gizi balita dapat menggunakan acuan dari *WHO Child Growth Standards* dan Pedoman Pelaksanaan Stimulasi, Deteksi, dan Intervensi Dini Tumbuh Kembang Anak (SDIDTK). WHO menyediakan standar pertumbuhan anak melalui beberapa indikator antropometri, yaitu *Weight-for-Age* (W/A), *Height-for-Age* (H/A), dan *Weight-for-Height* (W/H). Dalam Pedoman SDIDTK, indikator tersebut dikenal dengan istilah berat badan menurut umur (BB/U), panjang badan atau tinggi badan menurut umur (PB/U atau TB/U), serta

berat badan menurut panjang badan atau tinggi badan (BB/PB atau BB/TB) [79], [80].

Penilaian status pertumbuhan dan gizi balita tidak dapat dilakukan hanya dengan melihat angka berat badan atau tinggi badan secara langsung. Hasil pengukuran anak perlu dibandingkan dengan standar pertumbuhan yang sesuai dengan umur, jenis kelamin, berat badan, dan tinggi badan anak. Oleh karena itu, WHO dan SDIDTK menggunakan nilai *z-score* sebagai dasar penentuan kategori. Nilai *z-score* menunjukkan posisi hasil pengukuran anak terhadap nilai median pada standar pertumbuhan. Apabila nilai *z-score* berada di bawah atau di atas batas tertentu, anak dapat termasuk ke dalam kategori masalah pertumbuhan atau masalah gizi [79], [80]. Tabel 2.1 menampilkan kategori status pertumbuhan dan gizi balita berdasarkan standar WHO dan Pedoman SDIDTK.

Tabel 2. 1 Kategori Status Pertumbuhan dan Gizi Balita Berdasarkan WHO dan SDIDTK [79]

Indikator	**Nilai *Z-score***	**Kategori**	**Keterangan**
BB/U atau *Weight-for-Age* (W/A)	< -3 SD	Berat badan sangat kurang / *severely underweight*	Berat badan anak sangat kurang menurut umur
BB/U atau *Weight-for-Age* (W/A)	≥ -3 SD sampai < -2 SD	Berat badan kurang / *underweight*	Berat badan anak kurang menurut umur
BB/U atau *Weight-for-Age* (W/A)	≥ -2 SD sampai ≤ +1 SD	Berat badan normal	Berat badan anak sesuai menurut umur
BB/U atau *Weight-for-Age* (W/A)	> +1 SD	Risiko berat badan lebih	Perlu konfirmasi dan penilaian lanjut menggunakan indikator lain

Tabel 2.1 (Lanjutan)

Indikator	**Nilai *Z-score***	**Kategori**	**Keterangan**
PB/U atau TB/U atau *Height-for-Age* (H/A)	< -3 SD	Sangat pendek / *severely stunted*	Tinggi badan anak sangat rendah menurut umur
PB/U atau TB/U atau *Height-for-Age* (H/A)	≥ -3 SD sampai < -2 SD	Pendek / *stunted*	Tinggi badan anak rendah menurut umur
PB/U atau TB/U atau *Height-for-Age* (H/A)	≥ -2 SD sampai ≤ +3 SD	Normal / *Not Stunted*	Tinggi badan anak sesuai menurut umur
PB/U atau TB/U atau *Height-for-Age* (H/A)	> +3 SD	Tinggi	Perlu konfirmasi oleh tenaga kesehatan
BB/PB atau BB/TB atau *Weight-for-Height* (W/H)	< -3 SD	Gizi buruk / *severely wasted*	Berat badan sangat kurang dibandingkan panjang atau tinggi badan
BB/PB atau BB/TB atau *Weight-for-Height* (W/H)	≥ -3 SD sampai < -2 SD	Gizi kurang / *wasted*	Berat badan kurang dibandingkan panjang atau tinggi badan
BB/PB atau BB/TB atau *Weight-for-Height* (W/H)	≥ -2 SD sampai ≤ +1 SD	Gizi normal	Berat badan sesuai terhadap panjang atau tinggi badan
BB/PB atau BB/TB atau *Weight-for-Height* (W/H)	> +1 SD sampai ≤ +2 SD	Berisiko gizi lebih / *possible risk of overweight*	Anak berisiko mengalami kelebihan berat badan
BB/PB atau BB/TB atau *Weight-for-Height* (W/H)	> +2 SD sampai ≤ +3 SD	Gizi lebih / *overweight*	Anak mengalami kelebihan berat badan
BB/PB atau BB/TB atau *Weight-for-Height* (W/H)	> +3 SD	Obesitas / *obese*	Anak mengalami obesitas

Berdasarkan Tabel 2.1, kategori normal pada berat badan dan tinggi badan ditentukan sesuai indikator yang digunakan. Pada indikator BB/U atau *Weight-for-Age* (W/A), anak dinyatakan memiliki berat badan normal apabila nilai *z-score* berada pada rentang ≥ -2 SD sampai ≤ +1 SD. Rentang tersebut menunjukkan bahwa berat badan anak masih sesuai dengan umur anak.

Pada indikator PB/U atau TB/U atau *Height-for-Age* (H/A), anak dinyatakan memiliki tinggi badan normal apabila nilai *z-score* berada pada rentang ≥ -2 SD sampai ≤ +3 SD. Anak dengan nilai TB/U ≥ -2 SD termasuk ke dalam kategori normal atau *Not Stunted*. Sebaliknya, anak dengan nilai TB/U < -2 SD termasuk ke dalam kategori pendek atau *stunted*. Anak dengan nilai TB/U < -3 SD termasuk ke dalam kategori sangat pendek atau *severely stunted*.

Pada indikator BB/PB atau BB/TB atau *Weight-for-Height* (W/H), anak dinyatakan memiliki status gizi normal apabila nilai *z-score* berada pada rentang ≥ -2 SD sampai ≤ +1 SD. Indikator ini menunjukkan kesesuaian berat badan anak terhadap panjang badan atau tinggi badannya. Apabila nilai BB/TB berada di bawah -2 SD, anak dapat dikategorikan mengalami gizi kurang atau *wasted*. Apabila nilai BB/TB berada di atas +1 SD, anak perlu diperhatikan karena dapat berisiko mengalami gizi lebih.

Selain kategori berdasarkan nilai *z-score*, standar WHO juga dapat digunakan sebagai acuan untuk melihat contoh rentang berat badan dan tinggi badan normal balita pada beberapa usia tertentu. Tabel 2.2 menampilkan referensi ringkas berat badan dan tinggi badan normal balita berdasarkan standar

WHO. Tabel ini berfungsi sebagai gambaran umum agar pembaca lebih mudah memahami rentang pertumbuhan balita sesuai usia.

Tabel 2. 2 Referensi Ringkas Berat Badan dan Tinggi Badan Normal Balita Berdasarkan WHO [79]

Usia	**Berat Badan Normal**	**Tinggi Badan Normal**
6 bulan	6,4–8,6 kg	63,3–71,9 cm
12 bulan	7,7–11,0 kg	69,6–80,2 cm
24 bulan	9,7–14,5 kg	80,9–94,7 cm
36 bulan	12,0–17,2 kg	88,7–103,5 cm
48 bulan	13,7–20,5 kg	96,1–111,5 cm
59 bulan	15,2–23,4 kg	102,8–119,2 cm

Berdasarkan Tabel 2.2, setiap kelompok usia memiliki rentang berat badan dan tinggi badan normal yang berbeda. Anak usia 6 bulan memiliki rentang berat badan dan tinggi badan yang lebih rendah dibandingkan anak usia 24 bulan, 36 bulan, 48 bulan, dan 59 bulan. Perbedaan tersebut terjadi karena pertumbuhan balita berlangsung secara bertahap sesuai pertambahan usia.

Tabel referensi ringkas tersebut hanya digunakan sebagai informasi pendukung. Tabel tersebut tidak digunakan sebagai satu-satunya dasar untuk menentukan status pertumbuhan dan gizi balita. Penilaian akhir tetap perlu memperhatikan usia, jenis kelamin, indikator antropometri, dan nilai *z-score*.

Dalam standar WHO, tabel pertumbuhan dibedakan berdasarkan jenis kelamin dan indikator yang digunakan. Oleh karena itu, interpretasi akhir tetap mengacu pada indikator BB/U, PB/U atau TB/U, dan BB/PB atau BB/TB.

Nilai *z-score* digunakan untuk mengetahui posisi hasil pengukuran anak terhadap standar pertumbuhan WHO. Nilai ini menunjukkan apakah berat badan atau tinggi badan anak masih berada dalam rentang normal atau sudah berada di bawah atau di atas batas standar. Dalam standar WHO, nilai *z-score* disesuaikan dengan indikator antropometri, umur, jenis kelamin, berat badan, dan tinggi badan anak [79].

Dalam penerapannya, peneliti tidak menentukan batas kategori secara mandiri. Batas kategori tersebut mengacu pada standar WHO dan Pedoman SDIDTK. Pada indikator BB/U atau *Weight-for-Age*, nilai *z-score* digunakan untuk melihat kesesuaian berat badan anak terhadap umurnya. Pada indikator PB/U atau TB/U atau *Height-for-Age*, nilai *z-score* digunakan untuk melihat kesesuaian panjang badan atau tinggi badan anak terhadap umurnya. Sementara itu, pada indikator BB/PB atau BB/TB atau *Weight-for-Height*, nilai *z-score* digunakan untuk melihat kesesuaian berat badan anak terhadap panjang badan atau tinggi badannya.

Nilai -2 SD pada standar WHO menunjukkan batas bawah normal dari hasil pengukuran pertumbuhan anak. Anak dinyatakan berada di bawah -2 SD apabila hasil pengukurannya lebih rendah dari batas normal pada standar WHO sesuai indikator, umur, dan jenis kelamin anak. Oleh karena itu, penilaian status

pertumbuhan dan gizi balita tidak cukup dilakukan hanya dengan melihat angka berat badan atau tinggi badan secara langsung. Hasil pengukuran anak perlu dibandingkan dengan standar WHO agar kategori pertumbuhan dan gizinya dapat ditentukan dengan lebih tepat [79].

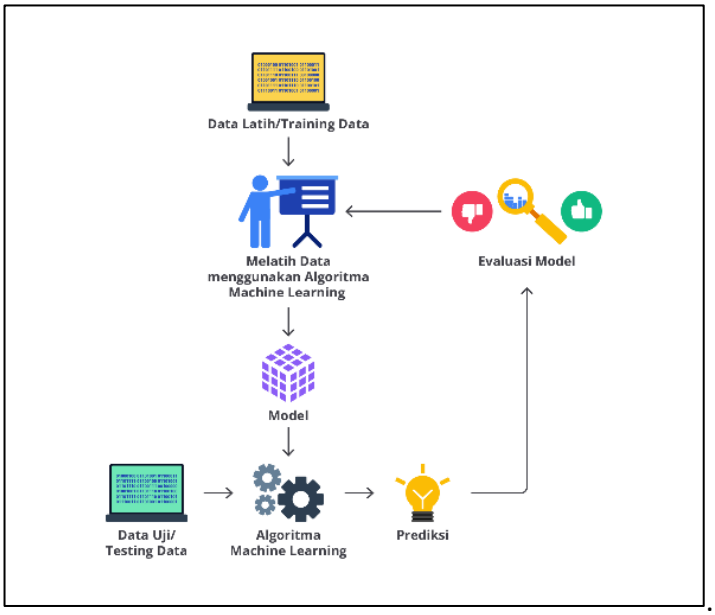
Pada indikator PB/U atau TB/U, anak dinyatakan *stunted* apabila nilai *Height-for-Age Z-score* atau TB/U berada di bawah -2 SD. Anak dengan nilai *z-score* < -3 SD termasuk kategori sangat pendek atau *severely stunted*. Anak dengan nilai *z-score* ≥ -3 SD sampai < -2 SD termasuk kategori pendek atau *stunted*. Sebaliknya, anak dinyatakan *Not Stunted* apabila nilai *z-score* berada pada batas ≥ -2 SD. Kriteria tersebut menunjukkan bahwa tinggi badan anak masih berada dalam batas normal menurut umur berdasarkan standar WHO dan SDIDTK [79], [80].
Pada indikator BB/U, anak dinyatakan memiliki berat badan kurang apabila nilai *z-score* berada di bawah -2 SD sesuai umur dan jenis kelamin. Pada indikator BB/PB atau BB/TB, anak dinyatakan mengalami gizi kurang atau *wasted* apabila nilai *z-score* berada di bawah -2 SD berdasarkan panjang badan atau tinggi badan dan jenis kelamin. Dengan demikian, istilah di bawah -2 SD berarti hasil pengukuran anak lebih rendah dari batas normal yang sudah ditetapkan dalam standar pertumbuhan WHO.

Pedoman SDIDTK menjelaskan bahwa anak dengan hasil PB/U atau TB/U di bawah -2 SD atau di atas +3 SD perlu dikonfirmasi oleh tenaga kesehatan yang berkompeten. Konfirmasi tersebut dilakukan melalui penilaian status gizi berdasarkan BB/U, PB/U atau TB/U, BB/PB atau BB/TB, IMT/U, serta tren

pertumbuhan anak [80]. Oleh karena itu, hasil klasifikasi pada penelitian ini digunakan sebagai alat bantu skrining awal dan bukan sebagai diagnosis akhir yang menggantikan pemeriksaan langsung oleh tenaga kesehatan.

2.2.5 Machine Learning

Machine learning merupakan salah satu cabang kecerdasan buatan (Artificial Intelligence) yang memungkinkan komputer mempelajari pola dari data dan meningkatkan performanya seiring waktu tanpa perlu diprogram secara rinci untuk setiap aturan [33]. Proses tersebut umumnya diawali dengan penyediaan data latih (training data) yang digunakan untuk melatih algoritma hingga terbentuk sebuah model. Selanjutnya, model diuji menggunakan data uji (testing data) untuk menghasilkan prediksi, kemudian dilakukan evaluasi model guna menilai tingkat ketepatan hasil prediksi. Alur ini berlangsung secara berulang sehingga performa model dapat diperbaiki secara bertahap yang dapat dilihat pada gambar 2.2.



Gambar 2. 3 Alur Kerja Machine Learning [33]

Dalam bidang kesehatan, machine learning banyak diterapkan untuk mendukung proses diagnosis, klasifikasi kondisi, serta prediksi risiko karena kemampuannya mengolah data berskala besar dan menangkap keterkaitan antarvariabel yang kompleks, yang sering kali sulit dianalisis secara manual [34]. Oleh sebab itu, pada penelitian ini machine learning dimanfaatkan untuk mengklasifikasikan status stunting balita berdasarkan data antropometri agar proses identifikasi dapat dilakukan lebih cepat, objektif, dan konsisten.

2.2.6 Klasifikasi

Klasifikasi merupakan salah satu metode dalam *machine learning* yang bertujuan mengelompokkan suatu data ke dalam kelas atau kategori tertentu berdasarkan pola yang dipelajari dari data latih. Dalam prosesnya, model dilatih menggunakan data yang telah memiliki label sehingga model mampu mengenali

karakteristik tiap kelas dan kemudian memprediksi label untuk data baru yang belum diketahui kategorinya [35].

Metode klasifikasi banyak dimanfaatkan di berbagai bidang, termasuk kesehatan, karena dapat membantu proses pengambilan keputusan seperti penentuan kondisi pasien atau identifikasi suatu penyakit secara otomatis berdasarkan fitur-fitur yang tersedia pada data [34]. Pada penelitian ini, klasifikasi digunakan untuk menentukan status stunting balita berdasarkan variabel antropometri sehingga proses skrining pertumbuhan dapat dilakukan secara lebih cepat, objektif, dan konsisten.

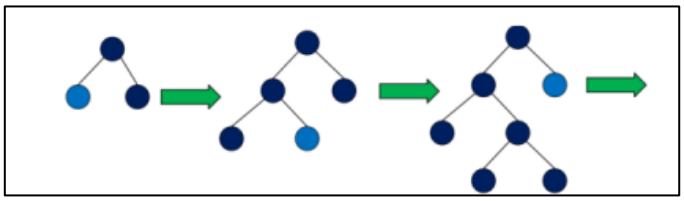
2.2.7 Light Gradient Boosting Machine (LightGBM)

Light Gradient Boosting Machine (LightGBM) merupakan salah satu algoritma machine learning berbasis gradient boosting yang dirancang untuk membuat proses pelatihan model menjadi lebih cepat dan efisien, terutama saat digunakan pada data tabular dalam jumlah besar. Algoritma ini diperkenalkan oleh Ke et al. sebagai pengembangan dari Gradient Boosting Decision Tree (GBDT) untuk mengatasi penurunan performa yang sering muncul ketika jumlah data dan fitur semakin banyak [36]. Dalam berbagai kajian tentang data tabular, model berbasis tree ensemble seperti LightGBM juga masih dinilai sangat andal karena mampu memberikan performa yang baik tanpa memerlukan penyesuaian yang terlalu kompleks dibandingkan banyak metode deep learning [37].

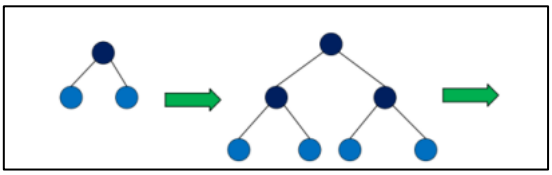
Salah satu hal yang membuat LightGBM menonjol adalah cara algoritma ini membangun pohon keputusan, yaitu dengan pendekatan leaf-wise tree growth. Pada pendekatan ini, cabang yang memberikan penurunan loss terbesar akan dipilih lebih dulu untuk dikembangkan. Gambar 2.3 memperlihatkan bahwa pertumbuhan pohon pada LightGBM tidak dilakukan secara merata pada setiap level, melainkan difokuskan pada leaf yang paling berpotensi meningkatkan performa model. Akibatnya, pohon yang terbentuk dapat menjadi lebih dalam pada bagian tertentu. Sebaliknya, Gambar 2.4 menunjukkan pendekatan level-wise tree growth yang umum digunakan pada algoritma boosting lain, yaitu dengan mengembangkan seluruh node pada level yang sama secara bersamaan. Perbedaan strategi inilah yang menjadi salah satu alasan mengapa LightGBM dapat bekerja lebih efisien dan tetap memberikan hasil yang kompetitif pada data tabular [36].

Selain itu, LightGBM juga didukung oleh dua teknik optimasi utama, yaitu Gradient-based One-Side Sampling (GOSS) dan Exclusive Feature Bundling (EFB) [36]. GOSS mempercepat proses pelatihan dengan cara mempertahankan data yang memiliki gradien besar karena data tersebut dianggap lebih penting dalam proses pembelajaran, kemudian mengurangi sebagian data dengan gradien yang lebih kecil. Sementara itu, EFB membantu mengurangi jumlah fitur yang diproses dengan menggabungkan fitur-fitur yang saling eksklusif. Melalui kedua mekanisme ini, LightGBM mampu meningkatkan efisiensi komputasi tanpa menurunkan akurasi model secara signifikan [36]. Tidak hanya unggul dari sisi efisiensi, LightGBM

juga memiliki kemampuan prediksi yang kompetitif dalam berbagai penelitian terapan. Pada salah satu penelitian yang membandingkan beberapa algoritma tree-based ensemble, LightGBM menunjukkan hasil yang sedikit lebih baik pada metrik accuracy, precision, recall, dan F1-score, meskipun XGBoost memperoleh nilai AUC yang sedikit lebih tinggi [38]. Temuan tersebut menunjukkan bahwa LightGBM tidak hanya cepat dalam proses pelatihan, tetapi juga tetap mampu menghasilkan performa klasifikasi yang baik pada data tabular.



Gambar 2. 4 Leaf-wise tree growth in LGBM [38]



Gambar 2. 5 Leaf-wise tree growth in LGBM [38]

Secara matematis, pada kasus klasifikasi multikelas, proses LightGBM diawali dengan menghitung prior kelas dan skor awal model. Prior kelas dinyatakan dengan [36]:

$$\pi_k = \frac{\mathrm{n}_k}{N}, \qquad F_k^0 = \ln(\pi_k) \tag{2.1}$$

Keterangan Simbol :

π_k= prior kelas ke-k atau proporsi data pada kelas ke-k

n_k= jumlah data pada kelas ke-k

N= jumlah seluruh data

F_k^0= skor awal untuk kelas ke-k

ln= logaritma natural

k= indeks kelas

dengan $\pi_k$sebagai prior kelas ke-k, $n_k$sebagai jumlah data pada kelas ke-k, dan Nsebagai jumlah seluruh data. Setelah itu, probabilitas tiap kelas dihitung menggunakan fungsi *softmax* [37]:

$$p_{jk}^{(t)} = \frac{e^{F_{jk}^{(t)}}}{\sum_{c=1}^{K} e^{F_{jc}^{(t)}}} \tag{2.2}$$

Keterangan Simbol:

$p_{jk}^{(t)}$= probabilitas data ke-j berada pada kelas ke-k pada iterasi ke-t

e= bilangan eksponensial

$F_{jk}^{(t)}$= skor model untuk data ke-j pada kelas ke-k di iterasi ke-t

$\sum$= simbol penjumlahan

c= indeks kelas pada proses penjumlahan

K= jumlah seluruh kelas

$F_{jc}^{(t)}$= skor model untuk data ke-j pada kelas ke-c di iterasi ke-t

j= indeks data

k= indeks kelas yang sedang dihitung probabilitasnya

t= iterasi ke-t

Agar perhitungan lebih stabil secara numerik, bentuk *softmax* dapat dituliskan kembali dengan mengurangi nilai maksimum skor, yaitu [37]:

$$m = max_k\left(F_{jk}^{(t)}\right) \tag{2.3}$$

Keterangan Simbol:

m = nilai maksimum skor untuk data ke-j pada iterasi ke-t

max= operator untuk mengambil nilai terbesar

k= indeks kelas

$F_{jk}^{(t)}$= skor model untuk data ke-j pada kelas ke-k di iterasi ke-t

j= indeks data

t= iterasi ke-t

$$p_{jk}^{(t)} = \frac{e^{F_{jk}^{(t)} - m}}{\sum_{c=1}^{K} e^{F_{jc}^{(t)} - m}} \tag{2.4}$$

Keterangan Simbol

$p_{jk}^{(t)}$ = probabilitas data ke-j berada pada kelas ke-k pada iterasi ke-t

e= bilangan eksponensial

$F_{jk}^{(t)}$= skor model untuk data ke-j pada kelas ke-k di iterasi ke-t

m= nilai maksimum skor dari seluruh kelas untuk data ke-j pada iterasi ke-t

$\sum$= simbol penjumlahan

c= indeks kelas pada proses penjumlahan

K= jumlah seluruh kelas

$F_{jc}^{(t)}$= skor model untuk data ke-j pada kelas ke-c di iterasi ke-t

j= indeks data

k= indeks kelas yang sedang dihitung probabilitasnya

t= iterasi ke-t

Selanjutnya, pada setiap *leaf* dilakukan perhitungan gradien dan *hessian* sebagai dasar pembaruan model. Perhitungan tersebut dirumuskan sebagai berikut [38]:

$$G_{jk}^{t} = n_j \cdot p_{jk}^{t-1} - n_{jk} \tag{2.5}$$

Keterangan Simbol:

G_{jk}^{t}= nilai gradien pada *leaf* ke-j untuk kelas ke-k pada iterasi ke-t

n_j= jumlah data pada *leaf* ke-j

$p_{jk}^{(t-1)}$= probabilitas data pada *leaf* ke-j untuk kelas ke-k pada iterasi sebelumnya, yaitu iterasi ke-$(t-1)$

n_{jk}= jumlah data kelas ke-k pada *leaf* ke-j

j= indeks *leaf*

k= indeks kelas

t= iterasi ke-t

$$H_{jk}^{t} = n_j \cdot p_{jk}^{t-1}(1 - p_{jk}^{t-1}) \tag{2.6}$$

Keterangan Simbol:

H_{jk}^{t}= nilai hessian pada leaf ke-j untuk kelas ke-k pada iterasi ke-t

n_j= jumlah data pada leaf ke-j

$p_{jk}^{(t-1)}$= probabilitas data pada leaf ke-j untuk kelas ke-k pada iterasi sebelumnya, yaitu iterasi ke-$(t-1)$ $1 - p_{jk}^{(t-1)}$= komplemen dari probabilitas kelas ke-k pada iterasi sebelumnya

j= indeks leaf

k= indeks kelas

t= iterasi ke-t

dengan $n_j$menyatakan jumlah data pada *leaf* ke-j, sedangkan n_{jk}adalah jumlah data kelas ke-k pada *leaf* tersebut. Berdasarkan nilai gradien dan *hessian* tersebut, bobot pada setiap *leaf* dihitung menggunakan persamaan:

Nilai bobot ini kemudian digunakan untuk memperbarui skor model dengan melibatkan *learning rate* η, yaitu:

$$F_{jk}^{t} = F_{jk}^{t-1} + \eta \cdot w_{jk}^{t} \quad (2.7)$$

Keterangan Simbol:

F_{jk}^{t} = skor model untuk *leaf* ke-j pada kelas ke-k di iterasi ke-t

$F_{jk}^{(t-1)}$= skor model untuk *leaf* ke-j pada kelas ke-k di iterasi sebelumnya, yaitu iterasi ke-$(t-1)$

η= *learning rate* atau laju pembelajaran

w_{jk}^{t}= bobot *leaf* ke-j untuk kelas ke-k pada iterasi ke-t

j= indeks *leaf*

k= indeks kelas

t= iterasi ke-t

Setelah seluruh iterasi selesai dilakukan, prediksi akhir kelas ditentukan berdasarkan probabilitas terbesar, yang dapat dinyatakan sebagai [36]:

$$\hat{y} = \arg\max_{k} p_{jk}^{T} \tag{2.8}$$

Keterangan Simbol:

$\hat{y}$= hasil prediksi akhir kelas

$\arg\max$= operator untuk memilih kelas dengan nilai probabilitas terbesar

k= indeks kelas

p_{jk}^{T}= probabilitas data ke-j berada pada kelas ke-k pada iterasi terakhir

j= indeks data

T= jumlah total iterasi atau iterasi terakhir

Dalam proses pembentukan pohon, LightGBM juga menggunakan perhitungan gain untuk menentukan split terbaik. Nilai gain ini dihitung berdasarkan gradien dan hessian pada node kiri, kanan, dan node induk, yaitu [39]:

$$\text{Gain} = \frac{1}{2}\sum_{k=1}^{K}\left(\frac{G_{Lk}^{2}}{H_{Lk}+\lambda} + \frac{G_{Rk}^{2}}{H_{Rk}+\lambda} - \frac{G_{Tk}^{2}}{H_{Tk}+\lambda}\right) \tag{2.9}$$

Keterangan Simbol:

Gain = nilai peningkatan kualitas *split*

$\frac{1}{2}$= konstanta dalam perhitungan *gain*

$\sum$= simbol penjumlahan

k= indeks kelas

K= jumlah seluruh kelas

G_{Lk}= jumlah gradien pada cabang kiri untuk kelas ke-k

H_{Lk}= jumlah hessian pada cabang kiri untuk kelas ke-k

G_{Rk}= jumlah gradien pada cabang kanan untuk kelas ke-k

H_{Rk}= jumlah hessian pada cabang kanan untuk kelas ke-k

G_{Tk}= jumlah gradien pada node induk untuk kelas ke-k

H_{Tk}= jumlah hessian pada node induk untuk kelas ke-k

λ= parameter regularisasi

Semakin besar nilai *gain* yang diperoleh, maka semakin baik *split* tersebut karena mampu menurunkan *loss* dan meningkatkan performa model secara lebih optimal.

LightGBM menyediakan parameter penting seperti *learning rate*, *max depth*, dan *num_leaves* yang mengatur kompleksitas pohon dan membantu meningkatkan kinerja model pada berbagai jenis dataset. Kombinasi teknik komputasi yang efisien serta fleksibilitas parameter menjadikan LightGBM sebagai salah satu algoritma boosting yang sangat kompetitif untuk tugas klasifikasi dan regresi pada data berskala besar maupun kompleks [39], [41].

2.2.8 Extreme Gradient Boosting (XGBoost)

Extreme Gradient Boosting (XGBoost) merupakan pengembangan dari metode *Gradient Tree Boosting* yang digunakan untuk menangani berbagai tugas *supervised learning*, seperti klasifikasi, regresi, prediksi, hingga *ranking*. Pada algoritma ini, model dibangun melalui penyusunan sejumlah pohon keputusan secara bertahap. Setiap pohon baru disusun berdasarkan kesalahan dari pohon sebelumnya, sehingga kemampuan prediksi model dapat ditingkatkan secara bertahap semakin meningkat [42].

Pada prosesnya, XGBoost memanfaatkan data latih yang berisi sekumpulan fitur $X_i$sebagai masukan untuk memprediksi variabel target Y_i. Prediksi akhir yang dihasilkan diperoleh dari penjumlahan kontribusi prediksi seluruh pohon yang terbentuk. Selain dikenal memiliki performa yang baik, XGBoost juga menerapkan mekanisme pengendalian kompleksitas model, seperti regularisasi, sehingga dapat membantu menekan risiko *overfitting* dan membuat model lebih stabil saat digunakan pada data baru.

Berikut tahapan dalam penyusunan algoritma XGBoost [43].

1. Menyusun dataset yang terdiri atas variabel Xsebagai data masukan dan variabel Ysebagai target yang akan diprediksi, yang kemudian digunakan dalam proses pembentukan model pohon XGBoost [44].
2. Menetapkan parameter yang diperlukan, lalu melakukan prediksi awal terhadap data dan menghitung nilai *residual* $(\hat{Y})$ pada seluruh titik data dalam

dataset. Persamaan digunakan untuk menentukan nilai prediksi awal sekaligus menghitung residual tersebut [43].

$$f0\ (x) = \ h0\ (x) = \ mean\ (Y\pi r^2) \qquad (2.10$$

Keterangan simbol:

f_0 (ef nol dari eks): nilai prediksi awal pada iterasi ke-0.

$h_0(x)$(ha nol dari eks): nilai model awal pada iterasi ke-0, yang disetarakan dengan $f_0(x)$.

x(eks): variabel masukan/fitur.

mean$(\cdot)$(mean/rata-rata): fungsi untuk menghitung nilai rata-rata.

Y(ye): kumpulan nilai target/label pada dataset $(Y = y_1, y_2, \dots, y_n)$.

π(pi): konstanta pi.

r(er): variabel jari-jari.

r^2(er kuadrat): nilai kuadrat dari r.

$$\hat{y} = y\ -\ f0\ (x) \qquad (2.11)$$

Keterangan simbol:

$\hat{y}$ (ye topi / *Y-hat*): residual/galat, yaitu selisih antara nilai target sebenarnya dan prediksi awal.

y(ye): nilai target sebenarnya (label asli) untuk suatu data.

$f_0(x)$(ef nol dari eks): prediksi awal model pada iterasi ke-0.

x(eks): data masukan/fitur (variabel input).

Tanda "−" (dikurangi): operasi pengurangan antara $y$dan $f_0(x)$.

3. Model pertama (M1) dilatih menggunakan pasangan data $[X, \hat{Y}]$. Pada tahap ini, data dipartisi menjadi dua bagian dengan menentukan titik pemisah (*split*) yang diperoleh dari nilai tengah antara dua kandidat cabang hingga terbentuk simpul-simpul akhir (*leaf node*). Perhitungan nilai *split* tersebut mengikuti persamaan yang digunakan dalam proses pembentukan pohon [43].

$$\bar{x}di = \frac{x_1 + x_2 + x_3 + .. + x_n}{n} \quad (2.12)$$

Keterangan simbol:

$\bar{x}_i$(eks bar i): nilai rata-rata (*mean*) dari data/variabel x(rata-rata sampel).

$x_1, x_2, x_3, \ldots, x_n$(eks satu, eks dua, eks tiga, …, eks en): nilai-nilai data $x$pada setiap observasi ke-1 sampai ke-n.

n(en): jumlah total data/observasi.

$$splits = \frac{\bar{x}di + \bar{x}di + 1}{2} \quad (2.13)$$

Keterangan Simbol:

(splits): nilai titik pemisah (*split point*) atau ambang pemotongan untuk membagi data.

$\bar{x}_{di}$(eks bar d i): nilai rata-rata (*mean*) pada indeks/kelompok ke-di.

$\bar{x}_{di+1}$(eks bar d i tambah satu): nilai rata-rata (*mean*) pada indeks/kelompok berikutnya $(di+1)$.

4. Menghitung nilai similarity dan gain pada seluruh pohon yang dibangun untuk menentukan kandidat pemisahan (split) yang paling optimal. Perhitungan nilai similarity dan gain dilakukan berdasarkan persamaan yang digunakan dalam XGBoost. Setelah itu, proses pemisahan (split) dilanjutkan kembali pada pohon yang memiliki nilai gain terbesar hingga struktur pohon terbentuk secara lengkap sesuai batas kedalaman maksimum yang telah ditetapkan [43].

$$similarity\ score = \frac{(\sum \hat{y}i)^2}{\sum[Previousfi(x) \times (1 - Previous\ fi(x)] + \lambda} \quad (2.14)$$

Keterangan Simbol

$\hat{y}_i$: residual atau turunan pertama (gradient) dari fungsi loss terhadap prediksi pada data ke-i.

$\sum \hat{y}_i$: jumlah seluruh residual dalam satu node.

Previous $f_i(x)$: probabilitas prediksi dari model pada iterasi sebelumnya untuk data ke-i.

$1 -$ Previous$f_i(x)$: komplemen probabilitas prediksi.

Previous$f_i(x) \times \big(1 -$ Previous$f_i(x)\big)$: turunan kedua (Hessian) dari logistic loss.

$\sum$: jumlah seluruh nilai Hessian dalam node.

λ: parameter regularisasi L2 untuk mencegah overfitting.

$$Gain = (Leftsimilarity + Rightsimilarity) - Rootsimilarity \quad (2.15)$$

Nilai Gain menyatakan besarnya peningkatan kualitas pemisahan data ketika sebuah node dipecah. Gain dihitung dengan menjumlahkan nilai Leftsimilarity (skor similarity pada cabang kiri) dan Rightsimilarity (skor similarity pada cabang kanan), kemudian mengurangi Rootsimilarity (skor similarity pada node akar sebelum pemisahan). Semakin besar nilai Gain, semakin baik pemisahan yang dihasilkan oleh split tersebut [43].

$$Output\ Value = \frac{(\sum \hat{y}i)}{\sum Previous_i(x) \times (1 - Previous\ f_i(x)] + \lambda} \quad (2.16)$$

Keterangan simbol:

(output value): nilai keluaran/bobot pada node atau daun (*leaf weight*).

$\sum i$sigma i): penjumlahan untuk seluruh data ke-i yang berada dalam node tersebut.

$\hat{y}_i$(ye topi i): nilai residual/galat (target sementara) untuk data ke-i.

Previous$f_i(x)$(previous ef i dari eks): nilai prediksi model sebelumnya untuk data ke-i.

$$f_i(x) = \sigma\left[\frac{(h_0(x)}{1 - (h_0(x)}\right] + (\mu\ x\ h_1(x)] \quad (2.17)$$

Keterangan simbol:

$f_i(x)$ (ef i dari eks): nilai keluaran/prediksi pada iterasi ke-i untuk input x.

$\sigma(\cdot)$(sigma): fungsi sigmoid/logistik yang memetakan nilai ke rentang 0–1.

$h_0(x)$(ha nol dari eks): nilai prediksi awal/baseline untuk input x.

$1 - h_0(x)$(satu dikurangi ha nol dari eks): komplemen dari prediksi awal.

$\frac{h_0(x)}{1-h_0(x)}$(ha nol dari eks dibagi satu dikurangi ha nol dari eks): komponen rasio yang menggambarkan perbandingan prediksi awal terhadap komplemennya.

μ(miu): parameter laju pembelajaran/koefisien pengali yang mengatur besar pengaruh pembaruan.

$h_1(x)$(ha satu dari eks): keluaran model/komponen koreksi pada tahap berikutnya untuk input x.

$$\sigma(x) = \frac{1}{1 + \exp(-x)} \tag{2.18}$$

Keterangan simbol:

(sigma dari eks): fungsi sigmoid/logistik yang memetakan nilai $x$ke rentang 0–1.

x(eks): nilai masukan (biasanya hasil perhitungan/skor).

$\exp(\cdot)$(eksponensial / e pangkat): fungsi eksponensial berbasis bilangan Euler e.

$-x$(minus eks): nilai $x$yang diberi tanda negatif.

2.2.9 Python

Python merupakan bahasa pemrograman tingkat tinggi yang dirancang untuk memudahkan penulisan dan pembacaan kode melalui sintaks yang ringkas dan jelas. Bahasa ini banyak dimanfaatkan dalam pengembangan perangkat lunak, analisis data, serta pembelajaran mesin karena didukung oleh beragam pustaka yang membantu pemrosesan data dan komputasi ilmiah secara efektif [45]. Selain

itu, Python termasuk bahasa pemrograman serbaguna (*general-purpose*) yang digunakan luas pada berbagai bidang seperti *data science*, kecerdasan buatan, dan komputasi ilmiah. Kemampuannya dalam mengolah data, melakukan visualisasi, serta membangun model analitik menjadikan Python salah satu bahasa yang paling sering dipilih dalam penelitian berbasis data [44].

2.2.10 Google Colab

Google Colaboratory (Google Colab) merupakan layanan berbasis *cloud computing* yang dikembangkan oleh Google untuk menjalankan kode Python secara daring melalui lingkungan *Jupyter Notebook* tanpa memerlukan instalasi perangkat lunak tambahan di komputer pengguna [46]. Google Colab menyediakan akses ke sumber daya komputasi seperti CPU, GPU, dan TPU yang dapat dimanfaatkan untuk pengolahan data, pelatihan model *machine learning*, serta eksperimen komputasi lainnya [46] [57].

Google Colab terintegrasi dengan Google Drive sehingga memudahkan penyimpanan dan pengelolaan dataset maupun hasil eksperimen [46]. Selain itu, Colab menggunakan konsep notebook yang sejalan dengan *Jupyter Notebook* sebagai format kerja komputasi interaktif yang mendukung dokumentasi, eksekusi kode, dan reproduksibilitas eksperimen [47] [58]. Dengan kemudahan akses, fleksibilitas, dan dukungan komputasi yang memadai, Google Colab banyak digunakan dalam penelitian dan pengembangan sistem berbasis kecerdasan buatan [46] [59].

2.2.11 React Native

React Native merupakan *framework* berbasis JavaScript yang digunakan untuk membangun aplikasi mobile pada platform Android dan iOS. Dengan React Native, proses pengembangan aplikasi dapat dilakukan lebih efisien karena satu basis kode dapat digunakan untuk beberapa platform [67]. Framework ini juga didukung oleh Expo sehingga proses pengujian tampilan dan fungsi aplikasi dapat dilakukan secara lebih cepat selama tahap pengembangan [67].

Pada pengembangan aplikasi mobile, React Native digunakan untuk membangun antarmuka pengguna yang responsif dan mudah digunakan. Framework ini banyak dipilih karena struktur kode yang sederhana, mendukung *cross-platform*, serta dapat mempercepat proses pembuatan aplikasi [68]. Dalam beberapa penelitian, React Native juga telah diterapkan pada aplikasi layanan kesehatan dan aplikasi deteksi penyakit berbasis mobile [68].

Oleh karena itu, React Native dinilai sesuai untuk digunakan dalam pengembangan aplikasi mobile karena dapat mendukung pembuatan tampilan, navigasi, dan fitur aplikasi secara lebih praktis. Selain itu, penggunaan React Native juga dapat membantu pengembang dalam membuat aplikasi yang dapat berjalan pada perangkat Android dengan proses pengembangan yang lebih efisien [67], [69].

2.2.12 Pandas

Pandas merupakan library *open-source* yang digunakan dalam bahasa pemrograman Python untuk proses pengolahan dan analisis data. Pada Pandas, struktur data seperti *DataFrame* dan *Series* telah disediakan agar data dalam bentuk tabel dapat dikelola dengan lebih mudah [70]. Selain itu, Pandas dapat digunakan untuk membaca, menggabungkan, menyaring, mengurutkan, serta memanipulasi data sesuai dengan kebutuhan analisis [71].

Dalam penelitian berbasis data, Pandas dapat dimanfaatkan pada tahap pra-pemrosesan sebelum model *machine learning* dibuat. Data yang berasal dari file CSV atau Excel dapat dibaca dan diubah ke dalam bentuk *DataFrame* sehingga proses pembersihan, pengelompokan, dan analisis data dapat dilakukan secara lebih terstruktur [71], [72]. Selain itu, Pandas juga dapat digunakan untuk pengolahan data skala kecil hingga menengah karena operasi pada data tabular didukung secara fleksibel.

2.2.13 Heatmap

Heatmap merupakan bentuk visualisasi data yang digunakan untuk menampilkan nilai atau hubungan antarvariabel melalui gradasi warna. Pada visualisasi ini, warna digunakan untuk menunjukkan besar kecilnya nilai sehingga pola data dapat lebih mudah diamati [73]. *Heatmap* juga dapat digunakan untuk menampilkan tingkat korelasi antarvariabel dalam sebuah dataset [73].

Dalam penelitian berbasis data, *heatmap* dapat dimanfaatkan untuk membantu proses analisis hubungan antarfitur. Nilai korelasi yang ditampilkan pada *heatmap* dapat menunjukkan arah dan kekuatan hubungan antarvariabel, misalnya korelasi positif, korelasi negatif, atau hubungan yang lemah [74]. Dengan visualisasi tersebut, fitur yang memiliki hubungan kuat dengan variabel lain dapat diidentifikasi secara lebih mudah.

2.2.14 Expo Go

Expo Go merupakan aplikasi pendukung yang digunakan dalam proses pengembangan aplikasi mobile berbasis React Native dengan framework Expo. Melalui Expo Go, pengembang dapat menguji dan melihat tampilan aplikasi secara langsung pada perangkat mobile, sehingga proses pemeriksaan antarmuka dan fungsi aplikasi dapat dilakukan dengan lebih praktis [75]. Proyek Expo yang dijalankan melalui *development server* akan menampilkan QR Code yang dapat dipindai pada perangkat mobile untuk membuka aplikasi. Selain itu, perubahan kode dapat dimuat kembali secara otomatis sehingga pengembang dapat melihat hasil perubahan selama proses pengembangan [76].

2.2.15 Seaborn

Seaborn merupakan pustaka visualisasi data pada bahasa pemrograman Python yang dibangun di atas *Matplotlib* dan digunakan untuk menampilkan grafik statistik secara lebih informatif dan mudah dipahami. Seaborn menyediakan

antarmuka tingkat tinggi yang memungkinkan data dianalisis dan divisualisasikan dalam bentuk grafik seperti *heatmap*, distribusi data, serta hubungan antarvariabel sehingga mempermudah proses interpretasi hasil analisis [48]. Dalam penelitian berbasis data, Seaborn banyak dimanfaatkan untuk proses eksplorasi data dan penyajian hasil model karena mampu mengubah data numerik menjadi visualisasi yang lebih jelas. Visualisasi ini membantu peneliti memahami pola serta kesalahan prediksi model, misalnya pada tampilan *confusion matrix* [49].

2.2.16 Joblib

Joblib merupakan *library* Python yang dapat digunakan untuk menyimpan dan memuat kembali model *machine learning* yang telah melalui proses pelatihan. Penyimpanan model memungkinkan sistem menggunakan model terbaik pada tahap implementasi tanpa perlu mengulangi proses pelatihan setiap kali prediksi dilakukan. Dalam penelitian ini, Joblib digunakan untuk menyimpan model klasifikasi terbaik agar model dapat diintegrasikan ke dalam aplikasi dan digunakan kembali dalam menghasilkan prediksi. Penggunaan Joblib tersebut mendukung proses penerapan model menjadi lebih praktis dan efisien [77].

2.2.17 MySQL

MySQL merupakan sistem manajemen basis data relasional yang

digunakan untuk menyimpan dan mengelola data secara terstruktur. MySQL mendukung penggunaan bahasa SQL (*Structured Query Language*) untuk menjalankan operasi dasar pengolahan data, seperti menambahkan, menampilkan, memperbarui, dan menghapus data. Pada penelitian ini, MySQL digunakan untuk menyimpan data pengguna serta riwayat hasil skrining pada aplikasi. Penggunaan MySQL membantu sistem dalam mengelola data secara terorganisasi dan menampilkan kembali informasi yang dibutuhkan oleh pengguna. Hal ini sejalan dengan penelitian Dachi dan Suhada yang menunjukkan bahwa MySQL mampu menjalankan operasi *Create, Read, Update,* dan *Delete* (CRUD) secara efektif serta tetap menjaga konsistensi data [78].

2.2.18 Visual Studio Code

Visual Studio Code (VS Code) merupakan perangkat lunak editor kode yang banyak digunakan sebagai lingkungan pengembangan (*development environment*) untuk menulis dan mengelola program. Pada penelitian di bidang sistem informasi, VS Code dijelaskan sebagai editor yang ringan namun andal serta mendukung berbagai bahasa pemrograman, seperti HTML, CSS, JavaScript, PHP, dan Python, sehingga memudahkan proses pengembangan aplikasi [50]**.** Dukungan lintas platform (Windows, Linux, dan macOS) serta fitur seperti penyorotan sintaks, saran penulisan kode (*auto-completion*), dan pengaturan format kode juga membantu meningkatkan efisiensi dalam penulisan program [51]**.**

Selain digunakan sebagai editor, VS Code juga sering dimanfaatkan dalam kegiatan pembelajaran dan praktik pemrograman karena menyediakan fasilitas yang mendukung proses pengujian serta penelusuran kesalahan (*debugging*). Dalam laporan pengalaman penggunaan VS Code untuk pembelajaran pemrograman, VS Code disebut memiliki fitur *linting*, *testing*, dan *debugging* yang membantu pengguna menemukan kesalahan dan memperbaiki kode secara lebih cepat [52]**.** Pada pengembangan berbasis *machine learning*, VS Code juga dapat diperluas melalui ekstensi (*extension*) untuk memenuhi kebutuhan tertentu. Hal ini terlihat pada penelitian yang mengembangkan ekstensi VS Code untuk membantu pendeskripsian dataset, yang menunjukkan bahwa VS Code mendukung penambahan fitur melalui ekosistem ekstensi sesuai kebutuhan pengembangan [53]**.** Dengan demikian, VS Code relevan digunakan sebagai alat pengembangan karena mendukung penulisan kode, pengujian, *debugging*, serta penambahan fitur melalui ekstensi.

2.2.19 Scikit-learn

Scikit-learn merupakan pustaka (*library*) *machine learning* pada Python yang menyediakan berbagai algoritma dan komponen pendukung untuk membangun model prediksi, baik untuk klasifikasi maupun regresi. Wang *et al.* (2024) menjelaskan bahwa scikit-learn banyak digunakan karena menawarkan koleksi algoritma yang luas, antarmuka yang seragam, serta kemudahan penerapan sehingga cocok untuk kebutuhan eksperimen dan pengembangan

model pada beragam kasus prediksi [54]**.** Dalam penelitian klasifikasi, scikit-learn sering dipakai karena mendukung alur kerja pemodelan secara lengkap, mulai dari penyiapan dan pengolahan data, pelatihan model, hingga pengujian dan evaluasi. (2024) menunjukkan pemanfaatan scikit-learn untuk mengimplementasikan serta mengevaluasi model klasifikasi menggunakan metrik seperti akurasi, precision, recall, dan F1-score untuk menilai kualitas prediksi [55]**.**

Selain akurasi, penilaian performa klasifikasi umumnya membutuhkan metrik tambahan, terutama ketika data terdiri dari banyak kelas. Helmiyah dan Pramestiawan (2025) menegaskan pentingnya penggunaan precision, recall, dan F1-score serta *confusion matrix* untuk memetakan kesalahan prediksi pada tiap kelas, sehingga analisis kinerja model dapat dilakukan lebih rinci, termasuk melihat kelas yang paling sering tertukar [56]**.**

2.2.20 Matplotlib

Matplotlib merupakan pustaka (*library*) visualisasi pada Python yang digunakan untuk menyajikan data dalam bentuk grafik, seperti grafik garis, diagram batang, histogram, dan *scatter plot*, sehingga informasi yang terkandung dalam data lebih mudah dipahami dan dianalisis [60]**.** Matplotlib banyak dimanfaatkan dalam proses analisis data karena mampu membantu peneliti melihat pola, tren, dan perbandingan nilai secara visual, yang sering kali sulit ditangkap apabila hanya disajikan dalam bentuk tabel [60]**.** Dalam penerapannya, Matplotlib digunakan untuk menampilkan hasil pengolahan data atau ringkasan

analisis ke dalam bentuk visual yang informatif. Contohnya, pada penelitian visualisasi data harga saham, Matplotlib digunakan untuk membangun berbagai jenis grafik (garis, batang, dan sebar) sebagai media penyajian hasil analisis agar lebih mudah ditafsirkan [61]**.** Selain visualisasi eksploratif, Matplotlib juga relevan untuk menyajikan hasil pemodelan atau evaluasi, karena grafik dapat membantu menjelaskan temuan secara lebih jelas dan komunikatif dalam laporan penelitian [62]**.**

2.2.21 Evaluasi Model Klasifikasi

Evaluasi model klasifikasi multi-class merupakan tahapan untuk menilai kinerja model pembelajaran mesin dalam mengelompokkan data ke dalam lebih dari dua kategori kelas. Berbeda dengan klasifikasi biner yang hanya membedakan dua kondisi, pada kasus multi-class model harus menentukan satu label yang paling sesuai dari beberapa kemungkinan kelas. Oleh karena itu, penilaian kinerja model tidak cukup hanya melihat jumlah prediksi yang benar secara keseluruhan, tetapi juga perlu mempertimbangkan kemampuan model dalam mengenali setiap kelas secara proporsional dan seimbang [63]. Pada penelitian ini, data memiliki tiga label keluaran sehingga digunakan confusion matrix multiclass sebagai dasar evaluasi untuk menghitung nilai akurasi, presisi, dan recall berdasarkan confusion matrix multiclass tersebut [64].

1. Average Accuracy

   Average accuracy Adalah rata-rata nilai akurasi yang dihitung untuk setiap

kelas pada klasifikasi multi-class. Pada metode ini, akurasi dihitung terlebih dahulu untuk masing-masing kelas, kemudian dirata-ratakan [64].

Rumus:

$$average\ accuracy = \frac{1}{N}\sum_{i=1}^{N}\left(\frac{TP_i + TN_i}{TP_i + TN_i + FP_i + FN_i}\right) \quad (2.19)$$

Average accuracy digunakan untuk memberikan gambaran umum kinerja model dalam mengklasifikasikan seluruh kelas.

2. Weighted precision

Weighted precision adalah rata-rata precision dari seluruh kelas dengan mempertimbangkan jumlah data pada masing-masing kelas [64].

Rumus:

$$Weighted\ Precsision = \frac{\sum_{i=1}^{N} Precision_i \times Number_i}{\sum_{i=1}^{N} Number_i} \quad (2.20)$$

Metrik ini digunakan untuk memberikan hasil yang lebih representatif Ketika jumlah data antar kelas tidak seimbang.

3. Weighted Recall

Weighted recall adalah rata-rata recall dari seluruh kelas dengan memperhitungkan jumlah data tiap kelas [64].

$$Weighted\ Recall = \frac{\sum_{i=1}^{N} Recall_i \times Number_i}{\sum_{i=1}^{N} Number_i} \quad (2.21)$$

4. Precision

   Precision adalah ukuran ketepatan model dalam memprediksi suatu kelas. Precision menunjukkan seberapa banyak prediksi pada kelas tersebut yang benar [64].

$$Precision_i = \frac{TP_i}{TP_i + FP_i} \tag{13}$$

5. Recall

   Recall adalah ukuran kemampuan model dalam menemukan seluruh data yang benar-benar termasuk dalam suatu kelas [64].

$$Recall_i = \frac{TP_i}{TP_i + FN_i} \tag{14}$$

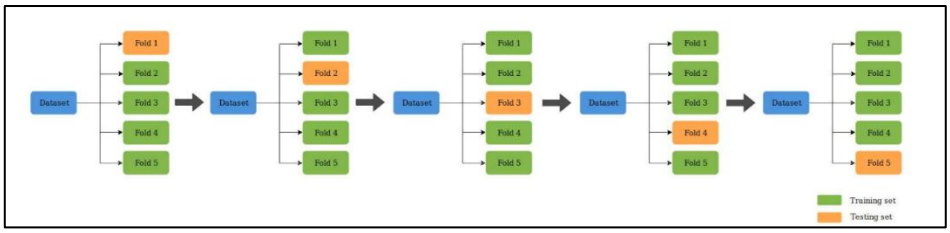
Keterangan simbol pada perhitungan evaluasi klasifikasi multi-class dapat dijelaskan sebagai berikut. Simbol N menyatakan jumlah keseluruhan kelas atau label yang terdapat dalam model klasifikasi. Notasi i menunjukkan indeks kelas ke-i yang sedang dihitung pada proses evaluasi. Simbol ∑ (sigma) digunakan untuk menyatakan operasi penjumlahan yang dilakukan dari kelas pertama hingga kelas ke-N. Nilai TP_i (True Positive) menunjukkan jumlah data pada kelas ke-i yang berhasil diprediksi dengan benar oleh model. Sebaliknya, TN_i (True Negative) merupakan jumlah data yang bukan termasuk kelas ke-i dan juga diprediksi dengan benar sebagai bukan kelas tersebut.

Sementara itu, FP_i (False Positive) menyatakan jumlah data yang sebenarnya tidak termasuk kelas ke-i, tetapi oleh model diprediksi sebagai kelas tersebut. Adapun FN_i (False Negative) adalah jumlah data yang seharusnya termasuk kelas ke-i, namun diprediksi sebagai kelas lain. Nilai Precision_i merepresentasikan tingkat ketepatan prediksi model pada kelas ke-i, sedangkan Recall_i menunjukkan kemampuan model dalam mengenali seluruh data yang benar-benar termasuk dalam kelas tersebut. Terakhir, Number_i (support) menyatakan jumlah data aktual yang terdapat pada kelas ke-i dan digunakan sebagai bobot dalam perhitungan metrik evaluasi berbasis weighted.

2.2.22 K – Fold Cross Validation

K-Fold Cross Validation adalah salah satu metode yang digunakan untuk mengevaluasi kinerja model agar hasil pengujiannya lebih objektif dan tidak hanya bergantung pada satu kali pembagian data. Pada metode ini, dataset dibagi menjadi beberapa bagian yang disebut *fold*. Setiap bagian kemudian digunakan secara bergantian sebagai data uji, sementara bagian lainnya dipakai sebagai data latih. Dengan cara ini, proses evaluasi dilakukan berulang pada susunan data yang berbeda, sehingga hasil yang diperoleh cenderung lebih stabil dan dapat memberikan gambaran yang lebih baik terhadap kemampuan model dalam memprediksi data baru [1], [2]. Metode ini cukup sering digunakan karena mampu memberikan keseimbangan antara ketelitian evaluasi dan efisiensi proses komputasi. Dibandingkan beberapa teknik validasi lain, K-Fold Cross Validation

dinilai lebih praktis untuk diterapkan dan tetap mampu menghasilkan penilaian performa yang baik. Selain itu, metode ini juga membantu mengurangi kemungkinan hasil evaluasi yang terlalu tinggi atau terlalu rendah akibat pembagian data yang kurang representatif [67], [68].



Gambar 2. 6 5 - Fold Validation

Sebagai contoh, pada 5-Fold Cross Validation, dataset dibagi menjadi lima bagian. Pada tahap pertama, satu bagian digunakan sebagai data pengujian dan empat bagian lainnya digunakan untuk melatih model. Setelah itu, bagian yang menjadi data uji akan diganti dengan bagian lain secara bergantian hingga semua bagian pernah digunakan untuk pengujian. Proses ini membuat setiap data memiliki kesempatan yang sama untuk ikut dalam tahap evaluasi, sehingga hasil pengujian model menjadi lebih adil, lebih menyeluruh, dan lebih dapat dipercaya [67].

2.2.23 User Acceptance Test (UAT)

User Acceptance Test (UAT) merupakan tahap pengujian yang melibatkan pengguna akhir untuk memastikan sistem yang dibangun sudah sesuai dengan kebutuhan serta dapat digunakan dengan baik pada situasi nyata. Pada tahap ini,

pengguna mencoba fitur-fitur utama sistem dan memberikan penilaian terkait kesesuaian fungsi, kemudahan penggunaan, serta kejelasan informasi yang dihasilkan [65]. UAT dilakukan untuk memverifikasi bahwa sistem tidak hanya berjalan secara teknis, tetapi juga memenuhi kebutuhan operasional pengguna. Masukan yang diperoleh dari pengguna digunakan sebagai dasar perbaikan dan penyempurnaan sebelum sistem diterapkan secara lebih luas. Dengan demikian, UAT menjadi langkah penting untuk memastikan sistem dapat diterima dan dimanfaatkan secara efektif oleh pengguna [66].

BAB III

RANCANGAN DAN PEMBUATAN

3.1 Rancangan Sistem

Rancangan sistem yang dikembangkan dalam penelitian ini berfokus pada pembangunan sistem klasifikasi status tumbuh kembang dan gizi balita berbasis *machine learning*. Sistem ini mendukung proses skrining awal pertumbuhan dan gizi balita secara lebih cepat dan konsisten. Sistem juga membantu tenaga kesehatan maupun pihak terkait dalam menentukan kategori kondisi balita berdasarkan data balita dan pengukuran antropometri. Melalui pemrosesan data secara terstruktur, sistem diharapkan dapat menghasilkan informasi klasifikasi yang lebih objektif sebagai pendukung pemantauan di layanan kesehatan.

Arsitektur sistem terdiri atas beberapa tahapan yang saling berkaitan. Pada tahap pertama, penelitian ini menggunakan dataset *Stunting and Nutritional Status of Toddler from Jeneponto Regency, South Sulawesi, Indonesia* yang diperoleh dari repositori Mendeley Data [9]. Dataset tersebut memuat data balita, data pengukuran antropometri, serta label status pertumbuhan dan gizi yang mengacu pada indikator antropometri. Tahap berikutnya mencakup proses pra-pemrosesan data, yaitu pemeriksaan dan penghapusan data duplikat, pembersihan nilai kosong (*missing value*), seleksi variabel, penyesuaian format tanggal, serta pengkodean variabel kategori agar data dapat digunakan dalam proses pemodelan.

Penelitian ini menggunakan enam variabel masukan dalam proses pemodelan, yaitu jenis kelamin, tanggal lahir, tanggal pengukuran, usia dalam bulan, berat badan, dan tinggi badan. Pada tahap pengolahan, sistem mengodekan variabel jenis kelamin menjadi *gender_enc*, sedangkan sistem mengonversi tanggal lahir dan tanggal pengukuran ke dalam format numerik agar dapat diproses oleh model. Sistem menggunakan tiga target klasifikasi, yaitu *Weight-for-Age* (W/A), *Height-for-Age* (H/A), dan *Weight-for-Height* (W/H).

Setelah menyiapkan data, penelitian ini membagi dataset menjadi data latih dan data uji agar proses pelatihan dan evaluasi model dapat dilakukan secara objektif. Selanjutnya, penelitian ini melatih model menggunakan algoritma *Light Gradient Boosting Machine* (LightGBM) dan *Extreme Gradient Boosting* (XGBoost). Kedua algoritma tersebut mempelajari hubungan antara variabel masukan dan label keluaran pada setiap indikator. Karena setiap indikator memiliki kategori kelas yang berbeda, penelitian ini membangun model W/A, model H/A, dan model W/H secara terpisah.

Pada indikator W/A, sistem menghasilkan kategori *Normal*, *Underfed*, *Malnutrition*, dan *Overnutrition*. Pada indikator H/A, sistem menghasilkan kategori *Stunted* dan *Not Stunted*. Sementara itu, pada indikator W/H, sistem menghasilkan kategori *Normal*, *Thin*, *Very Thin*, dan *Obese*. Setelah model terbentuk, sistem menggunakan model terbaik untuk memproses data balita baru dan menampilkan hasil klasifikasi pada aplikasi.

Tahap akhir mencakup evaluasi performa model untuk menilai kualitas hasil prediksi. Penelitian ini mengukur kinerja model menggunakan metrik *accuracy*, *precision*, *recall*, dan *F1-score*. Penelitian ini juga menggunakan *confusion matrix* untuk melihat pola prediksi benar dan salah pada setiap kelas, serta analisis *feature importance* untuk mengetahui variabel yang paling berpengaruh terhadap hasil klasifikasi. Seluruh rangkaian proses tersebut diimplementasikan menggunakan bahasa pemrograman Python dengan dukungan pustaka analisis data dan *machine learning*. Dengan rancangan tersebut, sistem diharapkan dapat menjadi alat bantu skrining awal status tumbuh kembang dan gizi balita yang memberikan hasil secara lebih cepat, konsisten, dan mudah dipahami.

3.1.1 Perencanaan Sistem

Perencanaan sistem merupakan tahap awal yang penting dalam pengembangan sistem klasifikasi status pertumbuhan balita berbasis machine learning. Tahap ini disusun untuk memastikan seluruh komponen sistem dirancang secara sistematis dan dapat bekerja saling mendukung, sehingga keluaran klasifikasi yang dihasilkan memiliki tingkat ketepatan yang baik, konsisten, serta mudah dipahami oleh pengguna, khususnya tenaga kesehatan. Sistem ini dirancang sebagai alat bantu skrining yang memanfaatkan data antropometri balita untuk menentukan status pertumbuhan berdasarkan acuan standar WHO.

Tahapan perencanaan dimulai dari pengumpulan dan penyiapan dataset. Data penelitian bersumber dari dataset Stunting and Nutritional Status of Toddler from Jeneponto Regency, South Sulawesi, Indonesia yang tersedia pada repositori Mendeley [9]. Dataset tersebut memuat informasi pendukung pencatatan, seperti identitas, lokasi layanan kesehatan, dan waktu pengukuran, serta data antropometri dan label status pertumbuhan balita. Setelah data diperoleh, dilakukan preprocessing yang meliputi penghapusan data duplikat, pembersihan nilai kosong (missing value), serta pemilihan variabel yang digunakan dalam pemodelan. Pada penelitian ini, variabel masukan dibatasi hanya pada tiga variabel utama, yaitu usia (Age/Month), berat badan (Weight), dan tinggi badan (Height), sehingga proses pelatihan model berfokus pada data antropometri yang paling relevan.

Setelah tahap pembersihan dan seleksi data, dataset dibagi menjadi data latih dan data uji agar pengujian model dapat dilakukan secara objektif. Tahap berikutnya adalah pelatihan model klasifikasi menggunakan Light Gradient Boosting Machine (LightGBM) dan Extreme Gradient Boosting (XGBoost) sebagai metode klasifikasi. Kedua algoritma tersebut digunakan untuk mempelajari pola hubungan antara variabel input dengan target keluaran yang digunakan dalam penelitian, yaitu Weight for Age, Height for Age, dan Weight for Height. Model yang terbentuk selanjutnya dimanfaatkan untuk melakukan prediksi terhadap data balita baru yang dimasukkan ke sistem.

Kinerja model yang dihasilkan kemudian dievaluasi menggunakan beberapa metrik, yaitu *Accuracy*, *Precision*, *Recall*, dan *F1-Score*, serta dilengkapi dengan *confusion matrix* untuk melihat pola kesalahan klasifikasi pada tiap kelas. Hasil evaluasi ini digunakan untuk menilai sejauh mana kemampuan model dalam mengklasifikasikan status pertumbuhan balita secara tepat.

Selanjutnya, sistem diimplementasikan dalam bentuk aplikasi berbasis mobile sebagai antarmuka pengguna. Melalui antarmuka ini, pengguna dapat memasukkan data usia, berat badan, dan tinggi badan, kemudian sistem memproses input tersebut dan menampilkan hasil klasifikasi secara langsung. Rancangan ini dibuat agar proses skrining dapat dilakukan dengan lebih praktis dan cepat.

Sebagai bagian akhir dari perencanaan, dilakukan pengujian dan validasi sistem. Pengujian fungsional dilakukan untuk memastikan seluruh fitur berjalan sesuai rancangan, mulai dari proses input, pemrosesan data, hingga penampilan hasil. Selain itu, sistem juga direncanakan untuk divalidasi melalui User Acceptance Test (UAT) dengan melibatkan tenaga kesehatan agar dapat dinilai dari sisi kemudahan penggunaan, kejelasan informasi, serta kesesuaian keluaran dengan kebutuhan skrining di lapangan. Masukan yang diperoleh pada tahap ini digunakan sebagai dasar penyempurnaan sistem sebelum diimplementasikan lebih lanjut.

3.1.2 Analisis Sistem

Tahapan analisis sistem adalah bagian penting untuk menjabarkan secara rinci perangkat keras dan perangkat lunak yang digunakan dalam pengembangan sistem klasifikasi status tumbuh kembang anak dan gizi balita berbasis *machine learning*. Analisis ini dilakukan agar kebutuhan teknis sistem dapat diketahui dengan jelas, potensi kendala selama pengembangan dapat diantisipasi, serta proses implementasi dan pengujian berjalan lebih terarah. Berikut adalah spesifikasi perangkat keras yang digunakan dalam perancangan sistem:

1. CPU : Intel® Core™ i3-1005G1 @ 1.20 GHz
2. RAM : 8 GB (7.75 GB usable)
3. Tipe Sistem : 64-bit Operating System, x64-based processor

Adapun perangkat lunak yang digunakan dalam perancangan sistem adalah sebagai berikut:

1. Windows 11 (64-bit)
2. Python 3.14.2
3. Google Colab
4. Visual Studio Code
5. Expo Go
6. React Native
7. Scikit-learn, Pandas, NumPy, Matplotlib, Seaborn

3.1.3 Perancangan Sistem

Perancangan sistem dilakukan setelah tahapan perencanaan dan analisis diselesaikan. Pada tahap ini dijelaskan gambaran umum bagaimana sistem klasifikasi status pertumbuhan balita akan dikembangkan, mencakup rancangan arsitektur sistem, alur pengolahan data dari input hingga keluaran, serta perancangan antarmuka pengguna yang digunakan untuk memasukkan data antropometri dan menampilkan hasil klasifikasi.

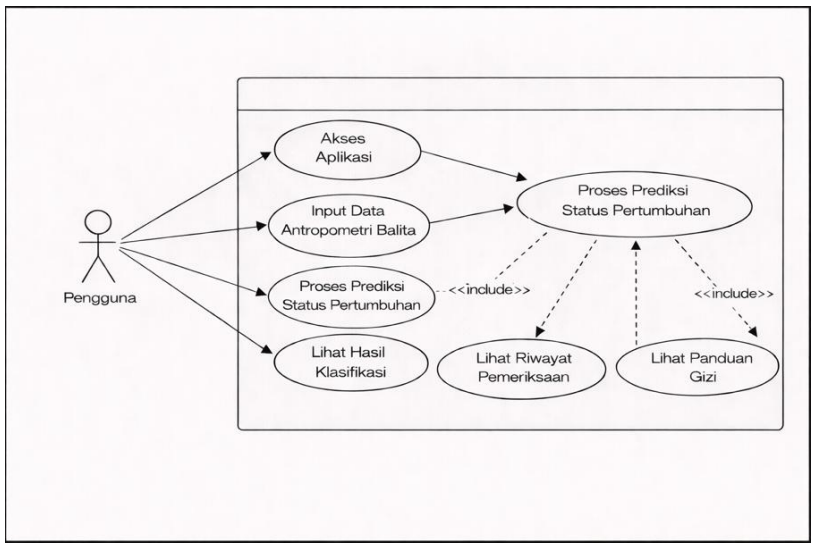
3.1.3.1 Skema Rancangan Sistem

Skema rancangan sistem menjelaskan alur penggunaan aplikasi serta interaksi antara pengguna dan sistem dalam melakukan klasifikasi status tumbuh kembang anak dan gizi balita. Gambar 3.1 menggambarkan proses yang diawali ketika pengguna mengakses aplikasilalu memasukkan data balita dan pengukuran antropometri yang meliputi jenis kelamin, tanggal lahir, tanggal pengukuran, usia (bulan), berat badan (kg), dan tinggi badan (cm). Setelah data dimasukkan, sistem melakukan tahap validasi untuk memastikan seluruh input telah terisi dan sesuai dengan format yang dipersyaratkan.

Apabila hasil validasi menyatakan data benar, sistem melanjutkan ke tahap prediksi dengan memanfaatkan model *machine learning* yang telah dilatih, yaitu LightGBM dan XGBoost, kemudian performanya dianalisis untuk menentukan pendekatan yang paling tepat. Selanjutnya, sistem melakukan klasifikasi

berdasarkan tiga indikator antropometri, yaitu Berat menurut Umur (BB/U), Tinggi menurut Umur (TB/U), dan Berat menurut Tinggi (BB/TB).

Setelah proses prediksi selesai, sistem menampilkan hasil klasifikasi untuk setiap indikator sekaligus memberikan ringkasan kondisi pertumbuhan secara umum. Gambar 3.1 juga menunjukkan bahwa aplikasi menyediakan fitur riwayat pemeriksaan untuk melihat hasil pemeriksaan terdahulu serta menu panduan gizi sebagai informasi edukatif pendukung. Dengan demikian, sistem tidak hanya berfungsi sebagai alat klasifikasi, tetapi juga mendukung pemantauan pertumbuhan dan penyediaan informasi terkait status pertumbuhan balita



Gambar 3. 1 Skema Rancangan Sistem

3.1.3.2 Skema Rancangan Tahap Pelatihan

Rancangan tahap penelitian ini disusun untuk menggambarkan urutan kegiatan pengolahan data hingga pemodelan dan evaluasi dalam

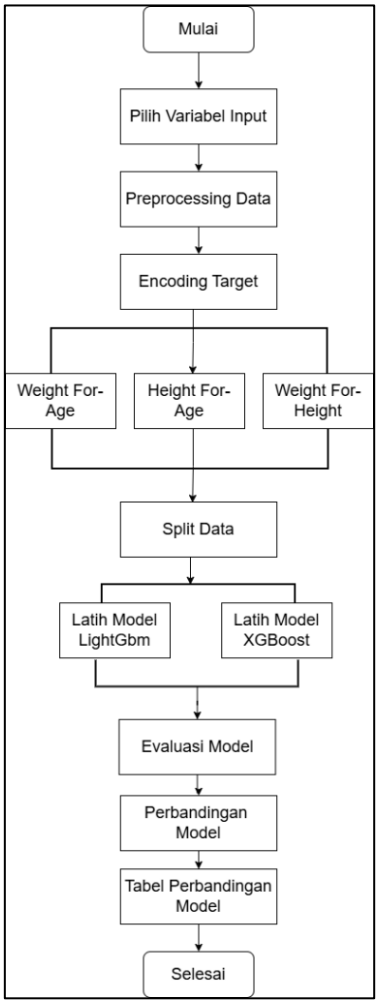
pengembangan sistem klasifikasi status pertumbuhan balita. Gambar 3.2 menunjukkan alur penelitian yang dimulai dari pemilihan variabel input, dilanjutkan dengan pra-pemrosesan data, penyiapan target, pembagian data, pelatihan model, evaluasi, sampai penyusunan perbandingan performa model.

Berdasarkan Gambar 3.2, tahap awal penelitian adalah menentukan variabel yang digunakan sebagai masukan, yaitu tiga data antropometri utama: usia (age_month) dalam bulan, berat badan (weight) dalam kilogram, dan tinggi badan (height) dalam sentimeter. Pemilihan ketiga variabel tersebut didasari pertimbangan bahwa data tersebut umumnya tersedia pada pemeriksaan balita serta menjadi komponen penting dalam pembentukan indikator antropometri yang dijadikan keluaran model.

Setelah variabel input ditetapkan, dataset diproses melalui tahap pra-pemrosesan (preprocessing) agar siap digunakan dalam pelatihan model. Tahap ini mencakup pengecekan dan perapihan data, seperti mengidentifikasi serta menghapus data duplikat (duplicate), menangani nilai kosong (missing value), dan memastikan seluruh atribut tersaji konsisten dalam format numerik. Data yang sudah dibersihkan kemudian digunakan sebagai dataset akhir untuk proses pemodelan. Pada tahap ini pula, sesuai Gambar 3.2, penelitian menyiapkan variabel target berdasarkan tiga indeks antropometri yang dianalisis, yaitu Weight-for-Age (W/A) atau BB/U, Height-for-Age (H/A) atau TB/U, serta Weight-for-Height (W/H) atau BB/TB. Karena target berbentuk kategori kelas, dilakukan proses encoding pada label target agar dapat diproses oleh algoritma klasifikasi.

Tahap berikutnya pada Gambar 3.2 adalah pembagian data (split data) menjadi data latih dan data uji. Pembagian ini bertujuan agar model dapat dievaluasi menggunakan data yang tidak digunakan saat pelatihan. Proporsi yang diterapkan adalah 80% sebagai data latih dan 20% sebagai data uji. Data latih digunakan untuk membangun model, sedangkan data uji digunakan untuk mengukur kemampuan model dalam melakukan prediksi pada data baru.

Selanjutnya, sebagaimana ditunjukkan pada Gambar 3.2, proses pelatihan dilakukan menggunakan dua algoritma, yaitu Light Gradient Boosting Machine (LightGBM) dan Extreme Gradient Boosting (XGBoost). Kedua algoritma tersebut merupakan metode boosting berbasis pohon keputusan yang dikenal efektif untuk data tabular, termasuk dalam klasifikasi multi-kelas. Setelah kedua model terbentuk, data uji dimasukkan untuk menghasilkan prediksi kelas. Kinerja prediksi kemudian dievaluasi menggunakan confusion matrix untuk melihat pola kesalahan klasifikasi, serta metrik accuracy, precision, recall, dan F1-score agar penilaian performa lebih menyeluruh.



Gambar 3. 2 Skema Rancangan Tahap Pelatihan

Tahap akhir pada Gambar 3.2 adalah membandingkan performa kedua model dan merangkum hasilnya dalam tabel perbandingan. Ringkasan tersebut digunakan untuk menentukan model yang paling sesuai sebagai dasar implementasi pada sistem klasifikasi status tumbuh kembang anak dan gizi balita.

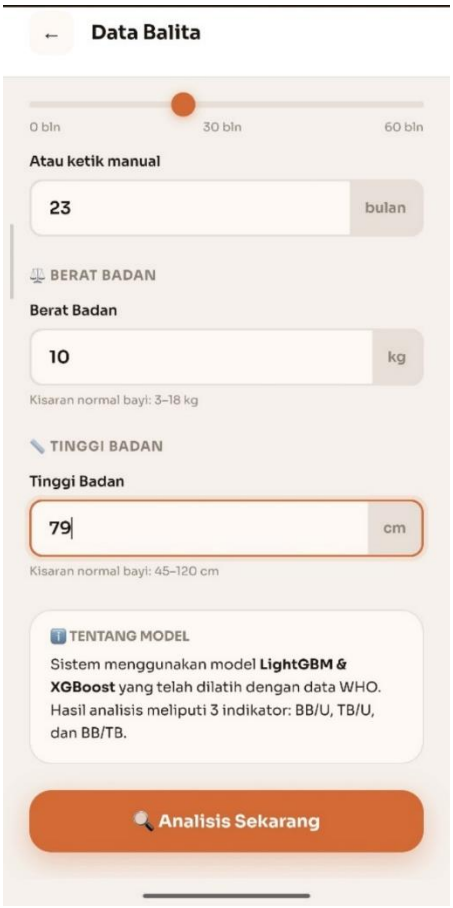
3.1.3.3 Rancangan Antarmuka

Rancangan antarmuka pada perancangan ini dirancang agar pengguna dapat menjalankan aplikasi GrowSmart Health secara mudah, jelas, dan terarah saat memeriksa status pertumbuhan balita. Alur penggunaan aplikasi diawali dari halaman beranda yang ditampilkan pada Gambar 3.3. Pada halaman ini pengguna dapat langsung menekan tombol “Mulai Pemeriksaan” untuk memulai proses deteksi. Beranda juga menampilkan ringkasan statistik pemeriksaan, seperti Total Cek, jumlah hasil Normal, dan Perlu Perhatian, serta menyediakan menu cepat menuju fitur Deteksi Gizi dan Riwayat. Untuk memudahkan perpindahan antarhalaman, navigasi tab (Beranda, Deteksi, Riwayat, Panduan) juga tersedia di bagian bawah.



Gambar 3. 3 Tampilan Beranda

Setelah itu, pengguna diarahkan ke halaman Data Balita pada Gambar 3.4 untuk mengisi data antropometri. Pada halaman ini pengguna memasukkan usia (bulan) melalui slider atau input manual, lalu mengisi berat badan (kg) dan tinggi badan (cm). Informasi singkat pada bagian “Tentang Model” menjelaskan bahwa sistem memanfaatkan LightGBM dan XGBoost serta menganalisis tiga indikator (BB/U, TB/U, dan BB/TB). Jika seluruh data sudah terisi, pengguna dapat menjalankan analisis melalui tombol “Analisis Sekarang”.



Gambar 3. 4 Input Data Balita

Hasil pengolahan kemudian ditampilkan pada halaman Hasil Analisis pada Gambar 3.5. Halaman ini menyajikan ringkasan data yang dimasukkan, menampilkan status keseluruhan, serta memberikan hasil klasifikasi untuk masing-masing indikator BB/U, TB/U, dan BB/TB. Agar pengguna memperoleh arahan yang lebih jelas, halaman ini juga dilengkapi bagian Rekomendasi dan tombol Simpan untuk menyimpan hasil, serta Cek Lagi untuk melakukan pemeriksaan ulang.



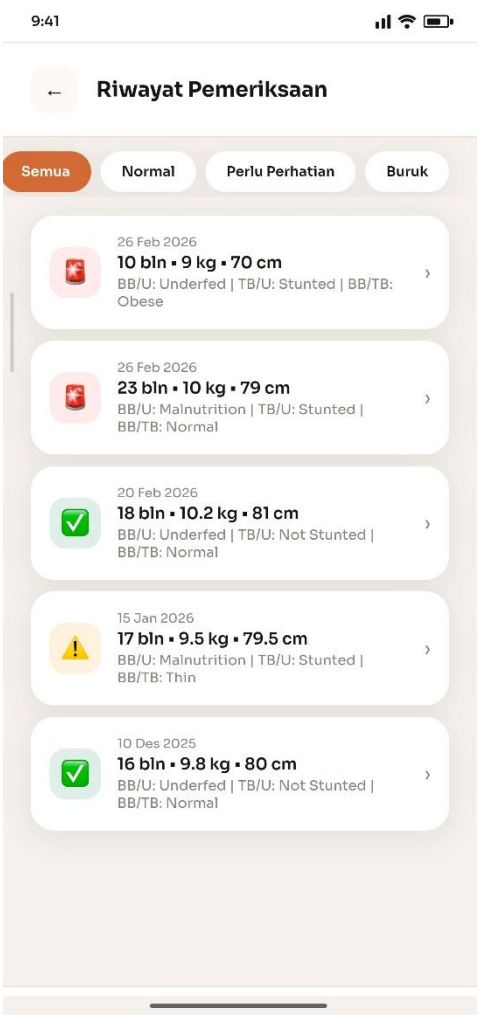
Gambar 3. 5 Hasil Analisis

Selain fitur pemeriksaan, aplikasi juga menyediakan informasi edukatif melalui halaman Panduan Gizi pada Gambar 3.6. Pada halaman ini pengguna dapat membaca penjelasan indikator yang digunakan berdasarkan standar WHO serta memahami makna tiap kategori hasil, sehingga pengguna tidak hanya melihat keluaran, tetapi juga memahami interpretasinya.



Gambar 3. 6 Panduan Gizi

Untuk mendukung pemantauan berkelanjutan, aplikasi menyediakan halaman Riwayat Pemeriksaan pada Gambar 3.7. Halaman ini menampilkan daftar pemeriksaan sebelumnya lengkap dengan tanggal, ringkasan data, dan hasil indikator BB/U, TB/U, dan BB/TB. Fitur filter kategori (misalnya Semua, Normal, Perlu Perhatian, Buruk) juga membantu pengguna menelusuri riwayat pemeriksaan secara lebih cepat dan praktis.



Gambar 3. 7 Riwayat Pemeriksaan

3.2 Dataset

Dataset yang digunakan dalam penelitian ini adalah Stunting and Nutritional Status of Toddler from Jeneponto Regency, South Sulawesi, Indonesia yang diperoleh dari repositori Mendeley Data (https://data.mendeley.com/datasets/wzwpc9j5bx/2) [9] dapat dilihat pada tabel 3.1. Dataset tersebut berisi data balita berusia 0–59 bulan yang berasal dari Kabupaten Jeneponto, Sulawesi Selatan, Indonesia. Data ini digunakan untuk

menggambarkan kondisi pertumbuhan dan status gizi balita berdasarkan hasil pengukuran antropometri.

Tabel 3. 1 Dataset Stunting

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q
1	Gender	Date of Birth	Regency/City	District	Public Health Center (Puskesmas)	Posyandu (Integrated Service Post)	Date of Measurement	Age (Month)	Weight	Height	Weight for Age	Z-Score W/A	Height for Age	Z-Score H/A	Weight for Height	Z-Score W/H	Year
2	F	2017-02-13	JENEPONTO	BONTORAMBA	BONTORAMBA	SAKURA	28/08/2021	54	13.2	97.5	Normal	-1.94	Stunted	-2.11	Normal	-0.95	2021
3	M	2017-12-05	JENEPONTO	TAROWANG	TAROWANG	SARROANGIN	16/08/2021	44	12	92	Normal	-1.92	Stunted	-2.22	Normal	-0.88	2021
4	M	2016-10-20	JENEPONTO	TAMATALATEA	TAMALATEA	Bontorea Kreatif	14/08/2021	57	14	97	Normal	-1.9	Stunted	-2.58	Normal	-0.48	2021
5	M	2019/06/17	JENEPONTO	TAMATALATEA	TAMALATEA	Matbrobaji	19/08/2021	26	11	79	Normal	-1.15	Stunted	-3.11	Normal	0.68	2021
6	F	2016-09-12	JENEPONTO	TAMATALATEA	TAMALATEA	Tunas Mekar	16/08/2021	59	14.6	98	Normal	-1.66	Stunted	-2.49	Normal	-0.18	2021
7	F	2017/10/16	JENEPONTO	BATANG	TOGO TOGO	BONTOSUNGGU	09/08/2021	45	11	90	Underfed	-2.74	Stunted	-2.87	Normal	-1.44	2021
8	M	2016/10/16	JENEPONTO	TAROWANG	TAROWANG	BORONG LOE	23/08/2021	58	14	97.5	Normal	-1.75	Stunted	-2.49	Normal	-0.28	2021
9	M	2017/06/13	JENEPONTO	TAROWANG	TAROWANG	BORONG LOE	23/08/2021	50	14	94.5	Normal	-1.4	Stunted	-2.53	Normal	0.2	2021
10	F	2016/09/17	JENEPONTO	BANGKALA	BANGKALA	BORONG PANDANG	14/08/2021	58	14.2	95.4	Normal	-1.86	Stunted	-3.04	Normal	0.04	2021
11	M	2016-10-29	JENEPONTO	BANGKALA	BANGKALA	BATU NAPARAKALOANG	2021/08/19	57	10	81	Malnutrition	-4.12	Stunted	-5.82	Normal	-0.5	2021
12	M	2017-06-19	JENEPONTO	BATANG	TOGO TOGO	BONTOSUNGGU	2021/08/09	49	11.5	90	Underfed	-2.93	Stunted	-3.52	Normal	-1.28	2021
13	F	2017-02-24	JENEPONTO	BATANG	TOGO TOGO	ULUGALUNG	2021/08/26	54	13.1	97	Underfed	-2.18	Stunted	-2.35	Normal	-1.17	2021
14	F	2018-03-24	JENEPONTO	BATANG	TOGO TOGO	ULUGALUNG	2021/08/26	41	11	86	Underfed	-2.35	Stunted	-3.27	Normal	-0.47	2021
15	M	2018-04-05	JENEPONTO	BATANG	TOGO TOGO	BONTOJANNANG	2021/08/12	40	11.1	89	Underfed	-2.19	Stunted	-2.23	Normal	-1.27	2021
16	M	2018-08-17	JENEPONTO	BATANG	TOGO TOGO	BONTOJANNANG	2021/08/12	35	11.1	84	Underfed	-2.12	Stunted	-3.24	Normal	-0.36	2021
17	M	2018-07-07	JENEPONTO	BATANG	TOGO TOGO	BONTO MANAI	2021/08/09	37	13	88	Normal	-0.92	Stunted	-2.53	Normal	0.74	2021
18	M	2017-08-06	JENEPONTO	BATANG	TOGO TOGO	BALLAPALENG	2021/08/23	48	9.5	86	Malnutrition	-4.21	Stunted	-4.19	Thin	-2.91	2021
19	M	2016-12-10	JENEPONTO	BATANG	TOGO TOGO	SARROANGING	2021/08/21	56	14.7	95	Normal	-1.43	Stunted	-2.88	Normal	0.55	2021

Secara umum, dataset ini terdiri atas 40.071 baris data dengan 17 kolom. Setiap baris data direpresentasikan sebagai satu data balita yang memuat informasi identitas, lokasi pencatatan, waktu pengukuran, data antropometri, serta hasil perhitungan status pertumbuhan dan gizi balita. Variabel yang terdapat dalam dataset meliputi gender, date of birth, regency/city, district, public health center, posyandu, date of measurement, year, age in months, weight, height, weight for age, height for age, dan weight for height. Variabel gender dan date of birth digunakan sebagai informasi identitas dasar balita. Variabel regency/city, district, public health center, dan posyandu digunakan sebagai informasi lokasi pencatatan data. Variabel date of measurement dan year digunakan sebagai informasi waktu pengukuran. Sementara itu, variabel age in months, weight, dan height digunakan sebagai data antropometri utama untuk menggambarkan kondisi pertumbuhan balita.

Dalam penelitian ini, tiga target keluaran digunakan untuk proses klasifikasi, yaitu Weight for Age (W/A/WAZ), Height for Age (H/A/HAZ), dan Weight for Height (W/H/WHZ). Indikator Weight for Age digunakan untuk menilai status berat badan balita berdasarkan umur. Indikator Height for Age digunakan untuk menilai tinggi badan balita berdasarkan umur, terutama untuk melihat kondisi stunting atau gangguan pertumbuhan linear kronis. Sementara itu, indikator Weight for Height digunakan untuk menilai kesesuaian berat badan balita terhadap tinggi badan.

Jumlah kelas pada setiap target keluaran memiliki perbedaan. Pada target Weight for Age (W/A/WAZ), terdapat empat label dataset, yaitu Normal, Underfed, Malnutrition, dan Overnutrition. Label pada target ini disesuaikan dengan istilah interpretasi WHO. Label Malnutrition diinterpretasikan sebagai kategori Severe Underweight, label Underfed diinterpretasikan sebagai kategori Underweight, label Normal tetap diinterpretasikan sebagai Normal, dan label Overnutrition diinterpretasikan sebagai kategori Overweight. Pada target Height for Age (H/A/HAZ), terdapat dua label dataset, yaitu Stunted dan Not Stunted. Label Stunted tetap diinterpretasikan sebagai kategori Stunted dalam istilah WHO, sedangkan label Not Stunted diinterpretasikan sebagai kondisi Normal karena balita pada kategori tersebut tidak termasuk dalam kondisi stunting. Penyesuaian ini didasarkan pada fungsi indikator HAZ dalam panduan WHO yang digunakan untuk menilai tinggi badan anak berdasarkan umur, khususnya dalam melihat status stunting. Pada target Weight for Height (W/H/WHZ), terdapat empat label

dataset, yaitu Normal, Thin, Very Thin, dan Obese. Berdasarkan interpretasi WHO, label Very Thin diinterpretasikan sebagai kondisi sangat kurus, label Thin diinterpretasikan sebagai kondisi kurus, label Normal tetap diinterpretasikan sebagai Normal, dan label Obese diinterpretasikan sebagai kondisi berat badan berlebih berdasarkan tinggi badan. Dengan demikian, 10 kategori kelas dari tiga target keluaran digunakan untuk menggambarkan status pertumbuhan dan gizi balita.

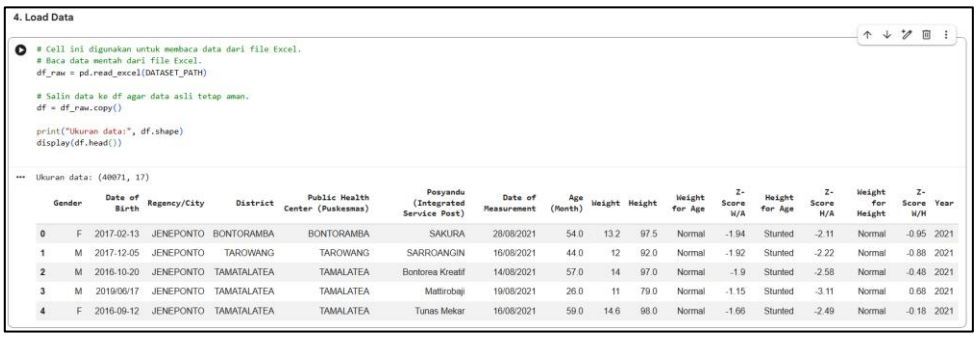
Dalam proses pemodelan *machine learning*, tidak semua variabel dalam dataset digunakan sebagai variabel masukan. Variabel masukan yang digunakan hanya tiga variabel antropometri utama, yaitu Age (Month) sebagai usia balita dalam bulan, Weight sebagai berat badan dalam kilogram, dan Height sebagai tinggi badan dalam sentimeter. Ketiga variabel tersebut digunakan sebagai dasar untuk memprediksi status pertumbuhan dan gizi balita. Sementara itu, variabel lain seperti lokasi pencatatan, waktu pengukuran, dan identitas pendukung tidak digunakan sebagai variabel utama dalam proses pelatihan model.

3.3 Modul Pra-pemrosesan Data

Pada gambar 3.9 menjelaskan tahap Load Data yang dilakukan untuk membaca dataset dari file Excel bernama DATASET_PATNH.xlsx. Pada tahap ini, sistem membaca data menggunakan fungsi pd.read_excel(), kemudian hasil pembacaan data disimpan ke dalam variabel df_raw. Setelah itu, data disalin ke dalam variabel df menggunakan perintah df_raw.copy(). Proses penyalinan ini

dilakukan agar data asli tetap aman dan tidak berubah secara langsung selama proses pengolahan data dilakukan.

Pada Gambar 3.8, ukuran dataset juga ditampilkan menggunakan perintah df.shape. Berdasarkan hasil yang muncul, dataset memiliki jumlah 40.071 baris dan 17 kolom. Selanjutnya, lima data pertama ditampilkan menggunakan perintah display(df.head()) untuk memastikan bahwa data sudah berhasil dimuat dengan benar. Beberapa kolom yang terlihat pada tampilan awal dataset adalah Gender, Date of Birth, Regency/City, District, Public Health Centre, Posyandu, Date of Measurement, Age, Weight, Height, Weight for Age, Z-Score W/A, Height for Age, Z-Score H/A, Weight for Height, Z-Score W/H, dan Year. Data yang sudah dimuat kemudian digunakan sebagai dasar untuk tahap berikutnya, seperti pengecekan data kosong, pemeriksaan data duplikat, penyesuaian format data, dan pemilihan fitur.



4. Load Data

```
# Cell ini digunakan untuk membaca data dari file Excel.
# Baca data mentah dari file Excel.
df_raw = pd.read_excel(DATASET_PATH)

# Salin data ke df agar data asli tetap aman.
df = df_raw.copy()

print("Ukuran data:", df.shape)
display(df.head())
```

```
Ukuran data: (40071, 17)
```

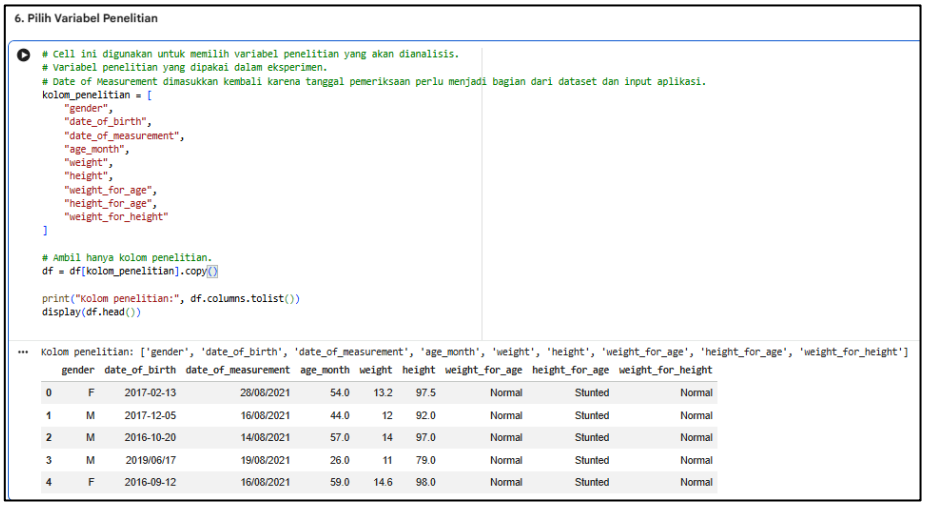
	Gender	Date of Birth	Regency/City	District	Public Health Center (Puskesmas)	Posyandu (Integrated Service Post)	Date of Measurement	Age (Month)	Weight	Height	Weight for Age	Z-Score W/A	Height for Age	Z-Score H/A	Weight for Height	Z-Score W/H	Year
0	F	2017-02-13	JENEPONTO	BONTORAMBA	BONTORAMBA	SAKURA	28/08/2021	54.0	13.2	97.5	Normal	-1.94	Stunted	-2.11	Normal	-0.95	2021
1	M	2017-12-05	JENEPONTO	TAROWANG	TAROWANG	SARROANGIN	16/08/2021	44.0	12	92.0	Normal	-1.92	Stunted	-2.22	Normal	-0.88	2021
2	M	2016-10-20	JENEPONTO	TAMATALATEA	TAMALATEA	Bontorea Kreatif	14/08/2021	57.0	14	97.0	Normal	-1.9	Stunted	-2.58	Normal	-0.48	2021
3	M	2019/06/17	JENEPONTO	TAMATALATEA	TAMALATEA	Mattirobaji	19/08/2021	26.0	11	79.0	Normal	-1.15	Stunted	-3.11	Normal	0.68	2021
4	F	2016-09-12	JENEPONTO	TAMATALATEA	TAMALATEA	Tunas Mekar	16/08/2021	59.0	14.6	98.0	Normal	-1.66	Stunted	-2.49	Normal	-0.18	2021

Gambar 3. 8 Load Dataset

Gambar 3.9 menjelaskan tahap pemilihan variabel penelitian yang digunakan dalam proses analisis data. Pada tahap ini, sistem memilih beberapa kolom yang dianggap relevan dengan kebutuhan penelitian. Pemilihan variabel

dilakukan agar data yang digunakan lebih terarah dan hanya berisi atribut yang diperlukan dalam proses klasifikasi status gizi balita.

Pada Gambar 3.9, variabel penelitian disimpan ke dalam daftar kolom_penelitian. Kolom yang digunakan terdiri dari gender, date_of_birth, date_of_measurement, age_month, weight, height, weight_for_age, height_for_age, dan weight_for_height. Kolom date_of_measurement digunakan karena tanggal pengukuran diperlukan sebagai bagian dari data pemeriksaan dan input pada aplikasi. Setelah variabel penelitian ditentukan, sistem mengambil kolom-kolom tersebut dari dataset utama menggunakan perintah df = df[kolom_penelitian].copy(). Proses ini dilakukan agar dataset hanya berisi variabel yang dibutuhkan dalam penelitian. Selanjutnya, sistem menampilkan daftar kolom penelitian menggunakan perintah print(df.columns.tolist()) dan menampilkan lima data pertama menggunakan display(df.head()). Tampilan ini digunakan untuk memastikan bahwa variabel yang dipilih sudah sesuai sebelum data diproses pada tahap berikutnya.



6. Pilih Variabel Penelitian

```
# Cell ini digunakan untuk memilih variabel penelitian yang akan dianalisis.
# Variabel penelitian yang dipakai dalam eksperimen.
# Date of Measurement dimasukkan kembali karena tanggal pemeriksaan perlu menjadi bagian dari dataset dan input aplikasi.
kolom_penelitian = [
    "gender",
    "date_of_birth",
    "date_of_measurement",
    "age_month",
    "weight",
    "height",
    "weight_for_age",
    "height_for_age",
    "weight_for_height"
]

# Ambil hanya kolom penelitian.
df = df[kolom_penelitian].copy()

print("Kolom penelitian:", df.columns.tolist())
display(df.head())
```

```
Kolom penelitian: ['gender', 'date_of_birth', 'date_of_measurement', 'age_month', 'weight', 'height', 'weight_for_age', 'height_for_age', 'weight_for_height']
```

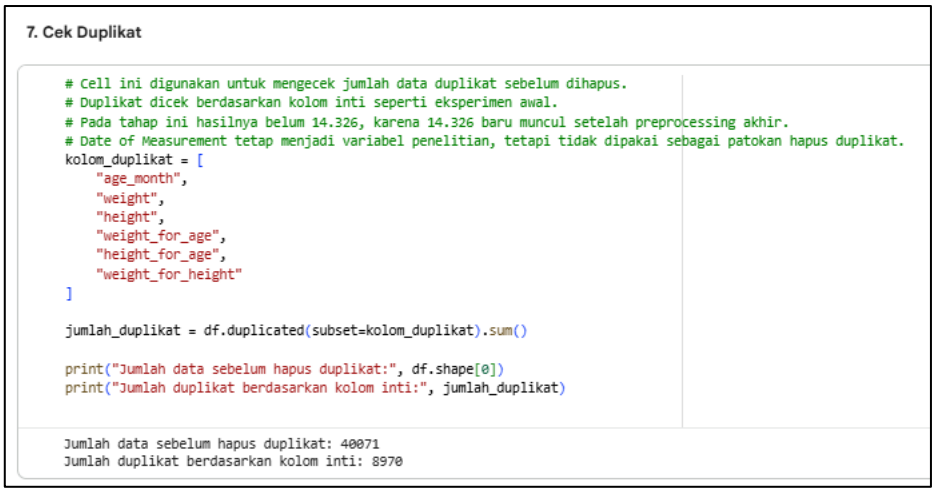
	gender	date_of_birth	date_of_measurement	age_month	weight	height	weight_for_age	height_for_age	weight_for_height
0	F	2017-02-13	28/08/2021	54.0	13.2	97.5	Normal	Stunted	Normal
1	M	2017-12-05	16/08/2021	44.0	12	92.0	Normal	Stunted	Normal
2	M	2016-10-20	14/08/2021	57.0	14	97.0	Normal	Stunted	Normal
3	M	2019/06/17	19/08/2021	26.0	11	79.0	Normal	Stunted	Normal
4	F	2016-09-12	16/08/2021	59.0	14.6	98.0	Normal	Stunted	Normal

Gambar 3. 9 Pilih Variabel Penelitian

Gambar 3.10 menjelaskan proses pengecekan data duplikat yang dilakukan sebelum data duplikat dihapus dari dataset. Pada tahap ini, sistem mengecek data yang memiliki kesamaan nilai berdasarkan beberapa kolom inti. Pengecekan ini dilakukan agar data yang digunakan dalam proses analisis tidak mengandung data berulang yang dapat memengaruhi hasil pengolahan dan pemodelan.

Pada Gambar 3.10, kolom yang dijadikan acuan pengecekan duplikat dimasukkan ke dalam variabel kolom_duplikat. Kolom tersebut meliputi age_month, weight, height, weight_for_age, height_for_age, dan weight_for_height. Sementara itu, kolom date_of_measurement tetap digunakan sebagai variabel penelitian, tetapi tidak digunakan sebagai acuan dalam proses penghapusan data duplikat. Jumlah data duplikat dihitung menggunakan perintah df.duplicated(subset=kolom_duplikat).sum(). Berdasarkan hasil yang ditampilkan, jumlah data sebelum proses penghapusan duplikat adalah 40.071 data. Setelah pengecekan dilakukan berdasarkan kolom inti, jumlah data duplikat yang

ditemukan adalah 8.970 data. Hasil tersebut menunjukkan bahwa sebagian data memiliki nilai yang sama pada kolom utama, sehingga data perlu dibersihkan sebelum masuk ke tahap pengolahan berikutnya.



Gambar 3. 10 Cek duplikat

Gambar 3.11 menjelaskan proses penghapusan data duplikat pada dataset. Pada tahap ini, sistem menghapus data yang memiliki nilai berulang berdasarkan kolom inti penelitian menggunakan perintah df.drop_duplicates(). Setelah data duplikat dihapus, indeks dataset diatur ulang dengan perintah reset_index(drop=True). Berdasarkan hasil yang ditampilkan, jumlah data setelah proses penghapusan duplikat adalah 31.101 data.

8. Hapus Duplikat

```
# Cell ini digunakan untuk menghapus data duplikat berdasarkan kolom inti penelitian.
# Hasil pada tahap hapus duplikat adalah 31.101 baris, bukan 14.326 baris.
# Jumlah 14.326 baris diperoleh setelah tahap preprocessing akhir.
df = df.drop_duplicates(subset=kolom_duplikat).reset_index(drop=True)

print("Jumlah data setelah hapus duplikat:", df.shape[0])
```

```
Jumlah data setelah hapus duplikat: 31101
```

Gambar 3. 11 Hapus Duplikat

Gambar 3.12 menjelaskan tahap pengecekan missing value sebelum proses cleaning dilakukan. Pada tahap ini, sistem menghitung jumlah data kosong pada setiap kolom menggunakan perintah df.isnull().sum(). Selain itu, persentase missing value juga dihitung agar jumlah data kosong dapat dilihat secara lebih jelas. Berdasarkan hasil yang ditampilkan, kolom age_month memiliki 2 missing value dengan persentase 0,01%, sedangkan kolom weight_for_height memiliki 5 missing value dengan persentase 0,02%. Kolom lainnya tidak memiliki missing value.

9. Cek Missing Value Sebelum Cleaning

```
# Cell ini digunakan untuk mengecek missing value sebelum proses cleaning.
# Hitung jumlah dan persentase missing value sebelum cleaning.
missing_sebelum = df.isnull().sum().to_frame("Jumlah")
missing_sebelum["Persentase (%)"] = (missing_sebelum["Jumlah"] / len(df) * 100).round(2)

print("===== Missing Value Sebelum Cleaning =====")
display(missing_sebelum)
```

```
===== Missing Value Sebelum Cleaning =====
```

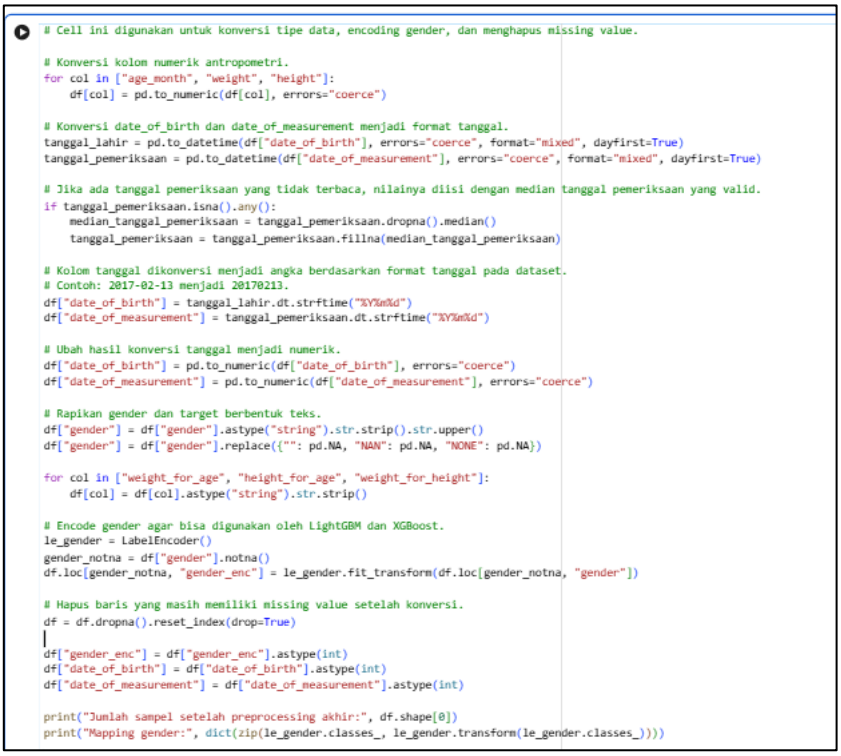
	Jumlah	Persentase (%)
gender	0	0.00
date_of_birth	0	0.00
date_of_measurement	0	0.00
age_month	2	0.01
weight	0	0.00
height	0	0.00
weight_for_age	0	0.00
height_for_age	0	0.00
weight_for_height	5	0.02

Gambar 3. 12 Cek Missing Value Sebelum Cleaning

Gambar 3.13 menjelaskan proses konversi tipe data, encoding gender, dan penghapusan missing value pada dataset. Pada tahap ini, sistem mengubah kolom age_month, weight, dan height menjadi tipe data numerik. Perubahan tipe data ini dilakukan agar nilai pada kolom tersebut dapat digunakan dalam proses pengolahan data dan pemodelan.

Selanjutnya, sistem mengubah kolom date_of_birth dan date_of_measurement menjadi format tanggal terlebih dahulu. Setelah itu, kedua kolom tersebut dikonversi menjadi bentuk angka dengan format YYYYMMDD. Konversi ini dilakukan agar data tanggal tetap mengikuti format asli dataset, tetapi tetap dapat diproses oleh model machine learning.

Sistem juga merapikan data pada kolom gender serta kolom target, yaitu weight_for_age, height_for_age, dan weight_for_height. Setelah itu, kolom gender dikodekan menjadi angka menggunakan LabelEncoder agar dapat digunakan oleh model LightGBM dan XGBoost. Pada tahap akhir, sistem menghapus baris yang masih memiliki missing value menggunakan perintah dropna(), kemudian indeks data diatur ulang agar dataset menjadi lebih rapi.



```
# Cell ini digunakan untuk konversi tipe data, encoding gender, dan menghapus missing value.

# Konversi kolom numerik antropometri.
for col in ["age_month", "weight", "height"]:
    df[col] = pd.to_numeric(df[col], errors="coerce")

# Konversi date_of_birth dan date_of_measurement menjadi format tanggal.
tanggal_lahir = pd.to_datetime(df["date_of_birth"], errors="coerce", format="mixed", dayfirst=True)
tanggal_pemeriksaan = pd.to_datetime(df["date_of_measurement"], errors="coerce", format="mixed", dayfirst=True)

# Jika ada tanggal pemeriksaan yang tidak terbaca, nilainya diisi dengan median tanggal pemeriksaan yang valid.
if tanggal_pemeriksaan.isna().any():
    median_tanggal_pemeriksaan = tanggal_pemeriksaan.dropna().median()
    tanggal_pemeriksaan = tanggal_pemeriksaan.fillna(median_tanggal_pemeriksaan)

# Kolom tanggal dikonversi menjadi angka berdasarkan format tanggal pada dataset.
# Contoh: 2017-02-13 menjadi 20170213.
df["date_of_birth"] = tanggal_lahir.dt.strftime("%Y%m%d")
df["date_of_measurement"] = tanggal_pemeriksaan.dt.strftime("%Y%m%d")

# Ubah hasil konversi tanggal menjadi numerik.
df["date_of_birth"] = pd.to_numeric(df["date_of_birth"], errors="coerce")
df["date_of_measurement"] = pd.to_numeric(df["date_of_measurement"], errors="coerce")

# Rapikan gender dan target berbentuk teks.
df["gender"] = df["gender"].astype("string").str.strip().str.upper()
df["gender"] = df["gender"].replace({"": pd.NA, "NAN": pd.NA, "NONE": pd.NA})

for col in ["weight_for_age", "height_for_age", "weight_for_height"]:
    df[col] = df[col].astype("string").str.strip()

# Encode gender agar bisa digunakan oleh LightGBM dan XGBoost.
le_gender = LabelEncoder()
gender_notna = df["gender"].notna()
df.loc[gender_notna, "gender_enc"] = le_gender.fit_transform(df.loc[gender_notna, "gender"])

# Hapus baris yang masih memiliki missing value setelah konversi.
df = df.dropna().reset_index(drop=True)

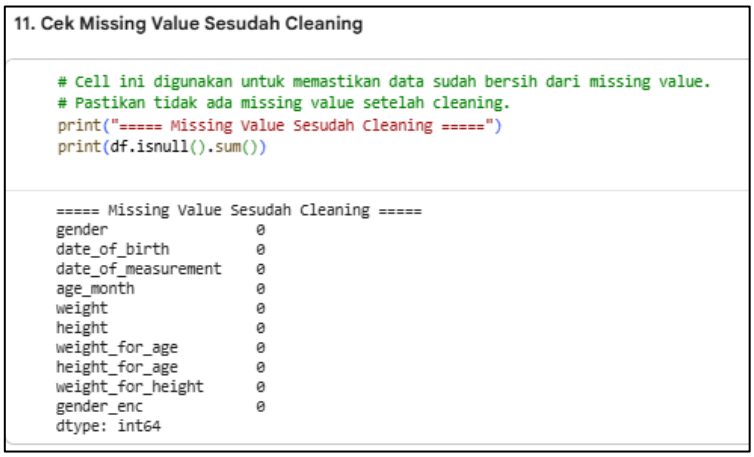
df["gender_enc"] = df["gender_enc"].astype(int)
df["date_of_birth"] = df["date_of_birth"].astype(int)
df["date_of_measurement"] = df["date_of_measurement"].astype(int)

print("Jumlah sampel setelah preprocessing akhir:", df.shape[0])
print("Mapping gender:", dict(zip(le_gender.classes_, le_gender.transform(le_gender.classes_))))
```

Gambar 3. 13 Konversi Numerik dan Hapus Missing

Gambar 3.14 menjelaskan tahap pengecekan missing value setelah proses cleaning dilakukan. Pada tahap ini, sistem memeriksa kembali setiap kolom menggunakan perintah df.isnull().sum() untuk memastikan bahwa tidak ada data kosong yang tersisa.

Berdasarkan hasil yang ditampilkan, seluruh kolom memiliki nilai missing value sebanyak 0, mulai dari gender, date_of_birth, date_of_measurement, age_month, weight, height, weight_for_age, height_for_age, weight_for_height, hingga gender_enc. Hasil ini menunjukkan bahwa dataset sudah bersih dan siap digunakan pada tahap pemodelan.



Gambar 3. 14 Cek Missing Value Sesudah Cleaning

Gambar 3.15 menjelaskan tahap encode target yang dilakukan untuk mengubah data kategori menjadi bentuk numerik. Pada tahap ini, mapping target dibuat secara manual agar kode angka yang digunakan sesuai dengan makna kategori penelitian, bukan berdasarkan urutan alfabet.

Pada target weight_for_age, kategori Malnutrition, Underfed, Normal, dan Overnutrition dikodekan menjadi angka. Pada target height_for_age, kategori Stunted dan Not Stunted juga dikonversi menjadi nilai numerik. Sementara itu, pada target weight_for_height, kategori Very Thin, Thin, Normal, dan Obese diubah menjadi kode angka.

Selain itu, mapping balik juga dibuat agar hasil prediksi dan confusion matrix dapat ditampilkan kembali dalam bentuk label kategori asli. Setelah proses encoding dilakukan, kolom target baru dengan akhiran _enc ditambahkan ke dalam dataset. Tahap ini dilakukan agar target yang semula berbentuk teks dapat diproses oleh model machine learning.

12. Encode Target

```
# Cell ini digunakan untuk melakukan encoding target secara manual sesuai kategori penelitian.
# Mapping target dibuat manual per target agar urutannya sesuai makna kategori, bukan urutan alfabet.
target_mappings = {
    "weight_for_age": {
        "Malnutrition": 0,
        "Underfed": 1,
        "Normal": 2,
        "Overnutrition": 3
    },
    "height_for_age": {
        "Stunted": 0,
        "Not Stunted": 1
    },
    "weight_for_height": {
        "Very Thin": 0,
        "Thin": 1,
        "Normal": 2,
        "Obese": 3
    }
}

# Mapping balik dipakai untuk membaca hasil prediksi dan confusion matrix.
target_inverse_mappings = {
    target: {kode: label for label, kode in mapping.items()}
    for target, mapping in target_mappings.items()
}

# Buat kolom target encoded.
for target, mapping in target_mappings.items():
    unknown_labels = sorted(set(df[target].dropna().unique()) - set(mapping.keys()))
    if unknown_labels:
        raise ValueError(f"Label tidak dikenali pada {target}: {unknown_labels}")
    df[f"{target}_enc"] = df[target].map(mapping).astype(int)

# Tabel mapping dibuat agar hasil encoding tidak terlihat seolah-olah sama semua.
mapping_rows = []
for target, mapping in target_mappings.items():
    for kategori, kode in mapping.items():
        mapping_rows.append({
            "Target": target,
            "Kategori": kategori,
            "Kode Encoding": kode
        })

mapping_target_df = pd.DataFrame(mapping_rows)
print("===== Mapping Encode Target =====")
display(mapping_target_df)

# Tampilkan contoh data yang berbeda untuk setiap kategori pada masing-masing target.
```

Gambar 3. 15 Target Encoder

Gambar 3.15 menjelaskan lanjutan dari tahap encode target yang digunakan untuk menampilkan contoh hasil encoding secara lebih beragam. Pada tahap ini, sistem memilih kolom target asli dan kolom target hasil encoding, yaitu weight_for_age, weight_for_age_enc, height_for_age, height_for_age_enc, weight_for_height, dan weight_for_height_enc. Data contoh ditampilkan menggunakan drop_duplicates() agar setiap kategori target dapat terlihat, karena lima baris pertama pada dataset memiliki label yang cenderung sama. Dengan

demikian, hasil perubahan label kategori menjadi kode angka dapat diperiksa dengan lebih jelas.

```
# Ini lebih informatif daripada df.head(), karena 5 baris pertama kebetulan memiliki label yang sama.
kolom_target_encode = [
    "weight_for_age", "weight_for_age_enc",
    "height_for_age", "height_for_age_enc",
    "weight_for_height", "weight_for_height_enc"
]

contoh_encode_target = pd.concat([
    df.drop_duplicates("weight_for_age")[kolom_target_encode],
    df.drop_duplicates("height_for_age")[kolom_target_encode],
    df.drop_duplicates("weight_for_height")[kolom_target_encode]
]).drop_duplicates().reset_index(drop=True)

print("===== Contoh Hasil Encode Target Beragam =====")
display(contoh_encode_target)
```

Gambar 3. 15 (Lanjutan)

Tabel 3.2 menjelaskan mapping encoder target yang digunakan untuk mengubah label kategori menjadi kode angka. Pada tabel tersebut, setiap target diberikan kode encoding sesuai dengan kategori masing-masing agar data dapat diproses oleh model machine learning. Target weight_for_age memiliki empat kategori, yaitu Malnutrition, Underfed, Normal, dan Overnutrition dengan kode encoding 0 sampai 3. Target height_for_age memiliki dua kategori, yaitu Stunted dan Not Stunted dengan kode encoding 0 dan 1. Sementara itu, target weight_for_height memiliki empat kategori, yaitu Very Thin, Thin, Normal, dan Obese dengan kode encoding 0 sampai 3.

Mapping encoder ini digunakan sebagai acuan dalam proses pengubahan data target dari bentuk teks menjadi bentuk numerik. Dengan proses tersebut, setiap kategori tetap memiliki makna yang sesuai, tetapi data sudah dapat digunakan pada tahap pelatihan dan pengujian model.

Tabel 3. 2 Mapping Encoder Target

No	Target	Kategori	Kode Encoding
0	weight_for_age	Malnutrition	0
1	weight_for_age	Underfed	1
2	weight_for_age	Normal	2
3	weight_for_age	Overnutrition	3
4	height_for_age	Stunted	0
5	height_for_age	Not Stunted	1
6	weight_for_height	Very Thin	0
7	weight_for_height	Thin	1
8	weight_for_height	Normal	2
9	weight_for_height	Obese	3

Gambar 3.16 menjelaskan proses penampilan dataset final setelah tahap preprocessing selesai dilakukan. Pada tahap ini, sistem menentukan fitur model, target hasil encoding, dan variabel penelitian yang digunakan dalam dataset akhir. Fitur model yang digunakan meliputi gender_enc, date_of_birth, date_of_measurement, age_month, weight, dan height.

Selain itu, sistem juga menentukan target hasil encoding yang terdiri dari weight_for_age_enc, height_for_age_enc, dan weight_for_height_enc. Jumlah variabel dataset tetap dihitung dari 9 variabel penelitian asli, yaitu gender, date_of_birth, date_of_measurement, age_month, weight, height,

weight_for_age, height_for_age, dan weight_for_height. Perhitungan ini dilakukan agar kolom hasil encoding tidak ikut dihitung sebagai variabel penelitian utama.

Pada tahap berikutnya, sistem membuat salinan dataset khusus untuk tampilan. Salinan ini digunakan agar kolom date_of_birth dan date_of_measurement dapat ditampilkan kembali dalam format tanggal YYYY-MM-DD. Setelah itu, sistem menampilkan 15 data pertama dari dataset final, tipe data setiap variabel penelitian, serta statistik fitur numerik yang digunakan oleh model. Proses ini dilakukan untuk memastikan bahwa dataset akhir sudah rapi dan siap digunakan dalam tahap pelatihan model.



```
# Cell ini digunakan untuk menampilkan dataset final setelah preprocessing.
# Jumlah variabel dataset dihitung dari 9 variabel penelitian asli, bukan dari kolom hasil encoding.

fitur_model = [
    "gender_enc",
    "date_of_birth",
    "date_of_measurement",
    "age_month",
    "weight",
    "height"
]

target_encoded = [
    "weight_for_age_enc",
    "height_for_age_enc",
    "weight_for_height_enc"
]

variabel_dataset = [
    "gender",
    "date_of_birth",
    "date_of_measurement",
    "age_month",
    "weight",
    "height",
    "weight_for_age",
    "height_for_age",
    "weight_for_height"
]

print("===== DATASET FINAL SETELAH PREPROCESSING =====")
print("Jumlah sampel:", df.shape[0])
print("Jumlah variabel:", len(variabel_dataset))
print("Fitur model:", fitur_model)

# Buat salinan khusus untuk tampilan agar kolom tanggal tetap terbaca sebagai tanggal.
# Kolom bantu display tidak ditambahkan ke dataset final.
df_tampilan_dataset_final = df.copy()

# Kolom tanggal dikembalikan ke format tanggal berdasarkan format YYYYMMDD.
df_tampilan_dataset_final["date_of_birth"] = pd.to_datetime(
    df_tampilan_dataset_final["date_of_birth"].astype(str),
    format="%Y%m%d",
    errors="coerce"
).dt.strftime("%Y-%m-%d")

df_tampilan_dataset_final["date_of_measurement"] = pd.to_datetime(
    df_tampilan_dataset_final["date_of_measurement"].astype(str),
    format="%Y%m%d",
    errors="coerce"
).dt.strftime("%Y-%m-%d")

# Tampilkan contoh data final dengan 9 variabel penelitian.
contoh_dataset_final = df_tampilan_dataset_final[variabel_dataset].head(15).reset_index(drop=True)

print("\nContoh dataset final setelah preprocessing:")
display(contoh_dataset_final)

print("\nTipe Data Variabel Penelitian:")
print(df[variabel_dataset].dtypes)

print("\nStatistik fitur numerik yang dipakai model:")
display(df[fitur_model].describe())
```

Gambar 3. 16 Dataset Final Setelah Preprocessing

Gambar 3.17 menjelaskan hasil dataset final setelah proses preprocessing dilakukan. Pada gambar tersebut, jumlah sampel akhir ditampilkan sebanyak 14.326 data dengan 9 variabel penelitian. Fitur model yang digunakan terdiri dari gender_enc, date_of_birth, date_of_measurement, age_month, weight, dan height. Selain itu, sistem menampilkan contoh 15 data pertama dari dataset final. Data yang ditampilkan meliputi gender, date_of_birth, date_of_measurement, age_month, weight, height, weight_for_age, height_for_age, dan weight_for_height. Kolom tanggal sudah ditampilkan kembali dalam format tanggal agar lebih mudah dibaca. Pada bagian bawah gambar, tipe data setiap variabel juga ditampilkan untuk memastikan bahwa data sudah sesuai sebelum digunakan dalam proses pemodelan.

```
===== DATASET FINAL SETELAH PREPROCESSING =====
Jumlah sampel: 14326
Jumlah variabel: 9
Fitur model: ['gender_enc', 'date_of_birth', 'date_of_measurement', 'age_month', 'weight', 'height']

Contoh dataset final setelah preprocessing:
```

	gender	date_of_birth	date_of_measurement	age_month	weight	height	weight_for_age	height_for_age	weight_for_height
0	F	2017-02-13	2021-08-28	54.0	13.2	97.5	Normal	Stunted	Normal
1	M	2017-12-05	2021-08-16	44.0	12.0	92.0	Normal	Stunted	Normal
2	M	2016-10-20	2021-08-14	57.0	14.0	97.0	Normal	Stunted	Normal
3	M	2019-06-17	2021-08-19	26.0	11.0	79.0	Normal	Stunted	Normal
4	F	2016-09-12	2021-08-16	59.0	14.6	98.0	Normal	Stunted	Normal
5	F	2017-10-16	2021-08-09	45.0	11.0	90.0	Underfed	Stunted	Normal
6	M	2016-10-16	2021-08-23	58.0	14.0	97.5	Normal	Stunted	Normal
7	M	2017-06-13	2021-08-23	50.0	14.0	94.5	Normal	Stunted	Normal
8	F	2016-09-17	2021-08-14	58.0	14.2	95.4	Normal	Stunted	Normal
9	M	2016-10-29	2021-08-19	57.0	10.0	81.0	Malnutrition	Stunted	Normal
10	M	2017-06-19	2021-08-09	49.0	11.5	90.0	Underfed	Stunted	Normal
11	F	2017-02-24	2021-08-26	54.0	13.1	97.0	Underfed	Stunted	Normal
12	F	2018-03-24	2021-08-26	41.0	11.0	86.0	Underfed	Stunted	Normal
13	M	2018-04-05	2021-08-12	40.0	11.1	89.0	Underfed	Stunted	Normal
14	M	2018-08-17	2021-08-12	35.0	11.1	84.0	Underfed	Stunted	Normal

```
Tipe Data Variabel Penelitian:
gender                string[python]
date_of_birth                  int64
date_of_measurement            int64
age_month                    float64
weight                       float64
height                       float64
weight_for_age        string[python]
height_for_age        string[python]
weight_for_height     string[python]
dtype: object
```

Gambar 3. 17 Output Dataset Final Setelah Preprocessing

3.4 Pembuatan Model Klasifikasi

Pembuatan model klasifikasi dilakukan untuk membangun model yang dapat mengenali kondisi tumbuh kembang dan status gizi balita berdasarkan data antropometri yang telah melalui tahap pra-pemrosesan. Dalam penelitian ini, proses pembuatan model dilakukan di Google Colab dengan menggunakan bahasa pemrograman Python. Model yang dibangun menggunakan dua algoritma, yaitu Light Gradient Boosting Machine (LightGBM) dan Extreme Gradient Boosting (XGBoost). Kedua algoritma tersebut digunakan untuk mengolah data masukan berupa usia dalam bulan, berat badan, dan tinggi badan, lalu menghasilkan klasifikasi pada indikator Weight-for-Age (W/A), Height-for-Age (H/A), dan Weight-for-Height (W/H). Keluaran model pada indikator W/A terdiri atas kategori Normal, Underfed, Malnutrition, dan Overnutrition. Pada indikator H/A, model menghasilkan kategori Stunted dan Not Stunted. Sementara itu, pada indikator W/H, keluaran model terdiri atas kategori Very Thin, Thin, Normal, dan Obese. Dengan demikian, model yang dibuat dalam penelitian ini mampu memberikan keluaran klasifikasi pada tiga kelompok indikator pertumbuhan dan status gizi balita.

3.4.1 Persiapan Fitur dan Target

Langkah pertama dalam pembuatan model klasifikasi adalah menyiapkan fitur dan target yang digunakan selama proses pelatihan dan pengujian. Fitur yang

digunakan dalam penelitian ini terdiri atas age_month, weight, dan height. Ketiga variabel tersebut dipilih karena merupakan data antropometri utama yang menggambarkan kondisi pertumbuhan balita. Sementara itu, target klasifikasi terdiri atas weight_for_age_enc, height_for_age_enc, dan weight_for_height_enc, yang merupakan hasil perubahan label kategori W/A, H/A, dan W/H ke dalam bentuk numerik. Perubahan ini perlu dilakukan agar data target dapat diproses oleh algoritma machine learning.

Gambar 3.18 menjelaskan tahap penyiapan fitur dan target model klasifikasi. Pada proses tersebut terlihat bahwa model menggunakan tiga variabel masukan, yaitu age_month, weight, dan height, serta tiga target keluaran, yaitu y_WA, y_HA, dan y_WH. Tahap ini penting karena menjadi dasar bagi model untuk mempelajari hubungan antara data antropometri dengan hasil klasifikasi yang ingin diprediksi.



Gambar 3. 18 Siapkan Fitur dan Target

3.4.2 Pembuatan Model LightGBM

Setelah menyiapkan fitur dan target klasifikasi, peneliti membangun model menggunakan algoritma LightGBM. Gambar 3.19 menampilkan proses pembuatan fungsi buat_model_lightgbm() yang digunakan untuk menghasilkan model sesuai dengan jumlah kelas pada setiap target. Fungsi tersebut terlebih dahulu menghitung jumlah kelas pada target yang akan diproses. Apabila target memiliki dua kelas, seperti Height for Age yang terdiri atas kategori Stunted dan Not Stunted, peneliti menggunakan objective="binary". Sementara itu, apabila target memiliki lebih dari dua kelas, seperti Weight for Age dan Weight for Height, peneliti menggunakan objective="multiclass" serta menetapkan num_class sesuai dengan jumlah kategori pada target.

Peneliti menggunakan parameter n_estimators=200 untuk menentukan jumlah pohon keputusan yang dibangun dalam proses boosting. Setiap pohon membantu model memperbaiki kesalahan prediksi dari pohon sebelumnya. Jumlah pohon tersebut dipilih agar model dapat mempelajari pola data secara memadai tanpa membuat proses pelatihan menjadi terlalu berat.

Parameter learning_rate=0.05 digunakan untuk mengatur besarnya kontribusi setiap pohon baru dalam proses pembelajaran model. Nilai tersebut membuat model mempelajari pola data secara bertahap, sehingga proses pelatihan dapat berlangsung lebih stabil. Selain itu, peneliti menggunakan parameter num_leaves=31 untuk menentukan jumlah maksimum daun pada setiap pohon. Parameter ini membantu model menangkap hubungan antara usia,

berat badan, dan tinggi badan terhadap target klasifikasi, tetapi tetap membatasi kompleksitas pohon agar model tidak terlalu menyesuaikan diri dengan data pelatihan.

Peneliti menggunakan parameter random_state=42 untuk menjaga konsistensi hasil eksperimen ketika proses pelatihan dijalankan kembali. Parameter n_jobs=1 digunakan untuk mengatur penggunaan satu inti pemrosesan agar proses pelatihan tetap stabil pada lingkungan notebook. Selanjutnya, parameter force_col_wise=True digunakan untuk mengatur proses pemrosesan data berdasarkan kolom agar pelatihan model pada data tabular dapat berjalan dengan lebih terarah. Parameter verbosity=-1 digunakan untuk menyembunyikan pesan proses pelatihan yang tidak diperlukan, sehingga hasil keluaran program terlihat lebih rapi.

Setelah menetapkan jenis klasifikasi dan seluruh parameter yang diperlukan, fungsi mengembalikan model LightGBM yang siap digunakan pada tahap pelatihan dan pengujian. Melalui fungsi tersebut, peneliti dapat menggunakan satu rancangan model untuk tiga target klasifikasi yang memiliki jumlah kelas berbeda.

17. Pembuatan Model LightGBM

```
# Cell ini digunakan untuk membuat model LightGBM
# LightGBM dipakai sebagai salah satu algoritma pembanding dalam klasifikasi status pertumbuhan dan gizi balita.
# Fungsi ini dibuat fleksibel agar bisa digunakan untuk target binary maupun multiclass.

def buat_model_lightgbm(y, random_state=42):
    # Menghitung jumlah kelas unik pada target.
    # Tujuannya untuk menentukan apakah target termasuk binary classification atau multiclass classification.
    n_class = len(np.unique(y))

    # Jika jumlah kelas hanya 2, maka model menggunakan objective binary.
    # Contohnya pada target Height for Age yang memiliki dua kelas.
    if n_class == 2:
        model = lgb.LGBMClassifier(
            objective="binary",          # Objective untuk klasifikasi dua kelas
            n_estimators=200,            # Jumlah pohon boosting yang dibuat
            learning_rate=0.05,          # Laju pembelajaran model
            num_leaves=31,               # Jumlah maksimum daun pada setiap pohon
            random_state=random_state,   # Seed acak agar hasil eksperimen konsisten
            n_jobs=1,                    # Menggunakan 1 core agar stabil di notebook lokal
            force_col_wise=True,         # Memaksa pemrosesan berbasis kolom agar training lebih stabil
            verbosity=-1                 # Menonaktifkan log training LightGBM yang terlalu panjang
        )

    # Jika jumlah kelas lebih dari 2, maka model menggunakan objective multiclass.
    # Contohnya pada target Weight for Age dan Weight for Height.
    else:
        model = lgb.LGBMClassifier(
            objective="multiclass",      # Objective untuk klasifikasi lebih dari dua kelas
            num_class=n_class,           # Jumlah kelas target yang akan diprediksi
            n_estimators=200,            # Jumlah pohon boosting yang dibuat
            learning_rate=0.05,          # Laju pembelajaran model
            num_leaves=31,               # Jumlah maksimum daun pada setiap pohon
            random_state=random_state,   # Seed acak agar hasil eksperimen konsisten
            n_jobs=1,                    # Menggunakan 1 core agar stabil di notebook lokal
            force_col_wise=True,         # Memaksa pemrosesan berbasis kolom agar training lebih stabil
            verbosity=-1                 # Menonaktifkan log training LightGBM yang terlalu panjang
        )

    # Mengembalikan model LightGBM yang sudah dibuat.
    return model
```

Gambar 3. 19 Pembuatan Model LightGBM

3.4.3 Pembuatan Model XGBoost

Selain membangun model LightGBM, peneliti juga membangun model klasifikasi XGBoost sebagai algoritma pembanding. Tahap pembuatan model tersebut ditampilkan pada Gambar 3.20. Peneliti membuat fungsi buat_model_xgboost() agar sistem dapat menentukan jenis klasifikasi sesuai dengan jumlah kelas pada masing-masing target. Fungsi tersebut menghitung jumlah kelas pada target terlebih dahulu menggunakan np.unique(y). Apabila target memiliki dua kelas, seperti Height for Age, peneliti menetapkan objective="binary:logistic" dan eval_metric="logloss". Sebaliknya, apabila target memiliki lebih dari dua kelas, seperti Weight for Age dan Weight for Height,

peneliti menetapkan objective="multi:softprob", eval_metric="mlogloss", serta num_class sesuai dengan jumlah kategori pada target.

Peneliti menggunakan parameter n_estimators=200 untuk menentukan jumlah pohon keputusan yang dibangun selama proses boosting. Setiap pohon memperbaiki kesalahan prediksi yang dihasilkan oleh pohon sebelumnya. Peneliti juga menggunakan parameter learning_rate=0.05 untuk mengatur besarnya kontribusi setiap pohon baru terhadap hasil prediksi. Nilai tersebut membantu model mempelajari pola data secara bertahap sehingga proses pelatihan dapat berjalan lebih stabil.

Parameter max_depth=6 mengatur kedalaman maksimum setiap pohon keputusan. Peneliti menggunakan parameter tersebut untuk membatasi kompleksitas model agar pohon tidak mempelajari data pelatihan secara berlebihan. Selain itu, parameter subsample=0.8 mengatur penggunaan 80% data pelatihan pada setiap proses pembentukan pohon. Pengaturan tersebut membantu model mengurangi risiko overfitting dan mempertahankan kemampuan prediksi pada data baru.

Peneliti menggunakan parameter colsample_bytree=0.8 untuk menentukan bahwa setiap pohon memanfaatkan 80% fitur yang tersedia. Pengaturan tersebut memberikan variasi pada proses pembentukan pohon dan membantu model membangun pola klasifikasi yang lebih baik. Selanjutnya, parameter random_state=42 menjaga konsistensi hasil eksperimen ketika peneliti menjalankan kembali proses pelatihan model.

Parameter n_jobs=1 mengatur penggunaan satu inti pemrosesan selama proses pelatihan agar eksekusi model tetap stabil pada lingkungan notebook. Sementara itu, parameter tree_method="hist" mengatur proses pembentukan pohon menggunakan metode histogram agar model dapat melakukan pelatihan secara lebih efisien pada data tabular.

Setelah menetapkan jenis klasifikasi dan seluruh parameter yang diperlukan, fungsi mengembalikan model XGBoost yang siap digunakan pada tahap pelatihan dan pengujian. Melalui fungsi tersebut, peneliti dapat menerapkan XGBoost pada tiga target klasifikasi meskipun setiap target memiliki jumlah kelas yang berbeda.

18. Pembuatan Model XGBoost

```
# Cell ini digunakan untuk membuat model XGBoost
# XGBoost dipakai sebagai salah satu algoritma pembanding dalam klasifikasi status pertumbuhan dan gizi balita.
# Fungsi ini dibuat fleksibel agar bisa digunakan untuk target binary maupun multiclass.

def buat_model_xgboost(y, random_state=42):
    # Menghitung jumlah kelas unik pada target.
    # Tujuannya untuk menentukan apakah target termasuk binary classification atau multiclass classification.
    n_class = len(np.unique(y))

    # Jika jumlah kelas hanya 2, maka model menggunakan objective binary:logistic.
    if n_class == 2:
        model = xgb.XGBClassifier(
            objective="binary:logistic",   # Objective untuk klasifikasi dua kelas
            eval_metric="logloss",         # Metrik evaluasi untuk klasifikasi biner
            n_estimators=200,              # Jumlah pohon boosting yang dibuat
            learning_rate=0.05,            # Laju pembelajaran model
            max_depth=6,                   # Kedalaman maksimum setiap pohon
            subsample=0.8,                 # Proporsi data yang digunakan pada setiap proses training pohon
            colsample_bytree=0.8,          # Proporsi fitur yang digunakan pada setiap pohon
            random_state=random_state,     # Seed acak agar hasil eksperimen konsisten
            n_jobs=1,                      # Menggunakan 1 core agar stabil di notebook lokal
            tree_method="hist"             # Metode pembuatan tree agar proses training lebih efisien
        )

    # Jika jumlah kelas lebih dari 2, maka model menggunakan objective multi:softprob.
    else:
        model = xgb.XGBClassifier(
            objective="multi:softprob",    # Objective untuk klasifikasi lebih dari dua kelas
            num_class=n_class,             # Jumlah kelas target yang akan diprediksi
            eval_metric="mlogloss",        # Metrik evaluasi untuk klasifikasi multikelas
            n_estimators=200,              # Jumlah pohon boosting yang dibuat
            learning_rate=0.05,            # Laju pembelajaran model
            max_depth=6,                   # Kedalaman maksimum setiap pohon
            subsample=0.8,                 # Proporsi data yang digunakan pada setiap proses training pohon
            colsample_bytree=0.8,          # Proporsi fitur yang digunakan pada setiap pohon
            random_state=random_state,     # Seed acak agar hasil eksperimen konsisten
            n_jobs=1,                      # Menggunakan 1 core agar stabil di notebook lokal
            tree_method="hist"             # Metode pembuatan tree agar proses training lebih efisien
        )

    # Mengembalikan model XGBoost yang sudah dibuat.
    return model


print("Fungsi pembuatan model XGBoost berhasil dibuat.")
```

```
Fungsi pembuatan model XGBoost berhasil dibuat.
```

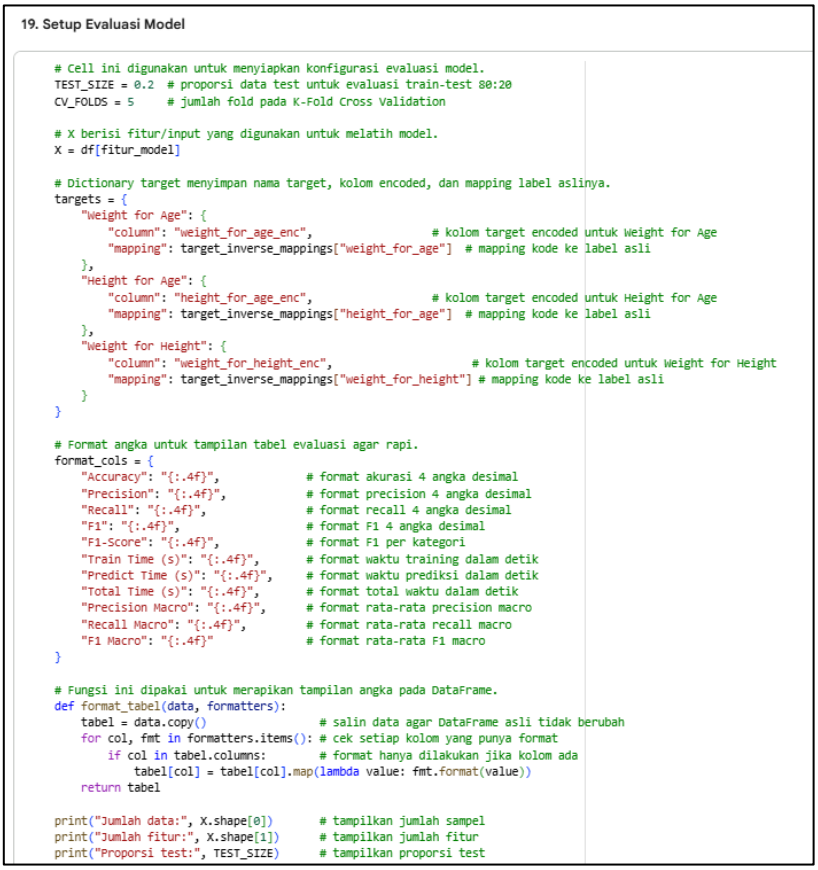
Gambar 3. 20 Pembuatan Model XGBoost

3.4.4 Setup Evaluasi Model

Gambar 3.21 menjelaskan tahap setup evaluasi model yang disiapkan sebelum proses pengujian dilakukan. Pada tahap ini, konfigurasi evaluasi ditentukan terlebih dahulu, yaitu proporsi data uji sebesar 0,2 atau 20% dan jumlah pengujian 5-fold cross validation. Data fitur yang digunakan untuk proses pelatihan model juga disimpan ke dalam variabel X berdasarkan fitur model yang telah ditentukan sebelumnya.

Selain itu, target klasifikasi disusun dalam bentuk dictionary yang memuat nama target, kolom target hasil encoding, dan mapping label asli. Target yang digunakan terdiri dari Weight for Age, Height for Age, dan Weight for Height. Mapping label disiapkan agar hasil prediksi yang berbentuk angka dapat dikembalikan ke bentuk kategori aslinya.

Pada tahap ini, format angka untuk hasil evaluasi juga diatur agar tabel evaluasi dapat ditampilkan dengan lebih rapi. Metrik yang diformat meliputi Accuracy, Precision, Recall, F1, F1-Score, waktu training, waktu prediksi, serta nilai rata-rata macro. Setelah itu, fungsi format_tabel() dibuat untuk merapikan tampilan angka pada DataFrame hasil evaluasi. Proses ini dilakukan agar evaluasi model dapat dijalankan secara lebih terstruktur dan hasilnya mudah dibaca.



19. Setup Evaluasi Model

```
# Cell ini digunakan untuk menyiapkan konfigurasi evaluasi model.
TEST_SIZE = 0.2  # proporsi data test untuk evaluasi train-test 80:20
CV_FOLDS = 5     # jumlah fold pada K-Fold Cross Validation

# X berisi fitur/input yang digunakan untuk melatih model.
X = df[fitur_model]

# Dictionary target menyimpan nama target, kolom encoded, dan mapping label aslinya.
targets = {
    "Weight for Age": {
        "column": "weight_for_age_enc",                # kolom target encoded untuk Weight for Age
        "mapping": target_inverse_mappings["weight_for_age"]  # mapping kode ke label asli
    },
    "Height for Age": {
        "column": "height_for_age_enc",                # kolom target encoded untuk Height for Age
        "mapping": target_inverse_mappings["height_for_age"]  # mapping kode ke label asli
    },
    "Weight for Height": {
        "column": "weight_for_height_enc",                   # kolom target encoded untuk Weight for Height
        "mapping": target_inverse_mappings["weight_for_height"] # mapping kode ke label asli
    }
}

# Format angka untuk tampilan tabel evaluasi agar rapi.
format_cols = {
    "Accuracy": "{:.4f}",            # format akurasi 4 angka desimal
    "Precision": "{:.4f}",           # format precision 4 angka desimal
    "Recall": "{:.4f}",              # format recall 4 angka desimal
    "F1": "{:.4f}",                  # format F1 4 angka desimal
    "F1-Score": "{:.4f}",            # format F1 per kategori
    "Train Time (s)": "{:.4f}",      # format waktu training dalam detik
    "Predict Time (s)": "{:.4f}",    # format waktu prediksi dalam detik
    "Total Time (s)": "{:.4f}",      # format total waktu dalam detik
    "Precision Macro": "{:.4f}",     # format rata-rata precision macro
    "Recall Macro": "{:.4f}",        # format rata-rata recall macro
    "F1 Macro": "{:.4f}"             # format rata-rata F1 macro
}

# Fungsi ini dipakai untuk merapikan tampilan angka pada DataFrame.
def format_tabel(data, formatters):
    tabel = data.copy()                # salin data agar DataFrame asli tidak berubah
    for col, fmt in formatters.items(): # cek setiap kolom yang punya format
        if col in tabel.columns:       # format hanya dilakukan jika kolom ada
            tabel[col] = tabel[col].map(lambda value: fmt.format(value))
    return tabel

print("Jumlah data:", X.shape[0])      # tampilkan jumlah sampel
print("Jumlah fitur:", X.shape[1])     # tampilkan jumlah fitur
print("Proporsi test:", TEST_SIZE)     # tampilkan proporsi test
```

Gambar 3. 21 Setup Evaluasi Model

Gambar 3.21 menjelaskan lanjutan dari tahap setup evaluasi model yang digunakan untuk menampilkan hasil konfigurasi awal sebelum pengujian dilakukan. Pada gambar tersebut, jumlah data ditampilkan sebanyak 14.326 data dengan 6 fitur model. Proporsi data uji ditetapkan sebesar 0,2 atau 20%, sedangkan jumlah cross validation ditentukan sebanyak 5 fold.

Selain itu, daftar target klasifikasi juga ditampilkan, yaitu Weight for Age, Height for Age, dan Weight for Height. Informasi tersebut ditampilkan agar konfigurasi evaluasi model dapat dipastikan sudah sesuai sebelum proses pelatihan dan pengujian model dilakukan.

```
print("Jumlah fold CV:", CV_FOLDS)      # tampilkan jumlah fold
print("Target:", list(targets.keys()))  # tampilkan daftar target
```

```
Jumlah data: 14326
Jumlah fitur: 6
Proporsi test: 0.2
Jumlah fold CV: 5
Target: ['Weight for Age', 'Height for Age', 'Weight for Height']
```

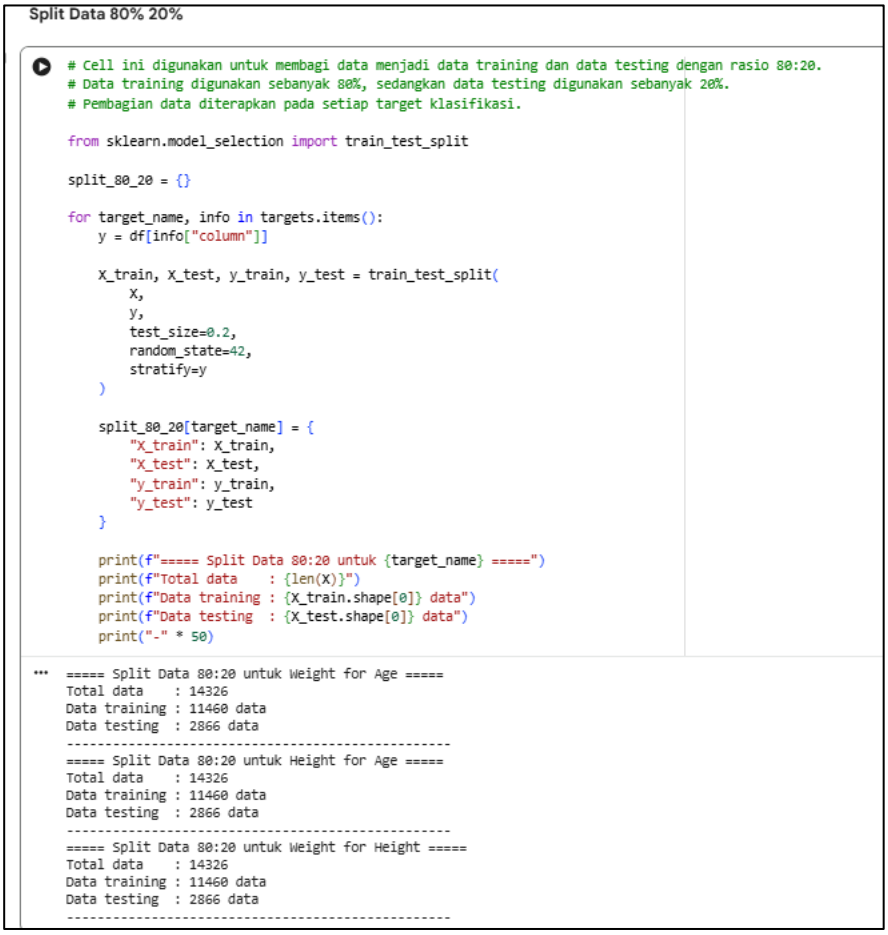
Gambar 3. 21 (Lanjutan)

3.4.5 Split Data 80% dan 20%

Gambar 3.22 menjelaskan proses pembagian data dengan rasio 80:20 sebelum model dilatih dan diuji. Pada tahap ini, sistem membagi dataset menjadi data training dan data testing menggunakan fungsi train_test_split. Data training ditetapkan sebesar 80%, sedangkan data testing ditetapkan sebesar 20%.

Pembagian data dilakukan pada tiga target klasifikasi, yaitu Weight for Age, Height for Age, dan Weight for Height. Parameter stratify=y digunakan agar perbandingan kelas pada data training dan data testing tetap seimbang. Selain itu, parameter random_state=42 digunakan agar hasil pembagian data tetap sama ketika proses dijalankan kembali.

Berdasarkan hasil yang ditampilkan, setiap target memiliki total data sebanyak 14.326 data. Setelah proses pembagian dilakukan, data training berjumlah 11.460 data, sedangkan data testing berjumlah 2.866 data. Data hasil pembagian tersebut kemudian digunakan pada tahap pelatihan dan pengujian model



Gambar 3. 22 Split Data 80% dan 20%

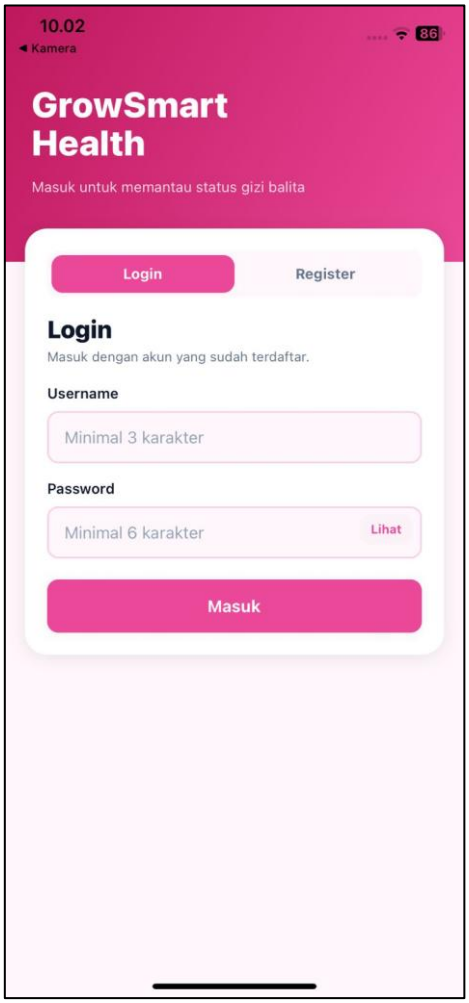
3.5 Tampilan Antarmuka Sistem

Pada bagian ini tampilan antarmuka sistem pada aplikasi GrowSmart Health yang berfungsi sebagai penghubung antara pengguna dengan sistem yang telah dikembangkan. Antarmuka aplikasi dirancang agar setiap fitur dapat digunakan dengan mudah, tampilan informasi lebih jelas, dan alur penggunaan terasa nyaman bagi pengguna. Penyusunan setiap halaman juga dibuat secara sederhana dan terstruktur supaya pengguna dapat memahami fungsi dari masing-masing menu dengan lebih mudah. Pada subbab ini, penjelasan tampilan

antarmuka disajikan berdasarkan halaman-halaman yang terdapat di dalam aplikasi, mulai dari halaman login, register, home, input data balita, hasil analisis, riwayat pemeriksaan, panduan gizi, hingga tentang aplikasi.

1. Tampilan Login

   Halaman login merupakan halaman awal yang ditampilkan kepada pengguna saat akan mengakses aplikasi GrowSmart Health, seperti terlihat pada Gambar 3.23. Halaman ini berfungsi sebagai pintu masuk pengguna ke dalam sistem dengan menggunakan akun yang telah terdaftar. Pada tampilan ini terdapat judul aplikasi, deskripsi singkat mengenai fungsi aplikasi, pilihan menu Login dan Register, kolom input username dan password, serta tombol Masuk. Desain halaman dibuat sederhana, rapi, dan mudah dipahami agar pengguna dapat melakukan proses login dengan nyaman dan efisien.

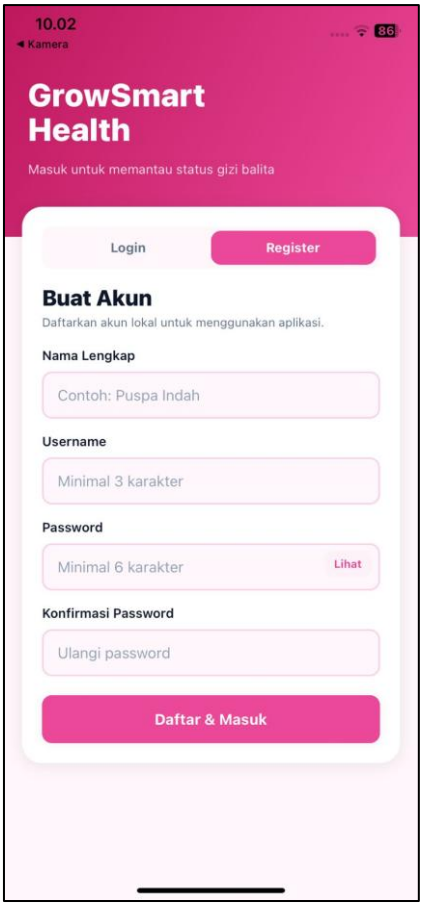


Gambar 3. 23 Tampilan Login

2. Tampilan Register

Halaman register merupakan halaman yang digunakan pengguna untuk membuat akun baru pada aplikasi GrowSmart Health, seperti terlihat pada Gambar 3.24. Halaman ini berfungsi sebagai sarana pendaftaran sebelum pengguna dapat mengakses fitur-fitur yang tersedia di dalam sistem. Pada tampilan ini terdapat pilihan menu Login dan Register, judul Buat Akun, kolom input nama lengkap, username, password, dan konfirmasi

password, serta tombol Daftar & Masuk. Desain halaman dibuat sederhana, rapi, dan mudah dipahami agar pengguna dapat melakukan proses pendaftaran akun dengan nyaman dan efisien.



Gambar 3. 24 Tampilan Register

3. Tampilan Home

Halaman home merupakan halaman utama yang muncul setelah pengguna berhasil masuk ke aplikasi GrowSmart Health, seperti terlihat pada Gambar 3.25. Halaman ini berfungsi sebagai pusat akses utama yang memudahkan pengguna saat ingin menggunakan fitur-fitur yang tersedia di dalam

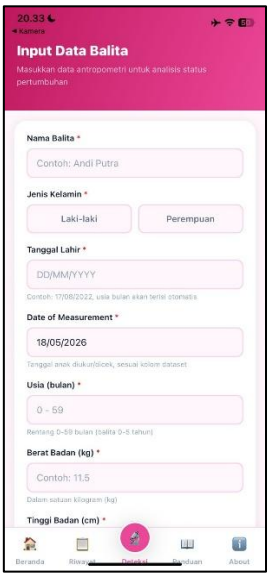
aplikasi. Pada tampilan ini terdapat sapaan untuk pengguna, judul aplikasi, tombol Mulai Pemeriksaan, ringkasan hasil pemeriksaan yang meliputi Total Cek, Normal, dan Perlu Perhatian, serta menu cepat seperti Deteksi Gizi, Riwayat, Panduan Gizi, dan About. Di bagian bawah juga tersedia navigation bar untuk membantu pengguna berpindah dari satu halaman ke halaman lainnya dengan lebih mudah. Secara keseluruhan, tampilan halaman ini dibuat sederhana, jelas, dan informatif agar pengguna dapat memahami fungsi setiap menu serta menggunakan aplikasi dengan lebih nyaman.



Gambar 3. 25 Tampilan Home

4. Tampilan Input Data Balita

Halaman input data balita merupakan halaman yang digunakan pengguna untuk memasukkan data antropometri anak sebelum proses analisis dilakukan, seperti terlihat pada Gambar 3.26. Pada halaman ini, pengguna diminta mengisi beberapa data penting, yaitu nama balita, jenis kelamin, tanggal lahir, usia dalam bulan, berat badan, dan tinggi badan. Selain itu, terdapat juga informasi bahwa sistem menggunakan model terbaik LightGBM untuk menganalisis tiga indikator status pertumbuhan, yaitu BB/U, TB/U, dan BB/TB. Tampilan halaman dibuat jelas dan terstruktur agar pengguna dapat mengisi data dengan mudah, sehingga proses pemeriksaan status pertumbuhan balita dapat dilakukan secara lebih praktis dan terarah.



Gambar 3. 26 Tampilan Input Data Balita

Halaman ini merupakan lanjutan dari proses input data balita pada aplikasi GrowSmart Health, pada Gambar 3.26 menampilkan kolom usia, berat badan, dan tinggi badan yang harus diisi oleh pengguna sebelum proses analisis dilakukan. Pengguna dapat menekan tombol Analisis Sekarang setelah seluruh data terisi dengan benar. Pada bagian bawah halaman, sistem juga menampilkan tabel Referensi Standar WHO yang berisi acuan berat badan normal dan tinggi badan normal berdasarkan usia balita. Informasi ini membantu pengguna memahami gambaran umum standar pertumbuhan anak sebelum hasil analisis ditampilkan oleh sistem.



Gambar 3.26 (Lanjutan)

5. Tampilan Input Data Balita Terisi

Halaman ini menampilkan form input data balita yang telah diisi oleh pengguna pada aplikasi GrowSmart Health, seperti terlihat pada Gambar 3.27. Pada tampilan ini, data yang dimasukkan meliputi nama balita, jenis kelamin, tanggal lahir, tanggal pengukuran, usia, berat badan, dan tinggi badan. Informasi tersebut menjadi dasar yang digunakan sistem untuk melakukan analisis status pertumbuhan balita. Setelah seluruh data terisi dengan lengkap, pengguna dapat menekan tombol Analisis Sekarang untuk memulai proses pemeriksaan. Tampilan halaman dirancang sederhana dan jelas agar pengguna dapat memeriksa kembali data yang telah dimasukkan sebelum melanjutkan ke tahap analisis.



Gambar 3. 27 Tampilan Input Data Balita Terisi

6. Tampilan Hasil Analisis

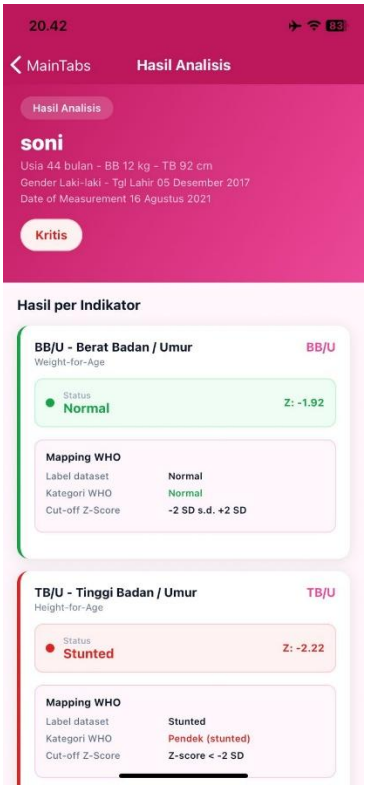
Halaman hasil analisis menampilkan ringkasan pemeriksaan status pertumbuhan balita setelah sistem memproses data yang telah dimasukkan oleh pengguna, seperti ditunjukkan pada Gambar 3.28. Sistem menampilkan identitas singkat balita yang terdiri atas nama, usia, berat badan, tinggi badan, jenis kelamin, tanggal lahir, dan tanggal pengukuran. Pada contoh tampilan tersebut, sistem menampilkan data balita bernama Soni dengan usia 44 bulan, berat badan 12 kg, tinggi badan 92 cm, jenis kelamin laki-laki, tanggal lahir 05 Desember 2017, dan tanggal pengukuran 16 Agustus 2021. Sistem juga menampilkan status utama pemeriksaan dengan kategori Kritis.

Selanjutnya, sistem menampilkan hasil analisis secara rinci pada bagian hasil per indikator. Pada indikator BB/U atau Berat Badan menurut Umur, sistem memberikan status Normal dengan nilai *z-score* sebesar -1,92. Sistem juga menampilkan pemetaan WHO yang menunjukkan bahwa label dataset dan kategori WHO berada pada kategori Normal. Informasi tersebut menunjukkan bahwa berat badan balita masih berada dalam kategori normal menurut umur berdasarkan standar yang digunakan.

Pada indikator TB/U atau Tinggi Badan menurut Umur, sistem memberikan status Stunted dengan nilai *z-score* sebesar -2,22. Sistem juga menampilkan pemetaan WHO yang menunjukkan bahwa label dataset berada pada kategori Stunted, sedangkan kategori WHO ditampilkan

sebagai Pendek (*stunted*). Hasil tersebut menunjukkan bahwa tinggi badan balita berada di bawah batas normal menurut umur, sehingga sistem memberikan peringatan pada indikator pertumbuhan tersebut.

Secara keseluruhan, tampilan halaman hasil analisis disusun secara ringkas, terstruktur, dan mudah dipahami. Sistem menampilkan hasil utama pemeriksaan, hasil per indikator, nilai *z-score*, serta pemetaan kategori WHO agar pengguna dapat memahami kondisi pertumbuhan balita secara lebih jelas. Dengan adanya tampilan ini, pengguna dapat memperoleh informasi awal mengenai status pertumbuhan balita secara lebih cepat, praktis, dan informatif.

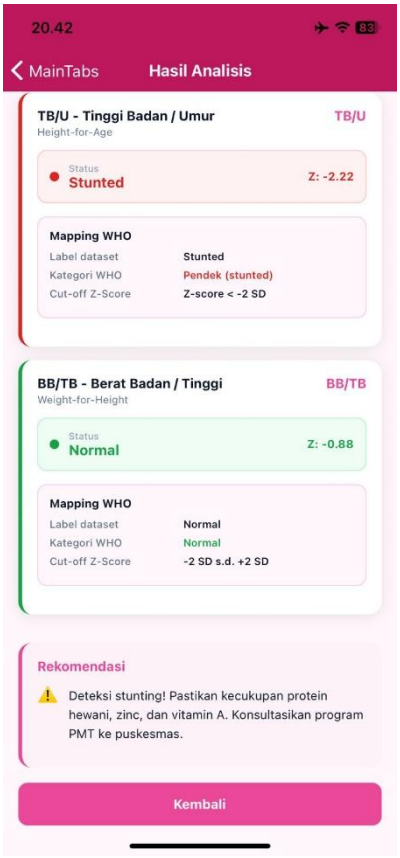


Gambar 3. 28 Tampilan Hasil Analisis

Halaman ini merupakan lanjutan dari tampilan hasil analisis pada aplikasi *GrowSmart Health*, seperti ditunjukkan pada Gambar 3.28 Sistem menampilkan hasil analisis pada indikator TB/U atau Tinggi Badan menurut Umur dan BB/TB atau Berat Badan menurut Tinggi Badan.

Pada indikator TB/U, sistem menampilkan status *Stunted* dengan nilai *z-score* sebesar -2,22. Pemetaan WHO menunjukkan bahwa label dataset berada pada kategori *Stunted*, sedangkan kategori WHO berada pada kategori Pendek (*stunted*) dengan batas *z-score* < -2 SD. Pada indikator BB/TB, sistem menampilkan status Normal dengan nilai *z-score* sebesar -0,88. Pemetaan WHO menunjukkan bahwa label dataset dan kategori WHO sama-sama berada pada kategori Normal.

Sistem juga menampilkan rekomendasi berupa peringatan deteksi *stunting*. Sistem menyarankan pengguna untuk memenuhi kecukupan protein hewani, zinc, dan vitamin A, serta berkonsultasi mengenai program PMT ke puskesmas. Secara keseluruhan, halaman ini disusun secara ringkas dan informatif agar pengguna dapat memahami hasil pemeriksaan dengan lebih mudah.



Gambar 3.28 (Lanjutan)

7. Riwayat Pemeriksaan

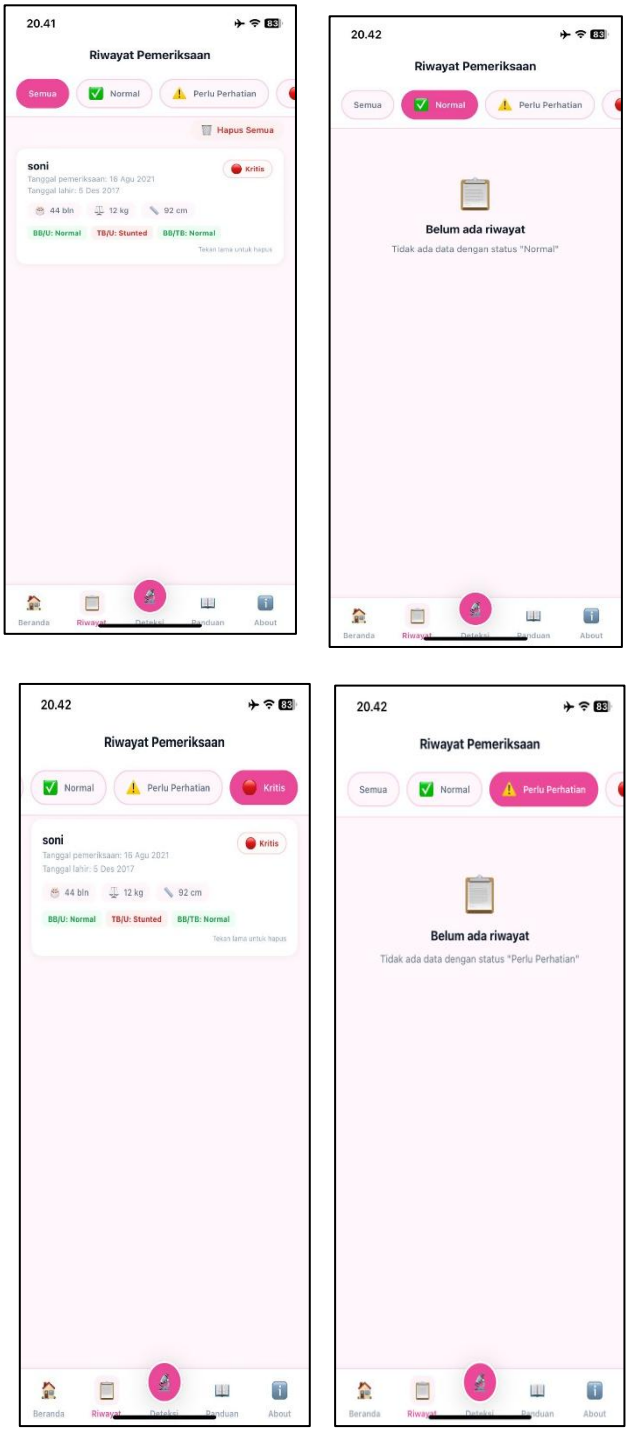
Halaman riwayat pemeriksaan pada aplikasi *GrowSmart Health* menampilkan data hasil pemeriksaan balita yang telah tersimpan, seperti ditunjukkan pada Gambar 3.29. Sistem menyediakan fitur filter agar pengguna dapat melihat riwayat pemeriksaan berdasarkan kategori tertentu. Pengguna dapat memilih filter *Semua*, *Normal*, *Perlu Perhatian*, dan *Kritis* sesuai kebutuhan.

Pada filter *Semua*, sistem menampilkan seluruh data riwayat pemeriksaan yang tersedia. Sistem menampilkan informasi berupa nama balita, tanggal

pemeriksaan, tanggal lahir, usia, berat badan, tinggi badan, serta hasil analisis pada indikator BB/U, TB/U, dan BB/TB. Pada contoh tampilan tersebut, sistem menampilkan data balita bernama soni dengan status utama Kritis**,** hasil BB/U Normal**,** TB/U Stunted, dan BB/TB Normal. Pada bagian ini, sistem juga menyediakan fitur Hapus Semua untuk menghapus seluruh data riwayat yang tersimpan.

Pada filter *Kritis*, sistem menampilkan data pemeriksaan yang memiliki status Kritis. Pada contoh tampilan, sistem kembali menampilkan data balita soni karena hasil pemeriksaannya termasuk dalam kategori tersebut. Sementara itu, pada filter *Perlu Perhatian*, sistem menampilkan pesan "Belum ada riwayat" karena tidak terdapat data pemeriksaan yang sesuai dengan kategori *Perlu Perhatian*. Pada filter *Normal*, sistem juga menampilkan pesan "Belum ada riwayat" karena tidak terdapat data pemeriksaan dengan status *Normal*.

Secara keseluruhan, halaman riwayat pemeriksaan ini disusun secara sederhana, terstruktur, dan mudah dipahami. Tampilan ini membantu pengguna menelusuri hasil pemeriksaan yang telah dilakukan berdasarkan kategori tertentu secara lebih praktis dan nyaman.



Gambar 3. 29 Tampilan Riwayat Pemeriksaan

Halaman ini menampilkan jendela konfirmasi saat pengguna menekan fitur Hapus Semua pada menu riwayat pemeriksaan, seperti terlihat pada

Gambar 3.30. Tampilan ini bertujuan untuk memastikan kembali keputusan pengguna sebelum seluruh data riwayat pemeriksaan dihapus dari sistem. Pada kotak dialog tersebut, sistem menampilkan pesan bahwa semua riwayat pemeriksaan akan dihapus, lalu menyediakan dua pilihan, yaitu tombol Batal untuk membatalkan tindakan dan tombol Hapus Semua untuk melanjutkan proses penghapusan. Adanya tampilan ini membantu mencegah kesalahan pengguna saat menghapus data yang sudah tersimpan. Secara keseluruhan, tampilan dibuat sederhana, jelas, dan mudah dipahami agar pengguna dapat mengambil keputusan dengan lebih aman dan tepat.



Gambar 3. 30 Tampilan Hapus Semua di Riwayat Pemeriksaan

8. Halaman Panduan Gizi

Halaman panduan gizi pada aplikasi *GrowSmart Health* menampilkan informasi pendukung untuk membantu pengguna memahami hasil pemeriksaan status gizi balita, seperti ditunjukkan pada Gambar 3.31. Sistem menampilkan panduan interpretasi berdasarkan *WHO Child Growth Standards* untuk anak usia 0–59 bulan. Halaman ini juga menjelaskan pemetaan istilah pada dataset ke dalam kategori gizi Indonesia dan istilah WHO.

Pada bagian indikator BB/U atau Berat Badan menurut Umur, sistem menjelaskan bahwa indikator ini digunakan untuk menilai berat badan anak berdasarkan usia. Sistem menampilkan kategori WHO yang terdiri atas berat badan sangat kurang (*severely underweight*), berat badan kurang (*underweight*), normal, dan gizi lebih (*overweight*). Setiap kategori dilengkapi dengan batas *z-score* dan status penilaian, seperti penanganan serius, perhatian, dan baik.

Sistem juga menampilkan bagian *Mapping Label dataset ke WHO* untuk menjelaskan perubahan istilah dari label dataset ke kategori WHO. Pada bagian tersebut, label *Malnutrition* dipetakan menjadi berat badan sangat kurang (*severely underweight*), label *Underfed* dipetakan menjadi berat badan kurang (*underweight*), dan label *Overnutrition* dipetakan menjadi gizi lebih (*overweight*).

Selain itu, sistem memberikan catatan bahwa kategori berat badan sangat kurang dan berat badan kurang memerlukan evaluasi asupan makan, pemeriksaan penyakit penyerta, serta pemantauan pertumbuhan secara berkala. Secara keseluruhan, halaman ini disusun secara rapi dan informatif agar pengguna dapat memahami panduan gizi dengan lebih mudah.



Gambar 3. 31 Halaman Panduan Gizi

Pada lanjutan halaman panduan gizi, aplikasi menampilkan penjelasan mengenai indikator TB/U atau Tinggi Badan menurut Umur, seperti

ditunjukkan pada Gambar 3.31. Sistem menggunakan indikator ini untuk menilai tinggi badan anak berdasarkan umur. Indikator TB/U juga membantu pengguna memahami kemungkinan adanya *stunting* atau gangguan pertumbuhan linear kronis pada balita.

Sistem menampilkan beberapa kategori WHO pada indikator TB/U, yaitu sangat pendek (*severely stunted*), pendek (*stunted*), normal, dan tinggi. Setiap kategori dilengkapi dengan batas *z-score* dan status penilaian. Kategori sangat pendek memiliki batas *z-score* < -3 SD dengan status penanganan serius. Kategori pendek memiliki batas -3 SD sampai < -2 SD dengan status perhatian. Kategori normal memiliki batas -2 SD sampai +3 SD dengan status baik. Kategori tinggi memiliki batas > +3 SD dengan status perhatian.

Sistem juga menyediakan bagian *Mapping Label dataset ke WHO* untuk menjelaskan pemetaan istilah dari dataset ke kategori WHO. Label *Stunted* dipetakan menjadi kategori sangat pendek atau pendek berdasarkan nilai *z-score*, sedangkan label *Not Stunted* dipetakan menjadi kategori normal. Selain itu, sistem menampilkan catatan bahwa intervensi paling efektif dilakukan sejak 1000 HPK atau hari pertama kehidupan. Informasi ini membantu pengguna memahami pentingnya pemantauan tinggi badan anak sejak dini.



Gambar 3.31 (Lanjutan)

Pada lanjutan halaman panduan gizi, aplikasi menampilkan penjelasan mengenai indikator BB/TB atau Berat Badan menurut Tinggi Badan, seperti ditunjukkan pada Gambar 3.31. Sistem menggunakan indikator ini untuk menilai kondisi gizi anak berdasarkan perbandingan berat badan dan tinggi badan. Indikator BB/TB membantu pengguna memahami kemungkinan adanya *wasting*, gizi lebih, atau obesitas pada balita.

Sistem menampilkan beberapa kategori WHO pada indikator BB/TB, yaitu gizi buruk (*severely wasted*), gizi kurang (*wasted*), normal, gizi lebih

(*overweight*), dan obesitas (*obese*). Setiap kategori dilengkapi dengan batas *z-score* dan status penilaian. Kategori gizi buruk memiliki status penanganan serius, kategori gizi kurang memiliki status perhatian, kategori normal memiliki status baik, kategori gizi lebih memiliki status perhatian, dan kategori obesitas memiliki status penanganan serius.

Sistem juga menyediakan bagian *Mapping Label dataset ke WHO* untuk menjelaskan pemetaan istilah dari dataset ke kategori WHO. Label *Very Thin* dipetakan menjadi gizi buruk (*severely wasted*), label *Thin* dipetakan menjadi gizi kurang (*wasted*), sedangkan label *Obese* dipetakan menjadi gizi lebih atau obesitas berdasarkan nilai *z-score*. Selain itu, sistem menampilkan catatan bahwa gizi buruk merupakan kondisi gizi darurat dan perlu evaluasi klinis segera. Sistem juga memberikan informasi bahwa aplikasi hanya berfungsi sebagai alat bantu skrining, sehingga hasil pemeriksaan tetap perlu dikonfirmasi oleh tenaga kesehatan.



Gambar 3.31 (Lanjutan)

9. Tentang Aplikasi

Halaman Tentang Aplikasi merupakan halaman yang berisi informasi umum mengenai aplikasi GrowSmart Health, seperti terlihat pada Gambar 3.32. Pada halaman ini, pengguna dapat melihat penjelasan singkat tentang fungsi aplikasi sebagai alat bantu skrining status gizi balita berbasis *machine learning* yang dirancang untuk membantu memantau pertumbuhan anak secara lebih praktis. Selain itu, halaman ini juga menampilkan profil aplikasi, seperti nama aplikasi, nama perancang, NIM, institusi, tahun pembuatan, serta dosen pembimbing, sehingga latar belakang pengembangan aplikasi dapat diketahui dengan lebih

jelas. Tidak hanya itu, pada bagian bawah juga terdapat informasi mengenai proses pembuatan aplikasi dan teknologi yang digunakan dalam pengembangannya. Secara keseluruhan, tampilan halaman ini dibuat rapi, informatif, dan mudah dipahami agar pengguna dapat mengenal aplikasi ini lebih jauh, baik dari sisi fungsi maupun dari sisi pengembangannya.



Gambar 3. 32 Tentang Aplikasi

Halaman ini merupakan bagian lanjutan dari menu Tentang Aplikasi pada aplikasi GrowSmart Health, seperti terlihat pada Gambar 3.32 Pada bagian ini, pengguna dapat melihat penjelasan mengenai proses pembuatan aplikasi, mulai dari data yang dimasukkan, tahapan analisis yang dilakukan sistem, hingga hasil yang

ditampilkan setelah proses pemeriksaan selesai. Penjelasan ini membantu pengguna memahami bahwa aplikasi bekerja melalui alur yang terstruktur dalam mengolah data antropometri balita menjadi informasi status pertumbuhan.

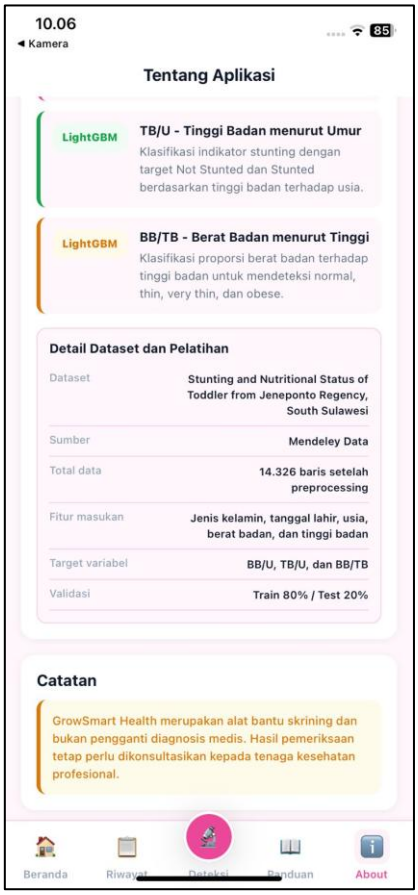
Selain itu, halaman ini juga memuat keterangan mengenai metode yang digunakan dalam aplikasi, yaitu metode klasifikasi *machine learning* yang mengacu pada standar antropometri WHO 2006. Melalui informasi tersebut, pengguna dapat mengetahui dasar metode yang digunakan untuk menganalisis kondisi pertumbuhan balita. Secara keseluruhan, tampilan halaman ini disusun dengan rapi, informatif, dan mudah dipahami agar pengguna dapat mengenal cara kerja aplikasi dengan lebih jelas.



Gambar 3.32 (Lanjutan)

Halaman ini merupakan bagian lanjutan dari menu Tentang Aplikasi pada aplikasi GrowSmart Health, seperti terlihat pada Gambar 3.32. Pada bagian ini, pengguna dapat melihat penjelasan mengenai model yang digunakan untuk menganalisis indikator pertumbuhan balita, yaitu TB/U (Tinggi Badan menurut Umur) dan BB/TB (Berat Badan menurut Tinggi). Informasi ini membantu pengguna memahami bahwa aplikasi memanfaatkan model LightGBM untuk mengolah data antropometri balita dan menghasilkan klasifikasi status pertumbuhan.

Selain itu, halaman ini juga memuat bagian detail dataset dan pelatihan yang berisi informasi tentang sumber data, jumlah data setelah *preprocessing*, fitur masukan, variabel target, serta pembagian data latih dan data uji. Penjelasan tersebut memberikan gambaran kepada pengguna mengenai dasar data dan proses pelatihan model yang digunakan dalam pengembangan aplikasi. Pada bagian bawah, terdapat pula catatan yang menegaskan bahwa aplikasi ini hanya digunakan sebagai alat bantu skrining dan tidak menggantikan diagnosis medis. Secara keseluruhan, tampilan halaman ini dibuat rapi, informatif, dan mudah dipahami agar pengguna dapat mengenal dasar pengembangan aplikasi dengan lebih jelas.



Gambar 3.32 (Lanjutan)

Pada halaman ini ditampilkan bagian akhir dari menu Tentang Aplikasi pada aplikasi GrowSmart Health, seperti yang ditunjukkan pada Gambar 3.32. Pada bagian ini, catatan penting ditampilkan untuk menjelaskan bahwa aplikasi hanya digunakan sebagai alat bantu skrining dan tidak dimaksudkan untuk menggantikan diagnosis medis. Penjelasan tersebut diberikan agar hasil pemeriksaan yang diperoleh dari aplikasi dapat dikonsultasikan lebih lanjut kepada tenaga kesehatan profesional.

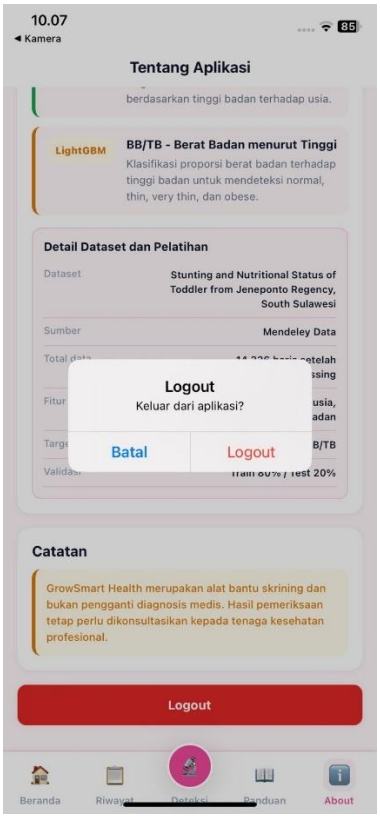
Di bagian bawah halaman juga tersedia tombol Logout yang berfungsi untuk keluar dari aplikasi setelah pengguna selesai menggunakan sistem. Keberadaan tombol

ini membantu pengguna mengakhiri sesi penggunaan aplikasi dengan lebih aman dan tertata. Secara keseluruhan, tampilan halaman ini dibuat sederhana, jelas, dan mudah dipahami agar informasi penting dapat diterima pengguna dengan baik.



Gambar 3. 33 Tampilan Logout

Halaman ini menampilkan kotak dialog konfirmasi logout pada aplikasi GrowSmart Health, seperti terlihat pada Gambar 3.34. Tampilan ini muncul ketika pengguna memilih tombol Logout sebagai langkah akhir untuk keluar dari aplikasi. Tujuan dari tampilan ini adalah untuk memastikan kembali keputusan pengguna, sehingga proses keluar dari sistem tidak terjadi secara tidak sengaja. Pada kotak dialog tersebut, sistem menampilkan pertanyaan singkat “Keluar dari aplikasi?” yang disertai dengan dua pilihan, yaitu tombol Batal untuk membatalkan proses keluar dan tombol Logout untuk melanjutkan keluar dari aplikasi.



Gambar 3. 34 Tampilan kotak dialog konfirmasi logout

BAB IV
PENGUJIAN

4.1 Cara Pengujian

Pada bagian ini, perancang menjelaskan tahapan pengujian yang dilakukan untuk menilai performa model klasifikasi yang telah dibangun. Pengujian dilakukan secara bertahap, mulai dari melihat distribusi target, memahami hubungan antar fitur, mengevaluasi performa model melalui *train-test split*, melakukan pengujian dengan K-Fold Cross Validation, hingga menentukan model terbaik. Melalui tahapan ini, perancang dapat memperoleh gambaran yang lebih jelas mengenai kemampuan model dalam mengklasifikasikan data pada setiap target.

4.1.1 Cara pengujian persiapan fitur dan target (Distribusi Target)

Pada tahap ini, pengujian dilakukan untuk mengetahui data yang telah melalui proses preprocessing sudah siap digunakan dalam proses pemodelan. Sebelum model dilatih, perancang terlebih dahulu memastikan bahwa fitur dan target yang digunakan sudah sesuai, baik dari segi jumlah data, nama kolom, maupun isi kategorinya. Setelah itu, pemeriksaan terhadap distribusi kelas pada setiap target dilakukan untuk mengetahui persebaran jumlah data pada masing-masing kategori.

Pengujian distribusi target dilakukan dengan menampilkan visualisasi dalam bentuk grafik menggunakan library Matplotlib dan Seaborn pada Python.

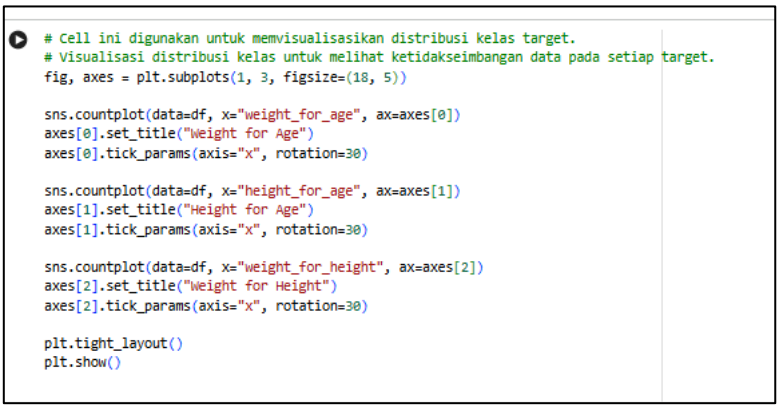
Visualisasi ini dibuat untuk tiga kelas data, yaitu weight for age (menilai berat badan berdasarkan usia), height for age (menilai tinggi badan berdasarkan usia), dan weight for height (menilai keseimbangan berat badan terhadap tinggi badan). Masing-masing target ditampilkan dalam grafik yang menunjukkan jumlah data pada setiap kelas. Dengan cara ini, perancang dapat melihat secara langsung kondisi jika ada kelas yang jumlah datanya jauh lebih banyak atau justru jauh lebih sedikit dibandingkan kelas lainnya.

Langkah pengujiannya dimulai dengan menyiapkan area visualisasi menggunakan plt.subplots() sehingga ketiga grafik dapat ditampilkan dalam satu tampilan. Setelah itu, fungsi sns.countplot() digunakan untuk menghitung sekaligus menampilkan jumlah data pada setiap kategori dari masing-masing target. Setiap grafik kemudian diberi judul sesuai targetnya, yaitu Weight for Age, Height for Age, dan Weight for Height, agar lebih mudah dibedakan saat dianalisis. Label pada sumbu x juga diputar agar nama kategori tetap terbaca dengan jelas dan tidak saling bertumpuk. Terakhir, digunakan plt.tight_layout() supaya tampilan antar grafik menjadi lebih rapi.

Melalui pengujian ini, perancang dapat memahami kondisi awal data target sebelum masuk ke tahap pelatihan model. Jika distribusi data antar kelas terlihat tidak seimbang, maka hal tersebut perlu diperhatikan karena dapat memengaruhi hasil klasifikasi. Model bisa saja lebih sering memprediksi kelas yang jumlah datanya lebih dominan dan kurang optimal dalam mengenali kelas yang jumlahnya

lebih sedikit. Oleh karena itu, pengujian distribusi target menjadi langkah awal yang penting untuk membantu perancang memahami karakteristik data yang digunakan.

Pada Gambar 4.1 dijelaskan visualisasi distribusi kelas pada tiga target, yaitu *weight for age*, *height for age*, dan *weight for height*. Dari gambar tersebut, persebaran jumlah data pada setiap kategori dapat dilihat, sehingga kondisi keseimbangan data target maupun perbedaan jumlah antar kelas dapat diketahui oleh perancang.



```
# Cell ini digunakan untuk memvisualisasikan distribusi kelas target.
# Visualisasi distribusi kelas untuk melihat ketidakseimbangan data pada setiap target.
fig, axes = plt.subplots(1, 3, figsize=(18, 5))

sns.countplot(data=df, x="weight_for_age", ax=axes[0])
axes[0].set_title("Weight for Age")
axes[0].tick_params(axis="x", rotation=30)

sns.countplot(data=df, x="height_for_age", ax=axes[1])
axes[1].set_title("Height for Age")
axes[1].tick_params(axis="x", rotation=30)

sns.countplot(data=df, x="weight_for_height", ax=axes[2])
axes[2].set_title("Weight for Height")
axes[2].tick_params(axis="x", rotation=30)

plt.tight_layout()
plt.show()
```

Gambar 4. 1 Cara pengujian persiapan fitur dan target (Distribusi Target)

4.1.2 Cara Pengujian Heatmap Korelasi

Pada tahap ini, pengujian dilakukan untuk melihat hubungan antar fitur numerik yang digunakan dalam model. Setelah data dinyatakan siap, perancang membuat visualisasi korelasi untuk memahami kondisi antar fitur dengan hubungan yang kuat, sedang, atau lemah. Langkah ini penting dilakukan karena hubungan antar fitur dapat memberikan gambaran awal mengenai pola data sebelum masuk ke proses pelatihan model.

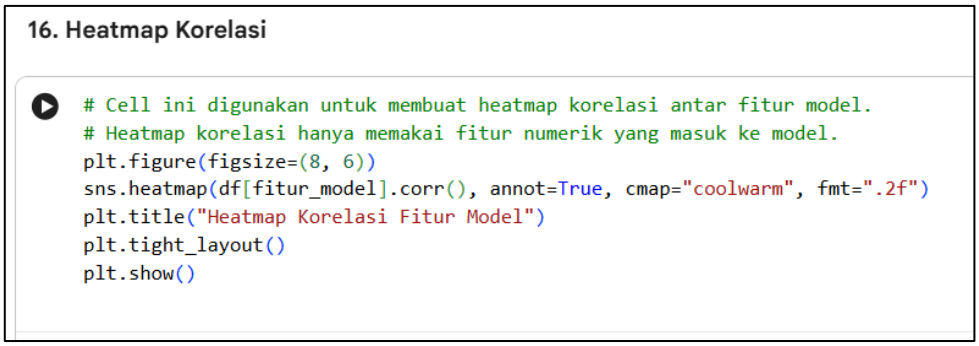
Pengujian ini dilakukan dengan bantuan library Matplotlib dan Seaborn pada Python. Heatmap dibuat dari fitur-fitur numerik yang digunakan dalam pemodelan, karena korelasi hanya dapat dihitung pada data berbentuk angka. Perancang terlebih dahulu menghitung nilai korelasi antar fitur menggunakan fungsi corr(), kemudian hasilnya divisualisasikan menggunakan sns.heatmap(). Dari visualisasi tersebut, setiap kotak pada heatmap menunjukkan hubungan antara satu fitur dengan fitur lainnya.

Agar hasilnya lebih mudah dipahami, nilai korelasi ditampilkan langsung pada setiap kotak dalam bentuk angka desimal. Selain itu, gradasi warna digunakan untuk membantu membedakan tingkat kekuatan hubungan antar fitur. Dengan tampilan ini, perancang dapat lebih mudah mengenali jenis fitur yang memiliki hubungan cukup kuat dan jenis fitur yang hubungannya lebih rendah.

Melalui heatmap korelasi, perancang dapat memperoleh gambaran awal mengenai struktur data yang digunakan. Jika terdapat dua atau lebih fitur yang memiliki korelasi sangat tinggi, hal ini perlu diperhatikan karena dapat menunjukkan adanya informasi yang saling berdekatan atau tumpang tindih. Sebaliknya, apabila korelasi antar fitur tidak terlalu tinggi, maka setiap fitur cenderung memberikan informasi yang berbeda dan dapat mendukung proses klasifikasi dengan lebih baik.

Gambar 4.2 menjelaskan visualisasi heatmap korelasi antar fitur numerik yang digunakan dalam model. Dari proses tersebut, perancang dapat melihat pola

hubungan antar variabel secara lebih jelas sebagai bagian dari proses pemahaman data sebelum dilakukan pelatihan dan evaluasi model.



Gambar 4. 2 Cara Pengujian Heatmap

4.1.3 Cara pengujian model Evaluasi detail dan Confusion Matrix

Pada tahap evaluasi detail dan confusion matrix, sistem menguji model menggunakan pembagian data latih dan data uji dengan perbandingan 80:20. Sistem menerapkan metode stratified split agar proporsi setiap kelas pada data latih dan data uji tetap seimbang. Tahapan pengujian ini dilakukan sebelum proses K-Fold Cross Validation, sehingga performa awal model dapat dilihat secara lebih rinci.

Sistem melakukan pengujian pada setiap target klasifikasi, yaitu BB/U, TB/U, dan BB/TB. Pada setiap target, sistem membangun dan membandingkan dua algoritma, yaitu LightGBM dan XGBoost. Sistem melatih model menggunakan data latih, kemudian sistem menggunakan model tersebut untuk memprediksi data uji.

Setelah proses prediksi selesai, sistem menghitung nilai accuracy, precision, recall, dan F1-score sebagai ukuran performa model. Sistem juga mencatat waktu

pelatihan, waktu prediksi, dan total waktu pemrosesan untuk mengetahui efisiensi model. Selain itu, sistem menghasilkan confusion matrix untuk melihat jumlah prediksi yang benar dan salah pada setiap kelas. Tahapan pengujian ini ditunjukkan pada Gambar 4.3.

```
# Cell ini digunakan untuk evaluasi detail train-test dan confusion matrix sebelum K-Fold.
# Evaluasi detail dilakukan lebih dulu menggunakan train-test split 80:20.
# Bagian K-Fold Cross Validation dijalankan setelah bagian ini.
from sklearn.model_selection import train_test_split

holdout_rows = []
holdout_detail_rows = []
holdout_confusion_data = {}

for target_name, info in targets.items():
    y = df[info["column"]]
    label_mapping = info["mapping"]
    labels = sorted(label_mapping.keys())

    # Split train-test dibuat stratified agar proporsi kelas tetap seimbang.
    X_train, X_test, y_train, y_test = train_test_split(
        X,
        y,
        test_size=TEST_SIZE,
        random_state=42,
        stratify=y
    )

    models = {
        "LightGBM": buat_model_lightgbm(y_train),
        "XGBoost": buat_model_xgboost(y_train)
    }

    for model_name, model in models.items():
        print(f"Evaluasi detail train-test: {target_name} - {model_name}")

        train_start = time.perf_counter()
        model.fit(X_train, y_train)
        train_time = time.perf_counter() - train_start

        predict_start = time.perf_counter()
        y_pred = model.predict(X_test)
        predict_time = time.perf_counter() - predict_start

        total_time = train_time + predict_time

        accuracy = accuracy_score(y_test, y_pred)
        precision, recall, f1, _ = precision_recall_fscore_support(
            y_test, y_pred, average="macro", zero_division=0
        )

        holdout_rows.append({
            "Target": target_name,
            "Model": model_name,
            "Accuracy": accuracy,
            "Precision": precision,
```

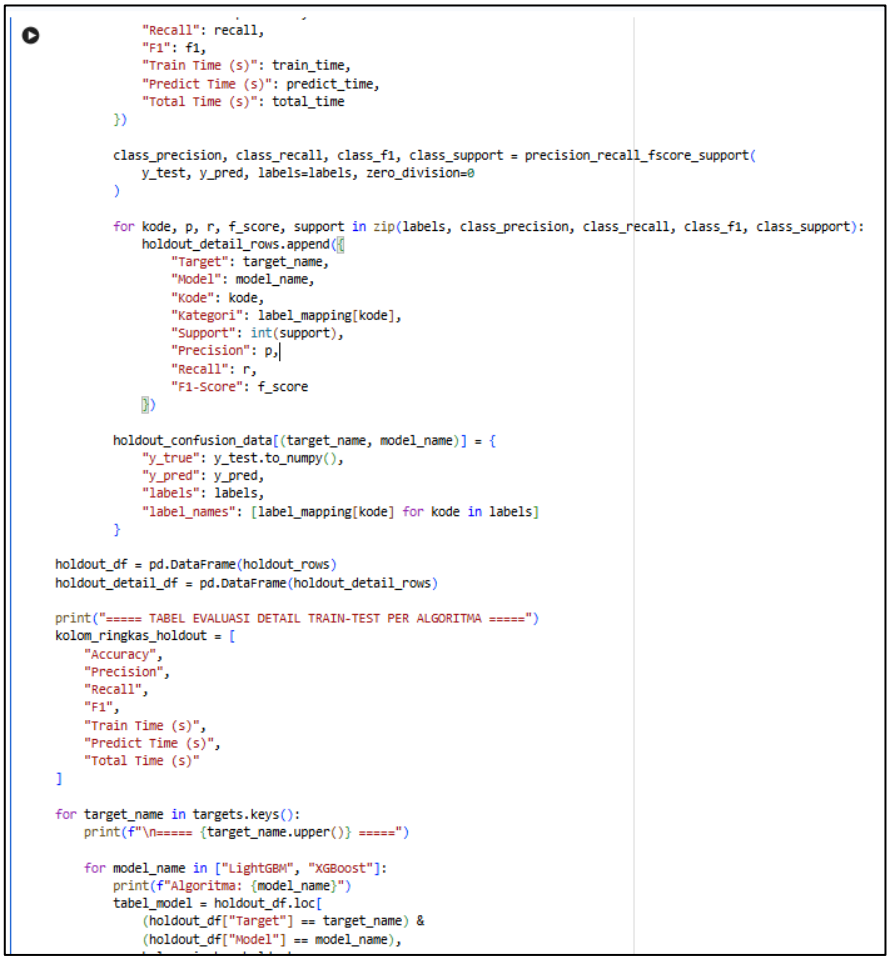
Gambar 4. 3 Cara pengujian model Evaluasi detail dan Confusion Matrix

Pada tahap lanjutan evaluasi detail, sistem menyimpan hasil pengujian model ke dalam beberapa bentuk data. Sistem mencatat nilai accuracy, precision, recall, F1-score, train time, predict time, dan total time untuk setiap algoritma.

Selain itu, sistem juga menghitung nilai evaluasi pada setiap kelas, seperti kategori Normal, Underfed, Malnutrition, atau kategori lain sesuai target yang diuji.

Sistem menyimpan hasil evaluasi per kelas yang terdiri dari kode kelas, nama kategori, jumlah data atau support, precision, recall, dan F1-score. Data ini digunakan untuk melihat kemampuan model dalam mengenali setiap kategori secara lebih rinci, bukan hanya berdasarkan nilai rata-rata keseluruhan.

Selanjutnya, sistem menyimpan data confusion matrix berupa nilai aktual, nilai prediksi, label kelas, dan nama label. Data tersebut digunakan untuk membuat visualisasi confusion matrix agar jumlah prediksi benar dan salah pada setiap kelas dapat terlihat dengan jelas. Setelah seluruh hasil evaluasi tersimpan, sistem menampilkan tabel evaluasi detail train-test untuk setiap target dan setiap algoritma. Tahapan lanjutan ini ditunjukkan pada Gambar 4.3



```
            "Recall": recall,
            "F1": f1,
            "Train Time (s)": train_time,
            "Predict Time (s)": predict_time,
            "Total Time (s)": total_time
        })

        class_precision, class_recall, class_f1, class_support = precision_recall_fscore_support(
            y_test, y_pred, labels=labels, zero_division=0
        )

        for kode, p, r, f_score, support in zip(labels, class_precision, class_recall, class_f1, class_support):
            holdout_detail_rows.append({
                "Target": target_name,
                "Model": model_name,
                "Kode": kode,
                "Kategori": label_mapping[kode],
                "Support": int(support),
                "Precision": p,
                "Recall": r,
                "F1-Score": f_score
            })

        holdout_confusion_data[(target_name, model_name)] = {
            "y_true": y_test.to_numpy(),
            "y_pred": y_pred,
            "labels": labels,
            "label_names": [label_mapping[kode] for kode in labels]
        }

holdout_df = pd.DataFrame(holdout_rows)
holdout_detail_df = pd.DataFrame(holdout_detail_rows)

print("===== TABEL EVALUASI DETAIL TRAIN-TEST PER ALGORITMA =====")
kolom_ringkas_holdout = [
    "Accuracy",
    "Precision",
    "Recall",
    "F1",
    "Train Time (s)",
    "Predict Time (s)",
    "Total Time (s)"
]

for target_name in targets.keys():
    print(f"\n===== {target_name.upper()} =====")

    for model_name in ["LightGBM", "XGBoost"]:
        print(f"Algoritma: {model_name}")
        tabel_model = holdout_df.loc[
            (holdout_df["Target"] == target_name) &
            (holdout_df["Model"] == model_name),
```

Gambar 4. 3 (Lanjutan)

Pada tahap akhir evaluasi detail, sistem menampilkan hasil evaluasi per kelas dalam bentuk tabel. Sistem mengurutkan data berdasarkan kode kelas agar hasil setiap kategori dapat dibaca secara lebih rapi dan terstruktur. Tabel tersebut memuat informasi mengenai kategori, jumlah data, precision, recall, dan F1-score untuk setiap target dan algoritma.

Setelah tabel evaluasi ditampilkan, sistem membuat visualisasi confusion matrix untuk setiap target klasifikasi, yaitu BB/U, TB/U, dan BB/TB. Sistem

menampilkan confusion matrix dari dua algoritma, yaitu LightGBM dan XGBoost, sehingga hasil prediksi kedua model dapat dibandingkan secara langsung.

Pada visualisasi confusion matrix, sistem menempatkan label prediksi pada sumbu horizontal dan label aktual pada sumbu vertikal. Tampilan ini membantu proses analisis karena jumlah prediksi benar dan salah pada setiap kelas dapat terlihat dengan lebih jelas. Tahapan pembuatan confusion matrix ini ditunjukkan pada Gambar 4.3.

```
            (holdout_detail_df["Model"] == model_name),
            kolom_detail_holdout
        ].sort_values("Kode").reset_index(drop=True)
        display(format_tabel(tabel_model, format_cols))

# Confusion matrix train-test dibuat sebelum K-Fold Cross Validation.
for target_name in targets.keys():
    fig, axes = plt.subplots(1, 2, figsize=(13, 5))
    fig.suptitle(f"Confusion Matrix Train-Test - {target_name}", fontsize=14)

    for ax, model_name in zip(axes, ["LightGBM", "XGBoost"]):
        info = holdout_confusion_data[(target_name, model_name)]
        cm = confusion_matrix(info["y_true"], info["y_pred"], labels=info["labels"])

        sns.heatmap(
            cm,
            annot=True,
            fmt="d",
            cmap="Blues",
            xticklabels=info["label_names"],
            yticklabels=info["label_names"],
            ax=ax
        )

        ax.set_title(model_name)
        ax.set_xlabel("Predicted Label")
        ax.set_ylabel("Actual Label")
        ax.tick_params(axis="x", rotation=30)
        ax.tick_params(axis="y", rotation=0)

    plt.tight_layout()
    plt.show()
```

Gambar 4. 3 (Lanjutan)

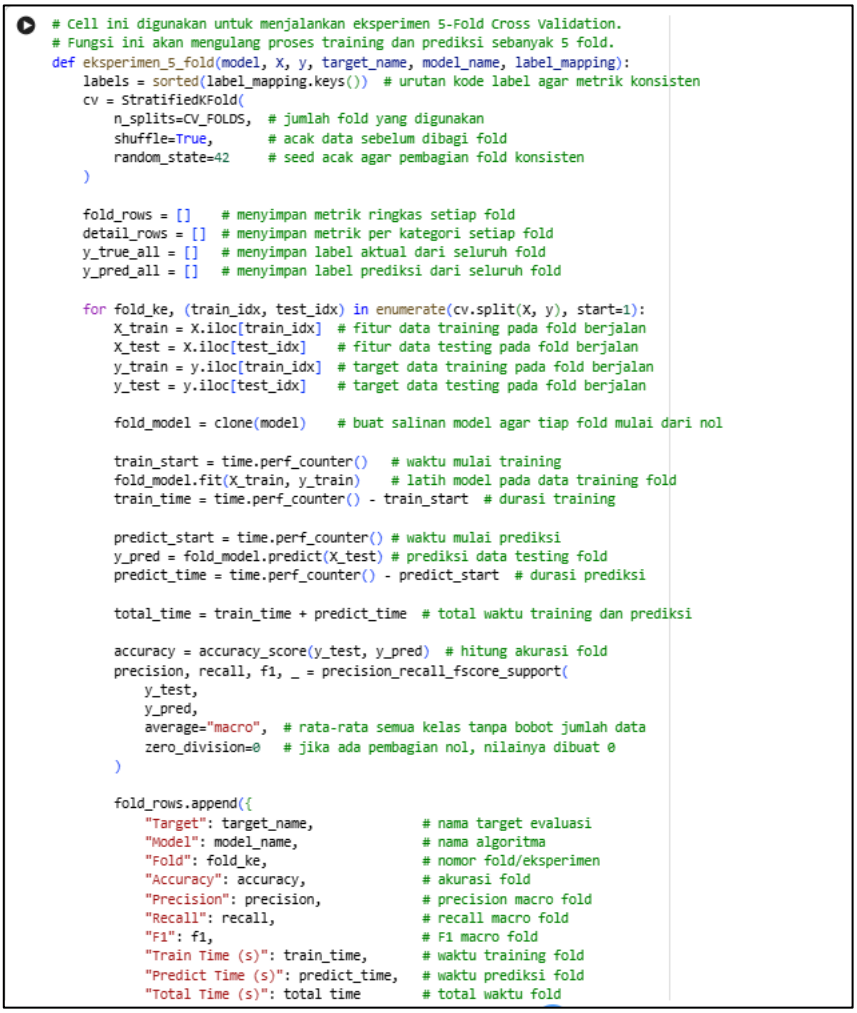
4.1.4 Cara Pengujian Fungsi Eksperimen 5-Fold Cross Validation

Pada tahap pengujian 5-Fold Cross Validation, sistem membagi dataset menjadi lima bagian atau fold dengan menggunakan metode StratifiedKFold. Sistem menggunakan metode ini agar proporsi setiap kelas pada setiap fold tetap

seimbang. Pengujian ini dilakukan untuk mengetahui kestabilan performa model ketika data latih dan data uji dibagi dalam beberapa kombinasi yang berbeda.

Sistem menjalankan proses pelatihan dan pengujian sebanyak lima kali. Pada setiap fold, sistem menggunakan sebagian data sebagai data uji dan bagian lainnya sebagai data latih. Sistem membuat salinan model pada setiap fold agar proses pelatihan dimulai dari kondisi awal yang sama. Setelah model dilatih, sistem melakukan prediksi terhadap data uji pada fold tersebut.

Sistem menghitung beberapa metrik evaluasi pada setiap fold, yaitu accuracy, precision, recall, dan F1-score. Sistem juga mencatat waktu pelatihan, waktu prediksi, dan total waktu pemrosesan untuk mengetahui efisiensi model. Seluruh hasil evaluasi pada setiap fold kemudian disimpan agar dapat dibandingkan dan dirata-ratakan pada tahap analisis berikutnya. Tahapan pengujian fungsi eksperimen 5-Fold Cross Validation ini ditampilkan pada Gambar 4.6.



```python
# Cell ini digunakan untuk menjalankan eksperimen 5-Fold Cross Validation.
# Fungsi ini akan mengulang proses training dan prediksi sebanyak 5 fold.
def eksperimen_5_fold(model, X, y, target_name, model_name, label_mapping):
    labels = sorted(label_mapping.keys())  # urutan kode label agar metrik konsisten
    cv = StratifiedKFold(
        n_splits=CV_FOLDS,  # jumlah fold yang digunakan
        shuffle=True,       # acak data sebelum dibagi fold
        random_state=42     # seed acak agar pembagian fold konsisten
    )

    fold_rows = []    # menyimpan metrik ringkas setiap fold
    detail_rows = []  # menyimpan metrik per kategori setiap fold
    y_true_all = []   # menyimpan label aktual dari seluruh fold
    y_pred_all = []   # menyimpan label prediksi dari seluruh fold

    for fold_ke, (train_idx, test_idx) in enumerate(cv.split(X, y), start=1):
        X_train = X.iloc[train_idx]  # fitur data training pada fold berjalan
        X_test = X.iloc[test_idx]    # fitur data testing pada fold berjalan
        y_train = y.iloc[train_idx]  # target data training pada fold berjalan
        y_test = y.iloc[test_idx]    # target data testing pada fold berjalan

        fold_model = clone(model)    # buat salinan model agar tiap fold mulai dari nol

        train_start = time.perf_counter()   # waktu mulai training
        fold_model.fit(X_train, y_train)    # latih model pada data training fold
        train_time = time.perf_counter() - train_start  # durasi training

        predict_start = time.perf_counter() # waktu mulai prediksi
        y_pred = fold_model.predict(X_test) # prediksi data testing fold
        predict_time = time.perf_counter() - predict_start  # durasi prediksi

        total_time = train_time + predict_time  # total waktu training dan prediksi

        accuracy = accuracy_score(y_test, y_pred)  # hitung akurasi fold
        precision, recall, f1, _ = precision_recall_fscore_support(
            y_test,
            y_pred,
            average="macro",  # rata-rata semua kelas tanpa bobot jumlah data
            zero_division=0   # jika ada pembagian nol, nilainya dibuat 0
        )

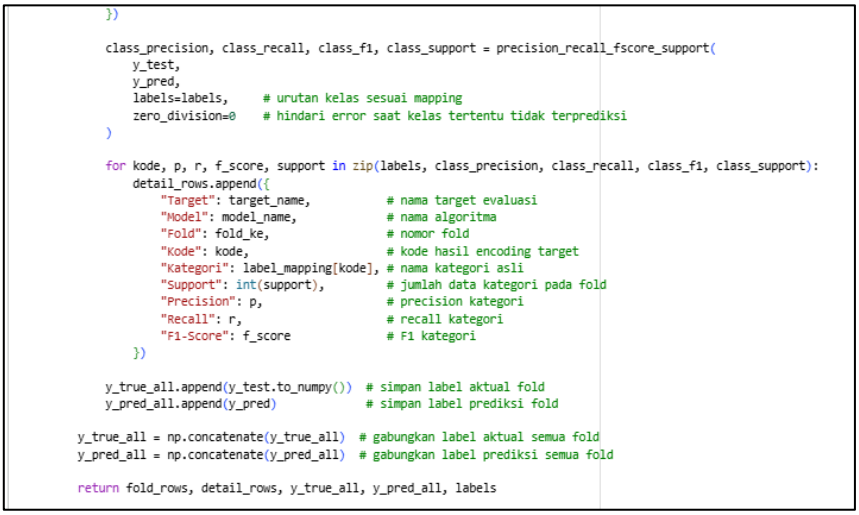
        fold_rows.append({
            "Target": target_name,              # nama target evaluasi
            "Model": model_name,                # nama algoritma
            "Fold": fold_ke,                    # nomor fold/eksperimen
            "Accuracy": accuracy,               # akurasi fold
            "Precision": precision,             # precision macro fold
            "Recall": recall,                   # recall macro fold
            "F1": f1,                           # F1 macro fold
            "Train Time (s)": train_time,       # waktu training fold
            "Predict Time (s)": predict_time,   # waktu prediksi fold
            "Total Time (s)": total time        # total waktu fold
```

Gambar 4. 4 Cara Pengujian Fungsi Eksperimen 5-Fold Cross Validation

Pada tahap pengujian ini, sistem melakukan evaluasi lanjutan pada proses 5-Fold Cross Validation dengan menghitung performa model untuk setiap kategori kelas. Sistem tidak hanya menghitung nilai evaluasi secara umum, tetapi juga menghitung nilai precision, recall, F1-score, dan support pada masing-masing kelas. Perhitungan ini dilakukan agar kemampuan model dalam mengenali setiap kategori dapat dianalisis secara lebih rinci.

Sistem mengambil label aktual dan label hasil prediksi dari setiap fold. Setelah itu, sistem menghitung metrik evaluasi berdasarkan urutan label yang sudah sesuai dengan mapping kategori. Nilai support digunakan untuk menunjukkan jumlah data pada setiap kelas, sedangkan nilai precision, recall, dan F1-score digunakan untuk menilai ketepatan model dalam memprediksi setiap kategori.

Selanjutnya, sistem menyimpan hasil evaluasi per kelas ke dalam daftar data detail. Data yang disimpan meliputi nama target, nama algoritma, nomor fold, kode kelas, nama kategori, jumlah data, precision, recall, dan F1-score. Sistem juga menyimpan seluruh label aktual dan label prediksi dari setiap fold. Setelah seluruh fold selesai diuji, sistem menggabungkan label aktual dan label prediksi tersebut untuk digunakan pada tahap analisis berikutnya, seperti pembuatan confusion matrix hasil 5-Fold Cross Validation. Tahapan pengujian ini ditunjukkan pada Gambar 4.4.



```
            })

            class_precision, class_recall, class_f1, class_support = precision_recall_fscore_support(
                y_test,
                y_pred,
                labels=labels,     # urutan kelas sesuai mapping
                zero_division=0    # hindari error saat kelas tertentu tidak terprediksi
            )

            for kode, p, r, f_score, support in zip(labels, class_precision, class_recall, class_f1, class_support):
                detail_rows.append({
                    "Target": target_name,          # nama target evaluasi
                    "Model": model_name,            # nama algoritma
                    "Fold": fold_ke,                # nomor fold
                    "Kode": kode,                   # kode hasil encoding target
                    "Kategori": label_mapping[kode], # nama kategori asli
                    "Support": int(support),        # jumlah data kategori pada fold
                    "Precision": p,                 # precision kategori
                    "Recall": r,                    # recall kategori
                    "F1-Score": f_score             # F1 kategori
                })

            y_true_all.append(y_test.to_numpy())  # simpan label aktual fold
            y_pred_all.append(y_pred)             # simpan label prediksi fold

        y_true_all = np.concatenate(y_true_all)  # gabungkan label aktual semua fold
        y_pred_all = np.concatenate(y_pred_all)  # gabungkan label prediksi semua fold

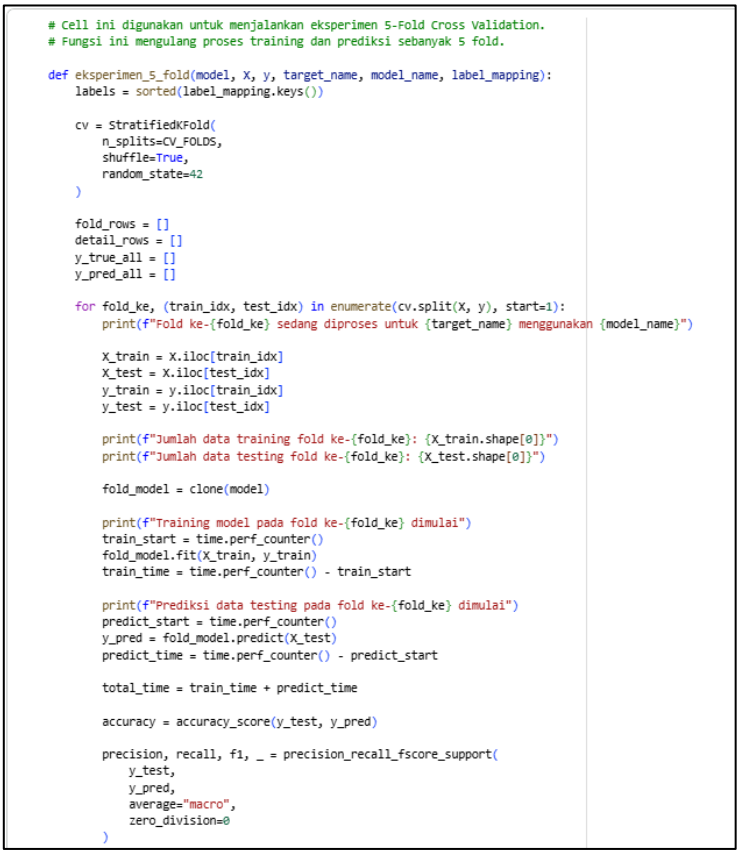
        return fold_rows, detail_rows, y_true_all, y_pred_all, labels
```

Gambar 4. 4 (Lanjutan)

Pada proses gambar 4.4 menjelaskan sistem menjalankan fungsi eksperimen 5-Fold Cross Validation untuk menguji performa model secara berulang. Sistem membagi data menjadi lima fold menggunakan metode StratifiedKFold agar proporsi setiap kelas tetap seimbang pada setiap pembagian data. Pengujian ini dilakukan untuk setiap target klasifikasi dan setiap algoritma yang digunakan.

Pada setiap fold, sistem memisahkan data menjadi data latih dan data uji. Sistem menampilkan jumlah data training dan data testing pada setiap fold agar proses pembagian data dapat dipantau dengan jelas. Setelah itu, sistem membuat salinan model menggunakan fungsi clone(model) agar model pada setiap fold dilatih dari kondisi awal yang sama.

Sistem kemudian melatih model menggunakan data training pada fold berjalan. Setelah proses pelatihan selesai, sistem melakukan prediksi terhadap data testing. Sistem juga mencatat waktu pelatihan dan waktu prediksi untuk mengetahui efisiensi proses model. Setelah prediksi dilakukan, sistem menghitung metrik evaluasi berupa accuracy, precision, recall, dan F1-score dengan rata-rata macro. Tahapan pengujian ini digunakan untuk mengetahui kestabilan dan kemampuan model dalam mengklasifikasikan setiap target pada lima pembagian data yang berbeda.



```python
# Cell ini digunakan untuk menjalankan eksperimen 5-Fold Cross Validation.
# Fungsi ini mengulang proses training dan prediksi sebanyak 5 fold.

def eksperimen_5_fold(model, X, y, target_name, model_name, label_mapping):
    labels = sorted(label_mapping.keys())

    cv = StratifiedKFold(
        n_splits=CV_FOLDS,
        shuffle=True,
        random_state=42
    )

    fold_rows = []
    detail_rows = []
    y_true_all = []
    y_pred_all = []

    for fold_ke, (train_idx, test_idx) in enumerate(cv.split(X, y), start=1):
        print(f"Fold ke-{fold_ke} sedang diproses untuk {target_name} menggunakan {model_name}")

        X_train = X.iloc[train_idx]
        X_test = X.iloc[test_idx]
        y_train = y.iloc[train_idx]
        y_test = y.iloc[test_idx]

        print(f"Jumlah data training fold ke-{fold_ke}: {X_train.shape[0]}")
        print(f"Jumlah data testing fold ke-{fold_ke}: {X_test.shape[0]}")

        fold_model = clone(model)

        print(f"Training model pada fold ke-{fold_ke} dimulai")
        train_start = time.perf_counter()
        fold_model.fit(X_train, y_train)
        train_time = time.perf_counter() - train_start

        print(f"Prediksi data testing pada fold ke-{fold_ke} dimulai")
        predict_start = time.perf_counter()
        y_pred = fold_model.predict(X_test)
        predict_time = time.perf_counter() - predict_start

        total_time = train_time + predict_time

        accuracy = accuracy_score(y_test, y_pred)

        precision, recall, f1, _ = precision_recall_fscore_support(
            y_test,
            y_pred,
            average="macro",
            zero_division=0
        )
```

Gambar 4. 4 (Lanjutan)

Pada tahap lanjutan gambar 4.4 menjelaskan pengujian 5-Fold Cross Validation, sistem menampilkan hasil evaluasi setelah setiap fold selesai diproses. Sistem menampilkan nilai accuracy, precision, recall, dan F1-score untuk setiap fold agar hasil pengujian dapat dipantau secara langsung.

Setelah nilai evaluasi dihitung, sistem menyimpan hasil setiap fold ke dalam daftar data. Data yang disimpan meliputi nama target, nama model, nomor fold, nilai accuracy, precision, recall, F1-score, waktu pelatihan, waktu prediksi, dan total waktu pemrosesan. Penyimpanan data ini dilakukan agar hasil dari seluruh fold dapat dibandingkan pada tahap analisis.

Selain evaluasi umum, sistem juga menghitung evaluasi pada setiap kategori kelas. Sistem menyimpan kode kelas, nama kategori, jumlah data atau support, precision, recall, dan F1-score untuk setiap kategori. Sistem kemudian menggabungkan seluruh label aktual dan label prediksi dari setiap fold. Data gabungan tersebut digunakan untuk membuat evaluasi lanjutan, seperti confusion matrix hasil 5-Fold Cross Validation.

```
        print(f"Fold ke-{fold_ke} selesai")
        print(f"Accuracy : {accuracy:.4f}")
        print(f"Precision: {precision:.4f}")
        print(f"Recall   : {recall:.4f}")
        print(f"F1-Score : {f1:.4f}")
        print()

        fold_rows.append({
            "Target": target_name,
            "Model": model_name,
            "Fold": fold_ke,
            "Accuracy": accuracy,
            "Precision": precision,
            "Recall": recall,
            "F1": f1,
            "Train Time (s)": train_time,
            "Predict Time (s)": predict_time,
            "Total Time (s)": total_time
        })

        class_precision, class_recall, class_f1, class_support = precision_recall_fscore_support(
            y_test,
            y_pred,
            labels=labels,
            zero_division=0
        )

        for kode, p, r, f_score, support in zip(labels, class_precision, class_recall, class_f1, class_support):
            detail_rows.append({
                "Target": target_name,
                "Model": model_name,
                "Fold": fold_ke,
                "Kode": kode,
                "Kategori": label_mapping[kode],
                "Support": int(support),
                "Precision": p,
                "Recall": r,
                "F1-Score": f_score
            })

        y_true_all.append(y_test.to_numpy())
        y_pred_all.append(y_pred)

    y_true_all = np.concatenate(y_true_all)
    y_pred_all = np.concatenate(y_pred_all)

    return fold_rows, detail_rows, y_true_all, y_pred_all, labels
```

Gambar 4. 4 (Lanjutan)

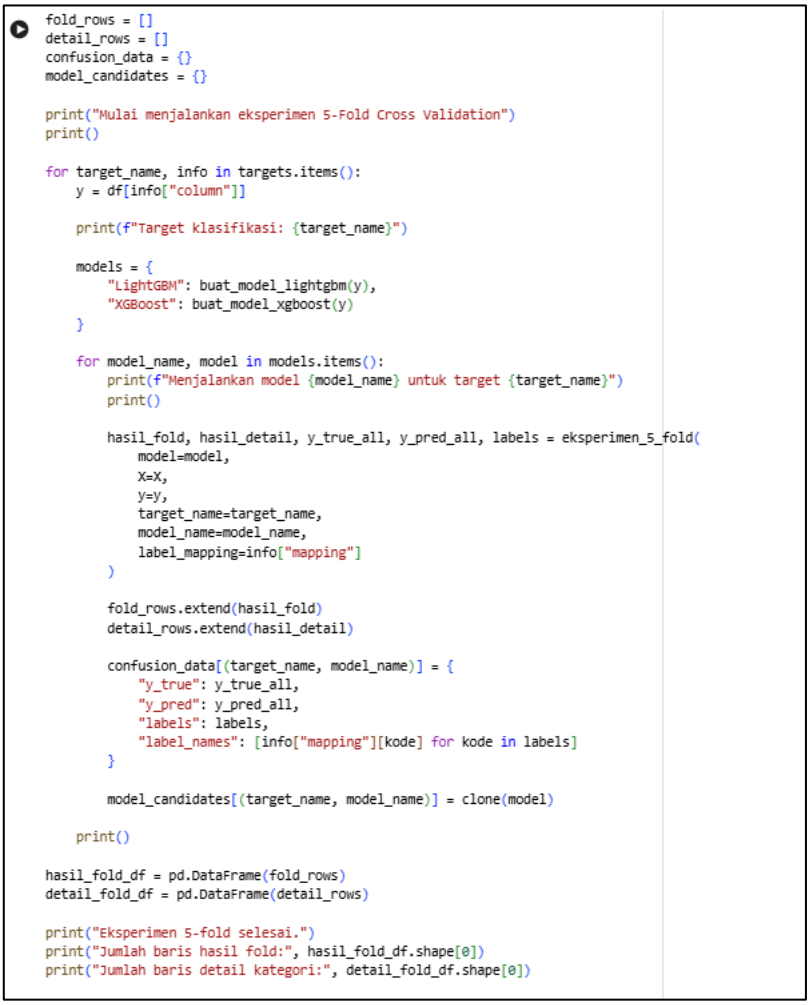
Pada proses gambar 4.4 menjelaskan sistem menjalankan eksperimen 5-Fold Cross Validation untuk setiap target klasifikasi. Sistem memproses target BB/U, TB/U, dan BB/TB secara bergantian. Pada setiap target, sistem mengambil

kolom target yang sesuai, kemudian sistem membangun dua model yang akan diuji, yaitu LightGBM dan XGBoost.

Setelah model dibuat, sistem menjalankan fungsi eksperimen 5-Fold Cross Validation pada masing-masing model. Fungsi tersebut menghasilkan data evaluasi per fold, data evaluasi per kategori, label aktual, label prediksi, dan daftar label kelas. Sistem kemudian menyimpan seluruh hasil tersebut ke dalam variabel yang sudah disiapkan.

Sistem juga menyimpan data untuk pembuatan confusion matrix, yaitu label aktual, label prediksi, kode kelas, dan nama kategori. Data ini digunakan agar hasil prediksi dari setiap model dapat divisualisasikan dan dibandingkan dengan lebih jelas. Selain itu, sistem menyimpan kandidat model dari setiap target dan algoritma untuk digunakan pada tahap pemilihan model terbaik.

Setelah seluruh proses selesai, sistem mengubah hasil evaluasi menjadi bentuk tabel menggunakan DataFrame. Proses sistem gambar 4.4 juga menampilkan jumlah baris hasil fold dan jumlah baris detail kategori sebagai tanda bahwa eksperimen 5-Fold Cross Validation telah selesai dijalankan.



```
fold_rows = []
detail_rows = []
confusion_data = {}
model_candidates = {}

print("Mulai menjalankan eksperimen 5-Fold Cross Validation")
print()

for target_name, info in targets.items():
    y = df[info["column"]]

    print(f"Target klasifikasi: {target_name}")

    models = {
        "LightGBM": buat_model_lightgbm(y),
        "XGBoost": buat_model_xgboost(y)
    }

    for model_name, model in models.items():
        print(f"Menjalankan model {model_name} untuk target {target_name}")
        print()

        hasil_fold, hasil_detail, y_true_all, y_pred_all, labels = eksperimen_5_fold(
            model=model,
            X=X,
            y=y,
            target_name=target_name,
            model_name=model_name,
            label_mapping=info["mapping"]
        )

        fold_rows.extend(hasil_fold)
        detail_rows.extend(hasil_detail)

        confusion_data[(target_name, model_name)] = {
            "y_true": y_true_all,
            "y_pred": y_pred_all,
            "labels": labels,
            "label_names": [info["mapping"][kode] for kode in labels]
        }

        model_candidates[(target_name, model_name)] = clone(model)

    print()

hasil_fold_df = pd.DataFrame(fold_rows)
detail_fold_df = pd.DataFrame(detail_rows)

print("Eksperimen 5-fold selesai.")
print("Jumlah baris hasil fold:", hasil_fold_df.shape[0])
print("Jumlah baris detail kategori:", detail_fold_df.shape[0])
```

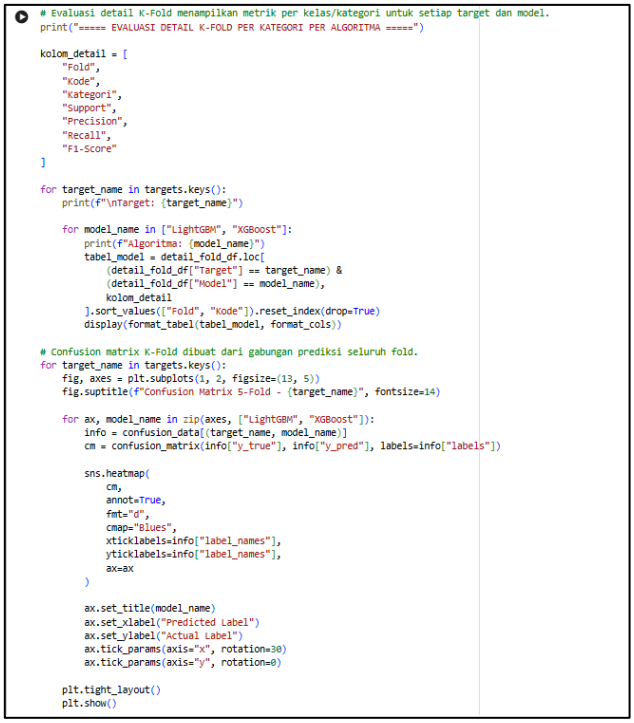
Gambar 4.4 (Lanjutan)

4.1.5 Cara pengujian Evaluasi K fold Cross Validation

Pada tahap evaluasi K-Fold Cross Validation, sistem menampilkan hasil pengujian model secara lebih rinci berdasarkan setiap target dan algoritma. Sistem menyusun tabel evaluasi per kategori untuk menampilkan nilai support, precision, recall, dan F1-score pada masing-masing kelas. Tabel ini digunakan untuk melihat kemampuan model dalam mengenali setiap kategori secara lebih detail.

Sistem menampilkan hasil evaluasi untuk setiap target klasifikasi, yaitu BB/U, TB/U, dan BB/TB. Pada setiap target, sistem membandingkan dua algoritma, yaitu LightGBM dan XGBoost. Sistem mengurutkan data berdasarkan nomor fold dan kode kelas agar hasil evaluasi dapat dibaca secara lebih rapi dan terstruktur.

Selain tabel evaluasi, sistem juga membuat confusion matrix dari gabungan hasil prediksi seluruh fold. Sistem menampilkan confusion matrix untuk setiap target dan setiap algoritma agar jumlah prediksi benar dan salah pada setiap kelas dapat terlihat dengan jelas. Pada visualisasi ini, sistem menempatkan label prediksi pada sumbu horizontal dan label aktual pada sumbu vertikal. Tahapan evaluasi K-Fold Cross Validation ini ditunjukkan pada Gambar 4.5



```
# Evaluasi detail K-Fold menampilkan metrik per kelas/kategori untuk setiap target dan model.
print("===== EVALUASI DETAIL K-FOLD PER KATEGORI PER ALGORITMA =====")

kolom_detail = [
    "Fold",
    "Kode",
    "Kategori",
    "Support",
    "Precision",
    "Recall",
    "F1-Score"
]

for target_name in targets.keys():
    print(f"\nTarget: {target_name}")

    for model_name in ["LightGBM", "XGBoost"]:
        print(f"Algoritma: {model_name}")
        tabel_model = detail_fold_df.loc[
            (detail_fold_df["Target"] == target_name) &
            (detail_fold_df["Model"] == model_name),
            kolom_detail
        ].sort_values(["Fold", "Kode"]).reset_index(drop=True)
        display(format_tabel(tabel_model, format_cols))

# Confusion matrix K-Fold dibuat dari gabungan prediksi seluruh fold.
for target_name in targets.keys():
    fig, axes = plt.subplots(1, 2, figsize=(13, 5))
    fig.suptitle(f"Confusion Matrix 5-Fold - {target_name}", fontsize=14)

    for ax, model_name in zip(axes, ["LightGBM", "XGBoost"]):
        info = confusion_data[(target_name, model_name)]
        cm = confusion_matrix(info["y_true"], info["y_pred"], labels=info["labels"])

        sns.heatmap(
            cm,
            annot=True,
            fmt="d",
            cmap="Blues",
            xticklabels=info["label_names"],
            yticklabels=info["label_names"],
            ax=ax
        )

        ax.set_title(model_name)
        ax.set_xlabel("Predicted Label")
        ax.set_ylabel("Actual Label")
        ax.tick_params(axis="x", rotation=30)
        ax.tick_params(axis="y", rotation=0)

    plt.tight_layout()
    plt.show()
```

Gambar 4. 5 Cara pengujian Evaluasi K fold Cross Validation

Pada tahap ini, sistem menampilkan tabel hasil 5-Fold Cross Validation secara ringkas untuk setiap target klasifikasi. Sistem menyusun tabel berdasarkan beberapa kolom evaluasi, yaitu Target, Model, Fold, Accuracy, Precision, Recall, F1, Train Time, Predict Time, dan Total Time. Kolom tersebut digunakan untuk menunjukkan performa model pada setiap fold sekaligus waktu komputasi yang dibutuhkan.

Sistem menampilkan hasil evaluasi untuk setiap target, yaitu BB/U, TB/U, dan BB/TB. Sistem juga memisahkan hasil berdasarkan algoritma yang digunakan, yaitu LightGBM dan XGBoost. Data hasil pengujian kemudian diurutkan berdasarkan nama model dan nomor fold agar hasil evaluasi lebih mudah dibaca dan dibandingkan.

Tabel ini digunakan untuk melihat kestabilan performa model pada setiap pembagian data. Dengan adanya tabel ini, peneliti dapat membandingkan nilai accuracy, precision, recall, dan F1-score dari setiap algoritma secara lebih terstruktur. Tahapan penampilan tabel hasil 5-Fold Cross Validation ini ditunjukkan pada Gambar 4.5.

```
# Cell ini digunakan untuk menampilkan tabel hasil 5-Fold Cross Validation.
# Format tabel mengikuti contoh: Target, Model, Fold, metrik, dan waktu komputasi.
print("===== TABEL HASIL 5-FOLD CROSS VALIDATION =====")

kolom_tabel_fold = [
    "Target",           # nama target evaluasi
    "Model",            # nama algoritma
    "Fold",             # nomor fold/eksperimen
    "Accuracy",         # akurasi fold
    "Precision",        # precision macro fold
    "Recall",           # recall macro fold
    "F1",               # F1 macro fold
    "Train Time (s)",   # waktu training
    "Predict Time (s)", # waktu prediksi
    "Total Time (s)"    # total waktu
]

for target_name in targets.keys():
    print(f"\n===== {target_name.upper()} =====")
    tabel_target = hasil_fold_df.loc[
        hasil_fold_df["Target"] == target_name, # filter target yang sedang ditampilkan
        kolom_tabel_fold                        # pilih kolom sesuai format tabel
    ].sort_values(["Model", "Fold"]).reset_index(drop=True)

    display(format_tabel(tabel_target, format_cols)) # tampilkan tabel rapi
```

Gambar 4. 5 (Lanjutan)

4.1.6 Cara Pengujian Ringkasan Eksperimen

Penelitian ini melakukan pengujian ringkasan hasil *5-Fold Cross Validation* untuk mengetahui performa umum dan kestabilan model pada setiap target klasifikasi. Sistem menggunakan hasil evaluasi dari setiap *fold* sebagai data utama dalam proses pengujian. Gambar 4.6 menampilkan proses pengujian ringkasan rata-rata dan standar deviasi tersebut.

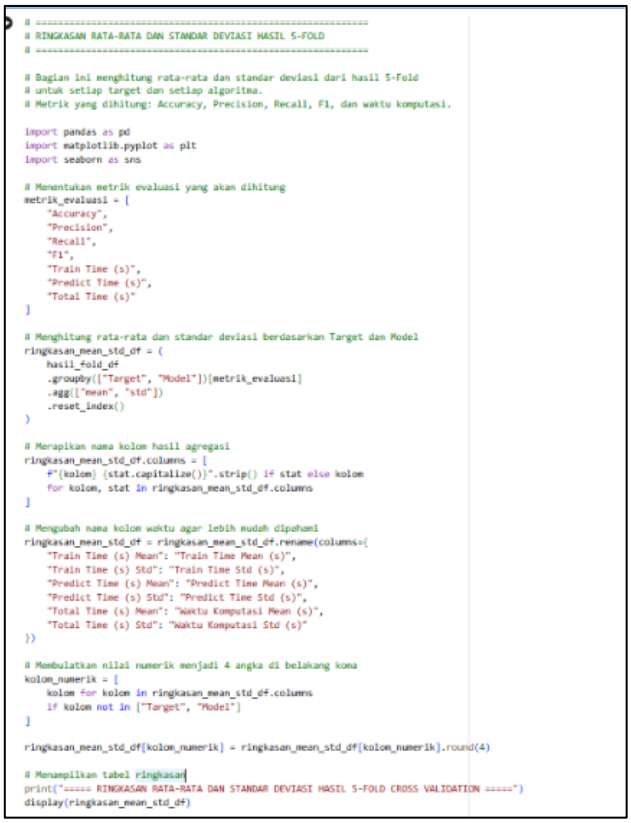
Sistem mengelompokkan data berdasarkan target klasifikasi dan model yang digunakan. Model yang digunakan dalam pengujian ini adalah *LightGBM* dan *XGBoost*. Setelah itu, sistem menghitung nilai rata-rata dan standar deviasi dari beberapa metrik evaluasi.

Metrik evaluasi yang digunakan terdiri dari *accuracy*, *precision*, *recall*, *F1-score*, *train time*, *predict time*, dan *total time*. Nilai rata-rata menunjukkan

gambaran umum performa model pada seluruh *fold*. Standar deviasi menunjukkan tingkat kestabilan model terhadap pembagian data yang berbeda.

Sistem juga merapikan nama kolom hasil perhitungan agar hasil pengujian lebih mudah dibaca. Sistem mengubah istilah *Total Time* menjadi waktu komputasi agar makna kolom lebih mudah dipahami. Pada tahap akhir, sistem membulatkan nilai numerik menjadi empat angka di belakang koma.

Pembulatan nilai dilakukan agar hasil ringkasan terlihat lebih rapi dan konsisten saat disajikan dalam tabel. Dengan demikian, proses pada Gambar 4.13 menghasilkan ringkasan performa model yang dapat digunakan untuk membandingkan algoritma *LightGBM* dan *XGBoost* pada setiap target klasifikasi.



```
# ============================================================
# RINGKASAN RATA-RATA DAN STANDAR DEVIASI HASIL 5-FOLD
# ============================================================

# Bagian ini menghitung rata-rata dan standar deviasi dari hasil 5-Fold
# untuk setiap target dan setiap algoritma.
# Metrik yang dihitung: Accuracy, Precision, Recall, F1, dan waktu komputasi.

import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# Menentukan metrik evaluasi yang akan dihitung
metrik_evaluasi = [
    "Accuracy",
    "Precision",
    "Recall",
    "F1",
    "Train Time (s)",
    "Predict Time (s)",
    "Total Time (s)"
]

# Menghitung rata-rata dan standar deviasi berdasarkan Target dan Model
ringkasan_mean_std_df = (
    hasil_fold_df
    .groupby(["Target", "Model"])[metrik_evaluasi]
    .agg(["mean", "std"])
    .reset_index()
)

# Merapikan nama kolom hasil agregasi
ringkasan_mean_std_df.columns = [
    f"{kolom} {stat.capitalize()}".strip() if stat else kolom
    for kolom, stat in ringkasan_mean_std_df.columns
]

# Mengubah nama kolom waktu agar lebih mudah dipahami
ringkasan_mean_std_df = ringkasan_mean_std_df.rename(columns={
    "Train Time (s) Mean": "Train Time Mean (s)",
    "Train Time (s) Std": "Train Time Std (s)",
    "Predict Time (s) Mean": "Predict Time Mean (s)",
    "Predict Time (s) Std": "Predict Time Std (s)",
    "Total Time (s) Mean": "Waktu Komputasi Mean (s)",
    "Total Time (s) Std": "Waktu Komputasi Std (s)"
})

# Membulatkan nilai numerik menjadi 4 angka di belakang koma
kolom_numerik = [
    kolom for kolom in ringkasan_mean_std_df.columns
    if kolom not in ["Target", "Model"]
]

ringkasan_mean_std_df[kolom_numerik] = ringkasan_mean_std_df[kolom_numerik].round(4)

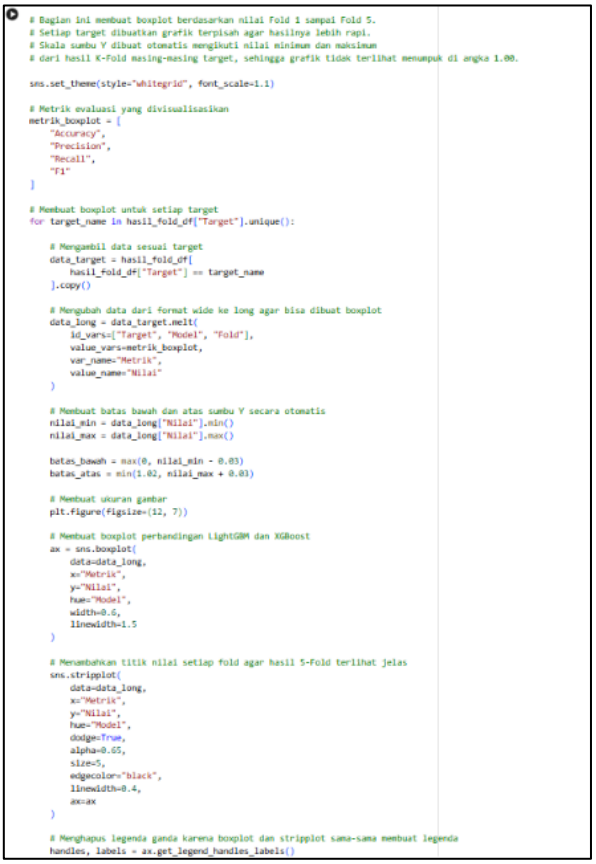
# Menampilkan tabel ringkasan
print("===== RINGKASAN RATA-RATA DAN STANDAR DEVIASI HASIL 5-FOLD CROSS VALIDATION =====")
display(ringkasan_mean_std_df)
```

Gambar 4. 6 Cara Pengujian Ringkasan Eksperimen

4.1.7 Cara Pengujian Boxplot Perbandingan Algoritma

Penelitian ini menggunakan visualisasi *boxplot* untuk membandingkan performa model *LightGBM* dan *XGBoost* pada hasil *5-Fold Cross Validation*. Sistem memanfaatkan nilai evaluasi dari setiap *fold* untuk melihat pola sebaran performa model pada setiap target klasifikasi. Tahap awal pembuatan visualisasi *boxplot* ditunjukkan pada Gambar 4.7.

Pada Gambar 4.7, sistem menetapkan metrik evaluasi yang akan ditampilkan dalam grafik. Metrik tersebut meliputi *accuracy*, *precision*, *recall*, dan *F1-score*. Setelah metrik ditentukan, sistem mengambil data berdasarkan masing-masing target klasifikasi, yaitu *Weight for Age*, *Height for Age*, dan *Weight for Height*. Sistem kemudian mengubah bentuk data dari format lebar menjadi format panjang agar data dapat divisualisasikan dalam bentuk *boxplot* berdasarkan metrik evaluasi dan model yang digunakan.



```
# Bagian ini membuat boxplot berdasarkan nilai Fold 1 sampai Fold 5.
# Setiap target dibuatkan grafik terpisah agar hasilnya lebih rapi.
# Skala sumbu Y dibuat otomatis mengikuti nilai minimum dan maksimum
# dari hasil K-Fold masing-masing target, sehingga grafik tidak terlihat menumpuk di angka 1.00.

sns.set_theme(style="whitegrid", font_scale=1.1)

# Metrik evaluasi yang divisualisasikan
metrik_boxplot = [
    "Accuracy",
    "Precision",
    "Recall",
    "F1"
]

# Membuat boxplot untuk setiap target
for target_name in hasil_fold_df["Target"].unique():

    # Mengambil data sesuai target
    data_target = hasil_fold_df[
        hasil_fold_df["Target"] == target_name
    ].copy()

    # Mengubah data dari format wide ke long agar bisa dibuat boxplot
    data_long = data_target.melt(
        id_vars=["Target", "Model", "Fold"],
        value_vars=metrik_boxplot,
        var_name="Metrik",
        value_name="Nilai"
    )

    # Membuat batas bawah dan atas sumbu Y secara otomatis
    nilai_min = data_long["Nilai"].min()
    nilai_max = data_long["Nilai"].max()

    batas_bawah = max(0, nilai_min - 0.03)
    batas_atas = min(1.02, nilai_max + 0.01)

    # Membuat ukuran gambar
    plt.figure(figsize=(12, 7))

    # Membuat boxplot perbandingan LightGBM dan XGBoost
    ax = sns.boxplot(
        data=data_long,
        x="Metrik",
        y="Nilai",
        hue="Model",
        width=0.6,
        linewidth=1.5
    )

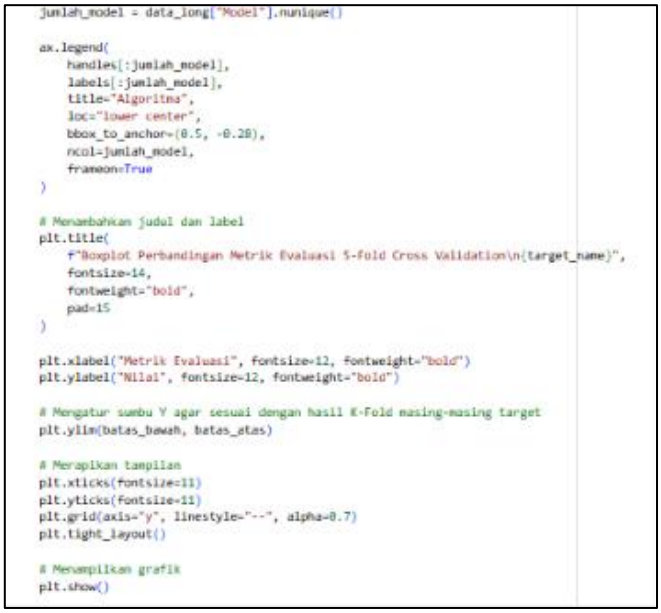
    # Menambahkan titik nilai setiap fold agar hasil 5-Fold terlihat jelas
    sns.stripplot(
        data=data_long,
        x="Metrik",
        y="Nilai",
        hue="Model",
        dodge=True,
        alpha=0.65,
        size=5,
        edgecolor="black",
        linewidth=0.4,
        ax=ax
    )

    # Menghapus legenda ganda karena boxplot dan stripplot sama-sama membuat legenda
    handles, labels = ax.get_legend_handles_labels()
```

Gambar 4. 7 Cara Pengujian Boxplot Perbandingan Algoritma

Sistem juga mengatur batas bawah dan batas atas pada sumbu Y secara otomatis. Sistem menentukan batas tersebut berdasarkan nilai minimum dan maksimum dari seluruh metrik evaluasi. Pengaturan ini membantu grafik menampilkan perbedaan nilai antar model dengan lebih jelas dan tidak terlalu rapat. Setelah batas sumbu ditentukan, sistem membuat *boxplot* untuk menampilkan perbandingan persebaran nilai antara model *LightGBM* dan *XGBoost*.

Tahap lanjutan pembuatan visualisasi *boxplot* ditunjukkan pada Gambar 4.7. Pada tahap ini, sistem menambahkan titik data menggunakan *stripplot*. Titik data tersebut menunjukkan nilai evaluasi dari setiap *fold*. Dengan adanya titik data, pengguna dapat melihat variasi nilai pada setiap *fold* secara lebih rinci, bukan hanya melihat ringkasan persebaran melalui *boxplot*.



```
    jumlah_model = data_long["Model"].nunique()

    ax.legend(
        handles[:jumlah_model],
        labels[:jumlah_model],
        title="Algoritma",
        loc="lower center",
        bbox_to_anchor=(0.5, -0.28),
        ncol=jumlah_model,
        frameon=True
    )

    # Menambahkan judul dan label
    plt.title(
        f"Boxplot Perbandingan Metrik Evaluasi 5-Fold Cross Validation\n{target_name}",
        fontsize=14,
        fontweight="bold",
        pad=15
    )

    plt.xlabel("Metrik Evaluasi", fontsize=12, fontweight="bold")
    plt.ylabel("Nilai", fontsize=12, fontweight="bold")

    # Mengatur sumbu Y agar sesuai dengan hasil K-Fold masing-masing target
    plt.ylim(batas_bawah, batas_atas)

    # Merapikan tampilan
    plt.xticks(fontsize=11)
    plt.yticks(fontsize=11)
    plt.grid(axis="y", linestyle="--", alpha=0.7)
    plt.tight_layout()

    # Menampilkan grafik
    plt.show()
```

Gambar 4. 7 (Lanjutan)

Selain itu, sistem mengatur legenda, judul grafik, label sumbu X, label sumbu Y, batas sumbu Y, dan garis bantu pada grafik. Sistem juga merapikan tata letak grafik agar hasil visualisasi dapat ditampilkan dengan jelas dan tidak terpotong. Dengan demikian, proses pada Gambar 4.7 menghasilkan visualisasi *boxplot* yang dapat digunakan untuk membandingkan kestabilan performa model *LightGBM* dan *XGBoost* pada setiap target klasifikasi.

4.1.8 Cara Pengujian Boxplot Waktu Komputasi

Penelitian ini menggunakan visualisasi *boxplot* untuk membandingkan waktu komputasi model *LightGBM* dan *XGBoost* pada hasil *5-Fold Cross Validation*. Sistem menggunakan nilai *Total Time* sebagai dasar perbandingan karena nilai tersebut mencakup waktu pelatihan dan waktu prediksi model. Proses pembuatan visualisasi waktu komputasi tersebut ditampilkan pada Gambar 4.8.

Pada Gambar 4.8, sistem mengambil data berdasarkan target klasifikasi yang sedang diproses. Target tersebut terdiri dari *Weight for Age*, *Height for Age*, dan *Weight for Height*. Sistem memisahkan data pada setiap target agar perbandingan waktu komputasi dapat ditampilkan secara lebih jelas untuk masing-masing target.

Setelah data target dipilih, sistem membuat grafik *boxplot* dengan menggunakan kolom *Model* sebagai sumbu X dan kolom *Total Time* sebagai sumbu Y. Sumbu X menunjukkan algoritma yang digunakan, yaitu *LightGBM* dan *XGBoost*. Sumbu Y menunjukkan waktu komputasi dalam satuan detik.

Sistem juga menambahkan titik data menggunakan *stripplot*. Titik data tersebut menunjukkan nilai waktu komputasi pada setiap *fold*. Penambahan titik data membantu pengguna melihat variasi waktu komputasi dari masing-masing model secara lebih rinci.

Pada tahap akhir, sistem menambahkan judul grafik, label sumbu, garis bantu, dan pengaturan tata letak. Pengaturan tersebut dilakukan agar grafik dapat ditampilkan dengan rapi dan mudah dibaca. Dengan demikian, proses pada

Gambar 4.8 menghasilkan visualisasi yang dapat digunakan untuk membandingkan efisiensi waktu komputasi model *LightGBM* dan *XGBoost* pada setiap target klasifikasi.

```
# Bagian ini membuat boxplot waktu komputasi berdasarkan Total Time (s).
# Total Time (s) digunakan karena sudah mencakup waktu training dan prediksi.

for target_name in hasil_fold_df["Target"].unique():

    # Mengambil data sesuai target
    data_target = hasil_fold_df[
        hasil_fold_df["Target"] == target_name
    ].copy()

    # Membuat ukuran gambar
    plt.figure(figsize=(9, 6))

    # Membuat boxplot waktu komputasi
    ax = sns.boxplot(
        data=data_target,
        x="Model",
        y="Total Time (s)",
        width=0.5,
        linewidth=1.5
    )

    # Menambahkan titik setiap fold agar variasi waktu komputasi terlihat
    sns.stripplot(
        data=data_target,
        x="Model",
        y="Total Time (s)",
        alpha=0.7,
        size=6,
        edgecolor="black",
        linewidth=0.4,
        ax=ax
    )

    # Menambahkan judul dan label
    plt.title(
        f"Boxplot Perbandingan Waktu Komputasi 5-Fold Cross Validation\n{target_name}",
        fontsize=14,
        fontweight="bold",
        pad=15
    )

    plt.xlabel("Algoritma", fontsize=12, fontweight="bold")
    plt.ylabel("Waktu Komputasi (detik)", fontsize=12, fontweight="bold")

    # Merapikan tampilan
    plt.xticks(fontsize=11)
    plt.yticks(fontsize=11)
    plt.grid(axis="y", linestyle="--", alpha=0.7)
    plt.tight_layout()

    # Menampilkan grafik
    plt.show()
```

Gambar 4. 8 Cara Pengujian Boxplot Waktu Komputasi

4.1.9 Pilih Model Terbaik

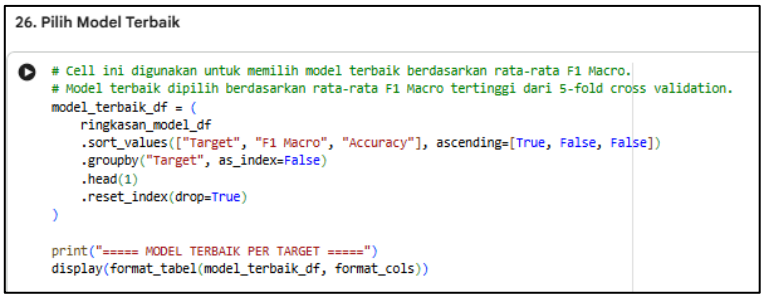
Pada tahap ini, perancang menentukan model terbaik untuk setiap target klasifikasi berdasarkan hasil evaluasi yang diperoleh dari 5-fold cross validation. Tujuan dari tahap ini adalah untuk memilih model yang memiliki performa paling

baik dan paling sesuai pada masing-masing target, sehingga model yang digunakan pada tahap akhir benar-benar berasal dari hasil pengujian yang telah dilakukan sebelumnya. Proses pemilihan model terbaik dilakukan menggunakan data ringkasan evaluasi yang tersimpan dalam ringkasan_model_df. Dari data tersebut, perancang mengurutkan hasil berdasarkan target, F1 Macro, dan accuracy. Pengurutan ini menunjukkan bahwa F1 Macro dijadikan sebagai acuan utama dalam pemilihan model, karena metrik ini dapat memberikan gambaran performa model yang lebih seimbang pada seluruh kelas. Sementara itu, accuracy digunakan sebagai nilai pendukung untuk membantu membedakan hasil yang nilainya berdekatan.

Setelah hasil diurutkan, data kemudian dikelompokkan berdasarkan masing-masing target. Dari setiap target, diambil satu hasil teratas yang menunjukkan model dengan performa terbaik. Dengan cara ini, setiap target klasifikasi akan memiliki satu model yang dipilih sebagai model terbaik dari perbandingan algoritma LightGBM dan XGBoost. Hasil akhir tersebut kemudian dirapikan kembali agar lebih mudah dibaca dan ditampilkan dalam bentuk tabel. Melalui tahap ini, perancang dapat menentukan model yang paling optimal untuk setiap target klasifikasi berdasarkan hasil evaluasi yang telah dilakukan secara menyeluruh. Model yang terpilih inilah yang kemudian digunakan sebagai model akhir karena dinilai memberikan performa terbaik pada target yang bersangkutan.

Gambar 4.9 menjelaskan proses pemilihan model terbaik untuk setiap target klasifikasi berdasarkan hasil evaluasi 5-fold cross validation. Dari gambar tersebut,

perancang dapat melihat bahwa model dipilih berdasarkan nilai F1 Macro tertinggi, dengan accuracy sebagai nilai pendukung, sehingga model yang terpilih merupakan model yang memiliki performa paling baik pada masing-masing target.



Gambar 4. 9 Pilih Model Terbaik

4.1.10 Cara Pengujian Latih Ulang dan Simpan Model Terbaik

Pada pengujian gambar 4.10 menjelaskan sistem melatih ulang dan menyimpan model terbaik berdasarkan hasil evaluasi sebelumnya. Sistem terlebih dahulu membuat folder model_terbaik sebagai tempat penyimpanan model. Setelah itu, sistem mengambil data model terbaik dari tabel model_terbaik_df, yang berisi target klasifikasi dan algoritma terbaik untuk setiap target.

Sistem mengambil kandidat model terbaik, kemudian sistem melatih ulang model tersebut menggunakan seluruh data fitur dan target. Proses pelatihan ulang ini dilakukan agar model akhir dapat mempelajari seluruh data yang tersedia sebelum digunakan pada aplikasi.

Setelah proses pelatihan selesai, sistem menyimpan model terbaik dalam format .pkl menggunakan joblib. Sistem juga menyimpan informasi tambahan dalam bentuk file best_models_info.json, seperti nama model, lokasi file model,

daftar fitur yang digunakan, dan mapping label setiap target. Informasi tersebut digunakan agar model dapat dipanggil kembali dengan benar saat proses prediksi pada aplikasi dilakukan.

```python
# Cell ini digunakan untuk melatih ulang dan menyimpan model terbaik.
# Folder output untuk model terbaik.
MODEL_DIR = Path("model_terbaik")
MODEL_DIR.mkdir(exist_ok=True)

best_models = {}

for _, row in model_terbaik_df.iterrows():
    target_name = row["Target"]
    model_name = row["Model"]
    y = df[targets[target_name]["column"]]

    # Ambil kandidat model terbaik, lalu latih ulang menggunakan seluruh data.
    best_model = clone(model_candidates[(target_name, model_name)])
    best_model.fit(X, y)

    safe_target_name = target_name.lower().replace(" ", "_")
    model_path = MODEL_DIR / f"best_model_{safe_target_name}_{model_name.lower()}.pkl"
    joblib.dump(best_model, model_path)

    best_models[target_name] = {
        "model_name": model_name,
        "model_path": str(model_path),
        "features": fitur_model,
        "label_mapping": targets[target_name]["mapping"]
    }

    print(f"Model terbaik {target_name} ({model_name}) disimpan ke: {model_path}")

BEST_MODELS_INFO_PATH = MODEL_DIR / "best_models_info.json"
with open(BEST_MODELS_INFO_PATH, "w", encoding="utf-8") as f:
    json.dump(best_models, f, indent=4)

print("Informasi model terbaik disimpan ke:", BEST_MODELS_INFO_PATH)
```

Gambar 4. 10 Cara Pengujian Latih Ulang dan Simpan Model Terbaik

4.1.8 Cara Pengujian BlackBox Testing

Peneliti menggunakan metode Black Box Testing untuk menguji fungsi-fungsi pada aplikasi GrowSmart Health. Pengujian ini berfokus pada kesesuaian antara tindakan pengguna dan keluaran yang diberikan oleh sistem tanpa meninjau kode program yang membangun aplikasi. Melalui pengujian ini, peneliti

dapat memastikan bahwa setiap fitur dapat digunakan sesuai dengan tujuan dan alur yang telah dirancang.

Peneliti menyusun 32 skenario pengujian yang mencakup fungsi utama dan fungsi pendukung aplikasi. Skenario tersebut meliputi proses autentikasi, navigasi halaman, pengisian data balita, validasi masukan, proses klasifikasi, penyajian hasil pemeriksaan, panduan gizi, riwayat pemeriksaan, respons tampilan, dan proses logout. Penguji menjalankan setiap skenario, kemudian membandingkan keluaran sistem dengan hasil yang diharapkan.

Pada tahap awal, penguji membuka aplikasi, melakukan registrasi akun, dan masuk ke dalam sistem melalui halaman login. Penguji juga memasukkan beberapa kondisi yang tidak sesuai, seperti data registrasi yang belum lengkap, email yang telah terdaftar, serta email atau password yang salah. Tahap ini bertujuan untuk memastikan bahwa sistem dapat menerima data autentikasi yang benar dan memberikan peringatan ketika pengguna memasukkan data yang tidak sesuai.

Selanjutnya, penguji membuka halaman pemeriksaan dan mengisi data balita yang diperlukan oleh sistem. Data tersebut terdiri atas nama balita, jenis kelamin, tanggal lahir, tanggal pengukuran, usia dalam bulan, berat badan, dan tinggi badan. Penguji juga melakukan pengujian terhadap validasi masukan dengan mengosongkan data wajib, memasukkan huruf pada kolom numerik, memasukkan angka nol, serta memasukkan nilai berat badan atau tinggi badan

yang tidak wajar. Tahap ini bertujuan untuk memastikan bahwa sistem dapat mencegah proses analisis terhadap data yang tidak valid.

Setelah penguji mengisi seluruh data dengan benar, penguji menjalankan proses analisis untuk memastikan bahwa sistem dapat menampilkan hasil klasifikasi berdasarkan indikator BB/U, TB/U, dan BB/TB. Penguji kemudian memeriksa halaman hasil analisis, fungsi penyimpanan hasil ke dalam riwayat, tampilan panduan gizi, fungsi penampilan dan penghapusan riwayat pemeriksaan, respons tampilan aplikasi, serta fungsi logout.

Penguji memberikan status Diterima apabila sistem menampilkan hasil yang sesuai dengan hasil yang diharapkan. Sebaliknya, penguji memberikan status Perbaikan apabila sistem belum menjalankan fungsi sesuai dengan rancangan. Daftar skenario yang digunakan pada proses pengujian Black Box Testing disajikan pada Tabel 4.1.

Tabel 4. 1 Pertanyaan BlackBox Testing

No.	**Fitur yang Diuji**	**Skenario Pengujian**	**Hasil yang Diharapkan**
1	Autentikasi dan Navigasi Dasar	Penguji membuka aplikasi GrowSmart Health.	Sistem menampilkan halaman awal atau halaman login aplikasi.
2	Autentikasi dan Navigasi Dasar	Penguji memilih menu Register, mengisi nama, email, dan password, kemudian menekan tombol Daftar.	Sistem membuat akun baru, menampilkan pemberitahuan pendaftaran berhasil, dan mengarahkan pengguna ke halaman login.
3	Autentikasi dan Navigasi Dasar	Penguji mengisi formulir registrasi dengan data yang belum lengkap.	Sistem menampilkan peringatan bahwa pengguna wajib mengisi seluruh data.

Tabel 4.1 (Lanjutan)

No.	Fitur yang Diuji	Skenario Pengujian	Hasil yang Diharapkan
4	Autentikasi dan Navigasi Dasar	Penguji melakukan registrasi menggunakan email yang telah terdaftar.	Sistem menampilkan informasi bahwa email telah digunakan atau akun telah terdaftar.
5	Autentikasi dan Navigasi Dasar	Penguji memasukkan email dan password yang valid, kemudian menekan tombol Login.	Sistem menerima proses login dan menampilkan halaman utama aplikasi.
6	Autentikasi dan Navigasi Dasar	Penguji memasukkan email atau password yang salah.	Sistem menolak proses login dan menampilkan pesan bahwa email atau password tidak sesuai.
7	Navigasi Dasar	Penguji menekan menu Beranda.	Sistem menampilkan halaman beranda yang memuat informasi utama aplikasi GrowSmart Health.
8	Navigasi Dasar	Penguji menekan menu Pemeriksaan atau tombol Mulai Pemeriksaan.	Sistem menampilkan halaman formulir pemeriksaan data balita.
9	Navigasi Dasar	Penguji menekan menu Riwayat.	Sistem menampilkan halaman riwayat pemeriksaan yang telah tersimpan.
10	Form Pemeriksaan Balita	Penguji membuka halaman pemeriksaan dan mengisi data balita secara lengkap.	Sistem menerima data nama balita, jenis kelamin, tanggal lahir, tanggal pengukuran, usia, berat badan, dan tinggi badan.
11	Form Pemeriksaan Balita	Penguji memilih jenis kelamin balita.	Sistem menyimpan pilihan jenis kelamin sesuai dengan masukan pengguna, yaitu laki-laki atau perempuan.
12	Form Pemeriksaan Balita	Penguji memasukkan tanggal lahir dan tanggal pengukuran balita.	Sistem menerima data tanggal dan menampilkan usia balita dalam satuan bulan sesuai dengan data yang dimasukkan.

Tabel 4.1 (Lanjutan)

No.	Fitur yang Diuji	Skenario Pengujian	Hasil yang Diharapkan
13	Form Pemeriksaan Balita	Penguji memasukkan berat badan balita dalam satuan kilogram.	Sistem menerima nilai berat badan dan menggunakan data tersebut dalam proses analisis.
14	Form Pemeriksaan Balita	Penguji memasukkan tinggi badan balita dalam satuan sentimeter.	Sistem menerima nilai tinggi badan dan menggunakan data tersebut dalam proses analisis.
15	Validasi Input Pemeriksaan	Penguji menekan tombol Analisis Sekarang tanpa melengkapi salah satu data wajib.	Sistem menampilkan peringatan bahwa pengguna wajib mengisi seluruh data pemeriksaan.
16	Validasi Input Pemeriksaan	Penguji memasukkan huruf pada kolom berat badan atau tinggi badan.	Sistem menolak masukan tersebut dan meminta pengguna memasukkan data dalam bentuk angka.
17	Validasi Input Pemeriksaan	Penguji memasukkan nilai nol pada kolom berat badan atau tinggi badan.	Sistem menampilkan peringatan bahwa nilai yang dimasukkan tidak valid.
18	Validasi Input Pemeriksaan	Penguji memasukkan nilai berat badan atau tinggi badan yang tidak wajar.	Sistem menampilkan peringatan agar pengguna memeriksa kembali data yang dimasukkan.
19	Proses Klasifikasi	Penguji mengisi seluruh data balita dengan benar, kemudian menekan tombol Analisis Sekarang.	Sistem memproses data dan menampilkan hasil analisis status pertumbuhan serta gizi balita.
20	Proses Klasifikasi BB/U	Sistem memproses data balita berdasarkan indikator berat badan menurut umur.	Sistem menampilkan hasil klasifikasi Weight for Age / BB/U sesuai dengan data balita.
21	Proses Klasifikasi TB/U	Sistem memproses data balita berdasarkan indikator tinggi badan menurut umur.	Sistem menampilkan hasil klasifikasi Height for Age / TB/U sesuai dengan data balita.

Tabel 4.1 (Lanjutan)

No.	Fitur yang Diuji	Skenario Pengujian	Hasil yang Diharapkan
22	Proses Klasifikasi BB/TB	Sistem memproses data balita berdasarkan indikator berat badan menurut tinggi badan.	Sistem menampilkan hasil klasifikasi Weight for Height / BB/TB sesuai dengan data balita.
23	Halaman Hasil Pemeriksaan	Penguji melihat halaman hasil setelah sistem menyelesaikan proses analisis.	Sistem menampilkan hasil pemeriksaan BB/U, TB/U, dan BB/TB secara jelas.
24	Halaman Hasil Pemeriksaan	Penguji membaca interpretasi hasil klasifikasi yang ditampilkan oleh sistem.	Sistem menampilkan kategori hasil dan penjelasan yang mudah dipahami oleh pengguna.
25	Halaman Hasil Pemeriksaan	Penguji menyimpan hasil pemeriksaan yang telah ditampilkan.	Sistem menyimpan data balita dan hasil klasifikasi ke dalam riwayat pemeriksaan.
26	Panduan Gizi	Penguji menekan menu Panduan Gizi pada aplikasi.	Sistem menampilkan halaman Panduan Gizi.
27	Panduan Gizi	Penguji membaca informasi pada halaman Panduan Gizi.	Sistem menampilkan informasi mengenai indikator dan kategori status gizi balita secara jelas dan mudah dipahami.
28	Riwayat Pemeriksaan	Penguji membuka halaman Riwayat setelah menyimpan hasil pemeriksaan.	Sistem menampilkan daftar hasil pemeriksaan yang telah tersimpan.
29	Riwayat Pemeriksaan	Penguji memilih salah satu data pada halaman riwayat pemeriksaan.	Sistem menampilkan informasi data balita dan hasil klasifikasi dari riwayat yang dipilih.
30	Riwayat Pemeriksaan	Penguji menghapus salah satu data riwayat pemeriksaan.	Sistem menghapus data yang dipilih dan memperbarui daftar riwayat pemeriksaan.
31	Respons Tampilan	Penguji membuka aplikasi melalui perangkat dengan	Sistem tetap menampilkan komponen halaman secara rapi dan aplikasi tetap dapat digunakan dengan baik.

Tabel 4.1 (Lanjutan)

No.	Fitur yang Diuji	Skenario Pengujian	Hasil yang Diharapkan
		ukuran layar yang berbeda.	
32	Logout	Penguji menekan tombol Logout.	Sistem mengeluarkan pengguna dari akun dan menampilkan kembali halaman login atau halaman awal.

4.1.9 Cara Pengujian Validasi Ahli

Tahap validasi ahli bertujuan untuk memastikan bahwa aplikasi GrowSmart Health menghasilkan analisis yang sesuai dengan kebutuhan pengguna dan kaidah keilmuan di bidang kesehatan anak serta gizi. Tahap ini juga menilai hasil klasifikasi status pertumbuhan balita agar tetap relevan, mudah dipahami, dan aman digunakan sebagai alat bantu skrining awal.

Penelitian ini menggunakan metode Expert Review pada tahap validasi ahli. Metode ini dilakukan melalui peninjauan langsung oleh ahli terhadap alur aplikasi, data masukan, hasil analisis, dan rekomendasi yang ditampilkan oleh sistem. Validasi ini melibatkan dua ahli, yaitu dokter anak dari Fakultas Kedokteran dan ahli gizi dari Rumah Sakit Islam Jakarta Cempaka Putih.

Dokter anak meninjau kesesuaian hasil analisis pertumbuhan balita berdasarkan indikator BB/U, TB/U, dan BB/TB. Ahli gizi menilai kesesuaian interpretasi status gizi dan rekomendasi yang diberikan oleh sistem. Kedua ahli

memberikan penilaian agar informasi yang ditampilkan aplikasi tetap sesuai dengan prinsip pemantauan pertumbuhan anak.

Peneliti menyajikan tampilan aplikasi dan hasil analisis dari beberapa contoh data balita kepada ahli. Ahli kemudian memberikan penilaian terhadap kejelasan informasi, ketepatan hasil, dan kesesuaian rekomendasi yang ditampilkan oleh sistem. Peneliti menggunakan masukan dari ahli untuk memperbaiki isi informasi, tampilan hasil analisis, dan penyampaian rekomendasi agar aplikasi menjadi lebih jelas, tepat, dan mudah dipahami oleh pengguna.

4.1.10 Cara Pengujian Keusioner

Pengujian kuesioner pengguna dilakukan untuk menilai pengalaman pengguna setelah mencoba aplikasi GrowSmart Health. Peneliti menyusun pengujian ini untuk mengukur kemudahan penggunaan aplikasi, kejelasan tampilan, serta relevansi informasi hasil analisis status pertumbuhan dan gizi balita yang disediakan oleh sistem.

Peneliti menyebarkan kuesioner kepada ibu yang memiliki balita di lingkungan RT setempat. Peneliti memilih responden tersebut karena ibu yang memiliki balita termasuk kelompok pengguna yang sesuai dengan tujuan aplikasi. Aplikasi GrowSmart Health dirancang untuk membantu pengguna memperoleh informasi awal mengenai status pertumbuhan dan gizi balita berdasarkan data antropometri.

Sebelum mengisi kuesioner, responden mencoba aplikasi secara langsung. Responden memasukkan data balita, menjalankan proses analisis, membaca hasil klasifikasi pada indikator BB/U, TB/U, dan BB/TB, serta melihat informasi pendukung yang ditampilkan oleh aplikasi. Setelah menyelesaikan proses uji coba, responden mengisi kuesioner melalui Google Form. Sistem kemudian merekap jawaban responden ke dalam bentuk spreadsheet untuk digunakan pada tahap pengolahan data.

Kuesioner pengguna terdiri atas empat bagian utama, yaitu:

1. Identitas Responden dan Data Balita, untuk mencatat informasi dasar responden serta balita yang digunakan dalam uji coba aplikasi.
2. Penilaian Pengalaman Menggunakan Aplikasi, untuk menilai kemudahan penggunaan, kejelasan tampilan, konsistensi sistem, kenyamanan, dan penerimaan pengguna terhadap aplikasi.
3. Relevansi Output Aplikasi, untuk menilai kejelasan hasil klasifikasi, kesesuaian informasi pendukung, dan manfaat hasil analisis yang ditampilkan oleh sistem.
4. Kritik dan Saran, untuk memberikan ruang bagi responden dalam menyampaikan masukan terhadap aplikasi.

Peneliti menggunakan skala Likert 5 poin pada bagian penilaian pengalaman menggunakan aplikasi dan relevansi output aplikasi. Responden memilih jawaban berdasarkan tingkat persetujuan terhadap setiap pernyataan setelah mencoba aplikasi. Ketentuan skala penilaian disajikan pada Tabel 4.2.

Tabel 4. 2 Skala Penilaian Kuesioner Pengguna

No.	**Pilihan Jawaban**	**Skor**
1	Sangat Tidak Setuju (STS)	1
2	Tidak Setuju (TS)	2
3	Netral (N)	3
4	Setuju (S)	4
5	Sangat Setuju (SS)	5

Kuesioner ini tidak menggunakan instrumen System Usability Scale (SUS) secara standar karena peneliti telah menyesuaikan pernyataan dengan kebutuhan aplikasi GrowSmart Health. Meskipun demikian, bagian pengalaman menggunakan aplikasi tetap menilai aspek *usability*, seperti kemudahan penggunaan, kejelasan tampilan, konsistensi sistem, rasa percaya diri pengguna, dan hambatan yang dirasakan selama menggunakan aplikasi. Daftar pertanyaan yang digunakan dalam pengujian kuesioner pengguna disajikan pada Tabel 4.3.

Tabel 4. 3 Daftar Pertanyaan Kuesioner Pengguna

No.	Pertanyaan
	A. Identitas Responden dan Data Balita
1	Alamat email responden
2	Nama lengkap atau nama panggilan responden
3	Usia balita dalam tahun atau bulan

Tabel 4.3 (Lanjutan)

No.	Pertanyaan
4	Jenis kelamin balita
	B. Penilaian Pengalaman Menggunakan Aplikasi
5	Saya merasa aplikasi ini mudah digunakan.
6	Saya merasa aplikasi ini terlalu rumit untuk digunakan.
7	Saya merasa sistem ini mudah digunakan.
8	Saya merasa membutuhkan bantuan orang lain untuk menggunakan aplikasi ini.
9	Saya merasa tampilan menu, tombol, dan halaman pada aplikasi ini sudah tersusun dengan jelas.
10	Saya merasa ada banyak hal yang tidak konsisten pada sistem.
11	Saya merasa percaya diri saat menggunakan aplikasi ini.
12	Saya merasa perlu mempelajari banyak hal terlebih dahulu sebelum dapat menggunakan aplikasi ini.
13	Saya merasa sistem ini membingungkan.
14	Menurut saya, aplikasi ini sudah bagus dan pantas untuk digunakan oleh orang banyak.
15	Saya bersedia menggunakan aplikasi ini kembali apabila membutuhkan informasi awal mengenai status pertumbuhan dan gizi balita.
	C. Relevansi Output Aplikasi

Tabel 4.3 (Lanjutan)

No.	Pertanyaan
16	Hasil klasifikasi status tumbuh kembang dan gizi balita yang ditampilkan aplikasi mudah dipahami.
17	Hasil klasifikasi pada indikator Weight-for-Age (W/A) atau berat badan menurut umur ditampilkan dengan jelas.
18	Hasil klasifikasi pada indikator Height-for-Age (H/A) atau tinggi badan menurut umur ditampilkan dengan jelas.
19	Hasil klasifikasi pada indikator Weight-for-Height (W/H) atau berat badan menurut tinggi badan ditampilkan dengan jelas.
20	Rekomendasi atau informasi pendukung yang diberikan aplikasi sesuai dengan hasil klasifikasi yang muncul.
21	Rekomendasi yang ditampilkan aplikasi membantu pengguna memahami kondisi awal tumbuh kembang dan gizi balita.
22	Informasi hasil aplikasi membantu pengguna mengetahui langkah awal yang dapat dilakukan setelah melihat hasil klasifikasi.
23	Hasil dan rekomendasi aplikasi tidak menimbulkan kesan sebagai diagnosis akhir.
24	Secara keseluruhan, output aplikasi sudah relevan dan bermanfaat sebagai alat bantu skrining awal status tumbuh kembang dan gizi balita.
	D. Kritik dan Saran

Tabel 4.3 (Lanjutan)

No.	Pertanyaan
25	Apakah terdapat kritik dan saran terhadap aplikasi yang digunakan?

Pada bagian Penilaian Pengalaman Menggunakan Aplikasi, peneliti menggunakan pernyataan positif dan negatif. Peneliti menggunakan skor asli pada pernyataan positif. Sementara itu, peneliti membalik skor pada pernyataan negatif agar skor yang lebih tinggi tetap menunjukkan penilaian yang lebih baik terhadap aplikasi. Pernyataan negatif yang memerlukan pembalikan skor disajikan pada Tabel 4.4.

Tabel 4. 4 Pernyataan Negatif

No.	**Pernyataan Negatif**
6	Saya merasa aplikasi ini terlalu rumit untuk digunakan.
8	Saya merasa membutuhkan bantuan orang lain untuk menggunakan aplikasi ini.
10	Saya merasa ada banyak hal yang tidak konsisten pada sistem.
12	Saya merasa perlu mempelajari banyak hal terlebih dahulu sebelum dapat menggunakan aplikasi ini.
13	Saya merasa sistem ini membingungkan.

Peneliti menggunakan skor asli pada setiap pernyataan positif. Sementara itu, peneliti melakukan pembalikan skor pada pernyataan negatif agar nilai yang

lebih tinggi tetap menunjukkan penilaian pengguna yang lebih baik terhadap aplikasi. Ketentuan pembalikan skor disajikan pada Tabel 4.5.

Tabel 4. 5 Konversi Skor Pernyataan Negatif

Jawaban Responden	**Skor Awal**	**Skor Setelah Dibalik**
Sangat Tidak Setuju (STS)	1	5
Tidak Setuju (TS)	2	4
Netral (N)	3	3
Setuju (S)	4	2
Sangat Setuju (SS)	5	1

Peneliti mengolah jawaban kuesioner setelah seluruh responden menyelesaikan proses pengisian. Pengolahan tersebut dilakukan untuk menghitung penilaian pengguna pada aspek pengalaman penggunaan aplikasi dan relevansi output. Hasil pengolahan kuesioner selanjutnya disajikan pada bagian hasil pengujian kuesioner pengguna.

4.2 Hasil Pengujian

4.2.1 Hasil Pengujian Persiapan Fitur dan Target (Distribusi Target)

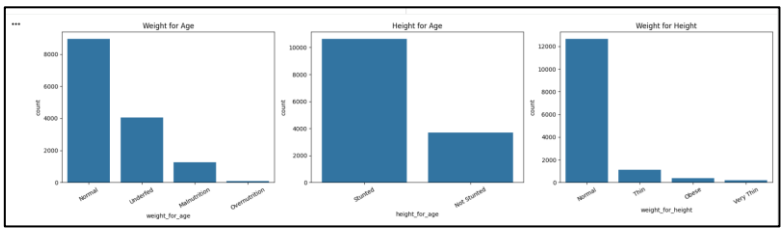
Berdasarkan gambar 4.11 menjelaskan hasil visualisasi distribusi target, perbedaan jumlah data pada setiap kelas dapat dilihat pada masing-masing variabel target. Pada target Weight for Age, jumlah data paling banyak ditunjukkan oleh kelas Normal, yaitu sekitar 9.000 data. Setelah itu, kelas Underfed menempati

jumlah terbanyak kedua dengan sekitar 4.000 data, kemudian kelas Malnutrition dengan sekitar 1.200 data. Sementara itu, jumlah data paling sedikit ditunjukkan oleh kelas Overnutrition. Hasil tersebut menunjukkan bahwa sebagian besar data balita dikategorikan memiliki berat badan normal berdasarkan usia, meskipun masih ditemukan data balita pada kategori underfed dan malnutrition.

Pada target Height for Age, distribusi data dibagi ke dalam dua kelas, yaitu Stunted dan Not Stunted. Berdasarkan grafik, jumlah data lebih banyak ditunjukkan oleh kelas Stunted, yaitu sekitar 10.500 data. Sementara itu, kelas Not Stunted memiliki jumlah data sekitar 3.700 data. Hasil tersebut menunjukkan bahwa sebagian besar data balita dalam dataset dikategorikan mengalami stunted. Selain itu, ketidakseimbangan data juga terlihat pada target Height for Age karena jumlah data pada kelas Stunted lebih dominan dibandingkan kelas Not Stunted.

Selanjutnya, pada target Weight for Height, jumlah data paling tinggi ditunjukkan oleh kelas Normal, yaitu sekitar 12.500 data. Sementara itu, jumlah data pada kelas Thin, Obese, dan Very Thin terlihat jauh lebih sedikit dibandingkan kelas Normal. Kelas Thin memiliki jumlah sekitar 1.100 data, sedangkan kelas Obese dan Very Thin memiliki jumlah data yang sangat kecil. Hasil tersebut menunjukkan bahwa sebagian besar data balita dikategorikan memiliki berat badan normal berdasarkan tinggi badan. Secara keseluruhan, ketidakseimbangan distribusi target dapat dilihat pada ketiga grafik tersebut. Beberapa kelas memiliki jumlah data yang sangat besar, sedangkan kelas lainnya memiliki jumlah data yang

jauh lebih sedikit. Kondisi ini perlu diperhatikan karena proses pelatihan model dapat dipengaruhi oleh jumlah data pada setiap kelas. Model cenderung lebih mudah mengenali kelas mayoritas, sedangkan kelas minoritas berpotensi lebih sulit diklasifikasikan secara tepat. Oleh karena itu, hasil distribusi target digunakan sebagai dasar untuk memahami karakteristik data sebelum model LightGBM dan XGBoost dilatih.



Gambar 4. 11 Hasil Pengujian Persiapan Fitur dan Target (Distribusi Target)

4.2.2 Hasil Pengujian Heatmap Korelasi

Gambar 4.12 menampilkan hasil pengujian *heatmap* korelasi untuk melihat hubungan antarfitur dalam *dataset*. Setiap kotak pada *heatmap* menunjukkan nilai korelasi antarfitur dengan rentang nilai -1 sampai 1. Nilai korelasi yang mendekati 1 menunjukkan hubungan positif yang kuat, sedangkan nilai korelasi yang mendekati -1 menunjukkan hubungan negatif yang kuat. Sementara itu, nilai korelasi yang mendekati 0 menunjukkan hubungan yang lemah atau hampir tidak memiliki hubungan *linear*.

Pada *heatmap* tersebut, fitur *age_month* dan *height* memiliki hubungan paling kuat dengan nilai korelasi sebesar 0,92. Nilai tersebut menunjukkan bahwa usia balita dalam bulan memiliki hubungan positif yang sangat kuat dengan tinggi

badan. Dengan demikian, semakin besar usia balita, maka tinggi badan balita cenderung meningkat. Hasil ini sesuai dengan kondisi pertumbuhan balita karena tinggi badan umumnya bertambah seiring dengan bertambahnya usia.

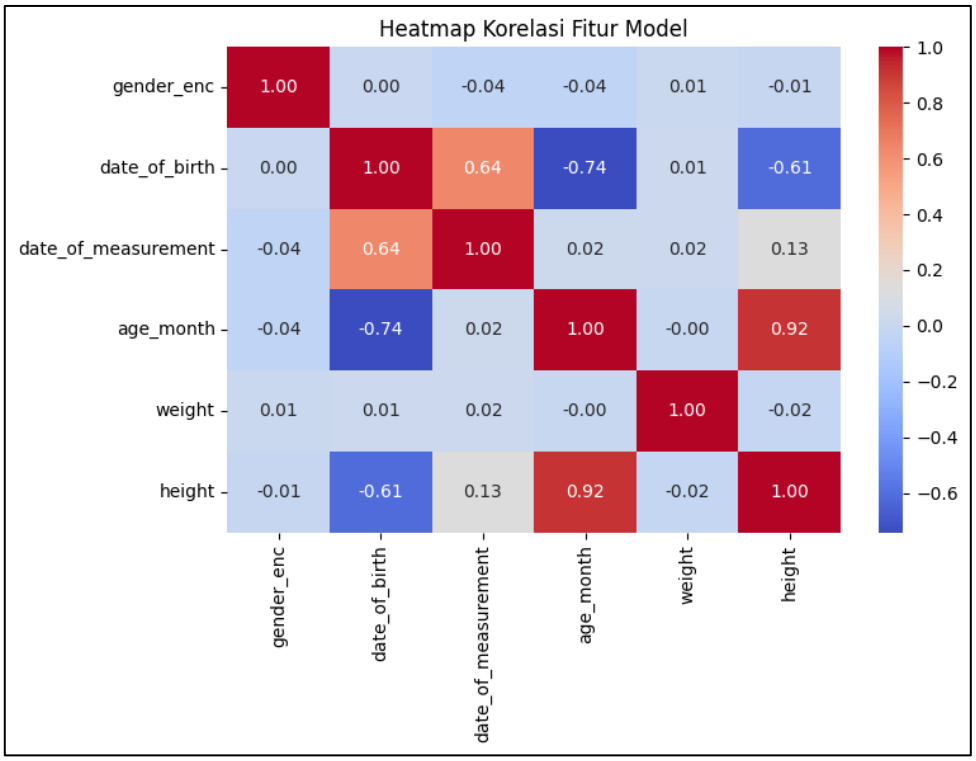
Selanjutnya, fitur *date_of_birth* dan *age_month* memiliki hubungan negatif yang cukup kuat dengan nilai korelasi sebesar -0,74. Nilai tersebut menunjukkan bahwa semakin baru tanggal lahir balita, maka usia balita dalam bulan cenderung semakin kecil. Kondisi ini dapat dianggap wajar karena balita yang lahir lebih akhir memiliki usia yang lebih muda dibandingkan balita yang lahir lebih awal. Selain itu, fitur *date_of_birth* dan *height* juga memiliki hubungan negatif dengan nilai korelasi sebesar -0,61. Nilai tersebut menunjukkan bahwa balita dengan tanggal lahir yang lebih baru cenderung memiliki tinggi badan yang lebih rendah karena usianya masih lebih kecil.

Pada fitur *date_of_birth* dan *date_of_measurement*, hubungan positif yang cukup kuat ditunjukkan dengan nilai korelasi sebesar 0,64. Nilai tersebut menunjukkan bahwa tanggal lahir memiliki hubungan dengan tanggal pengukuran. Hubungan ini dapat terjadi karena data pengukuran balita masih berkaitan dengan waktu kelahiran dan periode pemeriksaan yang dilakukan pada balita.

Sementara itu, fitur *gender_enc* menunjukkan nilai korelasi yang sangat kecil terhadap fitur lainnya, yaitu berada di sekitar -0,04 sampai 0,01. Hasil tersebut menunjukkan bahwa jenis kelamin tidak memiliki hubungan *linear* yang kuat dengan fitur lain dalam *dataset*. Selain itu, fitur *weight* juga menunjukkan

nilai korelasi yang rendah terhadap fitur lainnya karena nilainya mendekati 0. Dengan demikian, berat badan tidak menunjukkan hubungan *linear* yang kuat terhadap usia, tinggi badan, jenis kelamin, maupun tanggal pengukuran.

Secara keseluruhan, fitur *age_month* dan *height* menunjukkan hubungan paling kuat dalam *heatmap* korelasi. Sementara itu, sebagian besar fitur lainnya menunjukkan nilai korelasi yang rendah. Hasil pengujian ini digunakan untuk memahami hubungan antarfitur sebelum proses pelatihan *model* dilakukan. Melalui *heatmap* korelasi, karakteristik data dapat dianalisis lebih awal sehingga fitur yang digunakan pada *model LightGBM* dan *XGBoost* dapat dipahami berdasarkan hubungan antarvariabelnya.



Gambar 4. 12 Hasil Pengujian Heatmap Korelasi

4.2.3 Hasil Pengujian Model Evaluasi Detail dan Confusion Matrix

Pengujian model dilakukan untuk memperoleh hasil evaluasi dari algoritma *LightGBM* dan *XGBoost*. Penelitian ini menguji kedua algoritma pada tiga target klasifikasi, yaitu *Weight for Age*, *Height for Age*, dan *Weight for Height*. Metrik evaluasi yang digunakan meliputi *accuracy*, *precision*, *recall*, *F1-score*, *train time*, *predict time*, dan *total time*. Hasil pengujian model ditampilkan pada Tabel 4.6.

Berdasarkan Tabel 4.6, model *LightGBM* pada target *Weight for Age* memperoleh nilai *accuracy* sebesar 0.9341, *precision* sebesar 0.9109, *recall* sebesar 0.8084, dan *F1-score* sebesar 0.8460. Model ini membutuhkan *train time* sebesar 1.6140 detik, *predict time* sebesar 0.2173 detik, dan *total time* sebesar 1.8313 detik. Pada target yang sama, model *XGBoost* memperoleh nilai *accuracy* sebesar 0.9152, *precision* sebesar 0.8992, *recall* sebesar 0.7555, dan *F1-score* sebesar 0.8069. Model *XGBoost* membutuhkan *train time* sebesar 1.3333 detik, *predict time* sebesar 0.0548 detik, dan *total time* sebesar 1.3882 detik.

Pada target *Height for Age*, model *LightGBM* memperoleh nilai *accuracy* sebesar 0.9916, *precision* sebesar 0.9866, *recall* sebesar 0.9917, dan *F1-score* sebesar 0.9891. Model ini membutuhkan *train time* sebesar 0.3033 detik, *predict time* sebesar 0.0413 detik, dan *total time* sebesar 0.3446 detik. Pada target yang sama, model *XGBoost* memperoleh nilai *accuracy* sebesar 0.9892, *precision* sebesar 0.9829, *recall* sebesar 0.9892, dan *F1-score* sebesar 0.9860. Model

XGBoost membutuhkan *train time* sebesar 0.2692 detik, *predict time* sebesar 0.0153 detik, dan *total time* sebesar 0.2845 detik.

Pada target *Weight for Height*, model *LightGBM* memperoleh nilai *accuracy* sebesar 0.9613, *precision* sebesar 0.8895, *recall* sebesar 0.7735, dan *F1-score* sebesar 0.8218. Model ini membutuhkan *train time* sebesar 1.2356 detik, *predict time* sebesar 0.2593 detik, dan *total time* sebesar 1.4949 detik. Pada target yang sama, model *XGBoost* memperoleh nilai *accuracy* sebesar 0.9491, *precision* sebesar 0.8754, *recall* sebesar 0.6955, dan *F1-score* sebesar 0.7687. Model *XGBoost* membutuhkan *train time* sebesar 1.2531 detik, *predict time* sebesar 0.0552 detik, dan *total time* sebesar 1.3083 detik.

Secara keseluruhan, Tabel 4.6 menyajikan hasil evaluasi dari setiap model pada masing-masing target klasifikasi. Tabel tersebut menampilkan nilai performa klasifikasi dan waktu komputasi yang diperoleh oleh model *LightGBM* dan *XGBoost*.

Tabel 4. 6 Hasil Evaluasi Model pada Seluruh Target Klasifikasi

Target	**Model**	**Accuracy**	**Precision**	**Recall**	**F1**	**Train Time (s)**	**Predict Time (s)**	**Total Time (s)**
Weight for Age	LightGBM	0.9341	0.9109	0.8084	0.8460	1.6140	0.2173	1.8313
	XGBoost	0.9152	0.8992	0.7555	0.8069	1.3333	0.0548	1.3882
Height for Age	LightGBM	0.9916	0.9866	0.9917	0.9891	0.3033	0.0413	0.3446
	XGBoost	0.9892	0.9829	0.9892	0.9860	0.2692	0.0153	0.2845

Tabel 4.6 (Lanjutan)

Target	Model	Accuracy	Precision	Recall	F1	Train Time (s)	Predict Time (s)	Total Time (s)
Weight for Height	LightGBM	0.9613	0.8895	0.7735	0.8218	1.2356	0.2593	1.4949
	XGBoost	0.9491	0.8754	0.6955	0.7687	1.2531	0.0552	1.3083

Penelitian ini melakukan evaluasi detail per kategori untuk mengetahui performa model *LightGBM* pada setiap kelas target *Weight for Age*. Hasil evaluasi detail tersebut disajikan pada Tabel 4.7. Pada evaluasi detail per kategori untuk target *Weight for Age*, model *LightGBM* menghasilkan nilai evaluasi yang berbeda pada setiap kategori status gizi.

Pada kategori *Malnutrition*, data uji yang digunakan berjumlah 250 data. Model memperoleh nilai *precision* sebesar 0,9053, *recall* sebesar 0,8800, dan *F1-score* sebesar 0,8925. Hasil tersebut menunjukkan bahwa model mampu mengklasifikasikan kategori *Malnutrition* dengan baik.

Pada kategori *Underfed*, data uji yang digunakan berjumlah 811 data. Model menghasilkan nilai *precision* sebesar 0,8932, *recall* sebesar 0,8866, dan *F1-score* sebesar 0,8899. Nilai tersebut menunjukkan bahwa model mampu memprediksi kategori *Underfed* dengan cukup baik. Selain itu, nilai *precision* dan *recall* yang hampir seimbang menunjukkan bahwa model memiliki ketepatan prediksi dan kemampuan pengenalan data yang cukup stabil pada kategori ini.

Pada kategori *Normal*, data uji yang digunakan berjumlah 1.789 data. Model memperoleh nilai *precision* sebesar 0,9563, *recall* sebesar 0,9670, dan *F1-score* sebesar 0,9616. Hasil ini menunjukkan bahwa model memiliki performa paling baik pada kategori *Normal*. Kondisi tersebut dapat terjadi karena jumlah data pada kategori *Normal* lebih besar dibandingkan kategori lainnya, sehingga pola data lebih mudah dikenali oleh model.

Sementara itu, pada kategori *Overnutrition*, data uji yang digunakan hanya berjumlah 16 data. Model menghasilkan nilai *precision* sebesar 0,8889, *recall* sebesar 0,5000, dan *F1-score* sebesar 0,6400. Nilai *recall* yang lebih rendah menunjukkan bahwa model masih belum optimal dalam mengenali data pada kategori *Overnutrition*. Hal ini dapat dipengaruhi oleh jumlah data *Overnutrition* yang jauh lebih sedikit dibandingkan kategori lainnya.

Tabel 4. 7 Hasil Evaluasi Model Algoritma LightGBM Weight For Age

No	Kategori	Support	Precision	Recall	F1-Score
0	Malnutrition	250	0.9053	0.8800	0.8925
1	Underfed	811	0.8932	0.8866	0.8899
2	Normal	1789	0.9563	0.9670	0.9616
3	Overnutrition	16	0.8889	0.5000	0.6400

Penelitian ini melakukan evaluasi detail per kategori untuk mengetahui performa model *XGBoost* pada setiap kelas target *Weight for Age*. Hasil evaluasi detail tersebut disajikan pada Tabel 4.8. Pada evaluasi detail per kategori untuk

target *Weight for Age*, model *XGBoost* memperoleh hasil evaluasi yang berbeda pada setiap kategori status gizi.

Pada kategori *Malnutrition*, data uji yang digunakan berjumlah 250 data. Model menghasilkan nilai *precision* sebesar 0,9265, *recall* sebesar 0,7560, dan *F1-score* sebesar 0,8327. Hasil tersebut menunjukkan bahwa model cukup tepat saat memprediksi kategori *Malnutrition*, tetapi masih terdapat beberapa data *Malnutrition* yang belum berhasil dikenali dengan benar.

Pada kategori *Underfed*, data uji yang digunakan berjumlah 811 data. Model memperoleh nilai *precision* sebesar 0,8537, *recall* sebesar 0,8631, dan *F1-score* sebesar 0,8584. Nilai tersebut menunjukkan bahwa model mampu mengklasifikasikan kategori *Underfed* dengan cukup baik. Selain itu, nilai *precision* dan *recall* yang hampir seimbang menunjukkan bahwa model memiliki kemampuan prediksi dan pengenalan data yang cukup stabil pada kategori ini.

Pada kategori *Normal*, data uji yang digunakan berjumlah 1.789 data. Model menghasilkan nilai *precision* sebesar 0,9417, *recall* sebesar 0,9653, dan *F1-score* sebesar 0,9534. Hasil tersebut menunjukkan bahwa model memiliki performa paling baik pada kategori *Normal*. Kondisi ini dapat terjadi karena jumlah data pada kategori *Normal* lebih banyak dibandingkan kategori lainnya, sehingga pola data lebih mudah dipelajari oleh model.

Sementara itu, pada kategori *Overnutrition*, data uji yang digunakan hanya berjumlah 16 data. Model memperoleh nilai *precision* sebesar 0,8750, *recall* sebesar 0,4375, dan *F1-score* sebesar 0,5833. Nilai *recall* yang rendah

menunjukkan bahwa model belum optimal dalam mengenali kategori *Overnutrition*. Hal ini dapat dipengaruhi oleh jumlah data *Overnutrition* yang jauh lebih sedikit dibandingkan kategori lainnya.

Tabel 4. 8 Hasil Evaluasi Model XGBoost Weight For Age

No	Kode	Kategori	Support	Precision	Recall	F1-Score
0	0	Malnutrition	250	0.9265	0.7560	0.8326
1	1	Underfed	811	0.8537	0.8631	0.8584
2	2	Normal	1789	0.9417	0.9653	0.9534
3	3	Overnutrition	16	0.8750	0.4375	0.5833

Pada evaluasi detail per kategori untuk target Height for Age yang dapat dilihat pada table 4.9, model LightGBM memperoleh hasil evaluasi yang sangat baik pada kategori Stunted dan Not Stunted. Pada kategori Stunted, data uji yang digunakan berjumlah 2.124 data. Model menghasilkan nilai precision sebesar 0,9972, recall sebesar 0,9915, dan F1-score sebesar 0,9943. Hasil tersebut menunjukkan bahwa model mampu memprediksi kategori Stunted dengan tingkat ketepatan dan pengenalan data yang sangat tinggi.

Pada kategori Not Stunted, data uji yang digunakan berjumlah 742 data. Model memperoleh nilai precision sebesar 0,9761, recall sebesar 0,9919, dan F1-score sebesar 0,9840. Nilai tersebut menunjukkan bahwa model juga mampu mengklasifikasikan kategori Not Stunted dengan sangat baik. Selain itu, nilai recall yang tinggi menunjukkan bahwa sebagian besar data Not Stunted berhasil dikenali secara tepat oleh model.

Secara keseluruhan, model LightGBM menunjukkan performa yang sangat baik pada target Height for Age. Nilai precision, recall, dan F1-score yang tinggi pada kedua kategori menunjukkan bahwa model mampu membedakan kategori Stunted dan Not Stunted secara akurat.

Tabel 4. 9 Evaluasi Model LightGBM Height For Age

	Kode	**Kategori**	**Support**	**Precision**	**Recall**	**F1-Score**
0	0	Stunted	2124	0.9972	0.9915	0.9943
1	1	Not Stunted	742	0.9761	0.9919	0.9840

Penelitian ini melakukan evaluasi detail per kategori untuk mengetahui performa model *XGBoost* pada setiap kelas target *Height for Age*. Hasil evaluasi detail tersebut disajikan pada Tabel 4.10. Pada evaluasi detail per kategori untuk target *Height for Age*, model *XGBoost* memperoleh hasil evaluasi yang sangat baik pada kategori *Stunted* dan *Not Stunted*.

Pada kategori *Stunted*, data uji yang digunakan berjumlah 2.124 data. Model menghasilkan nilai *precision* sebesar 0,9962, *recall* sebesar 0,9892, dan *F1-score* sebesar 0,9924. Hasil tersebut menunjukkan bahwa model mampu mengklasifikasikan kategori *Stunted* dengan tingkat ketepatan yang sangat tinggi.

Pada kategori *Not Stunted*, data uji yang digunakan berjumlah 742 data. Model memperoleh nilai *precision* sebesar 0,9696, *recall* sebesar 0,9892, dan *F1-score* sebesar 0,9793. Nilai tersebut menunjukkan bahwa model mampu mengenali sebagian besar data pada kategori *Not Stunted* dengan baik. Selain itu,

nilai *recall* yang tinggi menunjukkan bahwa data pada kategori tersebut berhasil diklasifikasikan secara tepat oleh model.

Secara keseluruhan, model *XGBoost* menunjukkan performa yang sangat baik pada target *Height for Age*. Nilai *precision*, *recall*, dan *F1-score* yang tinggi pada kedua kategori menunjukkan bahwa model mampu membedakan kategori *Stunted* dan *Not Stunted* dengan akurat.

Tabel 4. 10 Evaluasi Model XGBoost Height For Age

No	Kode	Kategori	Support	Precision	Recall	F1-Score
0	0	Stunted	2124	0.9962	0.9892	0.9927
1	1	Not Stunted	742	0.9696	0.9892	0.9793

Penelitian ini melakukan evaluasi detail per kategori untuk mengetahui performa model *LightGBM* pada setiap kelas target *Weight for Height*. Hasil evaluasi detail tersebut disajikan pada Tabel 4.11. Pada evaluasi detail per kategori untuk target *Weight for Height*, model *LightGBM* menghasilkan nilai evaluasi yang berbeda pada setiap kategori status gizi.

Pada kategori *Very Thin*, data uji yang digunakan berjumlah 40 data. Model memperoleh nilai *precision* sebesar 0,8846, *recall* sebesar 0,5750, dan *F1-score* sebesar 0,6970. Hasil tersebut menunjukkan bahwa model cukup tepat saat memprediksi kategori *Very Thin*, tetapi model belum sepenuhnya optimal dalam mengenali seluruh data pada kategori tersebut.

Pada kategori *Thin*, data uji yang digunakan berjumlah 224 data. Model menghasilkan nilai *precision* sebesar 0,8271, *recall* sebesar 0,7902, dan *F1-score* sebesar 0,8082. Nilai tersebut menunjukkan bahwa model mampu mengklasifikasikan kategori *Thin* dengan cukup baik. Selain itu, nilai *precision* dan *recall* yang cukup seimbang menunjukkan bahwa model memiliki kemampuan prediksi dan pengenalan data yang cukup stabil pada kategori ini.

Pada kategori *Normal*, data uji yang digunakan berjumlah 2.529 data. Model memperoleh nilai *precision* sebesar 0,9754, *recall* sebesar 0,9889, dan *F1-score* sebesar 0,9821. Hasil tersebut menunjukkan bahwa model memiliki performa paling baik pada kategori *Normal*. Kondisi ini dapat terjadi karena jumlah data pada kategori *Normal* lebih banyak dibandingkan kategori lainnya, sehingga pola data lebih mudah dikenali oleh model.

Sementara itu, pada kategori *Obese*, data uji yang digunakan berjumlah 73 data. Model menghasilkan nilai *precision* sebesar 0,8710, *recall* sebesar 0,7397, dan *F1-score* sebesar 0,8000. Hasil tersebut menunjukkan bahwa model mampu mengklasifikasikan kategori *Obese* dengan cukup baik, meskipun masih terdapat beberapa data yang belum dikenali secara tepat.

Tabel 4. 11 Evaluasi Model LightGBM Weight For Height

No	Kategori	Support	Precision	Recall	F1-Score
0	Very Thin	40	0.8846	0.5750	0.6970
1	Thin	224	0.8271	0.7902	0.8082

Tabel 4.11 (Lanjutan)

No	Kategori	Support	Precision	Recall	F1-Score
2	Normal	2529	0.9754	0.9889	0.9821
3	Obese	73	0.8710	0.7397	0.8000

Penelitian ini melakukan evaluasi detail per kategori untuk mengetahui performa model *XGBoost* pada setiap kelas target *Weight for Height*. Hasil evaluasi detail tersebut disajikan pada Tabel 4.12. Pada evaluasi detail per kategori untuk target *Weight for Height*, model *XGBoost* menghasilkan nilai evaluasi yang berbeda pada setiap kategori status gizi.

Pada kategori *Very Thin*, data uji yang digunakan berjumlah 40 data. Model memperoleh nilai *precision* sebesar 0,8519, *recall* sebesar 0,5750, dan *F1-score* sebesar 0,6866. Hasil tersebut menunjukkan bahwa model cukup tepat dalam memprediksi kategori *Very Thin*, tetapi kemampuan model dalam mengenali seluruh data pada kategori tersebut masih belum maksimal.

Pada kategori *Thin*, data uji yang digunakan berjumlah 224 data. Model menghasilkan nilai *precision* sebesar 0,8512, *recall* sebesar 0,6384, dan *F1-score* sebesar 0,7296. Nilai tersebut menunjukkan bahwa model memiliki ketepatan prediksi yang cukup baik pada kategori *Thin*, tetapi masih terdapat beberapa data yang belum berhasil dikenali dengan tepat.

Pada kategori *Normal*, data uji yang digunakan berjumlah 2.529 data. Model memperoleh nilai *precision* sebesar 0,9584, *recall* sebesar 0,9933, dan *F1-*

score sebesar 0,9755. Hasil tersebut menunjukkan bahwa model memiliki performa paling baik pada kategori *Normal*. Kondisi ini dapat terjadi karena jumlah data pada kategori *Normal* lebih banyak dibandingkan kategori lainnya, sehingga pola data lebih mudah dipelajari oleh model.

Sementara itu, pada kategori *Obese*, data uji yang digunakan berjumlah 73 data. Model menghasilkan nilai *precision* sebesar 0,8400, *recall* sebesar 0,5753, dan *F1-score* sebesar 0,6829. Hasil tersebut menunjukkan bahwa model masih cukup baik dalam memprediksi kategori *Obese*, tetapi kemampuan pengenalan data pada kategori tersebut belum sepenuhnya optimal.

Tabel 4. 12 Evaluasi Model XGBoost Weight For Height

No	Kategori	Kode	Kategori	Support	Precision	Recall
0	0	Very Thin	40	0.8519	0.5750	0.6866
1	1	Thin	224	0.8512	0.6384	0.7296
2	2	Normal	2529	0.9584	0.9933	0.9755
3	3	Obese	73	0.8400	0.5753	0.6829

Evaluasi menggunakan *confusion matrix* dilakukan untuk melihat kemampuan model dalam membedakan setiap kategori pada target *Weight for Age*. Hasil evaluasi tersebut ditampilkan pada Gambar 4.13. *Confusion matrix* menunjukkan jumlah data yang diprediksi benar dan salah pada setiap kategori. Nilai pada diagonal utama menunjukkan jumlah data yang berhasil diklasifikasikan

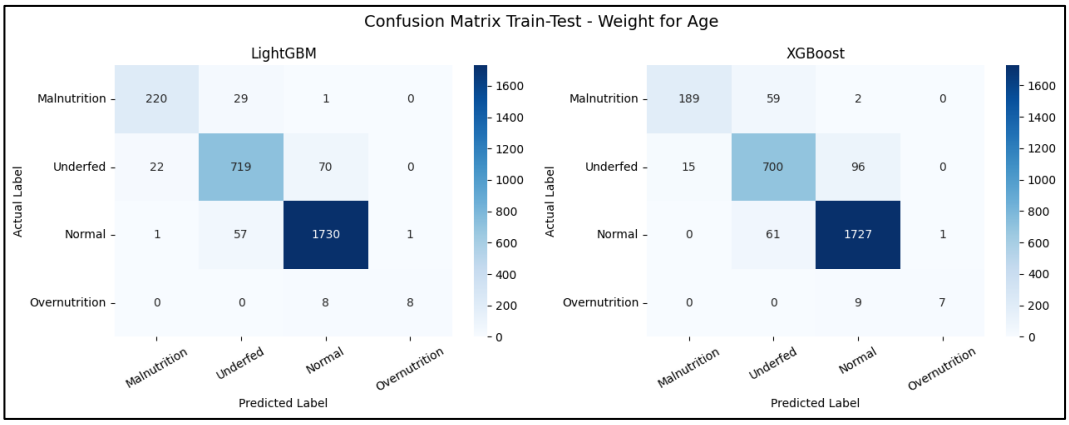
dengan benar. Nilai di luar diagonal menunjukkan jumlah data yang salah diklasifikasikan ke kategori lain.

Model *LightGBM* berhasil mengklasifikasikan kategori *Normal* dengan benar sebanyak 1.730 data. Model ini juga berhasil mengklasifikasikan kategori *Underfed* sebanyak 719 data, kategori *Malnutrition* sebanyak 220 data, dan kategori *Overnutrition* sebanyak 8 data. Kesalahan prediksi paling banyak terjadi pada kategori *Underfed* yang diprediksi sebagai *Normal* sebanyak 70 data. Selain itu, model *LightGBM* salah mengklasifikasikan 29 data *Malnutrition* sebagai *Underfed*, 57 data *Normal* sebagai *Underfed*, dan 8 data *Overnutrition* sebagai *Normal*.

Model *XGBoost* berhasil mengklasifikasikan kategori *Normal* dengan benar sebanyak 1.727 data. Model ini juga berhasil mengklasifikasikan kategori *Underfed* sebanyak 700 data, kategori *Malnutrition* sebanyak 189 data, dan kategori *Overnutrition* sebanyak 7 data. Kesalahan prediksi paling banyak terjadi pada kategori *Underfed* yang diprediksi sebagai *Normal* sebanyak 96 data. Selain itu, model *XGBoost* salah mengklasifikasikan 59 data *Malnutrition* sebagai *Underfed*, 61 data *Normal* sebagai *Underfed*, dan 9 data *Overnutrition* sebagai *Normal*.

Hasil pada Gambar 4.13 menunjukkan bahwa model *LightGBM* memiliki performa yang lebih baik dibandingkan model *XGBoost* pada target *Weight for Age*. Model *LightGBM* menghasilkan jumlah prediksi benar yang lebih tinggi pada beberapa kategori, yaitu *Malnutrition*, *Underfed*, *Normal*, dan *Overnutrition*. Model *LightGBM* juga menghasilkan kesalahan prediksi yang lebih sedikit,

terutama pada kategori *Underfed* yang diprediksi sebagai *Normal*. Dengan demikian, model *LightGBM* dapat dinilai lebih baik dalam mengklasifikasikan target *Weight for Age* berdasarkan hasil *confusion matrix*.



Gambar 4. 13 Hasil Confusion Matrix Train - Test Weight For Age

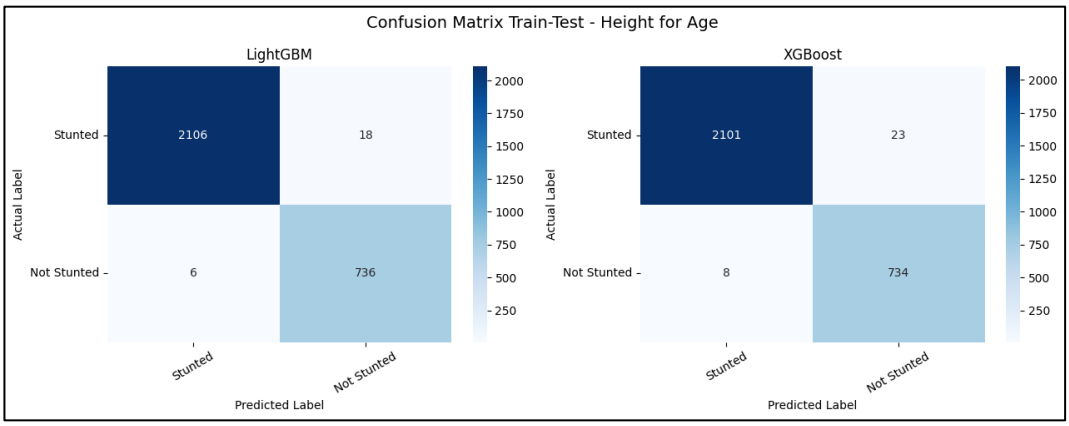
Evaluasi menggunakan *confusion matrix* dilakukan untuk melihat kemampuan model dalam membedakan kategori *Stunted* dan *Not Stunted* pada target *Height for Age*. Hasil evaluasi tersebut ditampilkan pada Gambar 4.14. *Confusion matrix* menunjukkan jumlah data yang berhasil diklasifikasikan dengan benar dan jumlah data yang salah diklasifikasikan pada setiap kategori.

Pada model *LightGBM*, kategori *Stunted* berhasil diklasifikasikan dengan benar sebanyak 2.106 data. Model ini juga berhasil mengklasifikasikan kategori *Not Stunted* dengan benar sebanyak 736 data. Kesalahan prediksi yang terjadi relatif kecil, yaitu 18 data *Stunted* diprediksi sebagai *Not Stunted* dan 6 data *Not Stunted* diprediksi sebagai *Stunted*.

Pada model *XGBoost*, kategori *Stunted* berhasil diklasifikasikan dengan benar sebanyak 2.101 data. Model ini juga berhasil mengklasifikasikan kategori

Not Stunted dengan benar sebanyak 734 data. Kesalahan prediksi yang terjadi juga rendah, yaitu 23 data *Stunted* diprediksi sebagai *Not Stunted* dan 8 data *Not Stunted* diprediksi sebagai *Stunted*.

Berdasarkan hasil pada Gambar 4.14, kedua model mampu membedakan kategori *Stunted* dan *Not Stunted* dengan sangat baik. Namun, model *LightGBM* menunjukkan hasil yang sedikit lebih unggul dibandingkan model *XGBoost*. Hal ini terlihat dari jumlah prediksi benar yang lebih tinggi dan jumlah kesalahan prediksi yang lebih sedikit pada kedua kategori.



Gambar 4. 14 Confusion Matrix Train - Test Height For Age

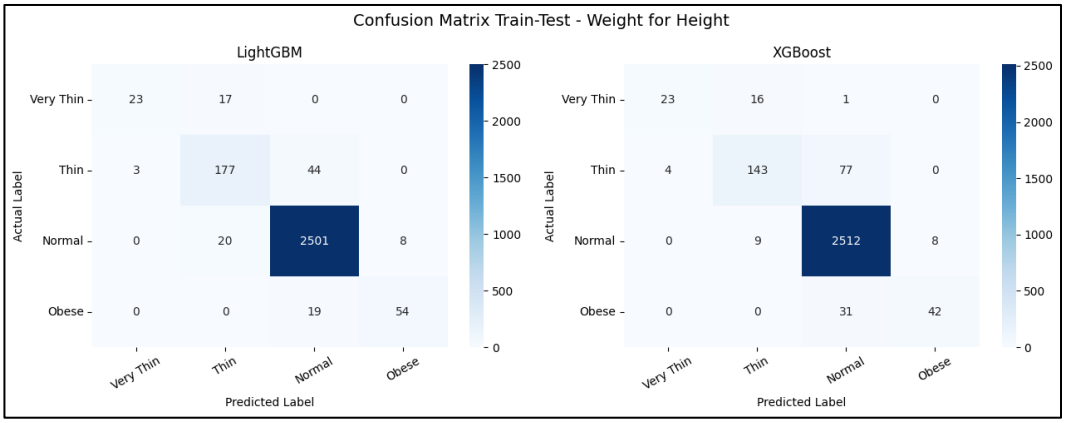
Evaluasi menggunakan *confusion matrix* dilakukan untuk melihat kemampuan model dalam membedakan setiap kategori pada target *Weight for Height*. Hasil evaluasi confusion matrix pada gambar 4.15 menunjukkan bahwa kategori *Normal* menjadi kategori yang paling banyak diprediksi dengan benar oleh kedua model.

Pada model *LightGBM*, kategori *Normal* berhasil diklasifikasikan dengan benar sebanyak 2.501 data. Model ini juga berhasil mengklasifikasikan kategori *Thin* sebanyak 177 data, kategori *Very Thin* sebanyak 23 data, dan kategori *Obese* sebanyak 54 data. Kesalahan prediksi paling banyak terjadi pada kategori *Thin* yang diprediksi sebagai *Normal* sebanyak 44 data. Selain itu, model *LightGBM* salah mengklasifikasikan 17 data *Very Thin* sebagai *Thin*, 20 data *Normal* sebagai *Thin*, 8 data *Normal* sebagai *Obese*, dan 19 data *Obese* sebagai *Normal*.

Pada model *XGBoost*, kategori *Normal* berhasil diklasifikasikan dengan benar sebanyak 2.512 data. Model ini juga berhasil mengklasifikasikan kategori *Thin* sebanyak 143 data, kategori *Very Thin* sebanyak 23 data, dan kategori *Obese* sebanyak 42 data. Kesalahan prediksi paling banyak terjadi pada kategori *Thin* yang diprediksi sebagai *Normal* sebanyak 77 data. Selain itu, model *XGBoost* salah mengklasifikasikan 16 data *Very Thin* sebagai *Thin*, 1 data *Very Thin* sebagai *Normal*, 9 data *Normal* sebagai *Thin*, 8 data *Normal* sebagai *Obese*, dan 31 data *Obese* sebagai *Normal*.

Berdasarkan hasil *confusion matrix*, kedua model memiliki kemampuan klasifikasi yang baik pada target *Weight for Height*, terutama pada kategori Normal. Namun, beberapa kategori dengan jumlah data lebih sedikit, seperti *Very Thin*, *Thin*, dan *Obese*, masih lebih sulit dikenali oleh model. Kondisi tersebut dapat terjadi karena jumlah data pada kelas minoritas lebih sedikit dibandingkan kelas *Normal*. Secara keseluruhan, model *LightGBM* menunjukkan performa yang lebih stabil dibandingkan model *XGBoost*, karena model *LightGBM* menghasilkan

jumlah prediksi benar yang lebih tinggi pada kategori *Thin* dan *Obese*, serta menghasilkan kesalahan prediksi yang lebih sedikit pada beberapa kategori minoritas.



Gambar 4. 15 Confusion Matrix Train - Test - Weight For Age

4.2.4 Hasil Pengujian Fungsi Eksperimen 5-Fold Cross Validation

Pada tahap ini, peneliti menguji kestabilan performa model menggunakan metode 5-Fold Cross Validation. Peneliti membagi dataset menjadi lima bagian atau *fold*. Dalam setiap iterasi, peneliti menggunakan satu *fold* sebagai data pengujian dan empat *fold* lainnya sebagai data pelatihan. Peneliti mengulangi proses tersebut hingga seluruh *fold* memperoleh giliran sebagai data pengujian.

Peneliti menerapkan pengujian ini pada tiga target klasifikasi, yaitu Weight for Age, Height for Age, dan Weight for Height. Peneliti menguji setiap target menggunakan dua algoritma, yaitu LightGBM dan XGBoost. Peneliti menggunakan nilai accuracy, precision, recall, dan F1-score untuk menilai performa masing-masing model pada setiap *fold*. Selain itu, peneliti menampilkan

jumlah data pelatihan dan data pengujian untuk menunjukkan pembagian data yang digunakan dalam setiap proses evaluasi.

Tabel 4.13 menjelaskan hasil pengujian 5-Fold Cross Validation pada setiap target klasifikasi dan model yang digunakan. Tabel tersebut menampilkan pembagian data pelatihan dan data pengujian, serta nilai evaluasi berupa accuracy, precision, recall, dan F1-score pada setiap fold.

Tabel 4. 13 Hasil Pengujian 5-Fold Cross Validation per Fold

Target	Model	Fold	Jumlah Data Training	Jumlah Data Testing	Accuracy	Precision	Recall	F1-Score
Weight for Age	LightGBM	1	11460	2866	0.9393	0.9196	0.8215	0.8585
	XGBoost		11460	2866	0.9187	0.9017	0.7654	0.8155
Weight for Age	LightGBM	2	11461	2865	0.9365	0.9386	0.7442	0.7849
	XGBoost		11461	2865	0.9246	0.9340	0.7352	0.7878
Weight for Age	LightGBM	3	11461	2865	0.9389	0.9454	0.8111	0.8571
	XGBoost		11461	2865	0.9302	0.9435	0.8078	0.8588
Weight for Age	LightGBM	4	11461	2865	0.9403	0.8939	0.8051	0.8402
	XGBoost		11461	2865	0.9218	0.9037	0.7443	0.7970
Weight for Age	LightGBM	5	11461	2865	0.9319	0.9398	0.7895	0.8340
	XGBoost		11461	2865	0.9124	0.9281	0.7222	0.7755
Height for Age	LightGBM	1	11460	2866	0.9927	0.9882	0.9929	0.9905
	XGBoost		11460	2866	0.9909	0.9857	0.9908	0.9882
Height for Age	LightGBM	2	11461	2865	0.9920	0.9877	0.9915	0.9896
	XGBoost		11461	2865	0.9927	0.9874	0.9937	0.9905
Height for Age	LightGBM	3	11461	2865	0.9906	0.9851	0.9906	0.9878
	XGBoost		11461	2865	0.9881	0.9806	0.9889	0.9847
	LightGBM	4	11461	2865	0.9902	0.9856	0.9890	0.9873

Tabel 4.13 (Lanjutan)

Target	Model	Fold	Jumlah Data Training	Jumlah Data Testing	Accuracy	Precision	Recall	F1-Score
Height for Age	XGBoost		11461	2865	0.9888	0.9838	0.9872	0.9855
Height for Age	LightGBM	5	11461	2865	0.9892	0.9833	0.9888	0.9860
	XGBoost		11461	2865	0.9871	0.9795	0.9873	0.9833
Weight for Height	LightGBM	1	11460	2866	0.9689	0.9282	0.7994	0.8481
	XGBoost		11460	2866	0.9578	0.9282	0.7149	0.7954
Weight for Height	LightGBM	2	11461	2865	0.9630	0.8502	0.8041	0.8236
	XGBoost		11461	2865	0.9522	0.8427	0.7316	0.7793
Weight for Height	LightGBM	3	11461	2865	0.9693	0.9007	0.8323	0.8630
	XGBoost		11461	2865	0.9581	0.8836	0.7466	0.8050
Weight for Height	LightGBM	4	11461	2865	0.9647	0.8773	0.8444	0.8601
	XGBoost		11461	2865	0.9557	0.9005	0.7259	0.7968
Weight for Height	LightGBM	5	11461	2865	0.9686	0.9147	0.8272	0.8661
	XGBoost		11461	2865	0.9550	0.8982	0.7155	0.7866

Berdasarkan Tabel 4.13, model *LightGBM* menunjukkan performa yang lebih baik dibandingkan model *XGBoost* pada target *Weight for Age*. Model *LightGBM* memperoleh nilai *accuracy* pada rentang 0,9319 sampai 0,9403. Model tersebut juga memperoleh nilai *F1-score* pada rentang 0,7849 sampai 0,8585. Sementara itu, model *XGBoost* memperoleh nilai *accuracy* pada rentang 0,9124 sampai 0,9302 dan nilai *F1-score* pada rentang 0,7755 sampai 0,8588. Hasil

tersebut menunjukkan bahwa model *LightGBM* memiliki kemampuan klasifikasi yang lebih baik pada sebagian besar *fold* untuk target *Weight for Age*.

Pada target *Height for Age*, model *LightGBM* dan *XGBoost* sama-sama menghasilkan performa klasifikasi yang sangat baik. Model *LightGBM* memperoleh nilai *accuracy* pada rentang 0,9892 sampai 0,9927 dan nilai *F1-score* pada rentang 0,9860 sampai 0,9905. Model *XGBoost* memperoleh nilai *accuracy* pada rentang 0,9871 sampai 0,9927 dan nilai *F1-score* pada rentang 0,9833 sampai 0,9905. Hasil tersebut menunjukkan bahwa kedua model mampu mengklasifikasikan kategori *Stunted* dan *Not Stunted* secara konsisten pada setiap *fold*. Namun, model *LightGBM* tetap menunjukkan hasil yang sedikit lebih stabil berdasarkan nilai evaluasi secara keseluruhan.

Pada target *Weight for Height*, model *LightGBM* kembali menunjukkan performa yang lebih unggul dibandingkan model *XGBoost*. Model *LightGBM* memperoleh nilai *accuracy* pada rentang 0,9630 sampai 0,9693 dan nilai *F1-score* pada rentang 0,8236 sampai 0,8661. Sementara itu, model *XGBoost* memperoleh nilai *accuracy* pada rentang 0,9522 sampai 0,9581 dan nilai *F1-score* pada rentang 0,7793 sampai 0,8050. Hasil tersebut menunjukkan bahwa model *LightGBM* lebih mampu menjaga keseimbangan performa klasifikasi pada target *Weight for Height*.

Selain menampilkan nilai evaluasi pada setiap *fold*, sistem juga menghasilkan jumlah baris pengujian dan detail evaluasi kategori. Tabel 4.14

menjelaskan jumlah data hasil pengujian yang diperoleh setelah proses 5-Fold Cross Validation selesai dilakukan**.**

Tabel 4. 14 Ringkasan Jumlah Hasil Pengujian 5-Fold Cross Validation

Keterangan	**Nilai**
Jumlah baris hasil fold	30
Jumlah baris detail kategori	100

Berdasarkan Tabel 4.14, sistem menghasilkan 30 baris hasil fold. Jumlah tersebut berasal dari pengujian pada tiga target klasifikasi, dua algoritma, dan lima *fold*, yaitu $3 \times 2 \times 5 = 30$. Selain itu, sistem menghasilkan 100 baris detail kategori yang menunjukkan bahwa evaluasi dilakukan secara lebih rinci pada setiap kelas dalam masing-masing target klasifikasi.

Secara keseluruhan, hasil pengujian 5-Fold Cross Validation menunjukkan bahwa model LightGBM memiliki performa yang lebih unggul dan lebih konsisten dibandingkan XGBoost pada sebagian besar target klasifikasi. Model LightGBM memberikan hasil paling baik terutama pada target Weight for Age dan Weight for Height, sedangkan pada target Height for Age kedua model menunjukkan performa yang sangat tinggi. Hasil pengujian ini selanjutnya digunakan sebagai dasar dalam proses pemilihan model terbaik untuk diterapkan pada aplikasi GrowSmart Health.

4.2.5 Hasil Pengujian Evaluasi Detail K-Fold Cross Validation

Pengujian *5-Fold Cross Validation* pada target *Weight for Age* dilakukan untuk melihat kestabilan performa model pada beberapa pembagian data. Pengujian ini menggunakan dua algoritma, yaitu *LightGBM* dan *XGBoost*. Hasil pengujian tersebut disajikan pada Tabel 4.15.

Tabel 4.20 menunjukkan hasil evaluasi model berdasarkan nilai *accuracy*, *precision*, *recall*, *F1-score*, *train time*, *predict time*, dan *total time*. Setiap model diuji sebanyak 5 *fold* untuk mengetahui perubahan performa pada setiap pembagian data. Hasil tersebut digunakan untuk membandingkan kemampuan klasifikasi dan waktu komputasi antara model *LightGBM* dan *XGBoost* pada target *Weight for Age*.

Pada model *LightGBM*, nilai *accuracy* berada pada rentang 0,9319 hingga 0,9403. Nilai tersebut menunjukkan bahwa model *LightGBM* mampu menghasilkan prediksi yang cukup stabil pada setiap *fold*. Nilai *F1-score* tertinggi diperoleh pada *fold* ke-1 sebesar 0,8585, sedangkan nilai *F1-score* terendah diperoleh pada *fold* ke-2 sebesar 0,7849. Hasil ini menunjukkan bahwa model *LightGBM* tetap memiliki performa klasifikasi yang baik, meskipun nilai evaluasi mengalami perubahan pada setiap pembagian data.

Pada model *XGBoost*, nilai *accuracy* berada pada rentang 0,9124 hingga 0,9302. Nilai *accuracy* tertinggi diperoleh pada *fold* ke-3 sebesar 0,9302, sedangkan nilai *accuracy* terendah diperoleh pada *fold* ke-5 sebesar 0,9124. Selain itu, nilai *F1-score* pada model *XGBoost* berada pada rentang 0,7755 hingga 0,8588.

Hasil tersebut menunjukkan bahwa model *XGBoost* masih mampu melakukan klasifikasi pada target *Weight for Age*, tetapi performanya cenderung lebih rendah dibandingkan model *LightGBM* pada sebagian besar *fold*.

Dari sisi waktu komputasi, model *LightGBM* membutuhkan *total time* sekitar 1,4406 hingga 2,1372 detik pada setiap *fold*. Sementara itu, model *XGBoost* membutuhkan *total time* sekitar 1,3581 hingga 1,6641 detik. Berdasarkan hasil tersebut, model *LightGBM* memiliki performa klasifikasi yang lebih baik pada target *Weight for Age*, sedangkan model *XGBoost* memiliki waktu komputasi yang relatif lebih singkat.

Tabel 4. 15 Hasil Pengujian 5 K-Fold Cross Validation Weight For Age

Target	Model	Fold	Accuracy	Precision	Recall	F1	Train Time (s)	Predict Time (s)	Total Time (s)
Weight for Age	LightGBM	1	0.9393	0.9196	0.8215	0.8585	1.2116	0.2290	1.4406
	XGBoost		0.9187	0.9017	0.7654	0.8155	1.3115	0.0555	1.3671
Weight for Age	LightGBM	2	0.9365	0.9386	0.7442	0.7849	1.4555	0.2917	1.7472
	XGBoost		0.9246	0.9340	0.7352	0.7878	1.3009	0.0572	1.3581
Weight for Age	LightGBM	3	0.9389	0.9454	0.8111	0.8571	1.8336	0.3037	2.1372
	XGBoost		0.9302	0.9435	0.8078	0.8588	1.6015	0.0625	1.6641
Weight for Age	LightGBM	4	0.9403	0.8939	0.8051	0.8402	1.2267	0.2564	1.4831
	XGBoost		0.9218	0.9037	0.7443	0.7970	1.3747	0.0586	1.4333
	LightGBM	5	0.9319	0.9398	0.7895	0.8340	1.2197	0.2324	1.4521

Tabel 4.15 (Lanjutan)

Target	Model	Fold	Accuracy	Precision	Recall	F1	Train Time (s)	Predict Time (s)	Total Time (s)
Weight for Age	XGBoost		0.9124	0.9281	0.7222	0.7755	1.3499	0.1088	1.4587

Pengujian *5-Fold Cross Validation* pada target *Height for Age* dilakukan untuk mengetahui kestabilan performa model pada beberapa pembagian data. Pengujian ini menggunakan dua algoritma, yaitu *LightGBM* dan *XGBoost*. Hasil pengujian tersebut disajikan pada Tabel 4.16.

Tabel 4.16 menunjukkan hasil evaluasi model berdasarkan nilai *accuracy*, *precision*, *recall*, *F1-score*, *train time*, *predict time*, dan *total time*. Setiap model diuji sebanyak 5 *fold* untuk melihat perubahan performa pada setiap pembagian data. Hasil tersebut digunakan untuk membandingkan kemampuan klasifikasi dan waktu komputasi antara model *LightGBM* dan *XGBoost* pada target *Height for Age*.

Pada model *LightGBM*, nilai *accuracy* berada pada rentang 0,9892 sampai 0,9927. Nilai tersebut menunjukkan bahwa model *LightGBM* mampu menghasilkan prediksi yang sangat baik dan stabil pada setiap *fold*. Model *LightGBM* memperoleh nilai *F1-score* tertinggi pada *fold* ke-1 sebesar 0,9905, sedangkan nilai *F1-score* terendah diperoleh pada *fold* ke-5 sebesar 0,9860. Hasil ini menunjukkan bahwa model *LightGBM* memiliki kemampuan klasifikasi yang sangat baik pada target *Height for Age*.

Pada model *XGBoost*, nilai *accuracy* berada pada rentang 0,9871 sampai 0,9927. Nilai *accuracy* tertinggi diperoleh pada *fold* ke-2 sebesar 0,9927, sedangkan nilai *accuracy* terendah diperoleh pada *fold* ke-5 sebesar 0,9871. Selain itu, nilai *F1-score* pada model *XGBoost* berada pada rentang 0,9833 sampai 0,9905. Hasil tersebut menunjukkan bahwa model *XGBoost* juga mampu mengklasifikasikan target *Height for Age* dengan sangat baik.

Dari sisi waktu komputasi, model *LightGBM* membutuhkan *total time* sekitar 0,4793 sampai 0,5503 detik pada setiap *fold*. Sementara itu, model *XGBoost* membutuhkan *total time* sekitar 0,2708 sampai 0,3014 detik. Berdasarkan hasil tersebut, kedua model memiliki performa klasifikasi yang sangat baik pada target *Height for Age*. Namun, model *LightGBM* menghasilkan nilai evaluasi yang sedikit lebih tinggi, sedangkan model *XGBoost* membutuhkan waktu komputasi yang lebih singkat.

Tabel 4. 16 Hasil Pengujian 5 K-Fold Cross Validation Height For Age

Target	Model	Fold	Accuracy	Precision	Recall	F1	Train Time (s)	Predict Time (s)	Total Time (s)
Height for Age	LightGBM	1	0.9927	0.9882	0.9929	0.9905	0.4351	0.0463	0.4814
	XGBoost		0.9909	0.9857	0.9908	0.9882	0.2802	0.0211	0.3014
Height for Age	LightGBM	2	0.9920	0.9877	0.9915	0.9896	0.4653	0.0461	0.5114
	XGBoost		0.9927	0.9874	0.9937	0.9905	0.2656	0.0165	0.2822
	LightGBM	3	0.9906	0.9851	0.9906	0.9878	0.4299	0.0494	0.4793

Tabel 4.16 (Lanjutan)

Target	Model	Fold	Accuracy	Precision	Recall	F1	Train Time (s)	Predict Time (s)	Total Time (s)
Height for Age	XGBoost		0.9881	0.9806	0.9889	0.9847	0.2574	0.0160	0.2734
Height for Age	LightGBM	4	0.9902	0.9856	0.9890	0.9873	0.4945	0.0558	0.5503
	XGBoost		0.9888	0.9838	0.9872	0.9855	0.2565	0.0269	0.2834
Height for Age	LightGBM	5	0.9892	0.9833	0.9888	0.9860	0.4520	0.0490	0.5010
	XGBoost		0.9871	0.9795	0.9873	0.9833	0.2557	0.0151	0.2708

Pengujian *5-Fold Cross Validation* pada target *Weight for Height* dilakukan untuk mengetahui kestabilan performa model pada beberapa pembagian data. Pengujian ini menggunakan dua algoritma, yaitu *LightGBM* dan *XGBoost*. Hasil pengujian tersebut disajikan pada Tabel 4.17.

Tabel 4.17 menunjukkan hasil evaluasi model berdasarkan nilai *accuracy*, *precision*, *recall*, *F1-score*, *train time*, *predict time*, dan *total time*. Setiap model diuji sebanyak 5 *fold* untuk melihat perubahan performa pada setiap pembagian data. Hasil tersebut digunakan untuk membandingkan kemampuan klasifikasi dan waktu komputasi antara model *LightGBM* dan *XGBoost* pada target *Weight for Height*.

Pada model *LightGBM*, nilai *accuracy* berada pada rentang 0,9630 sampai 0,9693. Nilai *accuracy* tertinggi diperoleh pada *fold* ke-3 sebesar 0,9693,

sedangkan nilai *accuracy* terendah diperoleh pada *fold* ke-2 sebesar 0,9630. Selain itu, nilai *F1-score* pada model *LightGBM* berada pada rentang 0,8236 sampai 0,8661. Nilai *F1-score* tertinggi diperoleh pada *fold* ke-5 sebesar 0,8661, sedangkan nilai terendah diperoleh pada *fold* ke-2 sebesar 0,8236. Hasil tersebut menunjukkan bahwa model *LightGBM* mampu menghasilkan performa klasifikasi yang baik dan cukup stabil pada target *Weight for Height*.

Pada model *XGBoost*, nilai *accuracy* berada pada rentang 0,9522 sampai 0,9581. Nilai *accuracy* tertinggi diperoleh pada *fold* ke-3 sebesar 0,9581, sedangkan nilai *accuracy* terendah diperoleh pada *fold* ke-2 sebesar 0,9522. Nilai *F1-score* pada model *XGBoost* berada pada rentang 0,7793 sampai 0,8050. Nilai *F1-score* tertinggi diperoleh pada *fold* ke-3 sebesar 0,8050, sedangkan nilai terendah diperoleh pada *fold* ke-2 sebesar 0,7793. Hasil tersebut menunjukkan bahwa model *XGBoost* masih mampu melakukan klasifikasi pada target *Weight for Height*, tetapi performanya cenderung lebih rendah dibandingkan model *LightGBM*.

Dari sisi waktu komputasi, model *LightGBM* membutuhkan *total time* sekitar 1,5028 sampai 1,6182 detik pada setiap *fold*. Sementara itu, model *XGBoost* membutuhkan total *time* sekitar 1,3046 sampai 2,1005 detik. Berdasarkan hasil tersebut, model *LightGBM* menunjukkan performa klasifikasi yang lebih baik dan lebih stabil pada target *Weight for Height*. Model *XGBoost* memiliki waktu komputasi yang lebih cepat pada beberapa *fold*, tetapi sebaran waktunya terlihat lebih bervariasi.

Tabel 4. 17 Hasil 5-Fold Cross Validation Target Weight for Height

Target	Model	Fold	Accuracy	Precision	Recall	F1	Train Time (s)	Predict Time (s)	Total Time (s)
Weight for Height	LightGBM	1	0.9689	0.9282	0.7994	0.8481	1.2504	0.2649	1.5153
	XGBoost		0.9578	0.9282	0.7149	0.7954	1.5140	0.1042	1.6181
Weight for Height	LightGBM	2	0.9630	0.8502	0.8041	0.8236	1.3242	0.2940	1.6182
	XGBoost		0.9522	0.8427	0.7316	0.7793	1.9867	0.1138	2.1005
Weight for Height	LightGBM	3	0.9693	0.9007	0.8323	0.8630	1.2512	0.2516	1.5028
	XGBoost		0.9581	0.8836	0.7466	0.8050	1.3290	0.0564	1.3854
Weight for Height	LightGBM	4	0.9647	0.8773	0.8444	0.8601	1.2743	0.2691	1.5434
	XGBoost		0.9557	0.9005	0.7259	0.7968	1.2465	0.0581	1.3046
Weight for Height	LightGBM	5	0.9686	0.9147	0.8272	0.8661	1.2476	0.2620	1.5096
	XGBoost		0.9550	0.8982	0.7155	0.7866	1.2899	0.0583	1.3482

Pada target Weight for Age, model LightGBM menampilkan hasil evaluasi detail untuk setiap kategori pada masing-masing fold. Evaluasi ini digunakan untuk mengetahui kemampuan model dalam mengklasifikasikan kategori Malnutrition, Underfed, Normal, dan Overnutrition. Setiap kategori dievaluasi berdasarkan jumlah data atau support, serta nilai precision, recall, dan F1-score. Tabel 4.18 menjelaskan hasil evaluasi detail model LightGBM pada target Weight for Age berdasarkan kategori, support, precision, recall, dan F1-score pada setiap fold.

Pada kategori Malnutrition, model LightGBM menunjukkan performa yang cukup baik pada setiap fold. Nilai precision berada pada rentang 0,9060 sampai 0,9313, sedangkan nilai recall berada pada rentang 0,8320 sampai 0,8996. Hasil tersebut menunjukkan bahwa model mampu memprediksi kategori Malnutrition dengan cukup tepat, meskipun masih terdapat beberapa data yang belum berhasil dikenali secara maksimal.

Pada kategori Underfed, model juga menghasilkan performa yang cukup stabil. Nilai precision berada pada rentang 0,8831 sampai 0,9019, sedangkan nilai recall berada pada rentang 0,8829 sampai 0,9199. Nilai tersebut menunjukkan bahwa model mampu mengenali kategori Underfed dengan baik pada setiap fold. Selain itu, nilai precision dan recall yang relatif seimbang menunjukkan bahwa model memiliki kemampuan klasifikasi yang cukup konsisten.

Pada kategori Normal, model LightGBM menghasilkan performa paling baik dibandingkan kategori lainnya. Nilai precision dan recall pada kategori ini berada di atas 0,95 pada seluruh fold. Hasil tersebut menunjukkan bahwa model mampu mengenali kategori Normal dengan sangat baik. Kondisi ini dapat dipengaruhi oleh jumlah data kategori Normal yang lebih banyak, sehingga pola data lebih mudah dipelajari oleh model.

Sementara itu, pada kategori Overnutrition, model memperoleh hasil evaluasi yang lebih rendah dibandingkan kategori lainnya. Nilai precision pada kategori ini cenderung tinggi, tetapi nilai recall masih rendah, yaitu berada pada rentang 0,2500 sampai 0,5294. Hasil tersebut menunjukkan bahwa model cukup

tepat ketika memprediksi kategori Overnutrition, tetapi model belum optimal dalam mengenali seluruh data pada kategori tersebut. Hal ini dapat terjadi karena jumlah data Overnutrition pada setiap fold jauh lebih sedikit dibandingkan kategori lain.

Tabel 4. 18 Hasil Pengujian Model LightGBM 5 K-Fold Cross

Fold	Kode	Kategori	Support	Precision	Recall	F1-Score
1	0	Malnutrition	249	0.9174	0.8916	0.9043
	1	Underfed	811	0.9019	0.8952	0.8985
	2	Normal	1789	0.9591	0.9698	0.9644
	3	Overnutrition	17	0.9000	0.5294	0.6667
2	0	Malnutrition	250	0.9060	0.8480	0.8760
	1	Underfed	810	0.8831	0.9136	0.8981
	2	Normal	1789	0.9653	0.9653	0.9653
	3	Overnutrition	16	1.0000	0.2500	0.4000
3	0	Malnutrition	250	0.9313	0.8680	0.8986
	1	Underfed	811	0.8861	0.9112	0.8985
	2	Normal	1788	0.9642	0.9653	0.9648
	3	Overnutrition	16	1.0000	0.5000	0.6667
4	0	Malnutrition	250	0.9204	0.8320	0.8739
	1	Underfed	811	0.8860	0.9199	0.9026
	2	Normal	1788	0.9692	0.9687	0.9690

Tabel 4.18 (Lanjutan)

Fold	Kode	Kategori	Support	Precision	Recall	F1-Score
	3	Overnutrition	16	0.8000	0.5000	0.6154
5	0	Malnutrition	249	0.9180	0.8996	0.9087
	1	Underfed	811	0.8883	0.8829	0.8856
	2	Normal	1788	0.9530	0.9636	0.9583
	3	Overnutrition	17	1.0000	0.4118	0.5833

Pada target *Weight for Age*, model *XGBoost* menampilkan hasil evaluasi detail untuk setiap kategori pada masing-masing *fold*. Evaluasi ini dilakukan untuk mengetahui kemampuan model dalam mengklasifikasikan kategori *Malnutrition*, *Underfed*, *Normal*, dan *Overnutrition*. Setiap kategori dinilai berdasarkan jumlah data atau *support*, serta nilai *precision*, *recall*, dan *F1-score*. Tabel 2.19 menjelaskan hasil evaluasi detail model *XGBoost* pada target *Weight for Age* berdasarkan kategori, *support*, *precision*, *recall*, dan *F1-score* pada setiap *fold*.

Pada kategori *Malnutrition*, model *XGBoost* menghasilkan nilai *precision* yang cukup tinggi pada setiap *fold*, yaitu berada pada rentang 0,9122 sampai 0,9538. Namun, nilai *recall* berada pada rentang 0,7440 sampai 0,8040. Hasil tersebut menunjukkan bahwa model cukup tepat dalam memprediksi kategori *Malnutrition*, tetapi model masih belum mengenali seluruh data *Malnutrition* secara maksimal.

Pada kategori *Underfed*, model menunjukkan performa yang cukup stabil. Nilai *precision* berada pada rentang 0,8529 sampai 0,8701, sedangkan nilai *recall* berada pada rentang 0,8508 sampai 0,9001. Nilai tersebut menunjukkan bahwa model mampu mengklasifikasikan kategori *Underfed* dengan cukup baik pada setiap *fold*. Selain itu, nilai *precision* dan *recall* yang cukup seimbang menunjukkan bahwa model memiliki kemampuan prediksi yang cukup konsisten pada kategori ini.

Pada kategori *Normal*, model *XGBoost* memperoleh hasil evaluasi paling baik dibandingkan kategori lainnya. Nilai *precision* berada pada rentang 0,9350 sampai 0,9557, sedangkan nilai *recall* berada pada rentang 0,9642 sampai 0,9670. Hasil tersebut menunjukkan bahwa model mampu mengenali kategori *Normal* dengan sangat baik. Kondisi ini dapat terjadi karena jumlah data pada kategori *Normal* lebih banyak dibandingkan kategori lainnya, sehingga pola data lebih mudah dipelajari oleh model.

Sementara itu, pada kategori *Overnutrition*, model memperoleh nilai *recall* yang lebih rendah dibandingkan kategori lain, yaitu berada pada rentang 0,2941 sampai 0,5625. Meskipun nilai *precision* pada beberapa *fold* tergolong tinggi, yaitu berada pada rentang 0,8571 sampai 1,0000, model belum optimal dalam mengenali seluruh data pada kategori *Overnutrition*. Hal ini dapat dipengaruhi oleh jumlah data *Overnutrition* yang jauh lebih sedikit pada setiap *fold* dibandingkan kategori lainnya.

Tabel 4. 19 Hasil Pengujian Model XGBoost 5 K-Fold Cross Validation Weight For Age

Fold	Kode	Kategori	Support	Precision	Recall	F1-Score
1	0	Malnutrition	249	0.9122	0.7510	0.8238
	1	Underfed	811	0.8592	0.8730	0.8661
	2	Normal	1789	0.9464	0.9670	0.9566
	3	Overnutrition	17	0.8889	0.4706	0.6154
2	0	Malnutrition	250	0.9187	0.7680	0.8366
	1	Underfed	810	0.8641	0.8951	0.8793
	2	Normal	1789	0.9531	0.9653	0.9592
	3	Overnutrition	16	1.0000	0.3125	0.4762
3	0	Malnutrition	250	0.9481	0.8040	0.8701
	1	Underfed	811	0.8701	0.9001	0.8848
	2	Normal	1788	0.9557	0.9648	0.9602
	3	Overnutrition	16	1.0000	0.5625	0.7200
4	0	Malnutrition	250	0.9538	0.7440	0.8360
	1	Underfed	811	0.8529	0.8940	0.8730
	2	Normal	1788	0.9509	0.9642	0.9575
	3	Overnutrition	16	0.8571	0.3750	0.5217
5	0	Malnutrition	249	0.9194	0.7791	0.8435
	1	Underfed	811	0.8582	0.8508	0.8545
	2	Normal	1788	0.9350	0.9648	0.9496
	3	Overnutrition	17	1.0000	0.2941	0.4545

Pada target *Height for Age*, model *LightGBM* menampilkan hasil evaluasi detail pada dua kategori, yaitu *Stunted* dan *Not Stunted* di setiap *fold*. Evaluasi ini digunakan untuk melihat kemampuan model dalam mengklasifikasikan status pertumbuhan balita berdasarkan indikator tinggi badan menurut umur. Setiap kategori dinilai berdasarkan jumlah data atau *support*, serta nilai *precision*, *recall*, dan *F1-score*. Tabel 4.20 menjelaskan hasil evaluasi detail model *LightGBM* pada target *Height for Age* berdasarkan kategori, *support*, *precision*, *recall*, dan *F1-score* pada setiap *fold*.

Pada kategori *Stunted*, model *LightGBM* menunjukkan performa yang sangat baik pada seluruh *fold*. Nilai *precision* berada pada rentang 0,9953 sampai 0,9976, sedangkan nilai *recall* berada pada rentang 0,9896 sampai 0,9925. Hasil tersebut menunjukkan bahwa model mampu memprediksi dan mengenali kategori *Stunted* dengan tingkat ketepatan yang tinggi dan stabil.

Pada kategori *Not Stunted*, model juga menghasilkan nilai evaluasi yang baik. Nilai *precision* berada pada rentang 0,9709 sampai 0,9788, sedangkan nilai *recall* berada pada rentang 0,9865 sampai 0,9933. Hasil tersebut menunjukkan bahwa model mampu mengenali sebagian besar data *Not Stunted* dengan tepat pada setiap *fold*.

Secara keseluruhan, model *LightGBM* menunjukkan performa yang sangat baik pada target *Height for Age*. Nilai *F1-score* yang tinggi pada kedua kategori menunjukkan bahwa model memiliki keseimbangan yang baik antara ketepatan prediksi dan kemampuan mengenali data. Dengan demikian, model *LightGBM*

dapat dinilai mampu mengklasifikasikan kategori *Stunted* dan *Not Stunted* secara akurat pada pengujian *K-Fold Cross Validation*.

Tabel 4. 20 Hasil Pengujian Model LightGBM 5 K-Fold Cross Validation

Height For Age

Fold	Kode	Kategori	Support	Precision	Recall	F1-Score
1	0	Stunted	2124	0.9976	0.9925	0.9950
	1	Not Stunted	742	0.9788	0.9933	0.9860
2	0	Stunted	2124	0.9967	0.9925	0.9946
	1	Not Stunted	741	0.9787	0.9906	0.9846
3	0	Stunted	2124	0.9967	0.9906	0.9936
	1	Not Stunted	741	0.9735	0.9906	0.9819
4	0	Stunted	2124	0.9953	0.9915	0.9934
	1	Not Stunted	741	0.9760	0.9865	0.9812
5	0	Stunted	2123	0.9957	0.9896	0.9927
	1	Not Stunted	742	0.9709	0.9879	0.9793

Pada target *Height for Age*, model *XGBoost* menampilkan hasil evaluasi detail pada dua kategori, yaitu *Stunted* dan *Not Stunted* untuk setiap *fold*. Evaluasi ini dilakukan untuk melihat kemampuan model dalam mengklasifikasikan status pertumbuhan balita berdasarkan indikator tinggi badan menurut umur. Setiap kategori dievaluasi menggunakan jumlah data atau *support*, serta nilai *precision*, *recall*, dan *F1-score*. Tabel 4.21 menjelaskan hasil evaluasi detail model *XGBoost*

pada target *Height for Age* berdasarkan kategori, *support*, *precision*, *recall*, dan *F1-score* pada setiap *fold*.

Pada kategori *Stunted*, model *XGBoost* memperoleh hasil yang sangat baik pada seluruh *fold*. Nilai *precision* berada pada rentang 0,9943 sampai 0,9986, sedangkan nilai *recall* berada pada rentang 0,9868 sampai 0,9915. Hasil tersebut menunjukkan bahwa model mampu memprediksi kategori *Stunted* dengan tingkat ketepatan yang tinggi dan konsisten.

Pada kategori *Not Stunted*, model juga menunjukkan performa yang baik. Nilai *precision* berada pada rentang 0,9632 sampai 0,9762, sedangkan nilai *recall* berada pada rentang 0,9838 sampai 0,9960. Nilai tersebut menunjukkan bahwa model mampu mengenali sebagian besar data *Not Stunted* dengan tepat pada setiap *fold*.

Secara keseluruhan, model *XGBoost* memiliki performa yang sangat baik pada target *Height for Age*. Nilai *F1-score* yang tinggi pada kedua kategori menunjukkan bahwa model memiliki keseimbangan yang baik antara ketepatan prediksi dan kemampuan mengenali data. Oleh karena itu, model *XGBoost* dapat dinilai mampu mengklasifikasikan kategori *Stunted* dan *Not Stunted* secara akurat pada pengujian *K-Fold Cross Validation*.

Tabel 4. 21 Hasil Pengujian Model XGBoost 5 K-Fold Cross Validation Height For Age

Fold	Kode	Kategori	Support	Precision	Recall	F1-Score
1	0	Stunted	2124	0.9967	0.9911	0.9939
	1	Not Stunted	742	0.9748	0.9906	0.9826
2	0	Stunted	2124	0.9986	0.9915	0.9950
	1	Not Stunted	741	0.9762	0.9960	0.9860
3	0	Stunted	2124	0.9967	0.9873	0.9920
	1	Not Stunted	741	0.9645	0.9906	0.9774
4	0	Stunted	2124	0.9943	0.9906	0.9925
	1	Not Stunted	741	0.9733	0.9838	0.9785
5	0	Stunted	2123	0.9957	0.9868	0.9912
	1	Not Stunted	742	0.9632	0.9879	0.9754

Pada target *Weight for Height*, model *LightGBM* menampilkan hasil evaluasi detail untuk setiap kategori pada setiap *fold*. Evaluasi ini dilakukan untuk mengetahui kemampuan model dalam mengklasifikasikan status gizi berdasarkan indikator berat badan menurut tinggi badan. Kategori yang digunakan terdiri dari *Very Thin*, *Thin*, *Normal*, dan *Obese*. Setiap kategori dievaluasi berdasarkan jumlah data atau *support*, serta nilai *precision*, *recall*, dan *F1-score*. Tabel 4.22 menjelaskan hasil evaluasi detail model *LightGBM* pada target *Weight for Height* berdasarkan kategori, *support*, *precision*, *recall*, dan *F1-score* pada setiap *fold*.

Pada kategori *Very Thin*, model *LightGBM* menghasilkan nilai evaluasi yang cukup beragam pada setiap *fold*. Nilai *precision* berada pada rentang 0,7500

sampai 0,9565, sedangkan nilai *recall* berada pada rentang 0,5366 sampai 0,7500. Hasil tersebut menunjukkan bahwa model cukup tepat dalam memprediksi kategori *Very Thin*, tetapi model masih belum maksimal dalam mengenali seluruh data pada kategori tersebut.

Pada kategori *Thin*, model menunjukkan performa yang cukup stabil. Nilai *precision* berada pada rentang 0,8060 sampai 0,8558, sedangkan nilai *recall* berada pada rentang 0,7768 sampai 0,8482. Nilai tersebut menunjukkan bahwa model mampu mengklasifikasikan kategori *Thin* dengan cukup baik pada setiap *fold*. Selain itu, nilai *precision* dan *recall* yang relatif seimbang menunjukkan bahwa model memiliki kemampuan klasifikasi yang cukup konsisten.

Pada kategori *Normal*, model *LightGBM* memperoleh hasil evaluasi paling baik dibandingkan kategori lainnya. Nilai *precision* dan *recall* pada kategori ini berada di atas 0,98 pada seluruh *fold*. Hasil tersebut menunjukkan bahwa model mampu mengenali kategori *Normal* dengan sangat baik. Kondisi ini dapat terjadi karena jumlah data pada kategori *Normal* lebih banyak dibandingkan kategori lain, sehingga pola data lebih mudah dikenali oleh model.

Sementara itu, pada kategori *Obese*, model juga memperoleh hasil evaluasi yang cukup baik. Nilai *precision* berada pada rentang 0,8451 sampai 0,9545, sedangkan nilai *recall* berada pada rentang 0,8219 sampai 0,8630. Hasil tersebut menunjukkan bahwa model mampu mengklasifikasikan kategori *Obese* dengan cukup baik pada setiap *fold*. Secara keseluruhan, model *LightGBM* dapat dinilai

memiliki performa yang baik dalam klasifikasi target *Weight for Height*, terutama pada kategori Normal dan *Obese*.

Tabel 4. 22 Hasil Pengujian Model LightGBM 5 K-Fold Cross Validation

Fold	Kode	Kategori	Support	Precision	Recall	F1-Score
1	0	Very Thin	41	0.9565	0.5366	0.6875
	1	Thin	224	0.8370	0.8482	0.8426
	2	Normal	2528	0.9816	0.9909	0.9862
	3	Obese	73	0.9375	0.8219	0.8759
2	0	Very Thin	40	0.7667	0.5750	0.6571
	1	Thin	224	0.8060	0.8348	0.8202
	2	Normal	2528	0.9830	0.9846	0.9838
	3	Obese	73	0.8451	0.8219	0.8333
3	0	Very Thin	40	0.8387	0.6500	0.7324
	1	Thin	224	0.8409	0.8259	0.8333
	2	Normal	2528	0.9827	0.9901	0.9864
	3	Obese	73	0.9403	0.8630	0.9000
4	0	Very Thin	40	0.7500	0.7500	0.7500
	1	Thin	224	0.8246	0.7768	0.8000
	2	Normal	2528	0.9800	0.9877	0.9838
	3	Obese	73	0.9545	0.8630	0.9065

Tabel 4.22 (Lanjutan)

Fold	Kode	Kategori	Support	Precision	Recall	F1-Score
5	0	Very Thin	40	0.9000	0.6750	0.7714
	1	Thin	224	0.8558	0.8214	0.8383
	2	Normal	2528	0.9800	0.9905	0.9852
	3	Obese	73	0.9231	0.8219	0.8696

Pada target *Weight for Height*, model *XGBoost* menampilkan hasil evaluasi detail pada setiap kategori di masing-masing *fold*. Evaluasi ini dilakukan untuk mengetahui kemampuan model dalam mengklasifikasikan status gizi berdasarkan indikator berat badan menurut tinggi badan. Kategori yang digunakan terdiri dari *Very Thin*, *Thin*, *Normal*, dan *Obese*. Setiap kategori dinilai berdasarkan jumlah data atau *support*, serta nilai *precision*, *recall*, dan *F1-score*. Tabel 4.23 menjelaskan hasil evaluasi detail model *XGBoost* pada target *Weight for Height* berdasarkan kategori, *support*, *precision*, *recall*, dan *F1-score* pada setiap *fold*.

Pada kategori *Very Thin*, model *XGBoost* menghasilkan nilai evaluasi yang cukup berbeda pada setiap *fold*. Nilai *precision* berada pada rentang 0,7037 sampai 0,9545, sedangkan nilai *recall* berada pada rentang 0,4750 sampai 0,6000. Hasil tersebut menunjukkan bahwa model cukup tepat ketika memprediksi kategori *Very Thin*, tetapi model masih belum maksimal dalam mengenali seluruh data pada kategori tersebut.

Pada kategori *Thin*, model memperoleh hasil evaluasi yang cukup baik. Nilai *precision* berada pada rentang 0,7800 sampai 0,8549, sedangkan nilai *recall* berada pada rentang 0,6964 sampai 0,7366. Hasil tersebut menunjukkan bahwa model mampu mengklasifikasikan kategori *Thin* dengan cukup baik, meskipun masih terdapat beberapa data yang belum berhasil dikenali secara tepat.

Pada kategori *Normal*, model *XGBoost* memperoleh performa paling tinggi dibandingkan kategori lainnya. Nilai *precision* berada pada rentang 0,9654 sampai 0,9695, sedangkan nilai *recall* berada pada rentang 0,9877 sampai 0,9945. Hasil tersebut menunjukkan bahwa model mampu mengenali kategori *Normal* dengan sangat baik. Kondisi ini dapat terjadi karena jumlah data pada kategori *Normal* lebih banyak dibandingkan kategori lain, sehingga pola data lebih mudah dipelajari oleh model.

Sementara itu, pada kategori *Obese*, model menghasilkan nilai evaluasi yang cukup baik. Nilai *precision* berada pada rentang 0,9180 sampai 0,9615, sedangkan nilai *recall* berada pada rentang 0,6164 sampai 0,7671. Hasil tersebut menunjukkan bahwa model cukup tepat dalam memprediksi kategori *Obese*, tetapi kemampuan model dalam mengenali seluruh data pada kategori tersebut masih belum optimal. Secara keseluruhan, model *XGBoost* dapat digunakan untuk klasifikasi target *Weight for Height*, terutama karena performanya sangat baik pada kategori Normal.

Tabel 4. 23 Hasil Pengujian Model XGboost 5 K-Fold Cross Validation

Weight For Height

Fold	Kode	Kategori	Support	Precision	Recall	F1-Score
1	0	Very Thin	41	0.9545	0.5122	0.6667
	1	Thin	224	0.8549	0.7366	0.7914
	2	Normal	2528	0.9658	0.9945	0.9799
	3	Obese	73	0.9375	0.6164	0.7438
2	0	Very Thin	40	0.7037	0.4750	0.5672
	1	Thin	224	0.7800	0.6964	0.7358
	2	Normal	2528	0.9690	0.9877	0.9783
	3	Obese	73	0.9180	0.7671	0.8358
3	0	Very Thin	40	0.8000	0.6000	0.6857
	1	Thin	224	0.8418	0.7366	0.7857
	2	Normal	2528	0.9695	0.9921	0.9806
	3	Obese	73	0.9231	0.6575	0.7680
4	0	Very Thin	40	0.8400	0.5250	0.6462
	1	Thin	224	0.8351	0.7009	0.7621
	2	Normal	2528	0.9654	0.9929	0.9789
	3	Obese	73	0.9615	0.6849	0.8000
5	0	Very Thin	40	0.8636	0.4750	0.6129
	1	Thin	224	0.8196	0.7098	0.7608
	2	Normal	2528	0.9661	0.9921	0.9789
	3	Obese	73	0.9434	0.6849	0.7937

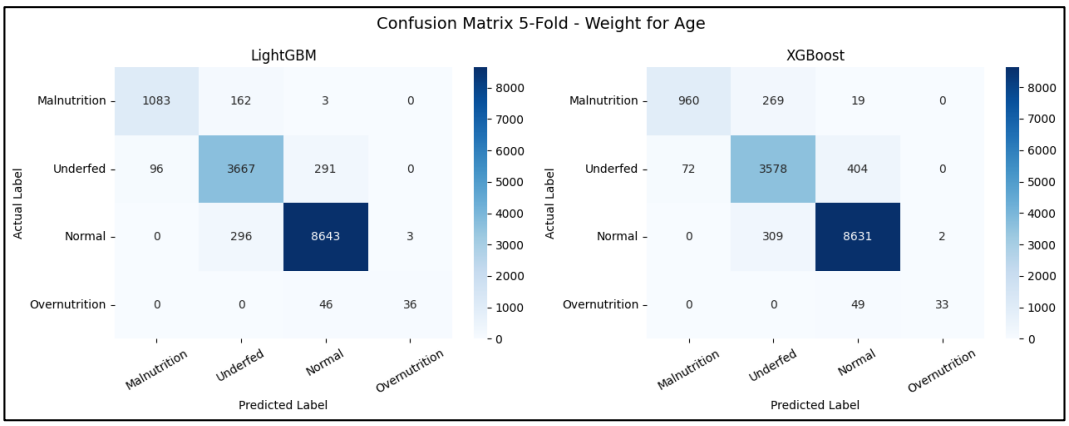
Evaluasi menggunakan *confusion matrix* dilakukan untuk melihat kemampuan model dalam mengklasifikasikan setiap kategori pada target *Weight for Age*. Hasil evaluasi tersebut ditampilkan pada Gambar 4.16. Pada gambar tersebut, baris menunjukkan label sebenarnya, sedangkan kolom menunjukkan label hasil prediksi model. Nilai pada diagonal utama menunjukkan jumlah data yang berhasil diprediksi dengan benar. Semakin besar nilai pada diagonal utama, semakin baik kemampuan model dalam mengklasifikasikan data.

Pada model *LightGBM*, kategori *Normal* menjadi kategori yang paling banyak diprediksi dengan benar, yaitu sebanyak 8.643 data. Model ini juga berhasil mengklasifikasikan kategori *Underfed* sebanyak 3.667 data, kategori *Malnutrition* sebanyak 1.083 data, dan kategori *Overnutrition* sebanyak 36 data. Namun, beberapa kesalahan prediksi masih ditemukan. Sebanyak 162 data *Malnutrition* diprediksi sebagai *Underfed*, 3 data *Malnutrition* diprediksi sebagai *Normal*, 96 data *Underfed* diprediksi sebagai *Malnutrition*, dan 291 data *Underfed* diprediksi sebagai *Normal*. Selain itu, 296 data *Normal* diprediksi sebagai *Underfed*, 3 data *Normal* diprediksi sebagai *Overnutrition*, serta 46 data *Overnutrition* diprediksi sebagai *Normal*.

Pada model *XGBoost*, kategori *Normal* juga menjadi kategori yang paling banyak diprediksi dengan benar, yaitu sebanyak 8.631 data. Model ini berhasil mengklasifikasikan kategori *Underfed* sebanyak 3.578 data, kategori *Malnutrition* sebanyak 960 data, dan kategori *Overnutrition* sebanyak 33 data. Meskipun demikian, kesalahan prediksi masih terjadi pada beberapa kategori. Sebanyak 269

data *Malnutrition* diprediksi sebagai *Underfed*, 19 data *Malnutrition* diprediksi sebagai *Normal*, 72 data *Underfed* diprediksi sebagai *Malnutrition*, dan 404 data *Underfed* diprediksi sebagai *Normal*. Selain itu, 309 data *Normal* diprediksi sebagai *Underfed*, 2 data *Normal* diprediksi sebagai *Overnutrition*, serta 49 data *Overnutrition* diprediksi sebagai *Normal*.

Berdasarkan hasil *confusion matrix* pada Gambar 4.24, model *LightGBM* menunjukkan hasil yang lebih baik dibandingkan model *XGBoost* pada target *Weight for Age*. Hal ini terlihat dari jumlah prediksi benar yang lebih tinggi pada kategori *Malnutrition*, *Underfed*, *Normal*, dan *Overnutrition*. Namun, kedua model masih mengalami kesulitan dalam mengenali kategori *Overnutrition*. Kondisi tersebut dapat dipengaruhi oleh jumlah data *Overnutrition* yang lebih sedikit dibandingkan kategori lainnya.



Gambar 4. 16 Confusion Matrix 5 Fold - Weight For Age

Evaluasi menggunakan *confusion matrix* dilakukan untuk melihat kemampuan model dalam mengklasifikasikan kategori *Stunted* dan *Not Stunted* pada target *Height for Age*. Hasil evaluasi tersebut ditampilkan pada Gambar 4.17.

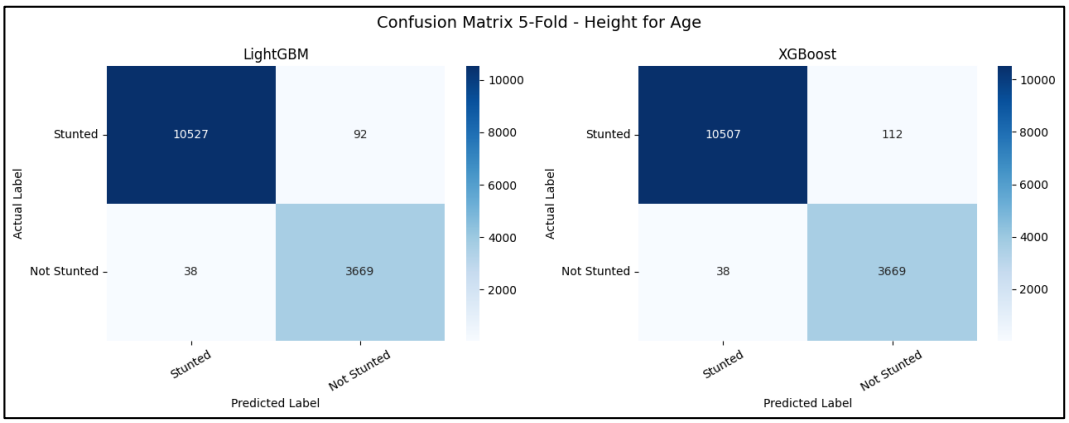
Pada gambar tersebut, baris menunjukkan label asli, sedangkan kolom menunjukkan label hasil prediksi model. Nilai pada diagonal utama menunjukkan jumlah data yang berhasil diklasifikasikan dengan benar oleh model.

Pada model *LightGBM*, kategori *Stunted* berhasil diklasifikasikan dengan benar sebanyak 10.527 data. Namun, sebanyak 92 data *Stunted* masih diprediksi sebagai *Not Stunted*. Pada kategori *Not Stunted*, model berhasil mengklasifikasikan 3.669 data dengan benar, sedangkan 38 data *Not Stunted* masih diprediksi sebagai *Stunted*. Hasil tersebut menunjukkan bahwa model *LightGBM* mampu membedakan kategori *Stunted* dan *Not Stunted* dengan sangat baik.

Pada model *XGBoost*, kategori *Stunted* berhasil diklasifikasikan dengan benar sebanyak 10.509 data. Namun, sebanyak 110 data *Stunted* masih diprediksi sebagai *Not Stunted*. Pada kategori *Not Stunted*, model berhasil mengklasifikasikan 3.666 data dengan benar, sedangkan 41 data *Not Stunted* masih diprediksi sebagai *Stunted*. Hasil tersebut menunjukkan bahwa model *XGBoost* juga memiliki kemampuan klasifikasi yang sangat baik pada target *Height for Age*.

Berdasarkan hasil *confusion matrix* pada Gambar 4.17, model *LightGBM* menunjukkan hasil yang sedikit lebih baik dibandingkan model *XGBoost*. Hal ini terlihat dari jumlah prediksi benar yang lebih tinggi pada kategori *Stunted* dan *Not Stunted*. Selain itu, model *LightGBM* juga menghasilkan jumlah kesalahan prediksi yang lebih rendah. Dengan demikian, model *LightGBM* dapat dinilai lebih unggul

dalam mengklasifikasikan target *Height for Age*, meskipun selisih performa kedua model tidak terlalu besar.



Gambar 4. 17 Confusion Matrix 5 Fold - Height For Age

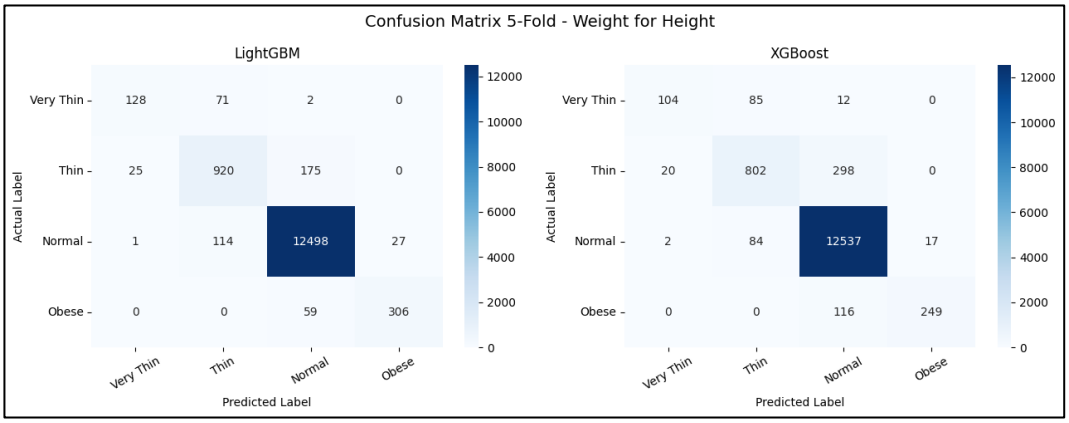
Evaluasi menggunakan *confusion matrix* dilakukan untuk melihat kemampuan model dalam mengklasifikasikan setiap kategori pada target *Weight for Height*. Hasil evaluasi tersebut ditampilkan pada Gambar 4.18. Pada gambar tersebut, baris menunjukkan label asli, sedangkan kolom menunjukkan label hasil prediksi. Nilai pada diagonal utama menunjukkan jumlah data yang berhasil diklasifikasikan dengan benar oleh model.

Pada model *LightGBM*, kategori *Normal* menjadi kategori yang paling banyak diklasifikasikan dengan benar, yaitu sebanyak 12.498 data. Selain itu, model juga berhasil mengklasifikasikan kategori *Thin* sebanyak 920 data, kategori *Obese* sebanyak 306 data, dan kategori *Very Thin* sebanyak 128 data. Namun, beberapa kesalahan prediksi masih terjadi. Sebanyak 71 data *Very Thin* diprediksi sebagai *Thin*, 2 data *Very Thin* diprediksi sebagai *Normal*, 25 data *Thin* diprediksi sebagai *Very Thin*, dan 175 data *Thin* diprediksi sebagai *Normal*. Selain itu, 1 data

Normal diprediksi sebagai *Very Thin*, 114 data *Normal* diprediksi sebagai *Thin*, 27 data *Normal* diprediksi sebagai *Obese*, serta 59 data *Obese* diprediksi sebagai *Normal*.

Pada model *XGBoost*, kategori *Normal* juga menjadi kategori yang paling banyak diklasifikasikan dengan benar, yaitu sebanyak 12.537 data. Model ini berhasil mengklasifikasikan kategori *Thin* sebanyak 802 data, kategori *Obese* sebanyak 249 data, dan kategori *Very Thin* sebanyak 104 data. Meskipun demikian, model masih menghasilkan beberapa kesalahan prediksi. Sebanyak 85 data *Very Thin* diprediksi sebagai *Thin*, 12 data *Very Thin* diprediksi sebagai *Normal*, 20 data *Thin* diprediksi sebagai *Very Thin*, dan 298 data *Thin* diprediksi sebagai *Normal*. Selain itu, 2 data *Normal* diprediksi sebagai *Very Thin*, 84 data *Normal* diprediksi sebagai *Thin*, 17 data *Normal* diprediksi sebagai *Obese*, serta 116 data *Obese* diprediksi sebagai *Normal*.

Berdasarkan hasil *confusion matrix* pada Gambar 4.18, model *LightGBM* menunjukkan performa yang lebih baik pada sebagian besar kategori, terutama pada kategori *Very Thin*, *Thin*, dan *Obese*. Sementara itu, model *XGBoost* memiliki jumlah prediksi benar yang lebih tinggi pada kategori *Normal*. Secara keseluruhan, model *LightGBM* dapat dinilai lebih stabil dalam mengklasifikasikan target *Weight for Height* karena jumlah kesalahan prediksi pada beberapa kategori lebih rendah dibandingkan model *XGBoost*.



Gambar 4. 18 Confusion Matrix 5 Fold - Weight For Age

4.2.6 Hasil Ringkasan Eksperimen

Setelah proses pengujian *5-Fold Cross Validation* selesai dilakukan pada setiap *fold*, penelitian ini menghitung nilai rata-rata dan standar deviasi dari seluruh metrik evaluasi. Metrik yang digunakan meliputi *accuracy*, *precision*, *recall*, *F1-score*, *train time*, *predict time*, dan waktu komputasi. Nilai rata-rata menunjukkan performa umum model pada seluruh pembagian data, sedangkan standar deviasi menunjukkan kestabilan performa model pada setiap *fold*. Hasil perhitungan rata-rata dan standar deviasi disajikan pada Tabel 4.24.

Tabel 4. 24 Hasil Ringkasan Eksperimen

Target	Model	Accuracy	Precision	Recall	F1-Score	Train Time (s)	Predict Time (s)	Waktu Komputasi (s)
Height for Age	LightGBM	0.9909 ± 0.0014	0.9860 ± 0.0020	0.9905 ± 0.0017	0.9882 ± 0.0018	0.4554 ± 0.0260	0.0493 ± 0.0039	0.5047 ± 0.0288
	XGBoost	0.9895 ± 0.0022	0.9834 ± 0.0033	0.9896 ± 0.0027	0.9864 ± 0.0029	0.2631 ± 0.0104	0.0191 ± 0.0049	0.2822 ± 0.0120

Tabel 4.24 (Lanjutan)

Target	Model	Accuracy	Precision	Recall	F1-Score	Train Time (s)	Predict Time (s)	Waktu Komputasi (s)
Weight for Age	LightGBM	0.9374 ± 0.0034	0.9275 ± 0.0211	0.7943 ± 0.0303	0.8349 ± 0.0299	1.3894 ± 0.2686	0.2626 ± 0.0340	1.6521 ± 0.2990
	XGBoost	0.9215 ± 0.0066	0.9222 ± 0.0186	0.7550 ± 0.0335	0.8069 ± 0.0324	1.3877 ± 0.1231	0.0685 ± 0.0227	1.4563 ± 0.1238
Weight for Height	LightGBM	0.9669 ± 0.0029	0.8942 ± 0.0310	0.8215 ± 0.0191	0.8522 ± 0.0174	1.2696 ± 0.0324	0.2683 ± 0.0158	1.5379 ± 0.0475
	XGBoost	0.9557 ± 0.0024	0.8906 ± 0.0313	0.7269 ± 0.0131	0.7926 ± 0.0099	1.4732 ± 0.3046	0.0782 ± 0.0283	1.5514 ± 0.3301

Berdasarkan Tabel 4.24, model *LightGBM* menunjukkan hasil evaluasi yang lebih tinggi pada sebagian besar target klasifikasi. Pada target *Height for Age*, model *LightGBM* memperoleh nilai *accuracy* sebesar 0,9909, *precision* sebesar 0,9860, *recall* sebesar 0,9905, dan *F1-score* sebesar 0,9882. Sementara itu, model *XGBoost* memperoleh nilai *accuracy* sebesar 0,9895, *precision* sebesar 0,9834, *recall* sebesar 0,9896, dan *F1-score* sebesar 0,9864. Hasil tersebut menunjukkan bahwa kedua model mampu mengklasifikasikan target *Height for Age* dengan sangat baik. Namun, model *LightGBM* memiliki nilai evaluasi yang sedikit lebih tinggi dibandingkan model *XGBoost*.

Pada target *Weight for Age*, model *LightGBM* memperoleh nilai *accuracy* sebesar 0,9374, *precision* sebesar 0,9275, *recall* sebesar 0,7943, dan *F1-score*

sebesar 0,8349. Model *XGBoost* memperoleh nilai *accuracy* sebesar 0,9215, *precision* sebesar 0,9222, *recall* sebesar 0,7550, dan *F1-score* sebesar 0,8069. Hasil tersebut menunjukkan bahwa model *LightGBM* memiliki kemampuan klasifikasi yang lebih baik pada target *Weight for Age*, terutama pada nilai *accuracy*, *recall*, dan *F1-score*.

Pada target *Weight for Height*, model *LightGBM* memperoleh nilai *accuracy* sebesar 0,9669, *precision* sebesar 0,8942, *recall* sebesar 0,8215, dan *F1-score* sebesar 0,8522. Model *XGBoost* memperoleh nilai *accuracy* sebesar 0,9557, *precision* sebesar 0,8906, *recall* sebesar 0,7269, dan *F1-score* sebesar 0,7926. Hasil tersebut menunjukkan bahwa model *LightGBM* kembali menghasilkan performa yang lebih baik dibandingkan model *XGBoost*, khususnya pada nilai *recall* dan *F1-score*.

Dari sisi waktu komputasi, model *XGBoost* memiliki waktu prediksi yang lebih cepat pada seluruh target klasifikasi. Pada target *Height for Age*, model *XGBoost* membutuhkan rata-rata waktu komputasi sebesar 0,2822 detik, sedangkan model *LightGBM* membutuhkan 0,5047 detik. Pada target *Weight for Age*, model *XGBoost* membutuhkan rata-rata waktu komputasi sebesar 1,4563 detik, sedangkan model *LightGBM* membutuhkan 1,6521 detik. Pada target *Weight for Height*, kedua model memiliki waktu komputasi yang hampir sama, yaitu 1,5379 detik pada model *LightGBM* dan 1,5514 detik pada model *XGBoost*.

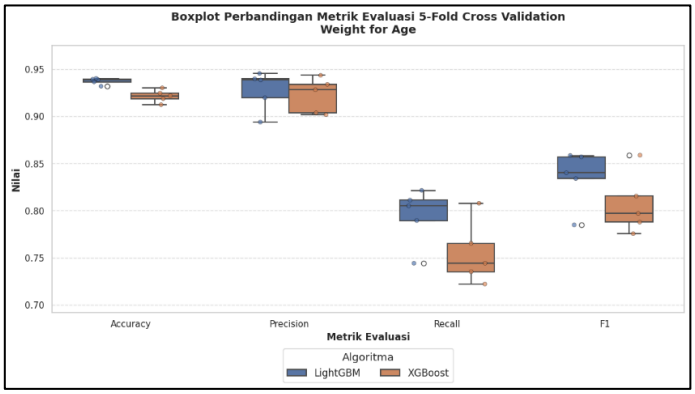
Secara keseluruhan, hasil ringkasan *5-Fold Cross Validation* menunjukkan bahwa model *LightGBM* lebih unggul dari sisi performa klasifikasi berdasarkan nilai

accuracy, *precision*, *recall*, dan *F1-score*. Sementara itu, model *XGBoost* lebih unggul dari sisi kecepatan prediksi. Dengan demikian, model *LightGBM* dapat dipilih sebagai model yang lebih baik untuk performa klasifikasi, sedangkan model *XGBoost* memiliki kelebihan pada efisiensi waktu prediksi.

4.2.7 Hasil Pengujian Boxplot Perbandingan Algoritma

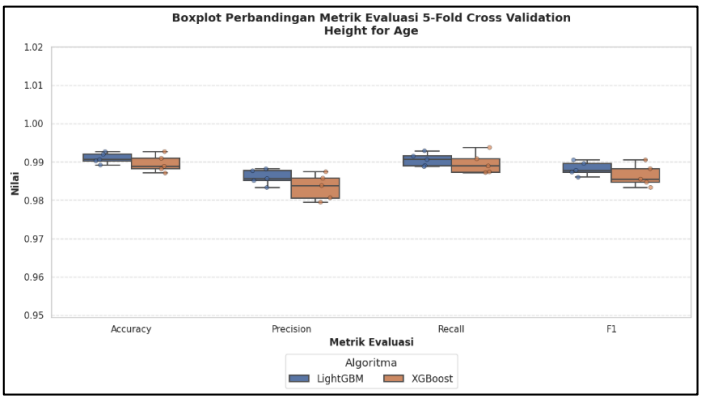
Penelitian ini menggunakan *boxplot* untuk menampilkan perbandingan sebaran nilai metrik evaluasi antara model *LightGBM* dan *XGBoost*. Pengujian ini menggunakan hasil *5-Fold Cross Validation* sebagai dasar analisis. Metrik evaluasi yang digunakan terdiri dari *accuracy*, *precision*, *recall*, dan *F1-score*.

Pada target *Weight for Age*, model *LightGBM* memperoleh nilai rata-rata *accuracy* sebesar 0,9374, *precision* sebesar 0,9275, *recall* sebesar 0,7943, dan *F1-score* sebesar 0,8349. Sementara itu, model *XGBoost* memperoleh nilai rata-rata *accuracy* sebesar 0,9215, *precision* sebesar 0,9222, *recall* sebesar 0,7550, dan *F1-score* sebesar 0,8069. Hasil tersebut menunjukkan bahwa model *LightGBM* memiliki performa yang lebih baik pada target *Weight for Age*. Model *LightGBM* menghasilkan nilai *accuracy*, *recall*, dan *F1-score* yang lebih tinggi dibandingkan model *XGBoost*. Hasil *boxplot* untuk target *Weight for Age* dapat dilihat pada Gambar 4.19.



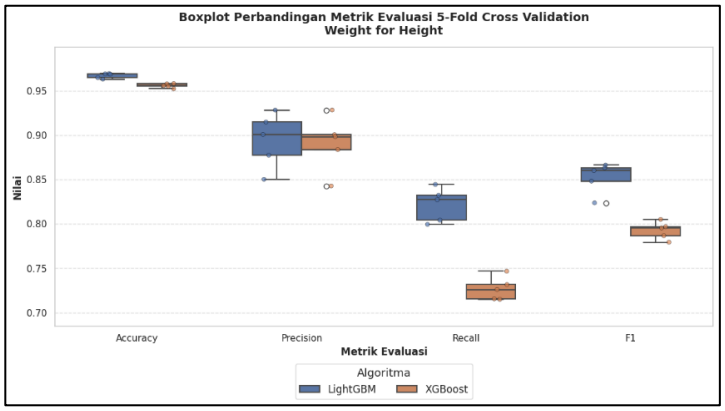
Gambar 4. 19 Boxplot Algoritma Weight For Age

Pada target *Height for Age*, model *LightGBM* memperoleh nilai rata-rata *accuracy* sebesar 0,9909, *precision* sebesar 0,9860, *recall* sebesar 0,9905, dan *F1-score* sebesar 0,9882. Model *XGBoost* memperoleh nilai rata-rata *accuracy* sebesar 0,9895, *precision* sebesar 0,9834, *recall* sebesar 0,9896, dan *F1-score* sebesar 0,9864. Hasil tersebut menunjukkan bahwa kedua model mampu menghasilkan performa klasifikasi yang sangat baik pada target *Height for Age*. Namun, model *LightGBM* tetap memiliki nilai rata-rata yang sedikit lebih tinggi pada sebagian besar metrik evaluasi. Hasil *boxplot* untuk target *Height for Age* dapat dilihat pada Gambar 4.20.



Gambar 4. 20 Boxplot Algoritma Height For Age

Pada target *Weight for Height*, model *LightGBM* memperoleh nilai rata-rata *accuracy* sebesar 0,9669, *precision* sebesar 0,8942, *recall* sebesar 0,8215, dan *F1-score* sebesar 0,8522. Sementara itu, model *XGBoost* memperoleh nilai rata-rata *accuracy* sebesar 0,9557, *precision* sebesar 0,8906, *recall* sebesar 0,7269, dan *F1-score* sebesar 0,7926. Hasil tersebut menunjukkan bahwa model *LightGBM* memiliki performa yang lebih unggul pada target *Weight for Height*. Model *LightGBM* menghasilkan nilai *recall* dan *F1-score* yang lebih tinggi, sehingga model tersebut lebih baik dalam mengenali kategori pada target tersebut. Hasil *boxplot* untuk target *Weight for Height* dapat dilihat pada Gambar 4.21.



Gambar 4. 21 Boxplot Algoritma Weight for Height

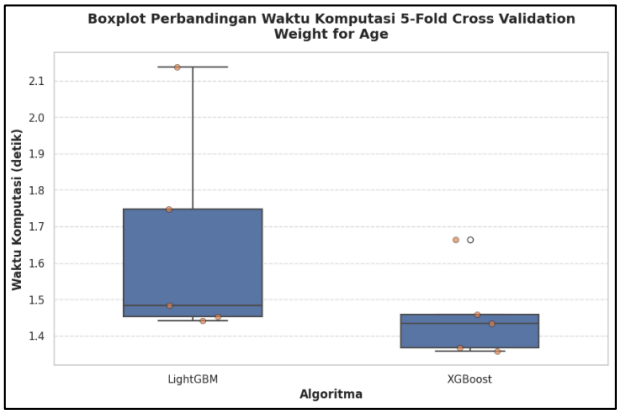
Secara keseluruhan, hasil pengujian *boxplot* menunjukkan bahwa model *LightGBM* memiliki performa yang lebih stabil dan lebih unggul pada sebagian besar target klasifikasi. Model *XGBoost* tetap menghasilkan performa yang baik, terutama pada target *Height for Age*. Namun, model *LightGBM* memiliki nilai evaluasi yang lebih tinggi pada beberapa metrik utama. Dengan demikian, hasil pengujian *boxplot* mendukung hasil evaluasi sebelumnya bahwa model *LightGBM*

lebih sesuai digunakan sebagai model utama dalam klasifikasi status pertumbuhan dan gizi balita.

4.2.8 Hasil Pengujian Boxplot Waktu Komputasi

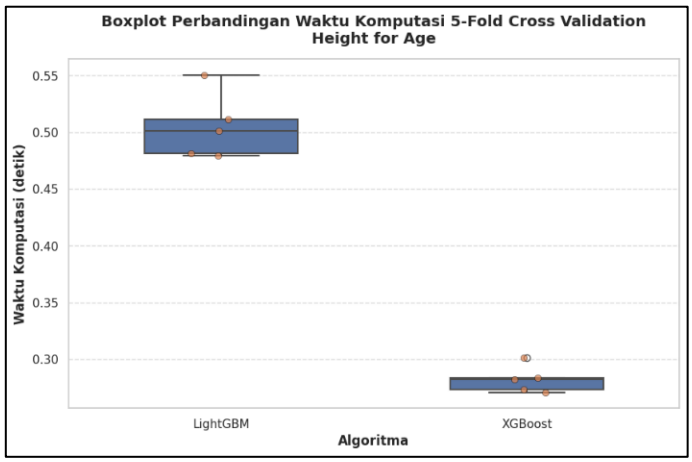
Penelitian ini menggunakan *boxplot* untuk menampilkan perbandingan sebaran waktu komputasi antara model *LightGBM* dan *XGBoost*. Pengujian ini menggunakan hasil *5-Fold Cross Validation* sebagai dasar analisis. Nilai yang digunakan dalam pengujian ini adalah *Total Time*. Nilai *Total Time* menunjukkan waktu keseluruhan yang dibutuhkan model dalam proses pelatihan dan prediksi.

Pada target *Weight for Age*, model *LightGBM* memperoleh rata-rata waktu komputasi sebesar 1,6521 detik dengan standar deviasi sebesar 0,2990. Model *XGBoost* memperoleh rata-rata waktu komputasi sebesar 1,4563 detik dengan standar deviasi sebesar 0,1238. Hasil tersebut menunjukkan bahwa model *XGBoost* membutuhkan waktu komputasi yang lebih cepat dibandingkan model *LightGBM*. Selain itu, model *XGBoost* juga menunjukkan waktu komputasi yang lebih stabil karena memiliki nilai standar deviasi yang lebih kecil. Hasil *boxplot* waktu komputasi pada target *Weight for Age* dapat dilihat pada Gambar 4.22.



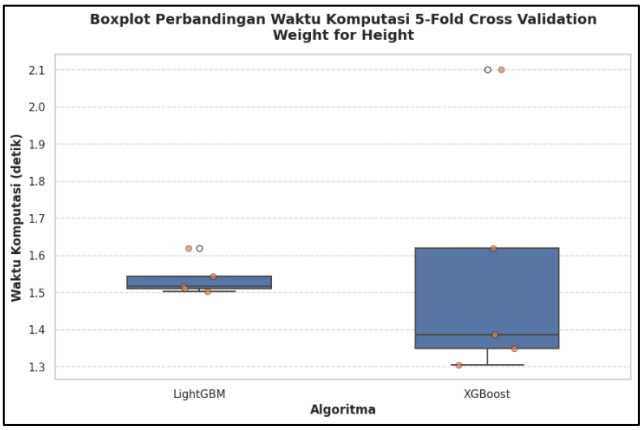
Gambar 4. 22 Boxplot Waktu Komputasi Weight For Age

Pada target *Height for Age*, model *LightGBM* memperoleh rata-rata waktu komputasi sebesar 0,5047 detik dengan standar deviasi sebesar 0,0288. Model *XGBoost* memperoleh rata-rata waktu komputasi sebesar 0,2822 detik dengan standar deviasi sebesar 0,0120. Hasil tersebut menunjukkan bahwa model *XGBoost* memiliki waktu komputasi yang lebih singkat pada target *Height for Age*. Model *XGBoost* juga memiliki sebaran waktu yang lebih stabil dibandingkan model *LightGBM*. Hasil *boxplot* waktu komputasi pada target *Height for Age* dapat dilihat pada Gambar 4.23.



Gambar 4. 23 Boxplot Waktu Komputasi Height For Age

Pada target *Weight for Height*, model *LightGBM* memperoleh rata-rata waktu komputasi sebesar 1,5379 detik dengan standar deviasi sebesar 0,0475. Model *XGBoost* memperoleh rata-rata waktu komputasi sebesar 1,5514 detik dengan standar deviasi sebesar 0,3301. Hasil tersebut menunjukkan bahwa kedua model memiliki rata-rata waktu komputasi yang hampir sama. Namun, model *LightGBM* memiliki waktu komputasi yang lebih stabil karena nilai standar deviasinya lebih kecil dibandingkan model *XGBoost*. Hasil *boxplot* waktu komputasi pada target *Weight for Height* dapat dilihat pada Gambar 4.24.



Gambar 4. 24 Boxplot Waktu Komputasi Weight For Height

Secara keseluruhan, hasil pengujian *boxplot* waktu komputasi menunjukkan bahwa model *XGBoost* lebih unggul dari sisi kecepatan pada target *Weight for Age* dan *Height for Age*. Model *LightGBM* menunjukkan kestabilan waktu komputasi yang lebih baik pada target *Weight for Height*. Dengan demikian, model *XGBoost* memiliki kelebihan pada efisiensi waktu, sedangkan model *LightGBM* memiliki kelebihan pada kestabilan waktu komputasi pada target tertentu.

4.2.9 Hasil Pemilihan Model Terbaik

Pemilihan model terbaik dilakukan untuk menentukan model yang paling sesuai pada setiap target klasifikasi. Sistem memilih model terbaik berdasarkan nilai evaluasi yang meliputi *accuracy*, *precision macro*, *recall macro*, *F1 macro*, serta waktu komputasi. Waktu komputasi tersebut terdiri dari *train time*, *predict time*, dan *total time*. Tabel 4.25 menjelaskan hasil pemilihan model terbaik pada target *Height for Age*, *Weight for Age*, dan *Weight for Height*.

Berdasarkan hasil pengujian, model *LightGBM* terpilih sebagai model terbaik pada tiga target klasifikasi, yaitu *Height for Age*, *Weight for Age*, dan *Weight for Height*. Pemilihan tersebut menunjukkan bahwa model *LightGBM* mampu menghasilkan nilai evaluasi yang lebih baik pada setiap target klasifikasi.

Pada target *Height for Age*, model *LightGBM* memperoleh nilai *accuracy* sebesar 0,9909, *precision macro* sebesar 0,9860, *recall macro* sebesar 0,9905, dan *F1 macro* sebesar 0,9882. Hasil tersebut menunjukkan bahwa model mampu mengklasifikasikan kategori *Stunted* dan *Not Stunted* dengan sangat baik. Selain itu, model membutuhkan *total time* sebesar 0,5047 detik, sehingga proses pelatihan dan prediksi dapat dilakukan dengan waktu yang relatif singkat.

Pada target *Weight for Age*, model *LightGBM* memperoleh nilai *accuracy* sebesar 0,9374, *precision macro* sebesar 0,9275, *recall macro* sebesar 0,7943, dan *F1 macro* sebesar 0,8349. Nilai tersebut menunjukkan bahwa model mampu melakukan klasifikasi status gizi berdasarkan berat badan menurut umur dengan

performa yang baik. Pada target ini, model membutuhkan *total time* sebesar 1,6521 detik.

Pada target *Weight for Height*, model *LightGBM* memperoleh nilai *accuracy* sebesar 0,9669, *precision macro* sebesar 0,8942, *recall macro* sebesar 0,8215, dan *F1 macro* sebesar 0,8522. Hasil tersebut menunjukkan bahwa model mampu mengklasifikasikan status gizi berdasarkan berat badan menurut tinggi badan dengan cukup baik. Pada target ini, model membutuhkan *total time* sebesar 1,5379 detik.

Secara keseluruhan, model *LightGBM* dipilih sebagai model terbaik karena model ini menghasilkan nilai evaluasi yang unggul pada setiap target klasifikasi. Model *LightGBM* menunjukkan performa paling tinggi pada target *Height for Age* dan tetap memberikan hasil yang baik pada target *Weight for Age* serta *Weight for Height*. Oleh karena itu, model *LightGBM* dapat digunakan sebagai model utama dalam proses klasifikasi status pertumbuhan dan gizi balita.

Tabel 4. 25 Hasil Model Terbaik

No	Target	Model	Accuracy	Precision Macro	Recall Macro	F1 Macro	Train Time (s)	Predict Time (s)	Total Time (s)
0	Height for Age	LightGBM	0.9909	0.9860	0.9905	0.9882	0.4554	0.0493	0.5047
1	Weight for Age	LightGBM	0.9374	0.9275	0.7943	0.8349	1.3894	0.2626	1.6521
2	Weight for Height	LightGBM	0.9669	0.8942	0.8215	0.8522	1.2696	0.2683	1.5379

4.2.10 Hasil Pengujian Latih Ulang dan Simpan Model Terbaik

Pada bagian tabel 4.26 menyajikan hasil latih ulang dan penyimpanan model terbaik. Setelah proses pemilihan model dilakukan, model LightGBM digunakan sebagai model terbaik untuk tiga target klasifikasi, yaitu Height for Age, Weight for Age, dan Weight for Height. Proses latih ulang dilakukan agar model yang sudah terpilih dapat disimpan dan digunakan kembali pada tahap prediksi tanpa perlu melakukan pelatihan ulang dari awal.

Pada target Height for Age, sistem menyimpan model LightGBM ke dalam file model_terbaik/best_model_height_for_age_lightgbm.pkl. Pada target Weight for Age, sistem menyimpan model LightGBM ke dalam file model_terbaik/best_model_weight_for_age_lightgbm.pkl. Selanjutnya, pada target Weight for Height, sistem menyimpan model LightGBM ke dalam file model_terbaik/best_model_weight_for_height_lightgbm.pkl.

Selain menyimpan file model, sistem juga menyimpan informasi model terbaik ke dalam file model_terbaik/best_models_info.json. File tersebut berisi keterangan mengenai model terbaik yang digunakan pada setiap target klasifikasi. Dengan adanya proses penyimpanan ini, model yang telah dilatih dapat digunakan kembali secara lebih mudah pada tahap implementasi sistem atau aplikasi.

Tabel 4. 26 Hasil Pengujian Latih Ulang dan Simpan Model

No.	Target Klasifikasi	Model Terbaik	Lokasi Penyimpanan
1	Height for Age	LightGBM	model_terbaik/best_model_height_for_age_lightgbm.pkl
2	Weight for Age	LightGBM	model_terbaik/best_model_weight_for_age_lightgbm.pkl
3	Weight for Height	LightGBM	model_terbaik/best_model_weight_for_height_lightgbm.pkl
4	Informasi model terbaik	-	model_terbaik/best_models_info.json

4.2.11 Hasil BlackBox Tesing

Salah satu calon pengguna aplikasi melakukan pengujian Black Box Testing pada aplikasi GrowSmart Health. Penguji menjalankan aplikasi secara langsung dan memeriksa setiap fitur dari sudut pandang pengguna akhir (end-user). Pengujian ini mencakup seluruh alur penggunaan aplikasi, mulai dari proses registrasi, login, navigasi halaman, pengisian data balita, proses analisis, pengelolaan riwayat pemeriksaan, hingga proses logout.

Penguji juga memeriksa fungsi validasi input dengan memasukkan data yang belum lengkap, data dalam format yang tidak sesuai, nilai nol, serta nilai berat badan atau tinggi badan yang tidak wajar. Setelah itu, penguji memeriksa

proses klasifikasi pada tiga indikator antropometri, yaitu BB/U, TB/U, dan BB/TB. Penguji juga menguji halaman hasil analisis, panduan gizi, penyimpanan dan penghapusan riwayat pemeriksaan, serta respons tampilan aplikasi pada ukuran layar yang berbeda. Rincian skenario pengujian, hasil yang diharapkan, respons sistem, dan kesimpulan pengujian disajikan pada Lampiran 12.

Berdasarkan hasil pengujian, seluruh 32 skenario pengujian memperoleh hasil “Sesuai”. Hasil tersebut menunjukkan bahwa aplikasi GrowSmart Health dapat menjalankan setiap fungsi sesuai dengan rancangan sistem. Sistem dapat menerima dan memvalidasi data masukan, memproses klasifikasi status pertumbuhan dan gizi balita, menampilkan hasil analisis dengan jelas, serta mengelola riwayat pemeriksaan dengan baik.

Dengan demikian, hasil Black Box Testing menunjukkan bahwa aplikasi GrowSmart Health telah memenuhi kebutuhan fungsional dari sisi pengguna. Pengujian ini memastikan bahwa fitur-fitur aplikasi dapat berjalan sesuai dengan alur yang dirancang. Selanjutnya, validasi ahli digunakan untuk menilai kesesuaian informasi kesehatan dan kelayakan aplikasi sebagai alat bantu skrining awal status pertumbuhan dan gizi balita.

4.2.12 Validasi Ahli

Setelah aplikasi GrowSmart Health selesai dibangun, peneliti melakukan proses validasi ahli untuk memastikan bahwa hasil analisis status pertumbuhan dan gizi balita sudah sesuai dengan kebutuhan pengguna dan kaidah kesehatan.

Validasi ini melibatkan dua ahli, yaitu dokter anak dari Fakultas Kedokteran Universitas Tarumanagara dan ahli gizi dari Rumah Sakit Islam Jakarta Cempaka Putih. Bukti pelaksanaan validasi ahli dapat dilihat pada lampiran 6 dokumen UAT masing-masing validator.

1. Validasi oleh Dokter Anak

   Validasi oleh dokter anak dilakukan bersama Dr. dr. Wiyarni Pambudi, Sp.A, IBCLC, selaku Dosen Departemen Ilmu Kesehatan Anak di Fakultas Kedokteran Universitas Tarumanagara. Validasi dilakukan pada 7 Mei 2026. Validasi ini berfokus pada kesesuaian input data balita, parameter antropometri, hasil klasifikasi BB/U, TB/U, dan BB/TB, kejelasan interpretasi hasil, serta kelayakan aplikasi sebagai alat bantu skrining awal. Hasil validasi menunjukkan bahwa aplikasi sudah cukup baik untuk digunakan sebagai alat bantu interpretasi antropometri dasar. Dokter anak menilai bahwa parameter yang digunakan, yaitu usia, berat badan, tinggi badan, dan jenis kelamin, sudah sesuai untuk skrining status pertumbuhan dan gizi balita. Namun, dokter anak juga memberikan beberapa masukan, seperti penambahan validasi rentang biologis pada input usia, berat badan, dan tinggi badan agar sistem dapat mencegah kesalahan input data yang ekstrem. Selain itu, dokter anak menyarankan agar usia balita dihitung otomatis berdasarkan tanggal lahir dan tanggal pemeriksaan, bukan diinput secara manual. Dokter anak juga memberikan masukan agar metode perhitungan z-score diperjelas, istilah stunted digunakan sesuai

definisi operasional WHO, serta kategori seperti perawakan tinggi dan overweight/obesity dapat diperhatikan pada pengembangan berikutnya. Secara keseluruhan, aplikasi dinyatakan layak sebagai alat skrining awal, tetapi hasil pemeriksaan tetap harus divalidasi oleh tenaga kesehatan.

2. Validasi oleh Ahli Gizi

Validasi oleh ahli gizi dilakukan bersama Syukriah Usman, S.Gz., RD, selaku dietisien di Rumah Sakit Islam Jakarta Cempaka Putih. Validasi dilakukan pada 13 Mei 2026. Validasi ini berfokus pada kesesuaian parameter gizi, hasil klasifikasi status pertumbuhan, interpretasi hasil, pesan peringatan, dan kelayakan aplikasi sebagai media pendukung pemeriksaan awal.

Hasil validasi menunjukkan bahwa seluruh item pengujian memperoleh status OK. Ahli gizi menilai bahwa aplikasi sudah dapat menampilkan input data balita, parameter pemeriksaan, hasil klasifikasi, dan informasi pendukung dengan cukup jelas. Ahli gizi juga menilai bahwa alur penggunaan aplikasi sudah mudah dipahami dan dapat digunakan sebagai media bantu awal untuk melihat status pertumbuhan dan gizi balita.

Namun, ahli gizi memberikan catatan bahwa penamaan klasifikasi pada setiap parameter masih perlu diperbaiki agar lebih sesuai dengan istilah gizi yang digunakan. Ahli gizi juga menyarankan agar hasil perhitungan pada setiap parameter diperiksa kembali supaya informasi yang ditampilkan lebih tepat dan tidak menimbulkan salah pemahaman bagi pengguna. Berdasarkan hasil validasi tersebut, aplikasi dinyatakan layak

dengan catatan masih memerlukan sedikit perbaikan pada bagian penamaan klasifikasi dan pengecekan hasil perhitungan.

4.2.13 Hasil Kuesioner

Peneliti melakukan pengujian kuesioner responden untuk memperoleh penilaian pengguna terhadap aplikasi GrowSmart Health. Pengujian ini melibatkan 15 responden, yaitu ibu yang memiliki balita di lingkungan RT setempat. Setiap responden mencoba aplikasi dengan memasukkan data balita, menjalankan proses analisis, membaca hasil klasifikasi, dan melihat informasi pendukung yang ditampilkan oleh sistem. Setelah mencoba aplikasi, responden mengisi kuesioner melalui Google Form.

Peneliti membagi kuesioner menjadi empat bagian, yaitu identitas responden dan data balita, pengalaman menggunakan aplikasi, relevansi output aplikasi, serta kritik dan saran. Peneliti menggunakan skala Likert 5 poin pada bagian pengalaman penggunaan aplikasi dan relevansi output aplikasi yang dapat dilihat pada lampiran 10. Peneliti juga membalik skor pada pernyataan negatif agar skor yang lebih tinggi menunjukkan penilaian yang semakin baik terhadap aplikasi

4.2.13.1 Distribusi Data Balita Berdasarkan Jenis Kelamin dan Kelompok Usia

Peneliti menggunakan data jenis kelamin dan usia balita untuk mengetahui karakteristik data yang dimasukkan oleh responden selama proses uji

coba aplikasi GrowSmart Health. Kedua data tersebut relevan untuk disajikan karena sistem menggunakan jenis kelamin dan usia balita dalam proses analisis status pertumbuhan dan gizi. Tabel 4.27 menyajikan distribusi data balita berdasarkan jenis kelamin.

Tabel 4. 27 Distribusi Data Balita Berdasarkan Jenis Kelamin

Jenis Kelamin Balita	Jumlah Data	Persentase
Laki-laki	7	46,67%
Perempuan	8	53,33%
Total	15	100,00%

Berdasarkan Tabel 4.27, responden memasukkan data balita perempuan sebanyak 8 data atau 53,33%, sedangkan responden memasukkan data balita laki-laki sebanyak 7 data atau 46,67%. Hasil tersebut menunjukkan bahwa proses pengujian aplikasi melibatkan data balita dari kedua jenis kelamin dengan jumlah yang relatif seimbang. Dengan demikian, responden telah mencoba fungsi pemeriksaan pada dua pilihan jenis kelamin yang tersedia dalam aplikasi.

Selain jenis kelamin, peneliti juga menganalisis usia balita yang digunakan selama proses uji coba aplikasi. Peneliti menyamakan seluruh data usia ke dalam satuan bulan agar sesuai dengan rentang usia pada aplikasi, yaitu 0–59 bulan. Dalam proses tersebut, usia yang ditulis dalam satuan tahun dikonversi ke dalam satuan bulan, seperti usia 4 tahun yang dikonversi menjadi 48 bulan. Tabel 4.28 menyajikan distribusi data balita berdasarkan kelompok usia.

Tabel 4. 28 Distribusi Data Balita Berdasarkan Kelompok Usia

Kelompok Usia Balita	Jumlah Data	Persentase
0–11 bulan	1	6,67%
12–23 bulan	3	20,00%
24–35 bulan	3	20,00%
36–47 bulan	5	33,33%
48–59 bulan	3	20,00%
Total	**15**	**100,00%**

Berdasarkan Tabel 4.28, kelompok usia 36–47 bulan memiliki jumlah data paling banyak, yaitu 5 data atau 33,33%. Kelompok usia 12–23 bulan, 24–35 bulan, dan 48–59 bulan masing-masing memiliki 3 data atau 20,00%. Sementara itu, kelompok usia 0–11 bulan memiliki jumlah data paling sedikit, yaitu 1 data atau 6,67%.

Hasil tersebut menunjukkan bahwa responden mencoba aplikasi menggunakan data balita dari beberapa kelompok usia yang masih termasuk dalam sasaran penggunaan sistem, yaitu balita berusia 0–59 bulan. Variasi usia tersebut mendukung proses pengujian karena sistem menggunakan usia balita sebagai salah satu dasar dalam menganalisis indikator BB/U dan TB/U. Dengan demikian, pengujian telah melibatkan data balita dengan karakteristik jenis kelamin dan usia yang beragam.

4.2.13.2Hasil Penilaian Pengalaman Menggunakan Aplikasi

Peneliti menggunakan bagian pengalaman menggunakan aplikasi untuk menilai kemudahan penggunaan, kejelasan tampilan, konsistensi sistem, kenyamanan, dan penerimaan responden terhadap aplikasi. Bagian ini terdiri atas 11 pernyataan. Peneliti menggunakan skor asli pada pernyataan positif dan membalik skor pada pernyataan negatif.

Peneliti menghitung skor maksimal berdasarkan jumlah responden, jumlah pernyataan, dan skor tertinggi pada skala Likert sebagai berikut: Skor maksimal = 15 × 11 × 5 = 825

Tabel 4.29 menyajikan hasil penilaian pengalaman responden setelah menggunakan aplikasi.

Tabel 4. 29 Hasil Penilaian Pengalaman Menggunakan Aplikasi

No.	**Pernyataan**	**Total Skor**	**Rata-rata**
1	Aplikasi mudah digunakan.	74	4,93
2	Aplikasi tidak terasa rumit untuk digunakan.*	71	4,73
3	Sistem mudah digunakan.	72	4,80
4	Pengguna tidak membutuhkan bantuan orang lain untuk menggunakan aplikasi.*	61	4,07
5	Tampilan menu, tombol, dan halaman tersusun dengan jelas.	73	4,87
6	Sistem tidak menunjukkan banyak ketidakkonsistenan.*	71	4,73
7	Pengguna merasa percaya diri saat menggunakan aplikasi.	74	4,93

Tabel 4.29 (Lanjutan)

No.	Pernyataan	Total Skor	Rata-rata
8	Pengguna tidak perlu mempelajari banyak hal terlebih dahulu sebelum menggunakan aplikasi.*	55	3,67
9	Sistem tidak membingungkan pengguna.*	66	4,40
10	Aplikasi sudah bagus dan pantas digunakan oleh masyarakat.	72	4,80
11	Pengguna bersedia menggunakan kembali aplikasi apabila membutuhkan informasi awal mengenai status pertumbuhan dan gizi balita.	71	4,73
	Total	**760**	**4,61**

Berdasarkan Tabel 4.29, responden memberikan total skor sebesar 760 dari skor maksimal 825 pada bagian pengalaman menggunakan aplikasi. Peneliti menghitung persentase penilaian pengalaman penggunaan aplikasi sebagai berikut: Persentase = (760 / 825) × 100% = 92,12%

Hasil tersebut menunjukkan bahwa responden memberikan penilaian yang sangat baik terhadap pengalaman penggunaan aplikasi GrowSmart Health. Responden memberikan nilai tertinggi pada pernyataan bahwa aplikasi mudah digunakan dan pengguna merasa percaya diri saat menggunakan aplikasi. Kedua pernyataan tersebut memperoleh nilai rata-rata sebesar 4,93.

Responden memberikan nilai terendah pada pernyataan bahwa pengguna tidak perlu mempelajari banyak hal terlebih dahulu sebelum menggunakan aplikasi, yaitu sebesar 3,67 setelah pembalikan skor. Hasil ini menunjukkan bahwa

beberapa responden masih memerlukan penyesuaian ketika pertama kali menggunakan aplikasi. Namun, persentase keseluruhan sebesar 92,12% menunjukkan bahwa responden tetap menilai aplikasi mudah dan nyaman untuk digunakan.

4.2.13.3 Hasil Penilaian Relevansi Output Aplikasi

Peneliti menggunakan bagian relevansi output aplikasi untuk menilai kejelasan dan manfaat hasil analisis yang ditampilkan oleh sistem. Bagian ini terdiri atas 9 pernyataan yang mencakup kejelasan hasil klasifikasi pada indikator BB/U, TB/U, dan BB/TB, kesesuaian informasi pendukung, manfaat rekomendasi, serta pemahaman responden terhadap fungsi aplikasi sebagai alat bantu skrining awal.

Tabel 4.30 menyajikan hasil penilaian responden terhadap relevansi output aplikasi.

Tabel 4. 30 Hasil Penilaian Relevansi Output Aplikasi

No.	Ringkasan Pernyataan	STS	TS	N	S	SS	Total Skor	Rata-rata
1	Hasil klasifikasi mudah dipahami.	0	0	1	2	12	71	4,73
2	Hasil klasifikasi BB/U ditampilkan dengan jelas.	0	0	0	3	12	72	4,80
3	Hasil klasifikasi TB/U ditampilkan dengan jelas.	0	0	0	3	12	72	4,80
4	Hasil klasifikasi BB/TB ditampilkan dengan jelas.	0	0	0	3	12	72	4,80

Tabel 4.30 (Lanjutan)

No.	Ringkasan Pernyataan	STS	TS	N	S	SS	Total Skor	Rata-rata
5	Informasi pendukung sesuai dengan hasil klasifikasi.	0	0	0	3	12	72	4,80
6	Rekomendasi membantu pengguna memahami kondisi awal balita.	0	0	0	1	14	74	4,93
7	Informasi hasil membantu pengguna mengetahui langkah awal yang dapat dilakukan.	0	0	0	2	13	73	4,87
8	Hasil dan rekomendasi tidak menimbulkan kesan sebagai diagnosis akhir.	1	1	2	1	10	63	4,20
9	Output aplikasi relevan dan bermanfaat sebagai alat bantu skrining awal.	0	0	0	2	13	73	4,87
	Total Jawaban/Skor	**1**	**1**	**3**	**20**	**110**	**642**	**4,76**

Peneliti menghitung skor maksimal pada bagian relevansi output aplikasi sebagai berikut: Skor maksimal = 15 × 9 × 5 = 675

Berdasarkan hasil perhitungan, responden memberikan total skor sebesar 642 dari skor maksimal 675. Peneliti menghitung persentase relevansi output aplikasi sebagai berikut: Persentase = (642 / 675) × 100% = 95,11%

Berdasarkan Tabel 4.30 responden memberikan penilaian yang sangat baik terhadap output aplikasi. Responden memilih jawaban Sangat Setuju (SS)

sebanyak 110 jawaban dan jawaban Setuju (S) sebanyak 20 jawaban. Kedua jawaban positif tersebut berjumlah 130 dari 135 jawaban atau sebesar 96,30%. Responden memberikan nilai tertinggi pada pernyataan bahwa rekomendasi membantu pengguna memahami kondisi awal tumbuh kembang dan gizi balita. Pernyataan tersebut memperoleh total skor sebesar 74 dengan rata-rata sebesar 4,93. Hasil ini menunjukkan bahwa informasi pendukung yang ditampilkan oleh aplikasi dapat membantu pengguna memahami hasil pemeriksaan awal balita.

Responden memberikan nilai terendah pada pernyataan bahwa hasil dan rekomendasi aplikasi tidak menimbulkan kesan sebagai diagnosis akhir. Pernyataan tersebut memperoleh total skor sebesar 63 dengan rata-rata sebesar 4,20. Meskipun nilai tersebut tetap berada pada kategori baik, hasil ini menunjukkan bahwa sistem perlu terus menampilkan penjelasan yang tegas bahwa aplikasi hanya membantu proses skrining awal dan tidak menggantikan pemeriksaan tenaga kesehatan.

4.2.13.4 Ringkasan Hasil Pengujian Kuesioner Responden

Tabel 4.31 menyajikan ringkasan hasil pengujian kuesioner responden berdasarkan aspek pengalaman menggunakan aplikasi dan relevansi output aplikasi.

Tabel 4. 31 Ringkasan Hasil Pengujian Kuesioner Responden

Aspek Penilaian	**Jumlah Pernyataan**	**Total Skor**	**Skor Maksimal**	**Persentase**
Pengalaman Menggunakan Aplikasi	11	760	825	92,12%
Relevansi Output Aplikasi	9	642	675	95,11%
Keseluruhan Penilaian	**20**	**1.402**	**1.500**	**93,47%**

Berdasarkan Tabel 4.31, aplikasi GrowSmart Health memperoleh total skor sebesar 1.402 dari skor maksimal 1.500, dengan persentase keseluruhan sebesar 93,47%. Hasil tersebut menunjukkan bahwa responden memberikan penilaian yang sangat baik terhadap aplikasi. Responden menilai bahwa aplikasi mudah digunakan, menampilkan hasil analisis secara jelas, dan memberikan informasi yang bermanfaat untuk membantu memperoleh gambaran awal mengenai status pertumbuhan dan gizi balita.

4.3 Pembahasan

4.3.1 Pembahasan Distribusi Kelas dan Korelasi Data

Distribusi kelas pada setiap target menunjukkan bahwa dataset memiliki jumlah data yang tidak seimbang. Pada target Weight for Age, kelas Normal mendominasi jumlah data dibandingkan kelas lainnya. Kondisi ini menunjukkan bahwa sebagian besar balita dalam dataset memiliki berat badan yang sesuai dengan usianya. Namun, kelas Underfed, Malnutrition, dan Overnutrition tetap

perlu diperhatikan karena ketiga kelas tersebut menunjukkan kondisi balita yang tidak termasuk dalam kategori normal.

Pada target Height for Age, kelas Stunted memiliki jumlah data lebih banyak dibandingkan kelas Not Stunted. Kondisi ini menunjukkan bahwa sebagian besar balita dalam dataset termasuk ke dalam kategori stunted. Ketidakseimbangan jumlah data tersebut dapat memengaruhi proses pembelajaran model. Model dapat lebih mudah mengenali kelas mayoritas, sedangkan model dapat mengalami kesulitan dalam mengenali kelas minoritas.

Pada target Weight for Height, kelas Normal juga memiliki jumlah data paling banyak. Sementara itu, kelas Thin, Very Thin, dan Obese memiliki jumlah data yang lebih sedikit. Kondisi ini menunjukkan bahwa sebagian besar balita dalam dataset memiliki proporsi berat badan terhadap tinggi badan yang normal. Namun, jumlah data yang kecil pada kelas minoritas dapat memengaruhi kemampuan model dalam mengenali pola pada kelas tersebut.

Secara keseluruhan, distribusi kelas pada tiga target menunjukkan adanya ketidakseimbangan data. Kondisi ini perlu diperhatikan dalam proses evaluasi model karena nilai akurasi saja belum cukup untuk menggambarkan performa model secara menyeluruh. Oleh karena itu, penelitian ini menggunakan metrik precision, recall, dan F1-score agar performa model pada setiap kelas dapat dianalisis dengan lebih adil.

Selain distribusi kelas, hasil heatmap korelasi menunjukkan bahwa fitur age_month dan height memiliki hubungan paling kuat. Hubungan positif antara

usia dan tinggi badan menunjukkan bahwa tinggi badan balita cenderung meningkat seiring bertambahnya usia. Hasil ini sesuai dengan pola pertumbuhan balita karena anak umumnya mengalami pertambahan tinggi badan ketika usianya bertambah.

Fitur date_of_birth memiliki hubungan negatif dengan age_month dan height. Kondisi ini menunjukkan bahwa balita dengan tanggal lahir yang lebih baru cenderung memiliki usia yang lebih kecil dan tinggi badan yang lebih rendah. Hubungan tersebut masih sesuai secara logis karena usia balita berkaitan langsung dengan tanggal lahir dan tanggal pengukuran.

Sementara itu, fitur gender_enc dan weight memiliki nilai korelasi yang rendah terhadap sebagian besar fitur lainnya. Hasil ini menunjukkan bahwa jenis kelamin dan berat badan tidak memiliki hubungan linear yang kuat dengan fitur lain dalam dataset. Meskipun demikian, fitur tersebut tetap digunakan dalam proses pemodelan karena algoritma LightGBM dan XGBoost dapat mempelajari pola data yang tidak selalu berbentuk hubungan linear.

4.3.2 Pembahasan Hasil Evaluasi Model

Hasil evaluasi model menunjukkan bahwa algoritma *LightGBM* dan *XGBoost* mampu mengklasifikasikan status pertumbuhan dan gizi balita dengan baik. Kedua algoritma menghasilkan nilai evaluasi yang cukup tinggi pada tiga target klasifikasi, yaitu *Weight for Age*, *Height for Age*, dan *Weight for Height*. Namun, hasil pengujian menunjukkan bahwa model *LightGBM* memberikan

performa yang lebih baik dibandingkan model *XGBoost* pada sebagian besar target, terutama pada nilai *accuracy*, *recall*, dan *F1-score*.

Pada target *Weight for Age*, model *LightGBM* memperoleh nilai *accuracy* sebesar 0,9341 dan *F1-score* sebesar 0,8460. Sementara itu, model *XGBoost* memperoleh nilai *accuracy* sebesar 0,9152 dan *F1-score* sebesar 0,8069. Hasil tersebut menunjukkan bahwa model *LightGBM* memiliki kemampuan yang lebih baik dalam mengklasifikasikan status berat badan balita berdasarkan usia. Nilai *recall* model *LightGBM* yang lebih tinggi juga menunjukkan bahwa model ini lebih mampu mengenali data pada setiap kategori dibandingkan model *XGBoost*.

Pada target *Height for Age*, kedua algoritma menghasilkan performa yang sangat baik. Model *LightGBM* memperoleh nilai *accuracy* sebesar 0,9916 dan *F1-score* sebesar 0,9891. Sementara itu, model *XGBoost* memperoleh nilai *accuracy* sebesar 0,9892 dan *F1-score* sebesar 0,9860. Hasil tersebut menunjukkan bahwa kedua model mampu membedakan kategori *Stunted* dan *Not Stunted* dengan sangat baik. Meskipun demikian, model *LightGBM* tetap menunjukkan hasil yang sedikit lebih unggul dibandingkan model *XGBoost*.

Pada target *Weight for Height*, model *LightGBM* kembali memperoleh hasil yang lebih baik dibandingkan model *XGBoost*. Model *LightGBM* memperoleh nilai *accuracy* sebesar 0,9613 dan *F1-score* sebesar 0,8218. Sementara itu, model *XGBoost* memperoleh nilai *accuracy* sebesar 0,9491 dan *F1-score* sebesar 0,7687. Hasil tersebut menunjukkan bahwa model *LightGBM* lebih stabil dalam mengklasifikasikan status gizi balita berdasarkan perbandingan berat badan dan

tinggi badan. Namun, model *XGBoost* tetap memiliki keunggulan pada waktu prediksi yang lebih cepat pada beberapa target.

Nilai *accuracy* yang diperoleh pada setiap target menunjukkan kemampuan model dalam menghasilkan prediksi benar dari seluruh data uji. Nilai *accuracy* yang tinggi pada target *Height for Age* terjadi karena model lebih mudah membedakan kategori *Stunted* dan *Not Stunted*. Hal ini dapat dipengaruhi oleh hubungan yang cukup jelas antara fitur usia dalam bulan dan tinggi badan. Oleh karena itu, model mampu menghasilkan jumlah prediksi benar yang tinggi pada target tersebut.

Nilai *precision* menunjukkan tingkat ketepatan model ketika memprediksi suatu kategori. Pada penelitian ini, nilai *precision* yang cukup tinggi menunjukkan bahwa model mampu mengurangi kesalahan prediksi pada beberapa kategori. Nilai *precision* cenderung lebih baik pada kategori dengan jumlah data yang besar, seperti *Normal* dan *Stunted*, karena model memiliki lebih banyak pola data yang dapat dipelajari. Sementara itu, nilai *precision* pada beberapa kategori minoritas dapat berubah karena jumlah data pada kategori tersebut lebih sedikit.

Nilai *recall* menunjukkan kemampuan model dalam mengenali seluruh data yang seharusnya masuk ke dalam suatu kategori. Pada beberapa target, nilai *recall* pada kelas mayoritas lebih tinggi karena jumlah data pelatihan pada kelas tersebut lebih banyak. Kondisi ini membuat model lebih mudah mengenali pola pada kelas mayoritas. Sebaliknya, nilai *recall* pada kelas minoritas, seperti *Overnutrition*, *Very Thin*, dan *Obese*, cenderung lebih rendah karena jumlah data

pada kelas tersebut lebih sedikit. Akibatnya, sebagian data pada kelas minoritas masih diprediksi ke kelas lain yang lebih dominan, seperti *Normal*.

Nilai *F1-score* menunjukkan keseimbangan antara *precision* dan *recall*. Nilai *F1-score* yang tinggi menunjukkan bahwa model tidak hanya tepat dalam memprediksi suatu kategori, tetapi juga mampu mengenali sebagian besar data pada kategori tersebut. Pada target *Height for Age*, nilai *F1-score* cenderung tinggi karena nilai *precision* dan *recall* pada kategori *Stunted* dan *Not Stunted* sama-sama baik. Sementara itu, pada target *Weight for Age* dan *Weight for Height*, nilai *F1-score* pada beberapa kategori lebih rendah karena model masih mengalami kesulitan dalam mengenali kelas minoritas.

Berdasarkan hasil evaluasi per kategori, model menghasilkan performa paling baik pada kelas dengan jumlah data besar, seperti *Normal* dan *Stunted*. Kondisi ini terjadi karena model memperoleh jumlah data pelatihan yang lebih banyak pada kelas mayoritas. Sebaliknya, model masih lebih sulit mengenali kelas dengan jumlah data kecil, seperti *Overnutrition*, *Very Thin*, dan *Obese*. Hal ini terlihat dari nilai *recall* dan *F1-score* yang lebih rendah pada beberapa kelas minoritas.

Hasil *confusion matrix* juga menunjukkan pola yang sama. Model lebih banyak menghasilkan prediksi benar pada kelas mayoritas, sedangkan kesalahan prediksi lebih sering terjadi pada kelas minoritas. Pada target *Weight for Age*, model masih sering mengklasifikasikan kategori *Underfed* sebagai *Normal*. Pada target *Weight for Height*, model juga masih mengklasifikasikan beberapa data *Thin*

dan *Obese* sebagai *Normal*. Kondisi tersebut menunjukkan bahwa ketidakseimbangan data dapat memengaruhi kemampuan model dalam mengenali kelas minoritas.

Secara keseluruhan, hasil evaluasi menunjukkan bahwa model sudah mampu melakukan klasifikasi dengan baik pada tiga indikator antropometri. Model *LightGBM* menunjukkan performa yang lebih stabil dibandingkan model *XGBoost* karena nilai *F1-score* lebih tinggi dan jumlah kesalahan prediksi lebih rendah pada beberapa kategori. Oleh karena itu, model *LightGBM* dapat digunakan sebagai model utama dalam aplikasi *GrowSmart Health*. Namun, hasil klasifikasi tetap digunakan sebagai alat bantu skrining awal dan tidak menggantikan pemeriksaan langsung oleh tenaga kesehatan.

4.3.3 Pembahasan Hasil 5-Fold Cross Validation

Hasil pengujian *5-Fold Cross Validation* menunjukkan bahwa model *LightGBM* dan *XGBoost* mampu menghasilkan performa klasifikasi yang baik pada tiga target, yaitu *Weight for Age*, *Height for Age*, dan *Weight for Height*. Pengujian ini dilakukan untuk melihat kestabilan performa model ketika data dibagi ke dalam beberapa *fold* yang berbeda. Melalui pengujian ini, performa model tidak hanya dinilai dari satu pembagian data, tetapi juga dari beberapa variasi data latih dan data uji.

Pada target *Weight for Age*, model *LightGBM* menunjukkan performa yang lebih stabil dibandingkan model *XGBoost*. Model *LightGBM* menghasilkan nilai

accuracy pada rentang 0,9319 sampai 0,9403, sedangkan model *XGBoost* menghasilkan nilai *accuracy* pada rentang 0,9124 sampai 0,9302. Selain itu, model *LightGBM* menghasilkan nilai *F1-score* pada rentang 0,7849 sampai 0,8585, sedangkan model *XGBoost* menghasilkan nilai *F1-score* pada rentang 0,7755 sampai 0,8588. Hasil tersebut menunjukkan bahwa model *LightGBM* lebih konsisten dalam mengklasifikasikan status berat badan balita berdasarkan usia pada sebagian besar *fold*.

Pada target *Height for Age*, kedua model menghasilkan performa yang sangat baik. Model *LightGBM* memperoleh nilai *accuracy* pada rentang 0,9892 sampai 0,9927, sedangkan model *XGBoost* memperoleh nilai *accuracy* pada rentang 0,9871 sampai 0,9927. Model *LightGBM* juga memperoleh nilai *F1-score* pada rentang 0,9860 sampai 0,9905, sedangkan model *XGBoost* memperoleh nilai *F1-score* pada rentang 0,9833 sampai 0,9905. Hasil tersebut menunjukkan bahwa kedua model mampu membedakan kategori *Stunted* dan *Not Stunted* dengan sangat baik. Namun, model *LightGBM* tetap menunjukkan performa yang sedikit lebih stabil berdasarkan nilai evaluasi secara keseluruhan.

Pada target *Weight for Height*, model *LightGBM* kembali menunjukkan performa yang lebih baik dibandingkan model *XGBoost*. Model *LightGBM* menghasilkan nilai *accuracy* pada rentang 0,9630 sampai 0,9693 dan nilai *F1-score* pada rentang 0,8236 sampai 0,8661. Sementara itu, model *XGBoost* menghasilkan nilai *accuracy* pada rentang 0,9522 sampai 0,9581 dan nilai *F1-score* pada rentang 0,7793 sampai 0,8050. Hasil tersebut menunjukkan bahwa model *LightGBM* lebih

mampu menjaga keseimbangan performa klasifikasi pada target *Weight for Height*, terutama dalam mengenali beberapa kategori yang jumlah datanya lebih sedikit.

Nilai *accuracy* yang diperoleh pada pengujian *5-Fold Cross Validation* menunjukkan tingkat ketepatan model dalam menghasilkan prediksi benar pada setiap pembagian data. Nilai *accuracy* yang tinggi pada target *Height for Age* terjadi karena model dapat membedakan kategori *Stunted* dan *Not Stunted* dengan cukup jelas. Kondisi ini dapat dipengaruhi oleh hubungan antara fitur usia dalam bulan dan tinggi badan, sehingga pola data pada target tersebut lebih mudah dipelajari oleh model.

Nilai *precision* menunjukkan ketepatan model ketika memprediksi suatu kategori. Pada pengujian ini, nilai *precision* cenderung lebih tinggi pada kategori dengan jumlah data besar, seperti *Normal* dan *Stunted*. Hal ini terjadi karena model memiliki lebih banyak contoh data untuk mempelajari pola pada kelas mayoritas. Sebaliknya, nilai *precision* pada beberapa kelas minoritas dapat berubah pada setiap *fold* karena jumlah data pada kelas tersebut lebih sedikit.

Nilai *recall* menunjukkan kemampuan model dalam mengenali seluruh data yang seharusnya masuk ke dalam suatu kategori. Pada beberapa kelas mayoritas, nilai *recall* cenderung lebih tinggi karena data pelatihan pada kelas tersebut lebih banyak. Sementara itu, pada kelas minoritas seperti *Overnutrition*, *Very Thin*, dan *Obese*, nilai *recall* cenderung lebih rendah karena jumlah data pada

kelas tersebut lebih sedikit. Akibatnya, sebagian data pada kelas minoritas masih diprediksi ke kategori yang lebih dominan, seperti *Normal*.

Nilai *F1-score* menunjukkan keseimbangan antara *precision* dan *recall*. Nilai *F1-score* yang tinggi menunjukkan bahwa model tidak hanya tepat dalam memberikan prediksi, tetapi juga mampu mengenali data pada kategori tersebut dengan baik. Pada target *Height for Age*, nilai *F1-score* cenderung tinggi karena nilai *precision* dan *recall* pada kategori *Stunted* dan *Not Stunted* sama-sama baik. Sementara itu, pada target *Weight for Age* dan *Weight for Height*, nilai *F1-score* pada beberapa kategori lebih rendah karena model masih lebih sulit mengenali kelas minoritas.

Berdasarkan hasil evaluasi per kategori, model menghasilkan performa paling tinggi pada kelas dengan jumlah data besar, seperti *Normal* dan *Stunted*. Kondisi ini terjadi karena model memiliki lebih banyak data untuk mempelajari pola pada kelas mayoritas. Sebaliknya, model masih mengalami kesulitan pada kelas dengan jumlah data kecil, seperti *Overnutrition*, *Very Thin*, dan *Obese*. Hal ini menunjukkan bahwa ketidakseimbangan data masih memengaruhi kemampuan model dalam mengenali kelas minoritas.

Hasil *confusion matrix* pada pengujian *K-Fold Cross Validation* juga menunjukkan pola yang sama. Model lebih banyak menghasilkan prediksi benar pada kelas mayoritas, sedangkan kesalahan prediksi lebih sering terjadi pada kelas minoritas. Pada target *Weight for Age*, kategori *Overnutrition* masih sulit dikenali oleh kedua model. Pada target *Weight for Height*, beberapa data *Very Thin*, *Thin*,

dan *Obese* masih diprediksi sebagai kategori *Normal*. Kondisi tersebut menunjukkan bahwa distribusi data yang tidak seimbang dapat memengaruhi kemampuan model dalam mengenali kategori dengan jumlah data yang lebih sedikit.

Secara keseluruhan, hasil evaluasi detail *K-Fold Cross Validation* menunjukkan bahwa model *LightGBM* memiliki performa yang lebih stabil dibandingkan model *XGBoost*. Model *LightGBM* menghasilkan nilai evaluasi yang lebih baik pada sebagian besar target dan memiliki jumlah kesalahan prediksi yang lebih rendah pada beberapa kategori. Oleh karena itu, model *LightGBM* dapat dinilai lebih sesuai untuk digunakan sebagai model utama dalam aplikasi *GrowSmart Health*, terutama karena model ini mampu memberikan hasil klasifikasi yang stabil pada beberapa pembagian data.

4.3.4 Pembahasan Pemilihan Model Terbaik

Hasil pemilihan model terbaik menunjukkan bahwa *LightGBM* menjadi model terbaik pada tiga target klasifikasi, yaitu *Height for Age*, *Weight for Age*, dan *Weight for Height*. Peneliti memilih model terbaik berdasarkan beberapa nilai evaluasi, yaitu *accuracy*, *precision macro*, *recall macro*, *F1 macro*, serta waktu komputasi. Penggunaan beberapa metrik tersebut dilakukan agar pemilihan model tidak hanya bergantung pada nilai akurasi, tetapi juga mempertimbangkan kemampuan model dalam mengenali setiap kelas secara lebih seimbang.

Pada target *Height for Age*, model *LightGBM* memperoleh hasil evaluasi paling tinggi dibandingkan target lainnya. Model menghasilkan *accuracy* sebesar 0,9909 dan *F1 macro* sebesar 0,9882. Hasil tersebut menunjukkan bahwa *LightGBM* mampu mengklasifikasikan kategori *Stunted* dan *Not Stunted* dengan sangat baik. Selain itu, model membutuhkan *total time* sebesar 0,5047 detik, sehingga proses pelatihan dan prediksi dapat berjalan dengan waktu yang relatif singkat.

Pada target *Weight for Age*, model *LightGBM* memperoleh *accuracy* sebesar 0,9374 dan *F1 macro* sebesar 0,8349. Hasil tersebut menunjukkan bahwa model mampu mengklasifikasikan status gizi berdasarkan berat badan menurut umur dengan performa yang baik. Namun, nilai *recall macro* yang lebih rendah dibandingkan target *Height for Age* menunjukkan bahwa beberapa kelas masih lebih sulit dikenali, terutama kelas dengan jumlah data yang lebih sedikit. Pada target ini, model membutuhkan *total time* sebesar 1,6521 detik.

Pada target *Weight for Height*, model *LightGBM* memperoleh *accuracy* sebesar 0,9669 dan *F1 macro* sebesar 0,8522. Hasil tersebut menunjukkan bahwa model mampu mengklasifikasikan status gizi berdasarkan perbandingan berat badan dan tinggi badan dengan cukup baik. Model juga menunjukkan performa yang stabil, meskipun beberapa kelas minoritas masih memiliki peluang kesalahan prediksi. Pada target ini, model membutuhkan *total time* sebesar 1,5379 detik.

Secara keseluruhan, *LightGBM* dipilih sebagai model utama karena model ini memberikan hasil evaluasi yang lebih baik pada ketiga target klasifikasi. Model

LightGBM juga menunjukkan keseimbangan yang cukup baik antara performa klasifikasi dan waktu komputasi. Oleh karena itu, model ini dinilai sesuai untuk digunakan dalam aplikasi *GrowSmart Health* sebagai model klasifikasi status pertumbuhan dan gizi balita.

Setelah proses pemilihan model terbaik selesai, sistem melakukan proses latih ulang terhadap model *LightGBM* pada masing-masing target. Proses latih ulang ini dilakukan agar model akhir dapat mempelajari data secara lebih menyeluruh sebelum digunakan pada aplikasi. Sistem kemudian menyimpan model terbaik dalam format .pkl, sehingga model dapat dipanggil kembali saat proses prediksi dilakukan.

Sistem menyimpan model *Height for Age* pada file model_terbaik/best_model_height_for_age_lightgbm.pkl. Sistem menyimpan model *Weight for Age* pada file model_terbaik/best_model_weight_for_age_lightgbm.pkl. Sistem juga menyimpan model *Weight for Height* pada file model_terbaik/best_model_weight_for_height_lightgbm.pkl. Selain itu, sistem menyimpan informasi model terbaik ke dalam file model_terbaik/best_models_info.json.

Penyimpanan model dan informasi pendukung tersebut membantu proses implementasi aplikasi menjadi lebih praktis. Aplikasi dapat menggunakan model yang sudah tersimpan tanpa perlu melakukan pelatihan ulang dari awal. Dengan

demikian, proses prediksi pada aplikasi dapat berjalan lebih cepat, konsisten, dan sesuai dengan model terbaik yang telah dipilih.

4.3.5 Pembahasan Black Box Testing

Hasil pengujian Black Box Testing menunjukkan bahwa aplikasi GrowSmart Health dapat menjalankan seluruh fungsi sesuai dengan rancangan sistem. Pengujian terhadap 32 skenario menghasilkan status “Sesuai” pada setiap fitur yang diuji. Hasil tersebut menunjukkan bahwa aplikasi telah memenuhi kebutuhan fungsional dari sisi pengguna.

Sistem dapat menjalankan proses autentikasi yang meliputi registrasi, login, dan logout dengan baik. Sistem juga dapat menampilkan halaman beranda, pemeriksaan, panduan gizi, dan riwayat pemeriksaan sesuai dengan menu yang dipilih oleh pengguna. Dengan demikian, pengguna dapat mengikuti alur penggunaan aplikasi sesuai dengan fungsi yang telah dirancang.

Pada proses pemeriksaan balita, sistem dapat menerima data masukan yang dibutuhkan untuk analisis. Sistem juga dapat memberikan peringatan ketika pengguna memasukkan data yang belum lengkap, menggunakan format yang tidak sesuai, atau memasukkan nilai yang tidak valid. Fungsi validasi tersebut membantu pengguna mengurangi kesalahan pengisian data sebelum sistem melakukan proses klasifikasi.

Setelah pengguna memasukkan data dengan benar, sistem dapat menjalankan proses klasifikasi dan menampilkan hasil analisis berdasarkan

indikator BB/U, TB/U, dan BB/TB. Hasil ini menunjukkan bahwa model LightGBM yang telah dipilih pada tahap evaluasi dapat diterapkan ke dalam aplikasi dan menghasilkan keluaran sesuai dengan alur sistem. Namun, pengujian Black Box hanya menilai fungsi aplikasi, sedangkan ketepatan model dan kesesuaian informasi kesehatan tetap mengacu pada hasil evaluasi model serta validasi ahli.

Sistem juga dapat menyimpan hasil pemeriksaan ke dalam riwayat, menampilkan kembali data pemeriksaan, dan menghapus data sesuai dengan tindakan pengguna. Selain itu, sistem dapat menampilkan informasi pada halaman panduan gizi dan mempertahankan susunan tampilan ketika aplikasi dibuka pada ukuran layar yang berbeda. Hasil tersebut menunjukkan bahwa fitur utama dan fitur pendukung aplikasi dapat digunakan sesuai dengan kebutuhan pengujian.

Secara keseluruhan, pengujian Black Box Testing menunjukkan bahwa aplikasi GrowSmart Health telah berjalan sesuai dengan fungsi yang dirancang. Aplikasi dapat membantu pengguna memasukkan data balita, memperoleh hasil analisis, dan mengelola riwayat pemeriksaan secara praktis. Meskipun demikian, hasil yang ditampilkan oleh aplikasi tetap berfungsi sebagai informasi skrining awal dan tidak menggantikan pemeriksaan lebih lanjut oleh tenaga kesehatan.

4.3.6 Pembahasan Validasi Ahli

Hasil pengujian User Acceptance Test (UAT) menunjukkan bahwa aplikasi GrowSmart Health sudah dapat digunakan sebagai alat bantu skrining awal status pertumbuhan dan gizi balita. Peneliti melakukan validasi ahli untuk memastikan

bahwa fitur, alur penggunaan, hasil analisis, dan rekomendasi pada aplikasi sudah sesuai dengan kebutuhan pengguna serta kaidah kesehatan anak. Validasi ini melibatkan dua ahli, yaitu dokter anak dari Fakultas Kedokteran Universitas Tarumanagara dan ahli gizi dari Rumah Sakit Islam Jakarta Cempaka Putih.

Pada validasi oleh dokter anak, ahli menilai bahwa aplikasi sudah cukup baik untuk membantu interpretasi antropometri dasar. Dokter anak menilai bahwa parameter usia, berat badan, tinggi badan, dan jenis kelamin sudah sesuai untuk mendukung proses skrining status pertumbuhan dan gizi balita. Hasil ini menunjukkan bahwa aplikasi sudah menggunakan data masukan yang relevan dengan kebutuhan penilaian antropometri.

Meskipun demikian, dokter anak memberikan beberapa masukan untuk pengembangan sistem. Dokter anak menyarankan agar sistem menambahkan validasi rentang biologis pada input usia, berat badan, dan tinggi badan. Validasi ini diperlukan agar pengguna tidak dapat memasukkan data yang terlalu ekstrem atau tidak sesuai secara biologis. Dokter anak juga menyarankan agar sistem menghitung usia secara otomatis berdasarkan tanggal lahir dan tanggal pemeriksaan, sehingga risiko kesalahan input usia dapat dikurangi.

Selain itu, dokter anak memberikan masukan agar sistem memperjelas metode perhitungan z-score dan menggunakan istilah stunted sesuai dengan definisi operasional WHO. Dokter anak juga menyarankan agar pengembangan berikutnya memperhatikan kategori perawakan tinggi serta overweight atau obesity. Masukan tersebut menunjukkan bahwa aplikasi sudah layak digunakan

sebagai alat bantu skrining awal, tetapi hasil pemeriksaan tetap perlu dikonfirmasi oleh tenaga kesehatan.

Pada validasi oleh ahli gizi, ahli menilai bahwa aplikasi sudah menampilkan input data, parameter pemeriksaan, hasil klasifikasi, dan informasi pendukung dengan cukup jelas. Ahli gizi juga menilai bahwa alur penggunaan aplikasi sudah mudah dipahami. Hasil ini menunjukkan bahwa aplikasi sudah memenuhi aspek kemudahan penggunaan dan dapat membantu pengguna dalam melihat gambaran awal status pertumbuhan serta gizi balita.

Namun, ahli gizi memberikan catatan bahwa penamaan klasifikasi pada setiap parameter masih perlu disesuaikan dengan istilah gizi yang lebih tepat. Ahli gizi juga menyarankan agar hasil perhitungan pada setiap parameter diperiksa kembali agar informasi yang ditampilkan tidak menimbulkan salah pemahaman bagi pengguna. Masukan ini penting karena aplikasi menampilkan informasi kesehatan yang harus disampaikan secara jelas, tepat, dan mudah dipahami.

Secara keseluruhan, hasil validasi ahli menunjukkan bahwa aplikasi GrowSmart Health dinyatakan layak sebagai media bantu skrining awal status pertumbuhan dan gizi balita. Aplikasi sudah memiliki alur penggunaan yang jelas, parameter input yang relevan, serta hasil analisis yang mudah dipahami. Namun, aplikasi tetap memiliki beberapa bagian yang perlu disempurnakan, terutama pada validasi input, penggunaan istilah klasifikasi, penjelasan hasil, dan pengecekan perhitungan. Oleh karena itu, hasil dari aplikasi ini sebaiknya

digunakan sebagai informasi awal dan tidak menggantikan pemeriksaan langsung oleh tenaga kesehatan.

4.3.7 Pembahasan Hasil Kuesioner Responden

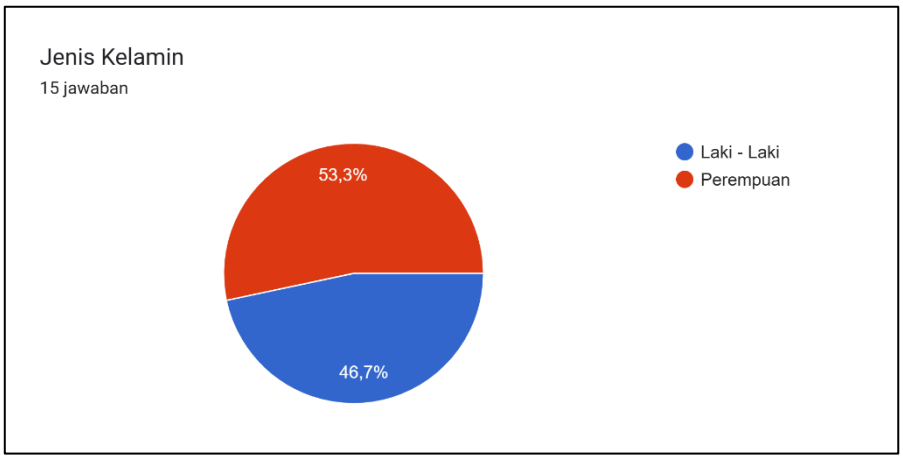
Hasil kuesioner digunakan untuk mengetahui tanggapan responden setelah menggunakan aplikasi GrowSmart Health. Peneliti melibatkan 15 responden, yaitu ibu yang memiliki balita di lingkungan RT setempat. Responden mencoba aplikasi dengan memasukkan data balita, menjalankan proses analisis, membaca hasil klasifikasi, serta melihat informasi pendukung yang ditampilkan oleh sistem. Peneliti kemudian mengolah jawaban responden untuk membahas pengalaman penggunaan aplikasi dan relevansi output yang diberikan.

1. Analisis Data Balita Responden

   Peneliti menganalisis jenis kelamin dan usia balita yang dimasukkan oleh responden selama proses uji coba aplikasi. Analisis tersebut digunakan untuk mengetahui variasi data balita yang digunakan dalam pengujian. Jenis kelamin dan usia juga menjadi data yang relevan karena aplikasi menggunakan informasi tersebut dalam proses pemeriksaan status pertumbuhan dan gizi balita.

   Berdasarkan gambar 4.25 distribusi jenis kelamin, responden memasukkan data balita perempuan sebanyak 8 data atau 53,33%, sedangkan responden memasukkan data balita laki-laki sebanyak 7 data atau 46,67%. Selisih jumlah data pada kedua kategori hanya sebesar satu data. Hasil tersebut

menunjukkan bahwa responden mencoba aplikasi menggunakan data balita laki-laki dan perempuan dengan proporsi yang relatif seimbang.

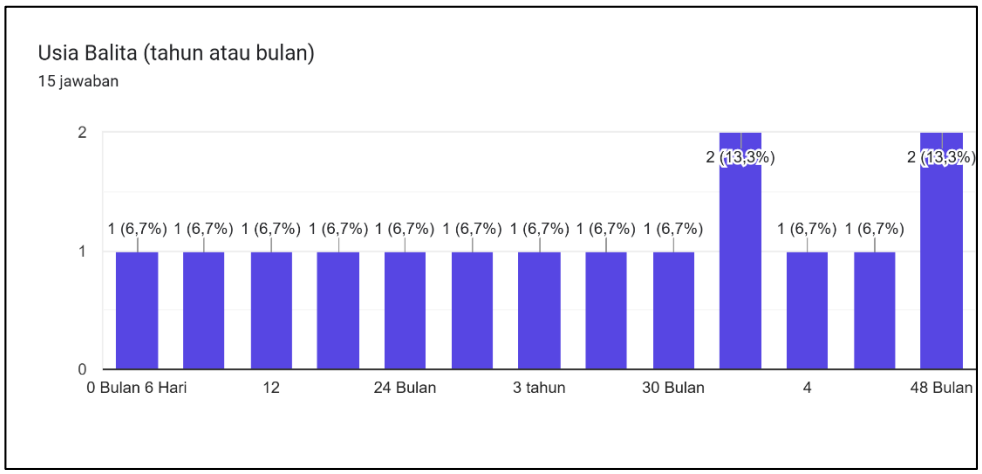


Gambar 4. 25 Grafik Data Balita Berdasarkan Jenis Kelamin

Selain jenis kelamin, peneliti juga menganalisis usia balita yang digunakan dalam proses pengujian. Peneliti menyamakan seluruh data usia ke dalam satuan bulan agar sesuai dengan rentang usia yang digunakan oleh aplikasi, yaitu 0–59 bulan. Berdasarkan hasil pengelompokan, kelompok usia 36–47 bulan memiliki jumlah data paling banyak, yaitu 5 data atau 33,33%. Kelompok usia 12–23 bulan, 24–35 bulan, dan 48–59 bulan masing-masing memiliki 3 data atau 20,00%. Sementara itu, kelompok usia 0–11 bulan memiliki jumlah data paling sedikit, yaitu 1 data atau 6,67%.

Distribusi usia dijelaskan pada gambar 4.26 menunjukkan bahwa responden mencoba aplikasi menggunakan data balita dari beberapa kelompok usia. Variasi data ini sesuai dengan sasaran penggunaan aplikasi yang mencakup balita usia 0–59 bulan. Selain itu, variasi usia mendukung proses pengujian

karena sistem menggunakan usia balita sebagai dasar dalam menampilkan hasil analisis pada indikator BB/U dan TB/U.



Gambar 4. 26 Grafik Data Balita Berdasarkan Kelompok Usia

2. Penilaian Pengalaman Menggunakan Aplikasi

Peneliti menggunakan penilaian pengalaman menggunakan aplikasi untuk mengetahui kemudahan, kenyamanan, kejelasan tampilan, serta penerimaan responden terhadap sistem. Berdasarkan hasil pengolahan data, aspek pengalaman menggunakan aplikasi memperoleh total skor sebesar 760 dari skor maksimal 825. Nilai tersebut menghasilkan persentase sebesar 92,12%. Persentase tersebut menunjukkan bahwa responden memberikan penilaian yang sangat baik terhadap pengalaman penggunaan aplikasi GrowSmart Health. Responden memberikan nilai tertinggi pada pernyataan bahwa aplikasi mudah digunakan dan responden merasa percaya diri saat menggunakan aplikasi. Kedua pernyataan tersebut memperoleh nilai rata-rata sebesar 4,93. Hasil ini menunjukkan bahwa responden dapat mengikuti

alur aplikasi dengan baik, mulai dari memasukkan data balita, menjalankan proses analisis, hingga membaca hasil yang ditampilkan oleh sistem.

Namun, responden memberikan nilai paling rendah pada pernyataan mengenai kebutuhan untuk mempelajari banyak hal terlebih dahulu sebelum menggunakan aplikasi. Setelah skor pernyataan negatif dibalik, pernyataan tersebut memperoleh nilai rata-rata sebesar 3,67. Hasil ini menunjukkan bahwa beberapa responden masih memerlukan penyesuaian ketika pertama kali menggunakan aplikasi. Penyesuaian tersebut dapat berkaitan dengan cara pengisian data balita maupun pemahaman terhadap indikator BB/U, TB/U, dan BB/TB.

Berdasarkan hasil tersebut, aplikasi telah memberikan pengalaman penggunaan yang baik bagi responden. Meskipun demikian, peneliti tetap dapat menyempurnakan aplikasi dengan menambahkan petunjuk penggunaan yang lebih singkat dan penjelasan istilah yang lebih sederhana. Penyempurnaan tersebut dapat membantu pengguna baru memahami fungsi aplikasi dengan lebih cepat.

3. Relevansi Output Aplikasi

Peneliti menggunakan penilaian relevansi output untuk mengetahui tanggapan responden terhadap hasil klasifikasi dan informasi pendukung yang ditampilkan oleh aplikasi. Penilaian ini mencakup kejelasan hasil pada indikator BB/U, TB/U, dan BB/TB, kesesuaian informasi pendukung, manfaat

rekomendasi, serta pemahaman pengguna mengenai fungsi aplikasi sebagai alat bantu skrining awal.

Berdasarkan hasil pengolahan data, aspek relevansi output aplikasi memperoleh total skor sebesar 642 dari skor maksimal 675. Nilai tersebut menghasilkan persentase sebesar 95,11%. Hasil ini menunjukkan bahwa responden memberikan penilaian yang sangat baik terhadap keluaran aplikasi.

Dari seluruh jawaban pada bagian relevansi output, responden memilih jawaban Setuju sebanyak 20 jawaban dan Sangat Setuju sebanyak 110 jawaban. Kedua jawaban positif tersebut mencapai 130 dari 135 jawaban atau sebesar 96,30%. Hasil ini menunjukkan bahwa sebagian besar responden menilai hasil analisis dan informasi pendukung pada aplikasi sudah jelas serta bermanfaat.

Responden memberikan nilai tertinggi pada pernyataan bahwa rekomendasi aplikasi membantu pengguna memahami kondisi awal pertumbuhan dan gizi balita. Pernyataan tersebut memperoleh nilai rata-rata sebesar 4,93. Hasil ini menunjukkan bahwa informasi pendukung yang ditampilkan oleh sistem dapat membantu responden memahami hasil pemeriksaan awal balita.

Selain itu, responden memberikan nilai rata-rata sebesar 4,80 pada kejelasan hasil klasifikasi indikator BB/U, TB/U, dan BB/TB. Nilai tersebut menunjukkan bahwa aplikasi dapat menyajikan hasil analisis per indikator secara terstruktur dan mudah dipahami oleh pengguna.

Meskipun demikian, pernyataan bahwa hasil dan rekomendasi aplikasi tidak menimbulkan kesan sebagai diagnosis akhir memperoleh nilai rata-rata paling rendah pada bagian relevansi output, yaitu sebesar 4,20. Nilai tersebut masih menunjukkan penilaian yang baik, tetapi hasil ini perlu menjadi perhatian dalam pengembangan aplikasi. Sistem perlu memberikan penegasan yang lebih jelas bahwa hasil analisis hanya berfungsi sebagai skrining awal dan tidak menggantikan pemeriksaan langsung oleh tenaga kesehatan.

4. Ringkasan Pembahasan Hasil Kuesioner Responden

Secara keseluruhan, responden memberikan penilaian yang sangat baik terhadap aplikasi GrowSmart Health. Aspek pengalaman menggunakan aplikasi memperoleh persentase sebesar 92,12%, sedangkan aspek relevansi output aplikasi memperoleh persentase sebesar 95,11%. Hasil penilaian keseluruhan memperoleh persentase sebesar 93,47%.

Hasil tersebut menunjukkan bahwa aplikasi dapat membantu responden melakukan pemeriksaan awal status pertumbuhan dan gizi balita melalui alur penggunaan yang mudah dipahami. Sistem juga dapat menyajikan hasil klasifikasi dan informasi pendukung yang relevan bagi pengguna. Hasil kuesioner ini mendukung hasil Black Box Testing yang menunjukkan bahwa seluruh fungsi aplikasi telah berjalan sesuai dengan rancangan.

Walaupun aplikasi memperoleh penilaian yang baik, peneliti tetap perlu memperhatikan beberapa aspek penyempurnaan. Peneliti dapat menambahkan petunjuk penggunaan yang lebih sederhana bagi pengguna

baru dan memperkuat informasi bahwa hasil aplikasi bukan merupakan diagnosis akhir. Dengan demikian, aplikasi GrowSmart Health dapat digunakan secara lebih tepat sebagai alat bantu skrining awal status pertumbuhan dan gizi balita.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan seluruh pengujian yang telah dilakukan terhadap aplikasi GrowSmart Health, peneliti memperoleh kesimpulan sebagai berikut:

1. Peneliti berhasil membangun model klasifikasi status pertumbuhan dan gizi balita menggunakan algoritma LightGBM dan XGBoost pada tiga indikator antropometri, yaitu Weight-for-Age (W/A), Height-for-Age (H/A), dan Weight-for-Height (W/H). Hasil evaluasi menunjukkan bahwa model LightGBM memberikan performa terbaik pada seluruh target klasifikasi. Pada target Height-for-Age, model LightGBM memperoleh nilai *accuracy* sebesar 0,9909 dan *F1 macro* sebesar 0,9882. Pada target Weight-for-Age, model memperoleh nilai *accuracy* sebesar 0,9374 dan *F1 macro* sebesar 0,8349. Sementara itu, pada target Weight-for-Height, model memperoleh nilai *accuracy* sebesar 0,9669 dan *F1 macro* sebesar 0,8522. Hasil tersebut menunjukkan bahwa LightGBM mampu menghasilkan klasifikasi yang baik dan dapat digunakan sebagai model utama pada aplikasi GrowSmart Health.
2. Pengujian Black Box Testing menunjukkan bahwa aplikasi dapat menjalankan seluruh fungsi sesuai dengan rancangan sistem. Sistem berhasil menjalankan proses autentikasi pengguna, navigasi halaman, pengisian dan validasi data balita, proses analisis pada indikator BB/U,

TB/U, dan BB/TB, penyajian hasil pemeriksaan, panduan gizi, pengelolaan riwayat pemeriksaan, serta proses *logout*. Seluruh skenario pengujian memperoleh hasil "Sesuai". Hasil tersebut menunjukkan bahwa sistem telah berfungsi dengan baik dari sisi pengguna dan model klasifikasi yang dipilih telah berhasil diimplementasikan ke dalam aplikasi.

3. Validasi ahli menunjukkan bahwa aplikasi GrowSmart Health sudah layak digunakan sebagai alat bantu skrining awal status pertumbuhan dan gizi balita. Dokter anak menilai bahwa parameter usia, berat badan, tinggi badan, dan jenis kelamin sudah sesuai untuk mendukung pemeriksaan antropometri dasar. Ahli gizi juga menilai bahwa aplikasi dapat menampilkan hasil klasifikasi dan informasi pendukung dengan cukup jelas. Namun, kedua ahli memberikan beberapa masukan, yaitu penambahan validasi rentang biologis pada data masukan, perhitungan usia secara otomatis, penyesuaian istilah klasifikasi, dan pemeriksaan kembali informasi hasil. Masukan tersebut menunjukkan bahwa aplikasi dapat digunakan untuk membantu pemeriksaan awal, tetapi hasil analisis tetap memerlukan konfirmasi dari tenaga kesehatan.

4. Hasil kuesioner responden menunjukkan bahwa pengguna memberikan tanggapan yang sangat baik terhadap aplikasi GrowSmart Health. Peneliti melibatkan 15 responden, yaitu ibu yang memiliki balita di lingkungan RT setempat. Berdasarkan pengolahan data menggunakan skala Likert 5 poin, aspek pengalaman menggunakan aplikasi memperoleh nilai sebesar 92,12%,

sedangkan aspek relevansi output aplikasi memperoleh nilai sebesar 95,11%. Secara keseluruhan, aplikasi memperoleh nilai sebesar 93,47%. Hasil tersebut menunjukkan bahwa responden menilai aplikasi mudah digunakan, mampu menampilkan hasil analisis secara jelas, dan memberikan informasi yang bermanfaat untuk membantu memahami kondisi awal pertumbuhan dan gizi balita.

Secara keseluruhan, peneliti berhasil mengembangkan aplikasi GrowSmart Health sebagai alat bantu skrining awal status pertumbuhan dan gizi balita berbasis model LightGBM. Aplikasi dapat menerima data balita, menjalankan proses klasifikasi pada tiga indikator antropometri, serta menampilkan hasil analisis dan informasi pendukung kepada pengguna. Hasil evaluasi model, pengujian fungsi, validasi ahli, dan penilaian responden menunjukkan bahwa aplikasi dapat digunakan secara praktis dan informatif. Meskipun demikian, pengguna tetap perlu memahami bahwa hasil aplikasi bukan merupakan diagnosis akhir dan tidak menggantikan pemeriksaan langsung oleh tenaga kesehatan.

5.2 Saran

Berdasarkan hasil evaluasi model, pengujian aplikasi, validasi ahli, dan penilaian responden, penelitian ini masih memiliki beberapa peluang untuk dikembangkan pada penelitian selanjutnya. Oleh karena itu, peneliti memberikan beberapa saran sebagai berikut.

1. Penelitian selanjutnya dapat menggunakan data balita dari wilayah atau fasilitas kesehatan yang lebih beragam. Penelitian ini menggunakan dataset yang berasal dari Kabupaten Jeneponto, Sulawesi Selatan. Oleh karena itu, penggunaan data dari daerah lain diperlukan agar kemampuan generalisasi model dapat diuji pada karakteristik balita yang berbeda.
2. Penelitian selanjutnya dapat menambahkan jumlah data pada kategori yang memiliki jumlah sampel lebih sedikit. Pada hasil evaluasi, beberapa kategori minoritas masih lebih sulit dikenali oleh model. Penambahan data pada kelas minoritas diharapkan dapat membantu model mempelajari pola data secara lebih seimbang.
3. Penelitian selanjutnya dapat menerapkan metode penanganan ketidakseimbangan kelas, seperti *oversampling*, *undersampling*, atau metode lain yang sesuai. Metode tersebut dapat digunakan untuk meningkatkan nilai *recall* dan *F1-score* pada kategori yang memiliki jumlah data lebih sedikit.
4. Penelitian selanjutnya dapat melakukan optimasi parameter secara lebih mendalam pada algoritma *LightGBM* dan *XGBoost*. Optimasi tersebut dapat dilakukan untuk memperoleh kombinasi parameter yang lebih baik, sehingga performa model dapat meningkat pada setiap target klasifikasi.
5. Penelitian selanjutnya dapat membandingkan algoritma lain selain *LightGBM* dan *XGBoost*. Perbandingan dengan metode lain, seperti *Random Forest*, *CatBoost*, atau algoritma *machine learning* lainnya, dapat digunakan

untuk mengetahui model yang paling sesuai dalam klasifikasi status pertumbuhan dan gizi balita.

6. Penelitian selanjutnya dapat melakukan pengujian aplikasi dengan jumlah responden yang lebih banyak dan latar belakang yang lebih beragam. Pengujian dapat melibatkan ibu yang memiliki balita, kader posyandu, ahli gizi, dokter anak, serta tenaga kesehatan lainnya. Pengujian tersebut dapat memberikan penilaian yang lebih luas terhadap kemudahan penggunaan, kejelasan informasi, dan manfaat aplikasi dalam pemantauan awal kondisi balita.
7. Penelitian selanjutnya dapat menerapkan aplikasi secara terbatas pada kegiatan posyandu atau fasilitas pelayanan kesehatan. Penerapan tersebut dapat membantu peneliti memperoleh masukan dari penggunaan aplikasi dalam kondisi nyata. Hasil dari penerapan tersebut dapat digunakan untuk menilai kesiapan sistem sebelum dikembangkan ke tahap yang lebih luas.

Secara keseluruhan, pengembangan penelitian selanjutnya dapat difokuskan pada perluasan dataset, peningkatan performa model, penanganan ketidakseimbangan kelas, perbandingan algoritma, serta pengujian aplikasi pada lingkungan penggunaan yang lebih nyata. Pengembangan tersebut diharapkan dapat meningkatkan kualitas aplikasi *GrowSmart Health* sebagai alat bantu skrining awal status pertumbuhan dan gizi balita.

DAFTAR PUSTAKA

[1] World Health Organization (WHO), “Malnutrition – Fact sheet (includes stunting),” World Health Organization (WHO). Accessed: Feb. 26, 2026. [Online]. Available: https://www.who.int/news-room/fact-sheets/detail/malnutrition

[2] T. Beal, A. Tumilowicz, A. Sutrisna, D. Izwardy, and L. M. Neufeld, “A review of child stunting determinants in Indonesia,” Oct. 01, 2018, *Blackwell Publishing Ltd*. doi: 10.1111/mcn.12617.

[3] Kementerian Kesehatan Republik Indonesia, “Strategi Nasional Percepatan Pencegahan Stunting 2021–2024,” Kementerian Kesehatan Republik Indonesia. Accessed: Feb. 26, 2026. [Online]. Available: https://promkes.kemkes.go.id/strategi-nasional-percepatan-pencegahan-stunting

[4] R. Ratnasari, A. J. Wahidin, and T. H. Andika, “Deteksi Dini Stunting Pada Anak Berdasarkan Indikator Antropometri dengan Menggunakan Algoritma Machine Learning,” *Jurnal Algoritma*, vol. 21, no. 2, pp. 378–387, Dec. 2024, doi: 10.33364/algoritma/v.21-2.2122.

[5] A. Candra, Moh. Erkamim, M. Muharrom, and E. Prayitno, “Klasifikasi Stunting Pada Balita Berdasarkan Status Gizi Menggunakan Pendekatan Support Vector Machine (SVM),” *Jurnal Ilmiah FIFO*, vol. 16, no. 2, p. 171, Nov. 2024, doi: 10.22441/fifo.2024.v16i2.007.

[6] H. Al Aziz and H. A. Santoso, “Model Prediksi Stunting Anak di Indonesia Menggunakan Extreme Gradient Boosting,” *Jurnal Algoritma*, vol. 22, no. 1, pp. 1072–1085, 2025, doi: 10.33364/algoritma/v.22-1.2289.

[7] G. Ke *et al.*, “LightGBM: A Highly Efficient Gradient Boosting Decision Tree,” 31st Conference on Neural Information Processing Systems (NIPS 2017), Long Beach, CA, USA., 2017, pp. 1–9. [Online]. Available: https://github.com/Microsoft/LightGBM.

[8] S. Devi, B. Bado, C. A. Kamaruddin, Irwandi, and S. Astuty, “Strategi Penanganan Stunting Di Kabupaten Jeneponto,” *JAE (Jurnal Akuntansi Dan Ekonomi)*, vol. 10, no. 1, pp. 87–98, Mar. 2025, doi: 10.29407/jae.v10i1.25064.

[9] A. H. RS, S. Lonang, and A. F. D. Putra, “Dataset Stunting and Nutritional Status of Toddler from Jeneponto Regency, South Sulawesi, Indonesia,” 2026. doi: 10.17632/wzwpc9j5bx.2.

[10] O. Pahlevi, D. A. N. Wulandari, L. K. Rahayu, H. Leidiyana, and Y. Handrianto, “Model Klasifikasi Risiko Stunting Pada Balita Menggunakan Algoritma CatBoost Classifier,” *Bulletin of Computer Science Research*, vol. 4, no. 6, pp. 414–421, Oct. 2024, doi: 10.47065/bulletincsr.v4i6.373.

[11] Y. F. Saputra, M. A. Al-Khasawneh, M. Milkhatun, N. W. W. Asthiningsih, and S. Rahmah, “Analisis Komparatif Klasifikasi Machine Learning Untuk Memprediksi Stunting Pada Anak Usia Di Bawah Lima Tahun,” *Syntax : Journal of Software Engineering, Computer Science and Information Technology*, vol. 6, no. 1, pp. 71–78, Jun. 2025, doi: 10.46576/syntax.v6i1.6852.

[12] F. Fernando, “Klasifikasi Tweet Cyberbullying Dengan Menggunakan Algoritma Svm Dan Xgboost,” *Jurnal Ilmu Komputer dan Sistem Informasi*, vol. 13, no. 1, pp. 1–6, Jan. 2025, doi: 10.24912/jiksi.v13i1.32857.

[13] F. Ad’ha Putra Sadewa and D. Kurniawan, “Application of ADASYN and Optuna in the XGBoost Algorithm for Stunting Detection,” *Journal of Applied Informatics and Computing (JAIC)*, vol. 10, no. 1, pp. 2548–6861, 2026, doi: 10.30871/jaic.v10i1.12035.

[14] D. Azriani, D. Agustian, Y. Zuhairini, I. N. Yulita, and M. Dhamayanti, “Prediction models for stunting at 2-years-old from Indonesian newborn population,” *BMC Pediatr.*, vol. 25, no. 1, p. 718, Oct. 2025, doi: 10.1186/s12887-025-06096-4.

[15] Sekretariat Nasional SDGs, “Meta Indikator SDGs,” Sekretariat Nasional SDGs. Accessed: Feb. 26, 2026. [Online]. Available: https://sdgs.bappenas.go.id/metadata-indikator-sdgs/

[16] LPPM Universitas Muhammadiyah Magelang, “Apa itu SDGs?,” *LPPM UNIMMA*. [Online]. Available: https://lppm.unimma.ac.id/sdgs/apa-itu-sdgs/. Accessed: Apr. 6, 2026.

[17] Kementerian Kesehatan Republik Indonesia, “Bayi dan Balita < 5 Tahun,” Ayo Sehat Kemenkes RI. [Online]. Available: https://ayosehat.kemkes.go.id/kategori-usia/bayi-dan-balita

[18] F. Agiwahyuanto, D. Ernawati, and E. Widianawati, “Hubungan Perilaku Hidup Sehat Orang Tua dan Literasi Kartu Menuju Sehat (KMS) terhadap Tumbuh Kembang Balita,” Jurnal Kesehatan, vol. 9, no. 1, pp. 21–32, 2021, doi: 10.25047/jkes.v9i1.207. [Online]. Available: https://jurkes.polije.ac.id/index.php/journal/article/view/207

[19] A. Subandi, I. Ariani, and Sujianti, “Perbedaan Karakteristik dan Tingkat Perkembangan pada Balita Stunting dan Non Stunting di Wilayah Puskesmas Cilacap Indonesia,” Jurnal Kesehatan Al-Irsyad, vol. 17, no. 2, pp. 56–63, 2024.

[20] G. L. Handayani, Abbasiah, and H. Rohmah, “Kajian Tumbuh Kembang Balita Usia 12–59 Bulan Berdasarkan Perspektif Pendapatan Keluarga dan Riwayat Pemberian ASI Eksklusif,” Jurnal Keperawatan Silampari, vol. 5, no. 2, 2022, doi: 10.31539/jks.v5i2.3454. [Online]. Available: https://journal.ipm2kpe.or.id/index.php/JKS/article/view/3454

[21] A. Istiqomah, K. Masmur S., R. A. Amali, and S. Tiawati, “Peran Gizi Terhadap Pertumbuhan dan Perkembangan Balita,” Antigen: Jurnal Kesehatan Masyarakat dan Ilmu Gizi, vol. 2, no. 2, pp. 67–74, 2024, doi: 10.57213/antigen.v2i2.257. [Online]. Available: https://jurnal.stikeskesosi.ac.id/index.php/Antigen/article/download/260/283/1328

[22] R. P. Kusumaningrum, T. Wahyudi, and M. Mursudarinah, “Analisis Faktor yang Mempengaruhi Tumbuh Kembang pada Anak Usia 0–24 Bulan,” Jurnal Penelitian Perawat Profesional, vol. 7, no. 1, 2024, doi: 10.37287/jppp.v7i1.3748. [Online]. Available: https://jurnal.globalhealthsciencegroup.com/index.php/JPPP/article/view/3748

[23] World Health Organization, “Child growth standards,” World Health Organization. [Online]. Available: https://www.who.int/tools/child-growth-standards/standards

[24] World Health Organization, “Infant and young child feeding,” World Health Organization, Dec. 20, 2023. [Online]. Available: https://www.who.int/news-room/fact-sheets/detail/infant-and-young-child-feeding

[25] World Health Organization, “Infant and young child feeding,” WHO Nutrition Landscape Information System. [Online]. Available: https://www.who.int/data/nutrition/nlis/info/infant-and-young-child-feeding

[26] S. M. Davidson, A. Khomsan, and H. Riyadi, “Status gizi dan perkembangan anak usia 3–5 tahun di Kabupaten Bogor,” Jurnal Gizi Indonesia (The Indonesian Journal of Nutrition), vol. 8, no. 2, pp. 143–148, Jun. 2020, doi: 10.14710/jgi.8.2.143-148. [Online]. Available: https://ejournal.undip.ac.id/index.php/jgi/article/view/25795

[27] World Health Organization, “Malnutrition,” World Health Organization, Mar. 1, 2024. [Online]. Available: https://www.who.int/news-room/fact-sheets/detail/malnutrition

[28] N. K. Nabilah, T. W. Agustini, and A. S. Nugraheni, “Faktor-Faktor yang Mempengaruhi Status Gizi pada Anak Usia Prasekolah,” Media Kesehatan Masyarakat Indonesia, 2024. [Online]. Available: https://ejournal.undip.ac.id/index.php/mkmi/article/view/45030

[29] World Health Organization, “Malnutrition in children,” World Health Organization. [Online]. Available: https://www.who.int/data/nutrition/nlis/info/malnutrition-in-children

[30] World Health Organization, “Weight-for-length/height,” World Health Organization. [Online]. Available: https://www.who.int/tools/child-growth-standards/standards/weight-for-length-height

[31] World Health Organization, “Weight-for-age,” World Health Organization. [Online]. Available: https://www.who.int/tools/child-growth-standards/standards/weight-for-age

[32] Kementerian Kesehatan Republik Indonesia, Peraturan Menteri Kesehatan Republik Indonesia Nomor 2 Tahun 2020 tentang Standar Antropometri Anak. Jakarta, Indonesia, 2020. [Online]. Available: https://peraturan.bpk.go.id/Download/144762/Permenkes%20Nomor%202%20Tahun%202020.pdf.

[33] A. S. Putra, “Penerapan Machine Learning dalam Analisis Data,” *Jurnal Teknologi Informasi dan Ilmu Komputer* , 2022, Accessed: Feb. 26, 2026. [Online]. Available: https://jtiik.ub.ac.id/index.php/jtiik/article/view/5938

[34] I. Akbar, F. Supriadi, and D. I. Junaedi, “Pemanfaatan Machine Learning Di Bidang Kesehatan,” *Jurnal Mahasiswa Teknik Informatika)*, vol. 9, no. 1, pp. 1744–1749, 2025, doi: 10.36040/jati.v9i1.12663.

[35] I. H. . Witten, Eibe. Frank, M. A. . Hall, and C. J. . Pal, *Data mining : practical machine learning tools and techniques*. Morgan Kaufmann, 2017.

[36] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, “LightGBM: A Highly Efficient Gradient Boosting Decision Tree,” in Advances in Neural Information Processing Systems 30 (NeurIPS 2017), 2017.

[37] R. Shwartz-Ziv and A. Armon, “Tabular data: Deep learning is not all you need,” Information Fusion, vol. 81, pp. 84–90, 2022, doi: 10.1016/j.inffus.2021.11.011.

[38] Z. Usta, H. Akıncı, and A. T. Akın, “Comparison of tree-based ensemble learning algorithms for landslide susceptibility mapping in Murgul (Artvin), Turkey,” Earth Science Informatics, vol. 17, pp. 1459–1481, 2024, doi: 10.1007/s12145-024-01259-w.

[39] A. F. Al Hafidz, E. Y. Puspaningrum, and A. L. Nurlaili, “Penerapan Lightgbm Menggunakan Ekstraksi Fitur Ruang Warna Hsv Untuk Klasifikasi Rempah Rimpang,” *JATI (Jurnal Mahasiswa Teknik Informatika)*, vol. 9, no. 3, pp. 5492–5498, May 2025, doi: 10.36040/jati.v9i3.14306.

[40] Y. Wang and T. Wang, “Application of Improved LightGBM Model in Blood Glucose Prediction,” *Applied Sciences*, vol. 10, no. 9, p. 3227, May 2020, doi: 10.3390/app10093227.

[41] J. Pinnywan Immanuel and T. Handhayani, “Prediksi Harga Pangan Jayapura Menggunakan ELM, LSTM, LIGHTGBM, Dan GB,” *Jurnal Ilmu Komputer dan Sistem Informasi*, vol. 13, no. 2, pp. 1–12, 2025.

[42] S. E. H. Yulianti, O. Soesanto, and Y. Sukmawaty, “Penerapan Metode Extreme Gradient Boosting (XGBOOST) pada Klasifikasi Nasabah Kartu Kredit,” *Journal of Mathematics: Theory and Applications*, vol. 4, no. 1, pp. 21–26, Aug. 2022, doi: 10.31605/jomta.v4i1.1792.

[43] N. R. Sutandi, “Sistem Klasifikasi Topik Tugas Akhir Mahasiswa Menggunakan Algoritma Xgboost,” Skripsi, Universitas Pakuan, Bogor, 2024.

[44] A. Rayhan and D. Gross, *The Rise of Python: A Survey of Recent Research*. License CC BY, 2023. doi: 10.13140/RG.2.2.27388.92809.

[45] S. Maesaroh and Afiyati, *Bahasa Pemrograman Python*. Serang: PT. Sada Kurnia Pustaka, 2024.

[46] Google Colaboratory, “Google Research,” Colab Research Google. Accessed: Mar. 01, 2026. [Online]. Available: https://colab.research.google.com/

[47] Kluyver Thomas *et al.*, “Jupyter Notebooks – a publishing format for reproducible computational workflows,” in *Positioning and Power in Academic Publishing: Players, Agents and Agendas*, IOS Press, 2016, pp. 87–90. doi: 10.3233/978-1-61499-649-1-87.

[48] K. Hermanto, D. Salim, B. Wu, O. R. Salim, and R. B. Gunadi, “Penggunaan python untuk menganalisis pola penyebaran covid-19 di masa pandemi.,” *Journal of Student Development Information System* , vol. 2, no. 2, pp. 120–133, 2022.

[49] R. Refianti, A. B. Mutiara, and A. S. Ariyanto, “Data Visualization of Climate Patterns in Indonesia Using Python and Looker Studio Dashboard: A Visual Data Mining Approach,” *Journal of Applied Data Sciences*, vol. 5, no. 4, pp. 2054–2066, Dec. 2024, doi: 10.47738/jads.v5i4.420.

[50] D. Rusdianto, M. Zaky, and S. Billah, “Rancang Bangun Sistem Informasi Kas Berbasis Web Untuk Meningkatkan Akurasi Data Menggunakan Framework Codeigniter (Studi Kasus: Rumah Makan Ampera Dadakan),” *Jurnal Sistem Informasi, J-SIKA*, vol. 06, no. 02, pp. 55–66, 2024, Accessed: Mar. 01, 2026. [Online]. Available: https://ejournal.unibba.ac.id/index.php/j-sika/article/view/1551

[51] Jihad and M. Fachrie, “Pengembangan Aplikasi Catering Pada Rumah Makan Berbasis Mobile,” *Jurnal Indonesia : Manajemen Informatika dan Komunikasi*, vol. 5, no. 2, pp. 1332–1343, May 2024, doi: 10.35870/jimik.v5i2.591.

[52] A. Brasoveanu, M. Moodie, and R. Agrawal, “Visual Studio Code in Introductory Computer Science Course: An Experience Report,” in *CEUR Workshop Proceedings*, CEUR-WS, 2020, pp. 1–9. doi: 10.48550/arXiv.2303.10174.

[53] J. Giner-Miguelez, A. Gómez, and J. Cabot, “DescribeML: A dataset description tool for machine learning,” *Sci. Comput. Program.*, vol. 231, p. 103030, Jan. 2024, doi: 10.1016/j.scico.2023.103030.

[54] D. Wang, Y. Shen, D. Ye, Y. Yang, X. Da, and J. Mo, “Evaluation of Scikit-Learn Machine Learning Algorithms for Improving CMA-WSP v2.0 Solar Radiation Prediction,” *Atmosphere (Basel).*, vol. 15, no. 8, p. 994, Aug. 2024, doi: 10.3390/atmos15080994.

[55] M. A. Sembiring, H. Saputra, R. A. Yusda, S. Sutarman, and E. B. Nababan, “Performance Of Robust Support Vector Machine Classification Model On Balanced, Imbalanced And Outliers Datasets,” *JITK (Jurnal Ilmu Pengetahuan dan Teknologi Komputer)*, vol. 10, no. 1, pp. 208–215, Aug. 2024, doi: 10.33480/jitk.v10i1.5272.

[56] S. Helmiyah and R. Pramestiawan, “Analisis Komparatif Algoritma Machine Learning dengan Metrik Akurasi, Presisi, Recall, dan F1-Score pada Dataset Kacang Kering,” *Jurnal Ilmu Komputer dan Teknologi (Ikomti)*, vol. 6, no. 3, pp. 152–159, 2025, doi: 10.35960/ikomti.v6i3.2031.

[57] Y. Sytnykova, V. Kyrpenko, S. Palevych, O. Pochuieva, S. Lamtiuhova, and O. Chaika, “Implementation of Professionally Oriented Tasks with Interactive Cloud Environment Google Colab,” *International Journal of Interactive Mobile Technologies (iJIM)*, vol. 19, no. 09, pp. 73–91, May 2025, doi: 10.3991/ijim.v19i09.53459.

[58] O. Arifin, F. Azim, Y. Hartati, D. K. Widyawati, and A. L. A. K. Ariffin, “Comparative Study on the Efficiency of Deep Learning Model Training in Cloud Environments: Google Colab vs AWS,” *Decode: Jurnal Pendidikan Teknologi Informasi*, vol. 5, no. 2, pp. 324–332, Jul. 2025, doi: 10.51454/decode.v5i2.1197.

[59] X. Zhang, T. Zhang, J. Lu, X. Fu, and F. Reveriano, “The Effect of High Performance Computer on Deep Neural Network,” *Engineered Science*, vol. 15, no. 3382, pp. 67–79, 2021, doi: 10.30919/es8d461.

[60] S. Han and I.-Y. Kwak, “Mastering data visualization with Python: practical tips for researchers,” *Journal of Minimally Invasive Surgery*, vol. 26, no. 4, pp. 167–175, Dec. 2023, doi: 10.7602/jmis.2023.26.4.167.

[61] A. Rahman and A. H. Putra, “Data Visualization of PT Aneka Tambang Tbk Stock Price Report Through Data Science Approach Using Google Colab,” *Journal of Mathematics and Its Application*, vol. 1, no. 1, pp. 23–29, 2024, doi: 10.61159/mortalita.

[62] R. Kaestria, E. F. Himmah, and R. Irawan, “Penerapan Matplotlib dalam Visualisasi Data untuk Analisis Hubungan Penggunaan Gadget dan Hasil Belajar,” *Journal of Digital Business and Information Technology*, vol. 1, no. 1, pp. 29–39, Jun. 2024, doi: 10.23971/jobit.v1i1.204.

[63] S. Farhadpour, T. A. Warner, and A. E. Maxwell, “Selecting and Interpreting Multiclass Loss and Accuracy Assessment Metrics for Classifications with Class Imbalance: Guidance and Best Practices,” *Remote Sens. (Basel).*, vol. 16, no. 3, pp. 1–22, Jan. 2024, doi: 10.3390/rs16030533.

[64] A. Ainurrohmah and D. T. Wiyanti, “Analisis Performa Algoritma Decision Tree, Naive Bayes, K-Nearest Neighbor untuk Klasifikasi Zona Daerah Risiko Covid-19 di Indonesia,” *Jurnal Teknologi Informasi dan Ilmu Komputer*, vol. 10, no. 1, pp. 115–122, Feb. 2023, doi: 10.25126/jtiik.2023105935.

[65] S. M. Nuralifah, M. R. H, P. F. Ahmad, and W. Amelia, “Pengguna (User Acceptance Testing) Pada Sistem Informasi Akademik EMACCA Universitas Teknologi AKBA Makassar,” *Inventor: Jurnal Inovasi dan Tren Pendidikan Teknologi Informasi*, vol. 3, no. 2, pp. 84–91, Jun. 2025, doi: 10.37630/inventor.v3i2.2541.

[66] A. S. Pratama, “Evaluasi Sistem Informasi Menggunakan Metode User Acceptance Test,” *Rekayasa Sistem dan Teknologi Informasi*, 2021, Accessed: Feb. 26, 2026. [Online]. Available: https://jurnal.iaii.or.id/index.php/RESTI/article/view/3471

[67] R. T. Yunandar and Priyono, “Pengujian Usability Sistem Framework React Native dengan Expo untuk Pengembangan Aplikasi Android Menggunakan USE Questionnaire,” Sinkron: Jurnal dan Penelitian Teknik Informatika, vol.

3, no. 1, pp. 252–259, 2018. [Online]. Available: https://jurnal.polgan.ac.id/index.php/sinkron/article/view/198

[68] R. Maulana and A. F. Pratama, “Penggunaan Framework React Native dalam Pengembangan Aplikasi Mobile,” IR: Jurnal Informatika dan Rekayasa, 2024. [Online]. Available: https://e-jurnal.dharmawacana.ac.id/index.php/ir/article/download/569/pdf

[69] A. A. Yonismara and A. Salam, “Implementasi Model Convolutional Neural Network (CNN) pada Aplikasi Deteksi Kanker Kulit Menggunakan Expo React Native,” Building of Informatics, Technology and Science (BITS), vol. 6, no. 1, pp. 226–235, 2024. [Online]. Available: https://ejurnal.seminar-id.com/index.php/bits/article/view/5351

[70] M. Irsan, F. T. Santos B., and A. Husain, “Implementasi Aplikasi Pandas (Phyton) Dalam Mengelola Data Excel Sebagai Media Persiapan Pelaporan Nilai Raport Siswa,” Jurnal Pengabdian Masyarakat Bangsa, vol. 2, no. 4, pp. 1243–1249, 2024. [Online]. Available: https://jurnalpengabdianmasyarakatbangsa.com/index.php/jpmba/article/view/977

[71] I. Albanna, “Implementasi Pandas Data frame sebagai Agregasi dan Tabulasi Penyajian Data Luaran Survei Kepuasan Pengguna Proses Pembelajaran dalam Pendidikan Tinggi,” Prosiding Seminar Nasional Sains dan Teknologi Terapan, 2022. [Online]. Available: https://ejurnal.itats.ac.id/sntekpan/article/view/3451/0

[72] S. Japit et al., “Pemanfaatan Pandas, NumPy, Spark, dan Tableau/Power BI dalam Pengolahan dan Visualisasi Big Data untuk Mendukung Pengambilan Keputusan,” Jurnal Minfo Polgan, vol. 14, no. 1, 2025. [Online]. Available: https://jurnal.polgan.ac.id/index.php/jmp/article/view/14762

[73] D. Leni, Muchlisinalahuddin, Maimuzar, Haris, and Hendra, “Analisis Heatmap Korelasi dan Scatterplot untuk Mengidentifikasi Faktor-Faktor yang Mempengaruhi Pelabelan AC efisiensi Energi,” Jurnal Rekayasa Material,

Manufaktur dan Energi, vol. 6, no. 1, 2023. [Online]. Available: https://jurnal.umsu.ac.id/index.php/RMME/article/view/13133

[74] D. N. Chasanah, R. Rosidi, M. J. A. Nasir, and M. A. Gumilang, "Analisis Korelasi Faktor-Faktor Penentu Produktivitas dalam Skema Remote Work Menggunakan Pendekatan Visualisasi dan Statistik," JTIM: Jurnal Teknologi Informasi dan Multimedia, vol. 7, no. 3, pp. 538–547, 2025. [Online]. Available: https://journal.sekawan-org.id/index.php/jtim/article/view/739

[75] F. A. Setiawan dan K. Haryono, "Digitalisasi Manajemen Pesanan Pabrik Abon melalui Aplikasi Mobile Point-of-Sales," Technologia: Jurnal Ilmiah, vol. 16, no. 4, pp. 832–840, 2025, doi: 10.31602/tji.v16i4.20679.

[76] Expo, "Start Developing," Expo Documentation, 2026. [Online]. Tersedia: https://docs.expo.dev/get-started/start-developing/?utm_source

[77] R. N. Zain, N. H. Harani, and S. F. Pane, "Enhancing Prediction Accuracy of the Happiness Index Using Multi-Estimator Stacking Regressor and Web Application Integration," Journal of Dinda: Data Science, Information Technology, and Data Analytics, vol. 5, no. 2, pp. 164–175, 2025, doi: 10.20895/dinda.v5i2.1871

[78] J. V. Dachi and J. Suhada, "Implementasi Basis Data Sederhana Menggunakan MySQL/PostgreSQL," Router: Jurnal Teknik Informatika dan Terapan, vol. 3, no. 1, pp. 49–59, 2025.

[79] World Health Organization, *WHO Child Growth Standards: Length/height-for-age, weight-for-age, weight-for-length, weight-for-height and body mass index-for-age: Methods and development*. Geneva: World Health Organization, 2006. [Online]. Available: https://www.who.int/publications/i/item/924154693X

[80] Kementerian Kesehatan Republik Indonesia, *Pedoman Pelaksanaan Stimulasi, Deteksi, dan Intervensi Dini Tumbuh Kembang Anak di Tingkat Pelayanan Kesehatan Dasar*. Jakarta: Kementerian Kesehatan Republik Indonesia, 2021. [Online]. Available:

https://id.scribd.com/document/572375538/Pedoman-Pelaksanaan-Stimulasi-Deteksi-Dan-Intervensi-Dini-Tumbuh-Kembang-Anak-2021

LAMPIRAN

Lampiran 1

Contoh Perhitungan Lightgbm

Perhitungan manual weight for height

Rumus Awal:

Prior kelas & skor awal

$$\pi_k = \frac{n_k}{N}, F_k^{(0)} = \ln(\pi_k)$$

Softmax (probabilitas)

$$p_{jk}^{(t)} = \frac{e^{F_{jk}^{(t)}}}{\sum_{c=1}^{K} e^{F_{jc}^{(t)}}}$$

Softmax stabil (kurangi maksimum):

$$m = \max_k\left(F_{jk}^{(t)}\right)$$

$$p_{jk}^{(t)} = \frac{e^{F_{jk}^{(t)}-m}}{\sum_{c=1}^{K} e^{F_{jc}^{(t)}-m}}$$

Agregasi gradien & hessian per leaf

$$G_{jk}^{(t)} = n_j \cdot p_{jk}^{(t-1)} - n_{jk}$$

$$H_{jk}^{(t)} = n_j \cdot p_{jk}^{(t-1)}\left(1 - p_{jk}^{(t-1)}\right)$$

1.5 Bobot leaf dan update skor

$$w_{jk}^{(t)} = -\frac{G_{jk}^{(t)}}{H_{jk}^{(t)} + \lambda}$$

$$F_{jk}^{(t)} = F_{jk}^{(t-1)} + \eta \cdot w_{jk}^{(t)}$$

1.6 Prediksi

$$\hat{y} = \arg\max_{k} \quad p_{jk}^{(T)}$$

1.7 Rumus Gain untuk memilih split terbaik (berbasis G, H)

$$Gain = \frac{1}{2} \sum_{k=1}^{K} \left(\frac{G_{Lk}^2}{H_{Lk} + \lambda} + \frac{G_{Rk}^2}{H_{Rk} + \lambda} - \frac{G_{Tk}^2}{H_{Tk} + \lambda} \right)$$

2) DATASET

2.1 Label encoding

Tabel L1. 1 Label encoding Perhitungan LightGBM

weight for height

Kelas	Simbol	Label
Very Thin	VT	0
Thin	Th	1
Normal	N	2
Obese	O	3

2.2 Data Latih

Tabel L1. 2 Data Latih Perhitungan LightGBM Weight For Height

No	Age	Weight	Height	Kelas
1	12	8.0	72	VT
2	18	9.2	78	N
3	24	10.5	85	N
4	30	11.0	88	N
5	36	12.3	95	N
6	14	8.6	74	Th
7	20	9.7	80	N
8	26	10.8	86	N
9	32	11.5	90	N
10	40	13.5	98	O
11	10	7.6	70	VT
12	22	10.1	83	N
13	28	10.9	87	N
14	34	11.8	92	N
15	42	14.2	100	O
16	16	8.9	76	Th
17	38	12.8	96	N

Tabel L1.2 (Lanjutan)

No	Age	Weight	Height	Kelas
18	44	14.8	102	O
19	46	15.2	104	O
20	48	15.6	105	O

Distribusi TRAIN

VT = 2, Th = 2, N = 11, O = 5

2.3 Data Uji

Tabel L1. 3 Data Uji Weight For Height

No	Age	Weight	Height	Kelas Asli
1	12	8.5	75	VT
2	24	10.2	85	N
3	36	13.5	95	N
4	18	7.8	80	Th
5	48	16.0	100	O
6	30	12.5	90	Th
7	42	15.8	105	O

3.1 Hitung prior kelas $\boldsymbol{\pi_k}$

$$\pi_{VT} = \frac{2}{20} = 0.10, \pi_{Th} = \frac{2}{20} = 0.10, \pi_N = \frac{11}{20} = 0.55, \pi_O = \frac{5}{20} = 0.25$$

3.6 Hitung skor awal $F_k^{(0)} = \ln(\pi_k)$

$$F_{VT}^{(0)} = \ln(0.10) = -2.302585$$

$$F_{Th}^{(0)} = \ln(0.10) = -2.302585$$

$$F_N^{(0)} = \ln(0.55) = -0.597837$$

$$F_O^{(0)} = \ln(0.25) = -1.386294$$

3.7 Probabilitas awal (softmax)

Karena $e^{\ln(\pi_k)} = \pi_k$dan $\sum_k \pi_k = 1$, maka:

$$p_k^{(0)} = \pi_k$$

Jadi:

$$p_{VT}^{(0)} = 0.10, p_{Th}^{(0)} = 0.10, p_N^{(0)} = 0.55, p_O^{(0)} = 0.25$$

3.4 Persiapan konstanta Hessian

Bagian $p_k^{(0)}\left(1 - p_k^{(0)}\right)$:

VT: $0.10(0.90) = 0.09$

Th: $0.10(0.90) = 0.09$

N : $0.55(0.45) = 0.2475$

O : $0.25(0.75) = 0.1875$

Sehingga untuk leaf berisi $\boldsymbol{n}$data:

$$\mathrm{H(n, VT)} = 0.09\mathrm{n}, \mathrm{H(n, Th)} = 0.09\mathrm{n}, \mathrm{H(n, N)} = 0.2475\mathrm{n}, \mathrm{H(n, O)} = 0.1875\mathrm{n}$$

3.5 Kandidat split (stump) berdasarkan Age

Data Train diurutkan menurut Age (Age, Kelas):

(10,VT), (12,VT), (14,Th), (16,Th), (18,N), (20,N), (22,N), (24,N), (26,N),

(28,N), (30,N), (32,N), (34,N), (36,N), (38,N), (40,O), (42,O), (44,O), (46,O), (48,O)

Kandidat threshold:

$$Age \leq 10,12,14,16,18,20,22,24,26,28,30,32,34,36,38,40,42,44,46$$

3.8

Tabel L1. 4 Tabel kumulatif jumlah kelas di sisi Kiri
Weight For Height

thr	$\boldsymbol{n_L}$	VT_L	$\mathrm{Th}_{\boldsymbol{L}}$	$N_{\boldsymbol{L}}$	$O_{\boldsymbol{L}}$	$\boldsymbol{n_R}$
10	1	1	0	0	0	19
12	2	2	0	0	0	18
14	3	2	1	0	0	17
16	4	2	2	0	0	16
18	5	2	2	1	0	15
20	6	2	2	2	0	14
22	7	2	2	3	0	13
24	8	2	2	4	0	12
26	9	2	2	5	0	11
28	10	2	2	6	0	10
30	11	2	2	7	0	9
32	12	2	2	8	0	8

Tabel L1.4 (Lanjutan)

thr	$\boldsymbol{n_L}$	VT_L	$\mathrm{Th}_{\boldsymbol{L}}$	$N_{\boldsymbol{L}}$	$O_{\boldsymbol{L}}$	$\boldsymbol{n_R}$
34	13	2	2	9	0	7
36	14	2	2	10	0	6
38	15	2	2	11	0	5
40	16	2	2	11	1	4
42	17	2	2	11	2	3
44	18	2	2	11	3	2
46	19	2	2	11	4	1

3.7 Rumus menghitung G_{Lk} dan G_{Rk}untuk sebuah threshold

Karena pada iterasi awal $p_{jk}^{(0)} = \pi_k$, maka:

$$G_{Lk} = n_L\pi_k - n_{Lk}$$

$$G_{Rk} = n_R\pi_k - n_{Rk}$$

dengan:

$$n_{Rk} = n_k - n_{Lk}, n_R = N - n_L$$

Hessian:

$$H_{Lk} = n_L\pi_k(1-\pi_k), H_{Rk} = n_R\pi_k(1-\pi_k)$$

3.8 Perhitungan Gain:

split terbaik Age ≤ 38

threshold 36 (sebelum 38),

threshold 38 (terpilih),

threshold 40 (sesudah 38).

Gunakan $\lambda = 1$.

Karena di root $G_{Tk} = 20\pi_k - n_k = 0$, maka:

$$Gain = \frac{1}{2}\sum_{k}\left(\frac{G_{Lk}^2}{H_{Lk}+1} + \frac{G_{Rk}^2}{H_{Rk}+1}\right)$$

3.8.1 Threshold = 36 ($Age \leq 36$)

Dari tabel kumulatif:

$n_L = 14, n_R = 6$

Left: VT=2, Th=2, N=10, O=0

Right: VT=0, Th=0, N=1, O=5 (karena total N=11, O=5)

Langkah A — Hitung G_{Lk}dan G_{Rk}

VT:

$$G_{L,VT} = 14(0.10) - 2 = 1.4 - 2 = -0.6$$

$$G_{R,VT} = 6(0.10) - 0 = 0.6$$

Th:

$$G_{L,Th} = 14(0.10) - 2 = -0.6, G_{R,Th} = 6(0.10) - 0 = 0.6$$

N:

$$G_{L,N} = 14(0.55) - 10 = 7.7 - 10 = -2.3$$

$$G_{R,N} = 6(0.55) - 1 = 3.3 - 1 = 2.3$$

O:

$$G_{L,O} = 14(0.25) - 0 = 3.5$$

$$G_{R,O} = 6(0.25) - 5 = 1.5 - 5 = -3.5$$

Langkah B — Hitung H_{Lk}dan H_{Rk}

Pakai konstanta:

VT/Th: $0.09n$

N: $0.2475n$

O: $0.1875n$

Untuk $n_L = 14, n_R = 6$:

VT: $H_{L,VT} = 0.09(14) = 1.26, H_{R,VT} = 0.09(6) = 0.54$

Th: sama (1.26 dan 0.54)

N : $H_{L,N} = 0.2475(14) = 3.465, H_{R,N} = 0.2475(6) = 1.485$

O : $H_{L,O} = 0.1875(14) = 2.625, H_{R,O} = 0.1875(6) = 1.125$

Langkah C — Hitung kontribusi gain per kelas

$$Gain_k = \frac{1}{2}\left(\frac{G_{Lk}^2}{H_{Lk}+1} + \frac{G_{Rk}^2}{H_{Rk}+1}\right)$$

VT:

$$\frac{(-0.6)^2}{1.26+1} = \frac{0.36}{2.26} = 0.159292$$

$$\frac{(0.6)^2}{0.54+1} = \frac{0.36}{1.54} = 0.233766$$

$$Gain_{VT} = \frac{1}{2}(0.159292 + 0.233766) = 0.196529$$

Th: sama → $Gain_{Th} = 0.196529$

N:

$$\frac{(-2.3)^2}{3.465+1} = \frac{5.29}{4.465} = 1.184770$$

$$\frac{(2.3)^2}{1.485+1} = \frac{5.29}{2.485} = 2.128773$$

$$Gain_N = \frac{1}{2}(1.184770 + 2.128773) = 1.656772$$

O:

$$\frac{(3.5)^2}{2.625+1} = \frac{12.25}{3.625} = 3.379310$$

$$\frac{(-3.5)^2}{1.125+1} = \frac{12.25}{2.125} = 5.764706$$

$$Gain_O = \frac{1}{2}(3.379310 + 5.764706) = 4.572008$$

Total gain (thr=36):

$$Gain = 0.196529 + 0.196529 + 1.656772 + 4.572008 = 6.621838$$

3.8.2 Threshold = 38 ($\boldsymbol{Age \leq 38}$)

$n_L = 15, n_R = 5$

Left: VT=2, Th=2, N=11, O=0

Right: VT=0, Th=0, N=0, O=5

Langkah A — Hitung G_{Lk}dan G_{Rk}

VT:

$$G_{L,VT} = 15(0.10) - 2 = 1.5 - 2 = -0.5$$

$$G_{R,VT} = 5(0.10) - 0 = 0.5$$

Th:

$$G_{L,Th} = 15(0.10) - 2 = -0.5, G_{R,Th} = 5(0.10) - 0 = 0.5$$

N:

$$G_{L,N} = 15(0.55) - 11 = 8.25 - 11 = -2.75$$

$$G_{R,N} = 5(0.55) - 0 = 2.75$$

O:

$$G_{L,O} = 15(0.25) - 0 = 3.75$$

$$G_{R,O} = 5(0.25) - 5 = 1.25 - 5 = -3.75$$

Langkah B — Hitung H_{Lk}dan H_{Rk}

Untuk $n_L = 15, n_R = 5$:

VT/Th: $H_L = 0.09(15) = 1.35$, $H_R = 0.09(5) = 0.45$

N: $H_L = 0.2475(15) = 3.7125$, $H_R = 0.2475(5) = 1.2375$

O: $H_L = 0.1875(15) = 2.8125$, $H_R = 0.1875(5) = 0.9375$

Langkah C — Hitung gain per kelas

VT:

$$\frac{(-0.5)^2}{1.35+1} = \frac{0.25}{2.35} = 0.106383$$

$$\frac{(0.5)^2}{0.45+1} = \frac{0.25}{1.45} = 0.172414$$

$$Gain_{VT} = \frac{1}{2}(0.106383 + 0.172414) = 0.139398$$

Th: sama → $Gain_{Th} = 0.139398$

N:

$$\frac{(-2.75)^2}{3.7125+1} = \frac{7.5625}{4.7125} = 1.604775$$

$$\frac{(2.75)^2}{1.2375+1} = \frac{7.5625}{2.2375} = 3.379888$$

$$Gain_N = \frac{1}{2}(1.604775 + 3.379888) = 2.492331$$

O:

$$\frac{(3.75)^2}{2.8125+1} = \frac{14.0625}{3.8125} = 3.688525$$

$$\frac{(-3.75)^2}{0.9375+1} = \frac{14.0625}{1.9375} = 7.258065$$

$$Gain_O = \frac{1}{2}(3.688525 + 7.258065) = 5.473295$$

Total gain (thr=38):

$$Gain = 0.139398 + 0.139398 + 2.492331 + 5.473295 = 8.244423$$

3.8.3 Threshold = 40 ($Age \leq 40$)

Dari tabel kumulatif:

$n_L = 16, n_R = 4$

Left: VT=2, Th=2, N=11, O=1

Right: VT=0, Th=0, N=0, O=4

Langkah A — G_{Lk}, G_{Rk}

VT: $G_L = 16(0.10) - 2 = -0.4, G_R = 4(0.10) - 0 = 0.4$

Th: sama -0.4dan 0.4

N : $G_L = 16(0.55) - 11 = 8.8 - 11 = -2.2, G_R = 4(0.55) - 0 = 2.2$

O : $G_L = 16(0.25) - 1 = 4 - 1 = 3.0, G_R = 4(0.25) - 4 = 1 - 4 = -3.0$

Langkah B — H_{Lk}, H_{Rk}

Untuk $n_L = 16, n_R = 4$:

VT/Th: $H_L = 0.09(16) = 1.44, H_R = 0.09(4) = 0.36$

N: $H_L = 0.2475(16) = 3.96, H_R = 0.2475(4) = 0.99$

O: $H_L = 0.1875(16) = 3.0, H_R = 0.1875(4) = 0.75$

Langkah C — gain per kelas

VT:

$$\frac{(-0.4)^2}{1.44+1} = \frac{0.16}{2.44} = 0.065574$$

$$\frac{(0.4)^2}{0.36+1} = \frac{0.16}{1.36} = 0.117647$$

$$Gain_{VT} = \frac{1}{2}(0.065574 + 0.117647) = 0.091610$$

Th: sama → $Gain_{Th} = 0.091610$

N:

$$\frac{(-2.2)^2}{3.96+1} = \frac{4.84}{4.96} = 0.975806$$

$$\frac{(2.2)^2}{0.99+1} = \frac{4.84}{1.99} = 2.432161$$

$$Gain_N = \frac{1}{2}(0.975806 + 2.432161) = 1.703984$$

O:

$$\frac{(3.0)^2}{3.0+1} = \frac{9}{4} = 2.25$$

$$\frac{(-3.0)^2}{0.75+1} = \frac{9}{1.75} = 5.142857$$

$$Gain_O = \frac{1}{2}(2.25 + 5.142857) = 3.696429$$

Total gain (thr=40):

$$Gain = 0.091610 + 0.091610 + 1.703984 + 3.696429 = 5.583633$$

3.9 Kesimpulan pemilihan split

Karena:

Gain(thr=36) = 6.621838

Gain(thr=38) = 8.244423 (terbesar)

Gain(thr=40) = 5.583633

Maka split terbaik:

$$\boxed{\boldsymbol{Age \leq 38}}$$

3.10 Hitung $\boldsymbol{G}, \boldsymbol{H}$untuk split terpilih (thr=38) dan bobot leaf $\boldsymbol{w}$

(A) Leaf L (Age ≤ 38)

$n_L = 15, n_{L,VT} = 2, n_{L,Th} = 2, n_{L,N} = 11, n_{L,O} = 0$

$G_{L,VT} = 15(0.10) - 2 = -0.5, H_{L,VT} = 15(0.09) = 1.35$

$G_{L,Th} = -0.5, H_{L,Th} = 1.35$

$G_{L,N} = 15(0.55) - 11 = -2.75, H_{L,N} = 15(0.2475) = 3.7125$

$G_{L,O} = 15(0.25) - 0 = 3.75, H_{L,O} = 15(0.1875) = 2.8125$

Bobot leaf (λ=1):

$$w_{L,VT} = -\frac{-0.5}{1.35 + 1} = 0.212766$$

$$w_{L,Th} = 0.212766$$

$$w_{L,N} = -\frac{-2.75}{3.7125 + 1} = 0.583554$$

$$w_{L,O} = -\frac{3.75}{2.8125 + 1} = -0.983607$$

(B) Leaf R (Age > 38)

$n_R = 5, n_{R,O} = 5$(lainnya 0)

$$G_{R,VT} = 5(0.10) - 0 = 0.5, H_{R,VT} = 5(0.09) = 0.45$$

$$G_{R,Th} = 0.5, H_{R,Th} = 0.45$$

$$G_{R,N} = 5(0.55) - 0 = 2.75, H_{R,N} = 5(0.2475) = 1.2375$$

$$G_{R,O} = 5(0.25) - 5 = -3.75, H_{R,O} = 5(0.1875) = 0.9375$$

Bobot leaf (λ=1):

$$w_{R,VT} = -\frac{0.5}{0.45 + 1} = -0.344828$$

$$w_{R,Th} = -0.344828$$

$$w_{R,N} = -\frac{2.75}{1.2375 + 1} = -1.229050$$

$$w_{R,O} = -\frac{-3.75}{0.9375 + 1} = 1.935484$$

3.11 Update skor $F_{jk}^{(1)} = F_k^{(0)} + \eta w_{jk}^{(1)}$(η=1)

Skor awal:

$$F_{VT}^{(0)} = -2.302585$$

$$F_{Th}^{(0)} = -2.302585$$

$$F_N^{(0)} = -0.597837$$

$$F_O^{(0)} = -1.386294$$

Leaf L (Age ≤ 38)

$$F_{L,VT}^{(1)} = -2.302585 + 0.212766 = -2.089819$$

$$F_{L,Th}^{(1)} = -2.089819$$

$$F_{L,N}^{(1)} = -0.597837 + 0.583554 = -0.014283$$

$$F_{L,O}^{(1)} = -1.386294 - 0.983607 = -2.369901$$

Leaf R (Age > 38)

$$F_{R,VT}^{(1)} = -2.302585 - 0.344828 = -2.647413$$

$$F_{R,Th}^{(1)} = -2.647413$$

$$F_{R,N}^{(1)} = -0.597837 - 1.229050 = -1.826887$$

$$F_{R,O}^{(1)} = -1.386294 + 1.935484 = 0.549190$$

3.12 Softmax akhir per leaf

(A) Leaf L (Age ≤ 38)

Skor:

$$[-2.089819,\ -2.089819,\ -0.014283,\ -2.369901]$$

Ambil $m = -0.014283$.

Hitung eksponensial:

VT: $e^{-2.089819-(-0.014283)} = e^{-2.075536} = 0.125489$

Th: 0.125489

N: $e^{0} = 1$

O: $e^{-2.369901-(-0.014283)} = e^{-2.355618} = 0.094835$

Jumlah:

$$S_L = 0.125489 + 0.125489 + 1 + 0.094835 = 1.345813$$

Probabilitas:

$$p_{L,VT} = 0.125489/1.345813 = 0.093244$$

$$p_{L,Th} = 0.093244$$

$$p_{L,N} = 1/1.345813 = 0.743045$$

$$p_{L,O} = 0.094835/1.345813 = 0.070467$$

(B) Leaf R (Age > 38)

Skor:

$$[-2.647413,\ -2.647413,\ -1.826887, 0.549190]$$

Ambil $m = 0.549190$.

Eksponensial:

VT: $e^{-2.647413-0.549190} = e^{-3.196603} = 0.040901$

Th: 0.040901

N: $e^{-1.826887-0.549190} = e^{-2.376077} = 0.092914$

O: $e^{0} = 1$

Jumlah:

$$S_R = 0.040901 + 0.040901 + 0.092914 + 1 = 1.174716$$

Probabilitas:

$$p_{R,VT} = 0.040901/1.174716 = 0.034818$$

$$p_{R,Th} = 0.034818$$

$$p_{R,N} = 0.092914/1.174716 = 0.079095$$

$$p_{R,O} = 1/1.174716 = 0.851269$$

4) Model Hasil Pelatihan

4.1 Aturan stump

Jika $\boldsymbol{Age \leq 38}$ ⇒ Leaf $\boldsymbol{L}$,Jika $\boldsymbol{Age > 38}$ ⇒ Leaf $\boldsymbol{R}$

4.2 Skor akhir per leaf (logit)

Leaf L (Age ≤ 38):

$$\mathrm{F}_L^{(1)} = [-2.089819,\ -2.089819,\ -0.014283,\ -2.369901]$$

Leaf R (Age > 38):

$$\mathrm{F}_R^{(1)} = [-2.647413,\ -2.647413,\ -1.826887, 0.549190]$$

4.3 Probabilitas per leaf (softmax)

Leaf L:

$$\mathrm{P}_L^{(1)} = [0.093244,\ 0.093244,\ 0.743045,\ 0.070467]$$

Leaf L:

$$\mathrm{P}_R^{(1)} = [0.034818,\ 0.034818,\ 0.079095,\ 0.851269$$

5) Prediksi Data Uji

5.1 Aturan prediksi

1. Tentukan leaf:

$$j = \begin{cases} L, & Age \leq 38 \\ R, & Age > 38 \end{cases}$$

2. Ambil skor $\mathrm{F}_j^{(1)}$

3. Hitung softmax (atau langsung gunakan $\mathrm{p}_j^{(1)}$karena konstan per leaf)

4. $\hat{y} = \mathrm{ar\,g\,ma\,x}_{\ k}\, p_{jk}^{(1)}$

5.2 Perhitungan prediksi per data uji

Data uji No. 1: (Age=12)

$12 \leq 38$ ⇒leaf L

Probabilitas leaf L: $[0.093244, 0.093244, 0.743045, 0.070467]$

Nilai terbesar 0.743045 → Prediksi = Normal

Data uji No. 2: (Age=24)

$24 \leq 38$ ⇒leaf L

Prediksi = Normal

Data uji No. 3: (Age=36)

$36 \leq 38$ ⇒leaf L

Prediksi = Normal

Data uji No. 4: (Age=18)

$18 \leq 38$ ⇒leaf L

Prediksi = Normal

Data uji No. 5: (Age=48)

$48 > 38$ ⇒leaf R

Probabilitas leaf R: $[0.034818, 0.034818, 0.079095, 0.851269]$

Nilai terbesar 0.851269 → Prediksi = Obese

Data uji No. 6: (Age=30)

$30 \leq 38$ ⇒leaf L

Prediksi = Normal

Data uji No. 7: (Age=42)

$42 > 38$ ⇒leaf R

Prediksi = Obese

5.3 Tabel hasil prediksi TEST

Tabel L1. 5 Tabel hasil prediksi TEST Weight For Height

No	Age	Weight	Height	Kelas Asli	Leaf	(p(VT))	(p(Th))	(p(N))	(p(O))	Prediksi
1	12	8.5	75	VT	L	0.09324	0.09324	0.74305	0.07047	Normal
2	24	10.2	85	N	L	0.09324	0.09324	0.74305	0.07047	Normal
3	36	13.5	95	N	L	0.09324	0.09324	0.74305	0.07047	Normal
4	18	7.8	80	Th	L	0.09324	0.09324	0.74305	0.07047	Normal
5	48	16	100	O	R	0.03482	0.03482	0.0791	0.85127	Obese
6	30	12.5	90	Th	L	0.09324	0.09324	0.74305	0.07047	Normal
7	42	15.8	105	O	R	0.03482	0.03482	0.0791	0.85127	Obese

1.1 Tabel hasil prediksi TEST

Urutan kelas untuk evaluasi:

$$[VT, Th, N, O] = [0,1,2,3]$$

Tabel L1.6 (Lanjutan)

No	Kelas Asli	Prediksi
1	VT	N
2	N	N
3	N	N
4	Th	N
5	O	O
6	Th	N
7	O	O

Ringkasan:

Prediksi **Normal (N)**: 5 data (No 1,2,3,4,6)

Prediksi **Obese (O)**: 2 data (No 5,7)

Prediksi **VT**: 0

Prediksi **Th**: 0

Support (jumlah data asli per kelas):

VT = 1

Th = 2

N = 2

O = 2

Total $N = 7$

2) Confusion Matrix (Multiclass)

2.1 Definisi

Elemen confusion matrix:

$$C_{i,j} = \qquad \text{(kelas asli } i \text{ diprediksi sebagai } j\text{)}$$

Dengan urutan kelas $[VT, Th, N, O]$maka matriksnya:

Tabel L1. 6 Hasil Perhitungan Confusion Matrix Weight For Height

True \ Pred	VT	Th	N	O
VT	0	0	1	0
Th	0	0	2	0
N	0	0	2	0
O	0	0	0	2

Cek total:

$$0 + 0 + 1 + 0 + 0 + 0 + 2 + 0 + 0 + 0 + 2 + 0 + 0 + 0 + 0 + 2 = 7$$

sesuai jumlah data uji.

3) Accuracy

3.1 Rumus

$$Accuracy = \frac{\sum_{k=1}^{K} T\,P_k}{N} = \frac{\text{jumlah diagonal}}{N}$$

3.2 Hitung

Diagonal confusion matrix:

VT→VT = 0

Th→Th = 0

N→N = 2

O→O = 2

Jumlah diagonal = $0 + 0 + 2 + 2 = 4$, $N = 7$

$$Accuracy = \frac{4}{7} = 0.5714$$

4) Precision, Recall, F1 per Kelas (One-vs-Rest)

4.1 Definisi TP, FP, FN, TN (one-vs-rest)

Untuk setiap kelas k:

TP_k: data asli kelas $k$diprediksi kelas k

FP_k: data asli bukan kelas k, tapi diprediksi kelas k

FN_k: data asli kelas k, tapi diprediksi bukan kelas k

TN_k: data asli bukan kelas k, dan diprediksi bukan kelas k

Rumus metrik:

$$Precision_k = \frac{TP_k}{TP_k + FP_k}$$

$$Recall_k = \frac{TP_k}{TP_k + FN_k}$$

$$F1_k = \frac{2 \cdot Precision_k \cdot Recall_k}{Precision_k + Recall_k}$$

Aturan pembagian nol:

jika $TP_k + FP_k = 0$maka $Precision_k = 0$

jika $TP_k + FN_k = 0$maka $Recall_k = 0$

4.2 Hitung TP, FP, FN, TN dari confusion matrix

(A) Kelas VT

$$TP_{VT} = C_{VT,VT} = 0$$

Prediksi VT total = kolom VT = $0 + 0 + 0 + 0 = 0$

$\Rightarrow FP_{VT} = 0$(karena tidak ada prediksi VT)

True VT total = baris VT = $0 + 0 + 1 + 0 = 1$

$$\Rightarrow FN_{VT} = 1 - TP = 1 - 0 = 1$$

$$TN_{VT} = N - (TP + FP + FN) = 7 - (0 + 0 + 1) = 6$$

Metrik:

Precision:

$$Precision_{VT} = \frac{0}{0 + 0} = 0$$

Recall:

$$Recall_{VT} = \frac{0}{0 + 1} = 0$$

F1:

$$F1_{VT} = 0$$

(B) Kelas Th

$$TP_{Th} = C_{Th,Th} = 0$$

Prediksi Th total = kolom Th = $0 + 0 + 0 + 0 = 0$

$$\Rightarrow FP_{Th} = 0$$

True Th total = baris Th = $0 + 0 + 2 + 0 = 2$

$$\Rightarrow FN_{Th} = 2 - 0 = 2$$

$$TN_{Th} = 7 - (0 + 0 + 2) = 5$$

Metrik:

$$Precision_{Th} = 0, Recall_{Th} = 0, F1_{Th} = 0$$

(C) Kelas N

$$TP_N = C_{N,N} = 2$$

Prediksi N total = kolom N = $1 + 2 + 2 + 0 = 5$

$$\Rightarrow FP_N = 5 - 2 = 3$$

True N total = baris N = $0 + 0 + 2 + 0 = 2$

$$\Rightarrow FN_N = 2 - 2 = 0$$

$$TN_N = 7 - (2 + 3 + 0) = 2$$

Metrik:

$$Precision_N = \frac{2}{2 + 3} = \frac{2}{5} = 0.4000$$

$$Recall_N = \frac{2}{2 + 0} = 1.0000$$

$$F1_N = \frac{2(0.4)(1)}{0.4 + 1} = \frac{0.8}{1.4} = 0.5714$$

(D) Kelas O

$$TP_O = C_{O,O} = 2$$

Prediksi O total = kolom O = $0 + 0 + 0 + 2 = 2$

$$\Rightarrow FP_O = 2 - 2 = 0$$

True O total = baris O = $0 + 0 + 0 + 2 = 2$

$$\Rightarrow FN_O = 2 - 2 = 0$$

$$TN_O = 7 - (2 + 0 + 0) = 5$$

Metrik:

$$Precision_O = \frac{2}{2 + 0} = 1.0000$$

$$Recall_O = \frac{2}{2 + 0} = 1.0000$$

$$F1_O = 1.0000$$

1.3 Tabel ringkasan TP/FP/FN/TN dan metrik per kelas

Tabel L1. 7 Ringkasan metrik perkelas Weight For Height

Kelas	TP	FP	FN	TN	Precision	Recall	F1
VT	0	0	1	6	0.0000	0.0000	0.0000
Th	0	0	2	5	0.0000	0.0000	0.0000
N	2	3	0	2	0.4000	1.0000	0.5714
O	2	0	0	5	1.0000	1.0000	1.0000

5) Macro Average

5.1 Rumus

$$Precision_{macro} = \frac{1}{K} \sum_{k=1}^{K} Precisio\, n_k$$

$$Recall_{macro} = \frac{1}{K}\sum_{k=1}^{K} Recal\,l_k$$

$$F1_{macro} = \frac{1}{K}\sum_{k=1}^{K} F\,1_k$$

5.2 Hitung (K=4)

$$Precision_{macro} = \frac{0+0+0.4+1}{4} = 0.3500$$

$$Recall_{macro} = \frac{0+0+1+1}{4} = 0.5000$$

$$F1_{macro} = \frac{0+0+0.5714+1}{4} = 0.3929$$

6) Weighted Average

6.1 Support per kelas

Support = jumlah kelas asli pada TEST:

VT=1, Th=2, N=2, O=2, total $N = 7$

6.2 Rumus

$$Metric_{weighted} = \sum_{k=1}^{K} \frac{support_k}{N} \cdot Metric_k$$

6.3 Precision weighted

$$Precision_{weighted} = \frac{1}{7}(0) + \frac{2}{7}(0) + \frac{2}{7}(0.4) + \frac{2}{7}(1)$$

$$= \frac{0 + 0 + 0.8 + 2}{7} = \frac{2.8}{7} = 0.4000$$

6.4 Recall weighted

$$Recall_{weighted} = \frac{1}{7}(0) + \frac{2}{7}(0) + \frac{2}{7}(1) + \frac{2}{7}(1)$$

$$= \frac{0 + 0 + 2 + 2}{7} = \frac{4}{7} = 0.5714$$

6.5 F1 weighted

$$F1_{weighted} = \frac{1}{7}(0) + \frac{2}{7}(0) + \frac{2}{7}(0.5714) + \frac{2}{7}(1)$$

$$= \frac{0 + 0 + 1.1428 + 2}{7} = \frac{3.1428}{7} = 0.4490$$

7) Micro Average

Untuk multiclass single-label, micro-average menghitung total TP, FP, FN global:

$$TP_{\text{micro}} = \sum_{k} T\,P_k$$

$$FP_{\text{micro}} = \sum_{k} F\,P_k$$

$$FN_{\text{micro}} = \sum_{k} F\,N_k$$

Dari tabel:

$$TP_{\text{micro}} = 0 + 0 + 2 + 2 = 4$$

$$FP_{\text{micro}} = 0 + 0 + 3 + 0 = 3$$

$$FN_{\text{micro}} = 1 + 2 + 0 + 0 = 3$$

Micro-precision:

$$Precision_{\text{micro}} = \frac{TP_{\text{micro}}}{TP_{\text{micro}} + FP_{\text{micro}}} = \frac{4}{4+3} = \frac{4}{7} = 0.5714$$

Micro-recall:

$$Recall_{\text{micro}} = \frac{TP_{\text{micro}}}{TP_{\text{micro}} + FN_{\text{micro}}} = \frac{4}{4+3} = \frac{4}{7} = 0.5714$$

Micro-F1:

Karena micro-precision = micro-recall, maka:

$$F1_{\text{micro}} = 0.5714$$

8) Ringkasan Evaluasi

Confusion matrix menunjukkan model hanya memprediksi Normal dan Obese

Accuracy:

$$Accuracy = \frac{4}{7} = 0.5714$$

Macro average:

Precision = 0.3500

Recall = 0.5000

F1 = 0.3929

Weighted average:

Precision = 0.4000

Recall = 0.5714

F1 = 0.4490

Micro average:

Precision = Recall = F1 = 0.5714

Perhitungan Manual untuk Weight-for-Age

A. Dataset

Data latih (N = 20)

Kolom: Age_month, Weight_kg, Height_cm, Weight for Age

Tabel L1. 8 Perhitungan Manual LightGBM Weight for Age

No	age (bulan)	weight (kg)	height (cm)	Label
1	12	8.0	72	Underfed
2	18	9.2	78	Normal
3	24	10.5	85	Normal
4	30	11.0	88	Normal
5	36	12.3	95	Normal
6	14	8.6	74	Underfed
7	20	9.8	80	Normal
8	26	10.7	86	Normal
9	32	11.8	90	Normal

Tabel L1. 9 (Lanjutan)

No	age (bulan)	weight (kg)	height (cm)	Label
10	40	13.8	98	Normal
11	10	7.6	70	Malnutrition
12	22	10.2	83	Normal
13	28	10.9	87	Normal
14	34	12.0	91	Normal
15	42	14.2	100	Normal
16	16	8.9	76	Underfed
17	21	9.5	79	Normal
18	27	10.8	86	Normal
19	33	11.6	89	Normal
20	45	14.8	102	Overnutrition

Urutan kelas (K=4) dipakai konsisten:

1. Malnutrition (M)
2. Normal (N)
3. Overnutrition (O)
4. Underfed (U)

Distribusi kelas data latih:

$n_M = 1, n_N = 15, n_O = 1, n_U = 3$(Total $N = 20$)

Data uji (m = 7)

Kolom: age, height, weight, Weight for Age

Tabel L1. 9 Distribusi Data Latih Weight For Age

No	age	weight	height	Label Aktual
1	12	8.5	75	Underfed
2	24	10.2	85	Normal
3	36	13.5	95	Normal
4	18	7.8	80	Malnutrition
5	48	16.0	100	Normal
6	30	11.0	90	Underfed
7	60	20.0	110	Overnutrition

B. Parameter Contoh Manual

1 iterasi:

Iterasi $T = 1$

Regularisasi: $\lambda = 1$

Learning rate: $\eta = 0.5$

Pohon sederhana (stump) membagi data menjadi 2 leaf (L dan R) dengan contoh split:

$$age \leq 17 \Rightarrow \text{leaf } L, age > 17 \Rightarrow \text{leaf } R$$

pada implementasi LightGBM, pemilihan split dilakukan otomatis berdasarkan kriteria terbaik. Pada contoh manual ini, split $age \leq 17$ digunakan agar langkah agregasi per leaf sesuai rumus dapat dihitung jelas dari tabel.

1. Rumus yang Digunakan

Misal jumlah kelas K, kelas k, leaf $j \in L, R$, iterasi t.

1.1 Prior kelas dan skor awal

$$\pi_k = \frac{n_k}{N}, F_k^{(0)} = \ln(\pi_k)$$

1.2 Softmax (probabilitas)

$$p_{jk}^{(t-1)} = \frac{e^{F_{jk}^{(t-1)}}}{\sum_{c=1}^{K} e^{F_{jc}^{(t-1)}}}$$

1.3 Agregasi gradien & hessian per leaf

$$G_{jk}^{(t)} = n_j \, p_{jk}^{(t-1)} - n_{jk}$$

$$H_{jk}^{(t)} = n_j \, p_{jk}^{(t-1)} \left(1 - p_{jk}^{(t-1)}\right)$$

1.4 Bobot leaf

$$w_{jk}^{(t)} = -\frac{G_{jk}^{(t)}}{H_{jk}^{(t)} + \lambda}$$

1.5 Update skor

$$F_{jk}^{(t)} = F_{jk}^{(t-1)} + \eta\, w_{jk}^{(t)}$$

1.6 Prediksi

$$\hat{y} = \arg\max_k \quad p_{jk}^{(T)}$$

2) Langkah 1 — Prior kelas $\pi_k$dan skor awal $F_k^{(0)}$

2.1 Prior kelas

$$\pi_M = \frac{1}{20} = 0.05, \pi_N = \frac{15}{20} = 0.75, \pi_O = \frac{1}{20} = 0.05, \pi_U = \frac{3}{20} = 0.15$$

2.2 Skor awal (log prior)

$$F_M^{(0)} = \ln(0.05) = -2.9957$$

$$F_N^{(0)} = \ln(0.75) = -0.2877$$

$$F_O^{(0)} = \ln(0.05) = -2.9957$$

$$F_U^{(0)} = \ln(0.15) = -1.8971$$

3) Langkah 2 — Softmax awal $p^{(0)}$

Karena $F_k^{(0)} = \ln(\pi_k)$, maka $e^{F_k^{(0)}} = \pi_k$.

Sehingga:

$$p_M^{(0)} = 0.05, p_N^{(0)} = 0.75, p_O^{(0)} = 0.05, p_U^{(0)} = 0.15$$

4) Langkah 3 — Membentuk leaf dan menghitung $n_j$serta n_{jk}

Split:

$$age \leq 17 \Rightarrow L, age > 17 \Rightarrow R$$

4.1 Anggota leaf dari data latih

Leaf L: age = 10, 12, 14, 16 → $n_L = 4$

Label: 1 Malnutrition + 3 Underfed

$$(n_{LM}, n_{LN}, n_{LO}, n_{LU}) = (1,0,0,3)$$

Leaf R: sisanya → $n_R = 16$

Label: 15 Normal + 1 Overnutrition

$$(n_{RM}, n_{RN}, n_{RO}, n_{RU}) = (0,15,1,0)$$

Tabel ringkas:

Tabel L1. 10 Ringkasan Perhitungan Data Latih

Leaf	n_j	n_{jM}	n_{jN}	n_{jO}	n_{jU}
L	4	1	0	0	3
R	16	0	15	1	0

5) Langkah 4 — Agregasi gradien & hessian per leaf (t=1)

Diketahui $p^{(0)} = [0.05, 0.75, 0.05, 0.15]$

5.1 Leaf L ($n_L = 4$)

5.1.1 Gradien $G_{Lk}^{(1)} = n_L p_k^{(0)} - n_{Lk}$

Malnutrition:

$$G_{LM} = 4(0.05) - 1 = 0.2 - 1 = -0.8$$

Normal:

$$G_{LN} = 4(0.75) - 0 = 3.0$$

Overnutrition:

$$G_{LO} = 4(0.05) - 0 = 0.2$$

Underfed:

$$G_{LU} = 4(0.15) - 3 = 0.6 - 3 = -2.4$$

5.1.2 Hessian $H_{Lk}^{(1)} = n_L p_k^{(0)}\left(1 - p_k^{(0)}\right)$

Malnutrition:

$$H_{LM} = 4(0.05)(0.95) = 0.19$$

Normal:

$$H_{LN} = 4(0.75)(0.25) = 0.75$$

Overnutrition:

$$H_{LO} = 4(0.05)(0.95) = 0.19$$

Underfed:

$$H_{LU} = 4(0.15)(0.85) = 0.51$$

5.2 Leaf R ($n_R = 16$)

5.2.1 Gradien $G_{Rk}^{(1)} = n_R p_k^{(0)} - n_{Rk}$

Malnutrition:

$$G_{RM} = 16(0.05) - 0 = 0.8$$

Normal:

$$G_{RN} = 16(0.75) - 15 = 12 - 15 = -3$$

Overnutrition:

$$G_{RO} = 16(0.05) - 1 = 0.8 - 1 = -0.2$$

Underfed:

$$G_{RU} = 16(0.15) - 0 = 2.4$$

5.2.2 Hessian $H_{Rk}^{(1)} = n_R p_k^{(0)}\left(1 - p_k^{(0)}\right)$

Malnutrition:

$$H_{RM} = 16(0.05)(0.95) = 0.76$$

Normal:

$$H_{RN} = 16(0.75)(0.25) = 3.00$$

Overnutrition:

$$H_{RO} = 16(0.05)(0.95) = 0.76$$

Underfed:

$$H_{RU} = 16(0.15)(0.85) = 2.04$$

6) Langkah 5 — Bobot leaf $w_{jk}^{(1)}$

Rumus:

$$w_{jk}^{(1)} = -\frac{G_{jk}^{(1)}}{H_{jk}^{(1)} + \lambda}, \lambda = 1$$

6.1 Bobot leaf L

$$w_{LM} = -\frac{-0.8}{0.19 + 1} = 0.6723$$

$$w_{LN} = -\frac{3.0}{0.75 + 1} = -1.7143$$

$$w_{LO} = -\frac{0.2}{0.19 + 1} = -0.1681$$

$$w_{LU} = -\frac{-2.4}{0.51 + 1} = 1.5894$$

6.2 Bobot leaf R

$$w_{RM} = -\frac{0.8}{0.76 + 1} = -0.4545$$

$$w_{RN} = -\frac{-3.0}{3.0 + 1} = 0.7500$$

$$w_{RO} = -\frac{-0.2}{0.76 + 1} = 0.1136$$

$$w_{RU} = -\frac{2.4}{2.04 + 1} = -0.7895$$

7) Langkah 6 — Update skor $F_{jk}^{(1)}$

Rumus:

$$F_{jk}^{(1)} = F_k^{(0)} + \eta w_{jk}^{(1)}, \eta = 0.5$$

7.1 Skor akhir pada leaf L (age ≤ 17)

$$F_{LM}^{(1)} = -2.9957 + 0.5(0.6723) = -2.6596$$

$$F_{LN}^{(1)} = -0.2877 + 0.5(-1.7143) = -1.1448$$

$$F_{LO}^{(1)} = -2.9957 + 0.5(-0.1681) = -3.0798$$

$$F_{LU}^{(1)} = -1.8971 + 0.5(1.5894) = -1.1024$$

Sehingga:

$$\mathrm{F}_L^{(1)} = [-2.6596, -1.1448, -3.0798, -1.1024]$$

7.2 Skor akhir pada leaf R (age > 17)

$$F_{RM}^{(1)} = -2.9957 + 0.5(-0.4545) = -3.2230$$

$$F_{RN}^{(1)} = -0.2877 + 0.5(0.7500) = 0.0873$$

$$F_{RO}^{(1)} = -2.9957 + 0.5(0.1136) = -2.9389$$

$$F_{RU}^{(1)} = -1.8971 + 0.5(-0.7895) = -2.2919$$

Sehingga:

$$\mathrm{F}_R^{(1)} = [-3.2230, 0.0873, -2.9389, -2.2919]$$

8) Model hasil pelatihan

Model LightGBM (T=1) dapat ditulis sebagai fungsi piecewise:

Jika $age \leq 17$

$$\mathrm{F}^{(1)}(x) = [-2.6596, -1.1448, -3.0798, -1.1024]$$

Jika $age > 17$

$$\mathrm{F}^{(1)}(x) = [-3.2230, 0.0873, -2.9389, -2.2919]$$

Urutan skor selalu $[M, N, O, U]$.

9) Prediksi data uji

9.1 Softmax leaf L (age ≤ 17)

$$p_{Lk}^{(1)} = \frac{e^{F_{Lk}^{(1)}}}{\sum_c e^{F_{Lc}^{(1)}}}$$

Hasil softmax leaf L:

$$P_L(M) = 0.0913$$

$$P_L(N) = 0.4153$$

$$P_L(O) = 0.0600$$

$$P_L(U) = 0.4333$$

Prediksi leaf L:

$$\hat{y} = U$$

9.2 Softmax leaf R (age > 17)

Hasil softmax leaf R:

$$P_R(M) = 0.0310$$

$$P_R(N) = 0.8492$$

$$P_R(O) = 0.0412$$

$$P_R(U) = 0.0787$$

Prediksi leaf R:

$$\hat{y} = N$$

9.3 Tabel hasil prediksi seluruh data uji

Tabel L1. 11 hasil prediksi seluruh data uji

No	age	weight	height	Leaf	Aktual	Prediksi	P(M)	P(N)	P(O)	P(U)
1	12	8.5	75	L	Underfed	Underfed	0.0913	0.4153	0.06	0.4333
2	24	10.2	85	R	Normal	Normal	0.031	0.8492	0.0412	0.0787
3	36	13.5	95	R	Normal	Normal	0.031	0.8492	0.0412	0.0787
4	18	7.8	80	R	Malnutrition	Normal	0.031	0.8492	0.0412	0.0787
5	48	16	100	R	Normal	Normal	0.031	0.8492	0.0412	0.0787
6	30	11	90	R	Underfed	Normal	0.031	0.8492	0.0412	0.0787
7	60	20	110	R	Overnutrition	Normal	0.031	0.8492	0.0412	0.0787

10) Evaluasi

Urutan kelas untuk confusion matrix: $[M, N, O, U]$

10.1 Confusion matrix multiclass

Baris = aktual, kolom = prediksi:

$$CM = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 3 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 1 \end{bmatrix}$$

Tabel:

Aktual \ Prediksi	M	N	O	U	Total
Malnutrition	0	1	0	0	1
Normal	0	3	0	0	3
Overnutrition	0	1	0	0	1
Underfed	0	1	0	1	2

10.2 Accuracy

$$Accuracy = \frac{\text{jumlah benar}}{m} = \frac{0+3+0+1}{7} = \frac{4}{7} = 0.5714$$

$$Accuracy = 57.14$$

10.3 Precision, Recall, F1 per kelas (one-vs-rest)

Rumus:

$$Precision_k = \frac{TP_k}{TP_k + FP_k}, Recall_k = \frac{TP_k}{TP_k + FN_k}$$

$$F1_k = \frac{2 \cdot Precision_k \cdot Recall_k}{Precision_k + Recall_k}$$

Dari confusion matrix:

Kelas	TP	FP	FN	Support	Precision	Recall	F1
M	0	0	1	1	0.0000	0.0000	0.0000
N	3	3	0	3	0.5000	1.0000	0.6667
O	0	0	1	1	0.0000	0.0000	0.0000
U	1	0	1	2	1.0000	0.5000	0.6667

10.4 Macro-average, Weighted-average, Micro-average (multiclass)

Macro-average

$$MacroPrecision = \frac{0 + 0.5 + 0 + 1}{4} = 0.3750$$

$$MacroRecall = \frac{0 + 1 + 0 + 0.5}{4} = 0.3750$$

$$MacroF1 = \frac{0 + 0.6667 + 0 + 0.6667}{4} = 0.3333$$

Weighted-average (support: M=1, N=3, O=1, U=2)

$$WeightedF1 = \frac{1(0) + 3(0.6667) + 1(0) + 2(0.6667)}{7} = 0.4762$$

Micro-average

Untuk single-label multiclass:

$$MicroPrecision = MicroRecall = MicroF1 = Accuracy = 0.5714$$

Perhitungan Manual Height-for-Age

Fitur: Age (bulan), Weight (kg), Height (cm)

Target (2 kelas/binary):

0 = Not Stunted

1 = Stunted

Parameter contoh manual: T = 1 iterasi (1 tree), 1 split → 2 leaf (L, R), $\lambda = 1$, $\eta = 1$.

Data yang digunakan

Data latih (N = 20)

Tabel L1. 12 Data latih Height For Age

No	Age	Weight	Height	Label	y
1	12	8.0	72	Stunted	1
2	18	9.2	78	Not Stunted	0
3	24	10.5	85	Not Stunted	0
4	30	11.0	88	Not Stunted	0
5	36	12.3	95	Not Stunted	0
6	14	8.6	74	Stunted	1
7	20	9.8	80	Not Stunted	0
8	26	10.7	86	Not Stunted	0
9	32	11.8	90	Not Stunted	0
10	40	13.8	98	Not Stunted	0
11	10	7.6	70	Stunted	1
12	22	10.2	83	Not Stunted	0
13	28	10.9	87	Not Stunted	0
14	34	12.0	91	Not Stunted	0
15	42	14.2	100	Not Stunted	0
16	16	8.9	76	Stunted	1
17	21	9.5	79	Not Stunted	0
18	27	10.8	86	Not Stunted	0
19	33	11.6	89	Not Stunted	0
20	45	14.8	102	Not Stunted	0

Distribusi kelas:

$$n_0 = 16, n_1 = 4, N = 20, K = 2$$

1.2 Data uji (N = 7)

Tabel L1. 13 Data Uji Height For Age

No	Age	Weight	Height	Label	y
1	12	8.5	75	Not Stunted	0
2	24	10.2	85	Stunted	1
3	36	13.5	95	Not Stunted	0
4	18	7.8	80	Stunted	1
5	48	16.0	100	Not Stunted	0
6	30	11.0	90	Stunted	1
7	60	20.0	110	Not Stunted	0

Rumusan awal

Misal jumlah kelas K, kelas $k \in 0,1$, leaf $j \in L, R$, iterasi t.

2.1 Prior kelas & skor awal

$$\pi_k = \frac{n_k}{N}, F_k^{(0)} = l\,n(\pi_k)$$

2.2 Softmax (probabilitas)

$$p_{jk}^{(t-1)} = \frac{e^{F_{jk}^{(t-1)}}}{\sum_{c=0}^{K-1} e^{F_{jc}^{(t-1)}}}$$

2.3 Agregasi gradien & hessian per leaf

$$G_{jk}^{(t)} = n_j\, p_{jk}^{(t-1)} - n_{jk}$$

$$H_{jk}^{(t)} = n_j \, p_{jk}^{(t-1)} \left(1 - p_{jk}^{(t-1)}\right)$$

2.4 Bobot leaf

$$w_{jk}^{(t)} = -\frac{G_{jk}^{(t)}}{H_{jk}^{(t)} + \lambda}$$

2.5 Update skor

$$F_{jk}^{(t)} = F_{jk}^{(t-1)} + \eta \, w_{jk}^{(t)}$$

2.6 Prediksi

$$\hat{y} = ar\,g\,ma\underset{k}{x} \quad p_{jk}^{(T)}$$

3. Pelatihan model (t = 0 → 1)

3.1 Prior kelas

$$\pi_0 = \frac{16}{20} = 0.8, \pi_1 = \frac{4}{20} = 0.2$$

3.2 Skor awal

$$F_0^{(0)} = l\,n(0.8) = -0.2231436, F_1^{(0)} = l\,n(0.2) = -1.6094379$$

3.3 Probabilitas awal (softmax dari skor awal)

Karena $e^{-0.2231436} = 0.8$dan $e^{-1.6094379} = 0.2$, maka:

$$p_0^{(0)} = \frac{0.8}{0.8 + 0.2} = 0.8, p_1^{(0)} = 0.2$$

3.4 Struktur tree (1 split)

Tree-1 menggunakan aturan:

a. Age < 17 → Leaf L
b. Age ≥ 17 → Leaf R

Assignment leaf (data latih)

a. Leaf L memuat: Age = 10, 12, 14, 16 → 4 data (semua y=1)
b. Leaf R memuat: sisa data → 16 data (semua y=0)

Rekap:

Leaf j	Kondisi	n_j	n_{j0}	n_{j1}
L	Age < 17	4	0	4
R	Age ≥ 17	16	16	0

3.5 Perhitungan $G_{jk}^{(1)}$ dan $H_{jk}^{(1)}$

Dengan $p_0^{(0)} = 0.8$, $p_1^{(0)} = 0.2$:

$$p(1-p) = 0.8(0.2) = 0.16$$

Leaf L (n=4)

$$G_{L0}^{(1)} = 4(0.8) - 0 = 3.2, H_{L0}^{(1)} = 4(0.16) = 0.64$$
$$G_{L1}^{(1)} = 4(0.2) - 4 = -3.2, H_{L1}^{(1)} = 0.64$$

Leaf R (n=16)

$$G_{R0}^{(1)} = 16(0.8) - 16 = -3.2, H_{R0}^{(1)} = 16(0.16) = 2.56$$
$$G_{R1}^{(1)} = 16(0.2) - 0 = 3.2, H_{R1}^{(1)} = 2.56$$

Tabel ringkas:

Leaf	$G_0^{(1)}$	$H_0^{(1)}$	$G_1^{(1)}$	$H_1^{(1)}$
L	3.2	0.64	-3.2	0.64
R	-3.2	2.56	3.2	2.56

3.6 Perhitungan bobot leaf $w_{jk}^{(1)}(\lambda = 1)$

$$w_{jk}^{(1)} = -\frac{G_{jk}^{(1)}}{H_{jk}^{(1)} + 1}$$

Leaf L

$$w_{L0}^{(1)} = -\frac{3.2}{0.64 + 1} = -\frac{3.2}{1.64} = -1.9512195$$

$$w_{L1}^{(1)} = -\frac{-3.2}{1.64} = +1.9512195$$

Leaf R

$$w_{R0}^{(1)} = -\frac{-3.2}{2.56 + 1} = +\frac{3.2}{3.56} = +0.8988764$$

$$w_{R1}^{(1)} = -\frac{3.2}{3.56} = -0.8988764$$

Tabel bobot leaf:

Leaf	$w_0^{(1)}$	$w_1^{(1)}$
L	-1.9512195	+1.9512195
R	+0.8988764	-0.8988764

3.7 Update skor leaf $F_{jk}^{(1)}(\eta = 1)$

$$F_{jk}^{(1)} = F_k^{(0)} + w_{jk}^{(1)}$$

Leaf L

$$F_{L0}^{(1)} = -0.2231436 - 1.9512195 = -2.1743631$$

$$F_{L1}^{(1)} = -1.6094379 + 1.9512195 = 0.3417816$$

Leaf R

$$F_{R0}^{(1)} = -0.2231436 + 0.8988764 = 0.6757328$$

$$F_{R1}^{(1)} = -1.6094379 - 0.8988764 = -2.5083143$$

3.8 Probabilitas akhir per leaf (softmax)

$$p_{j0}^{(1)} = \frac{e^{F_{j0}^{(1)}}}{e^{F_{j0}^{(1)}} + e^{F_{j1}^{(1)}}}, p_{j1}^{(1)} = 1 - p_{j0}^{(1)}$$

Hasil (dibulatkan 6 desimal):

Leaf L: $p_{L0}^{(1)} = 0.074734, p_{L1}^{(1)} = 0.925266$

Leaf R: $p_{R0}^{(1)} = 0.960230, p_{R1}^{(1)} = 0.039770$

4. Model hasil pelatihan

Model akhir (T=1, 1 tree, 2 leaf):

Aturan split:

Jika Age < 17 → Leaf L

Jika Age ≥ 17 → Leaf R

Skor leaf (untuk softmax):

Leaf L: $(F_0, F_1) = (-2.174363, 0.341782)$

Leaf R: $(F_0, F_1) = (0.675733, -2.508314)$

Probabilitas leaf:

Leaf L: $(p_0, p_1) = (0.074734, 0.925266)$→ prediksi 1 (Stunted)

Leaf R: $(p_0, p_1) = (0.960230, 0.039770)$→ prediksi 0 (Not Stunted)

5. Prediksi data uji

5.1 Langkah prediksi untuk setiap data uji

1. Tentukan leaf dari aturan tree berdasarkan Age.
2. Ambil (F_0, F_1)sesuai leaf.
3. Hitung softmax (p_0, p_1)atau gunakan nilai leaf yang sudah dihitung.
4. Tentukan kelas $\hat{y} = ar\,g\,m\,a\,x(p_0, p_1)$.

5.2 Data Uji

Data: Age=12, Weight=8.5, Height=75

Karena $12 < 17$→ Leaf L. Ambil skor:

$$F_0 = -2.1743631, F_1 = 0.3417816$$

Hitung:

$$e^{F_0} \approx 0.1137, e^{F_1} \approx 1.4070, S = 1.5207$$

$$p_0 = \frac{0.1137}{1.5207} = 0.074734, p_1 = \frac{1.4070}{1.5207} = 0.925266$$

$$\hat{y} = ar\,g\,m\,a\,x(0.074734, 0.925266) = 1$$

5.4 Tabel prediksi seluruh data uji

Tabel L1. 14 prediksi seluruh data uji

No	Age	y aktual	Leaf	p_0	p_1	$\hat{y}$
1	12	0	L	0.074734	0.925266	1
2	24	1	R	0.960230	0.039770	0
3	36	0	R	0.960230	0.039770	0
4	18	1	R	0.960230	0.039770	0
5	48	0	R	0.960230	0.039770	0
6	30	1	R	0.960230	0.039770	0
7	60	0	R	0.960230	0.039770	0

6. Evaluasi (data uji)

Kelas positif: 1 (Stunted).

Dari tabel:

TP = 0 (tidak ada aktual 1 yang diprediksi 1)

TN = 3 (aktual 0 diprediksi 0: No.3,5,7)

FP = 1 (aktual 0 diprediksi 1: No.1)

FN = 3 (aktual 1 diprediksi 0: No.2,4,6)

6.1 Confusion matrix

Aktual \ Pred	0	1
0	3	1
1	3	0

6.2 Accuracy

$$Accuracy = \frac{TP + TN}{N} = \frac{0 + 3}{7} = 0.428571\ (42.86$$

6.3 Precision (kelas 1)

$$Precision = \frac{TP}{TP + FP} = \frac{0}{0 + 1} = 0$$

6.4 Recall (kelas 1)

$$Recall = \frac{TP}{TP + FN} = \frac{0}{0 + 3} = 0$$

6.5 F1-score

$$F1 = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall} = 0$$

Berdasarkan perhitungan manual LightGBM (T=1), model membentuk satu pohon dengan aturan Age < 17 → Stunted dan Age ≥ 17 → Not Stunted. Hasil pelatihan menunjukkan pemisahan kelas yang sempurna pada data latih karena pola umur yang jelas.

Namun, pada data uji diperoleh akurasi 42,86% dengan precision, recall, dan F1-score kelas Stunted sebesar 0, sehingga dapat disimpulkan bahwa model satu iterasi masih belum mampu melakukan generalisasi dengan baik terhadap data baru.

Lampiran 2

Perhitungan Manual XGBOOST

Kelas Weight-for-Height

1.1 Variabel Input (X)

a. x_1= Age (bulan)

b. x_2= Weight (kg)

c. x_3= Height (cm)

1.2 Variabel Target (y)

Kelas Weight-for-Height (4 kategori):

a. Very Thin

b. Thin

c. Normal

d. Obese

1.3 Label Encoding

a. Very Thin = 0

b. Thin = 1

c. Normal = 2

d. Obese = 3

Notasi label:

$$y_i \in 0,1,2,3$$

Untuk perhitungan softmax multiclass dipakai indikator:

$$1(y_i = k) = \begin{cases} 1, & \text{jika data ke-}i\text{ berkelas }k \\ 0, & \text{lainnya} \end{cases}$$

kelas disingkat:

a. VT = Very Thin
b. Th = Thin
c. N = Normal
d. O = Obese

Dataset

2.1 TRAIN = 20 (data latih)

Tabel L2. 1 TRAIN = 20 (data latih) Weight For Height

No	Age (bulan)	Weight (kg)	Height (cm)	Kelas Weight-for-Height
1	12	8.0	72	Very Thin
2	18	9.2	78	Normal
3	24	10.5	85	Normal
4	30	11.0	88	Normal
5	36	12.3	95	Normal
6	14	8.6	74	Thin
7	20	9.7	80	Normal
8	26	10.8	86	Normal
9	32	11.5	90	Normal
10	40	13.5	98	Obese
11	10	7.6	70	Very Thin
12	22	10.1	83	Normal
13	28	10.9	87	Normal
14	34	11.8	92	Normal
15	42	14.2	100	Obese
16	16	8.9	76	Thin
17	38	12.8	96	Normal

Tabel L2.1 (Lanjutan)

No	Age (bulan)	Weight (kg)	Height (cm)	Kelas Weight-for-Height
18	44	14.8	102	Obese
19	46	15.2	104	Obese
20	48	15.6	105	Obese

Tabel L2. 2 TEST = 7 (data uji)

No	Age (bulan)	Weight (kg)	Height (cm)	Kelas Asli
1	12	8.5	75	Very Thin
2	24	10.2	85	Normal
3	36	13.5	95	Normal
4	18	7.8	80	Thin
5	48	16.0	100	Obese
6	30	12.5	90	Thin
7	42	15.8	105	Obese

Konsep XGBoost Multiclass

3.1 Bentuk model

XGBoost membangun skor/logit:

$$z_{ik} = \sum_{t=1}^{T} f_{t,k}\,(x_i)$$

a. $T = 1$(hanya 1 round)
b. Objective multiclass → dalam 1 round, XGBoost membentuk K tree (di sini 4 stump), satu untuk tiap kelas.

Maka:

$$z_{ik} = f_{1,k}(x_i)$$

3.2 Softmax

$$p_{ik} = \frac{e^{z_{ik}}}{\sum_{j=1}^{4} e^{z_{ij}}}$$

Prediksi:

$$\hat{y}_i = ar\ g\ ma\underset{k}{x} \quad p_{ik}$$

Pelatihan Manual

Inisialisasi skor awal

Sebelum ada tree:

$$z_{ik}^{(0)} = 0 \forall i, k$$

Karena $K = 4$, probabilitas awal:

$$p_{ik}^{(0)} = \frac{1}{4} = 0.25$$

One-Hot Label untuk 20 Data

Tabel indikator $1(y_i = k)$

Tabel L2. 3 Indikator

No	Age	Kelas	y(VT)	y(Th)	y(N)	y(O)
1	12	VT	1	0	0	0
2	18	N	0	0	1	0
3	24	N	0	0	1	0
4	30	N	0	0	1	0
5	36	N	0	0	1	0
6	14	Th	0	1	0	0
7	20	N	0	0	1	0
8	26	N	0	0	1	0
9	32	N	0	0	1	0
10	40	O	0	0	0	1
11	10	VT	1	0	0	0

Tabel L2. 3 (Lanjutan)

No	Age	Kelas	y(VT)	y(Th)	y(N)	y(O)
12	22	N	0	0	1	0
13	28	N	0	0	1	0
14	34	N	0	0	1	0
15	42	O	0	0	0	1
16	16	Th	0	1	0	0
17	38	N	0	0	1	0
18	44	O	0	0	0	1
19	46	O	0	0	0	1
20	48	O	0	0	0	1

5.3 Gradient dan Hessian (Softmax)

Rumus per data $i$dan kelas k:

$$g_{ik} = p_{ik} - 1(y_i = k)$$

$$h_{ik} = p_{ik}(1 - p_{ik})$$

Karena $p_{ik} = 0.25$:

$$h_{ik} = 0.25(1 - 0.25) = 0.1875$$

5.3.1 Pola nilai gradient saat inisialisasi

a. Jika kelas benar = k: $g_{ik} = 0.25 - 1` = -0.75$

b. Jika kelas salah: g_{ik}= 0.25 - 0 = 0.25

Cek jumlah gradient per baris:

$$\sum_{k=1}^{4} g_{ik} = (0.25 + 0.25 + 0.25 + 0.25) - 1 = 0$$

Sehingga tiap data punya $\sum g_{ik} = 0$

Tabel Gradient 20 Data

Vektor gradient ditulis $[g_{VT}, g_{Th}, g_N, g_O]$.

Tabel L2. 4 Gradient 20 Data

No	Age	Kelas	g(VT)	g(Th)	g(N)	g(O)	Σg
1	12	VT	-0.75	0.25	0.25	0.25	0
2	18	N	0.25	0.25	-0.75	0.25	0
3	24	N	0.25	0.25	-0.75	0.25	0
4	30	N	0.25	0.25	-0.75	0.25	0
5	36	N	0.25	0.25	-0.75	0.25	0
6	14	Th	0.25	-0.75	0.25	0.25	0
7	20	N	0.25	0.25	-0.75	0.25	0
8	26	N	0.25	0.25	-0.75	0.25	0
9	32	N	0.25	0.25	-0.75	0.25	0
10	40	O	0.25	0.25	0.25	-0.75	0
11	10	VT	-0.75	0.25	0.25	0.25	0
12	22	N	0.25	0.25	-0.75	0.25	0
13	28	N	0.25	0.25	-0.75	0.25	0
14	34	N	0.25	0.25	-0.75	0.25	0
15	42	O	0.25	0.25	0.25	-0.75	0
16	16	Th	0.25	-0.75	0.25	0.25	0
17	38	N	0.25	0.25	-0.75	0.25	0
18	44	O	0.25	0.25	0.25	-0.75	0

Tabel L2. 4 (Lanjutan)

No	Age	Kelas	g(VT)	g(Th)	g(N)	g(O)	Σg
19	46	O	0.25	0.25	0.25	-0.75	0
20	48	O	0.25	0.25	0.25	-0.75	0

Total Hessian per kelas

Karena setiap data punya $h_{ik} = 0.1875$:

$$H_T = \sum_{i=1}^{20} h_{ik} = 20 \times 0.1875 = 3.75$$

Total Gradient per kelas (TRAIN)

Gunakan distribusi kelas dari tabel:

$$n_{VT} = 2, n_{Th} = 2, n_N\text{=}11, n_O\text{=}5$$

Karena $g_{ik} = 0.25 - 1(y_i = k)$, maka total:

$$G_T^k = \sum_{i=1}^{20} g_{ik} = 20(0.25) - n_k = 5 - n_k$$

Hitung:

a. $G_T^{VT} = 5 - 2 = 3.0$

b. $G_T^{Th} = 5 - 2 = 3.0$

c. $G_T^N = 5 - 11 = -6.0$

d. $G_T^O = 5 - 5 = 0.0$

Cek konsistensi:

$$G_T^{VT} + G_T^{Th} + G_T^N + G_T^O = 3 + 3 - 6 + 0 = 0$$

Pencarian Split Stump (berbasis fitur Age)

6.1 Kandidat threshold Age

Age pada TRAIN (urut):

10, 12, 14, 16, 18, 20, 22, 24, 26, 28, 30, 32, 34, 36, 38, 40, 42, 44, 46, 48

Kandidat threshold (agar Right tidak kosong) memakai semua kecuali 48:

$$Age \leq 10{,}12{,}14{,}16, \ldots{,}46$$

Tabel kumulatif jumlah kelas di sisi Left (berdasarkan threshold)

Tabel ini dipakai untuk menentukan n_L dan $n_{k,L}$.

Tabel L2. 5 kumulatif jumlah kelas di sisi Left

thr	nL	VT_L	Th_L	N_L	O_L
10	1	1	0	0	0
12	2	2	0	0	0
14	3	2	1	0	0
16	4	2	2	0	0
18	5	2	2	1	0
20	6	2	2	2	0
22	7	2	2	3	0
24	8	2	2	4	0
26	9	2	2	5	0
28	10	2	2	6	0
30	11	2	2	7	0
32	12	2	2	8	0
34	13	2	2	9	0
36	14	2	2	10	0
38	15	2	2	11	0
40	16	2	2	11	1
42	17	2	2	11	2

Tabel L2. 5 (Lanjutan)

thr	nL	VT_L	Th_L	N_L	O_L
44	18	2	2	11	3
46	19	2	2	11	4

Rumus menghitung G_L, H_L, G_R, H_R

Untuk sebuah kelas k:

Karena pada inisialisasi $g_{ik} = 0.25 - 1(y_i = k)$, maka jika:

a. n_L= jumlah data di Left

b. $n_{k,L}$= jumlah data kelas $k$di Left

maka:

$$G_L^k = \sum_{i \in L} g_{ik} = n_L(0.25) - n_{k,L}$$

$$H_L = \sum_{i \in L} h_{ik} = n_L(0.1875)$$

Sisi Right:

$$G_R^k = G_T^k - G_L^k, H_R = H_T - H_L$$

Gain Split (XGBoost) dan Pemilihan Threshold Terbaik

7.1 Rumus Gain

$$Gain = \frac{1}{2}\left(\frac{(G_L^k)^2}{H_L + \lambda} + \frac{(G_R^k)^2}{H_R + \lambda} - \frac{(G_T^k)^2}{H_T + \lambda}\right) - \gamma$$

Dengan $\lambda = 1, \gamma = 0, H_T = 3.75$

Tabel Gain lengkap per kelas (19 threshold)

7.2.1 Kelas Very Thin (VT)

thr	nL	n(VT,L)	GL	HL	GR	HR	Gain
10	1	1	-0.75	0.1875	3.75	3.5625	0.830570
12	2	2	-1.50	0.3750	4.50	3.3750	2.185099
14	3	2	-1.25	0.5625	4.25	3.1875	1.709348
16	4	2	-1.00	0.7500	4.00	3.0000	1.338346
18	5	2	-0.75	0.9375	3.75	2.8125	1.042055
20	6	2	-0.50	1.1250	3.50	2.6250	0.801110
22	7	2	-0.25	1.3125	3.25	2.4375	0.602509
24	8	2	0.00	1.5000	3.00	2.2500	0.437247
26	9	2	0.25	1.6875	2.75	2.0625	0.299260
28	10	2	0.50	1.8750	2.50	1.8750	0.183908
30	11	2	0.75	2.0625	2.25	1.6875	0.087634
32	12	2	1.00	2.2500	2.00	1.5000	0.007692
34	13	2	1.25	2.4375	1.75	1.3125	0.058178
36	14	2	1.50	2.6250	1.50	1.1250	0.142372
38	15	2	1.75	2.8125	1.25	0.9375	0.264657
40	16	2	2.00	3.0000	1.00	0.7500	0.430756
42	17	2	2.25	3.1875	0.75	0.5625	0.647841
44	18	2	2.50	3.3750	0.50	0.3750	0.924949
46	19	2	2.75	3.5625	0.25	0.1875	1.275377

Split terbaik VT: $Age \leq 12$

7.2.2 Kelas Thin (Th)

thr	nL	n(Th,L)	GL	HL	GR	HR	Gain

10	1	0	0.25	0.1875	2.75	3.5625	-0.092286
12	2	0	0.50	0.3750	2.50	3.3750	-0.142174
14	3	1	-0.25	0.5625	3.25	3.1875	0.333826
16	4	2	-1.00	0.7500	4.00	3.0000	1.338346
18	5	2	-0.75	0.9375	3.75	2.8125	1.042055
20	6	2	-0.50	1.1250	3.50	2.6250	0.801110
22	7	2	-0.25	1.3125	3.25	2.4375	0.602509
24	8	2	0.00	1.5000	3.00	2.2500	0.437247
26	9	2	0.25	1.6875	2.75	2.0625	0.299260
28	10	2	0.50	1.8750	2.50	1.8750	0.183908
30	11	2	0.75	2.0625	2.25	1.6875	0.087634
32	12	2	1.00	2.2500	2.00	1.5000	0.007692
34	13	2	1.25	2.4375	1.75	1.3125	0.058178
36	14	2	1.50	2.6250	1.50	1.1250	0.142372
38	15	2	1.75	2.8125	1.25	0.9375	0.264657
40	16	2	2.00	3.0000	1.00	0.7500	0.430756
42	17	2	2.25	3.1875	0.75	0.5625	0.647841
44	18	2	2.50	3.3750	0.50	0.3750	0.924949
46	19	2	2.75	3.5625	0.25	0.1875	1.275377

Split terbaik Thin: $Age \leq 16$

1.2.3 Kelas Normal (N)

thr	nL	n(N,L)	GL	HL	GR	HR	Gain
10	1	0	0.25	0.1875	-6.25	3.5625	0.517664
12	2	0	0.5	0.375	-6.5	3.375	1.130007
14	3	0	0.75	0.5625	-6.75	3.1875	1.830825
16	4	0	1	0.75	-7	3	2.621241
18	5	1	0.25	0.9375	-6.25	2.8125	1.349606
20	6	2	-0.5	1.125	-5.5	2.625	0.441764
22	7	3	-1.25	1.3125	-4.75	2.4375	0.119481

24	8	4	-2	1.5	-4	2.25	0.007692
26	9	5	-2.75	1.6875	-3.25	2.0625	0.29926
28	10	6	-3.5	1.875	-2.5	1.875	0.80111
30	11	7	-4.25	2.0625	-1.75	1.6875	1.338346
32	12	8	-5	2.25	-1	1.5	1.939103
34	13	9	-5.75	2.4375	-0.25	1.3125	2.636008
36	14	10	-6.5	2.625	0.5	1.125	3.184615
38	15	11	-7.25	2.8125	1.25	0.9375	3.507195
40	16	11	-7	3	1	0.75	2.621241
42	17	11	-6.75	3.1875	0.75	0.5625	1.830825
44	18	11	-6.5	3.375	0.5	0.375	1.279594
46	19	11	-6.25	3.5625	0.25	0.1875	0.953071

Split terbaik Normal: $Age \leq 38$

1.2.4 Kelas Obese (O)

thr	nL	n(O,L)	GL	HL	GR	HR	Gain
10	1	0	0.25	0.1875	-0.25	3.5625	0.033165
12	2	0	0.5	0.375	-0.5	3.375	0.119481
14	3	0	0.75	0.5625	-0.75	3.1875	0.247164
16	4	0	1	0.75	-1	3	0.410714
18	5	0	1.25	0.9375	-1.25	2.8125	0.608144
20	6	0	1.5	1.125	-1.5	2.625	0.841346
22	7	0	1.75	1.3125	-1.75	2.4375	1.119481
24	8	0	2	1.5	-2	2.25	1.452381
26	9	0	2.25	1.6875	-2.25	2.0625	1.853191
28	10	0	2.5	1.875	-2.5	1.875	2.337302
30	11	0	2.75	2.0625	-2.75	1.6875	2.924554
32	12	0	3	2.25	-3	1.5	3.640814
34	13	0	3.25	2.4375	-3.25	1.3125	4.518741
36	14	0	3.5	2.625	-3.5	1.125	5.60084
38	15	0	3.75	2.8125	-3.75	0.9375	5.473295
40	16	1	3	3	-3	0.75	3.696429
42	17	2	2.25	3.1875	-2.25	0.5625	2.233607
44	18	3	1.5	3.375	-1.5	0.375	1.709348
46	19	4	0.75	3.5625	-0.75	0.1875	1.275377

Split terbaik Obese: $Age \leq 38$

8. Substitusi Angka (Gain) untuk Split Terbaik

8.1 VT: split terbaik $Age \leq 12$

Dari tabel kumulatif: thr=12 → $n_L = 2, n_{VT,L} = 2$

Hitung:

$$G_L^{VT} = 0.25(2) - 2 = 0.5 - 2 = -1.5$$

$$H_L = 0.1875(2) = 0.375$$

$$G_T^{VT} = 3.0 \Rightarrow G_R^{VT} = 3.0 - (-1.5) = 4.5$$

$$H_T = 3.75 \Rightarrow H_R = 3.75 - 0.375 = 3.375$$

Gain:

$$Gain = \frac{1}{2}\left(\frac{(-15)^2}{0.375 + 1} + \frac{(4.5)^2}{3.375 + 1} - \frac{(3.0)^2}{3.75 + 1}\right)$$

Komponen:

a. $\frac{2.25}{1.375} = 1.6363636$

b. $\frac{20.25}{4.375} = 4.6285714$

c. $\frac{9}{4.75} = 1.8947368$

$$Gain = \frac{1}{2}(1.6363636 + 4.6285714 - 1.8947368) = 2.1850991$$

8.2 Thin: split terbaik $Age \leq 16$

thr=16 → $n_L = 4,\ n_{Th,L} = 2$

$$G_L^{Th} = 0.25(4) - 2 = 1 - 2 = -1$$

$$H_L = 0.1875(4) = 0.75$$

$$G_T^{Th} = 3 \Rightarrow G_R^{Th} = 3 - (-1) = 4$$

$$H_R = 3.75 - 0.75 = 3$$

$$Gain = \frac{1}{2}\left(\frac{(-1)^2}{0.75+1} + \frac{(4)^2}{3+1} - \frac{(3)^2}{3.75+1}\right)$$

Komponen:

a. $\frac{1}{1.75} = 0.5714286$

b. $\frac{16}{4} = 4$

c. $\frac{9}{4.75} = 1.8947368$

$$Gain = \frac{1}{2}(0.5714286 + 4 - 1.8947368) = 1.3383459$$

8.3 Normal: split terbaik $Age \leq 38$

thr=38 → $n_L = 15,\ n_{N,L} = 11$

$$G_L^N = 0.25(15) - 11 = 3.75 - 11 = -7.25$$

$$H_L = 0.1875(15) = 2.8125$$

$$G_T^N = -6 \Rightarrow G_R^N = -6 - (-7.25) = 1.25$$

$$H_R = 3.75 - 2.8125 = 0.9375$$

$$Gain = \frac{1}{2}\left(\frac{(-0.75)^2}{2.8125+1} + \frac{(1.25)^2}{0.9375+1} - \frac{(-6)^2}{3.75+1}\right)$$

Komponen:

a. $\frac{52.5625}{3.8125} = 13.787705$

b. $\frac{1.5625}{1.9375} = 0.806452$

c. $\frac{36}{4.75} = 7.578947$

$$Gain = \frac{1}{2}(13.787705 + 0.806452 - 7.578947) = 3.5071947$$

8.4 Obese: split terbaik $Age \leq 38$

thr=38 → $n_L = 15, n_{O,L} = 0$

$$G_L^O = 0.25(15) - 0 = 3.75$$

$$H_L = 2.8125$$

$$G_T^O = 0 \Rightarrow G_R^O = 0 - 3.75 = -3.75$$

$$H_R = 0.9375$$

$$Gain = \frac{1}{2}\left(\frac{(3.75)^2}{2.8125 + 1} + \frac{(-3.75)^2}{0.9375 + 1} - \frac{(0)^2}{3.75 + 1}\right)$$

Komponen:

a. $\frac{14.0625}{3.8125} = 3.688525$

b. $\frac{14.0625}{1.9375} = 7.258065$

c. komponen terakhir = 0

$$Gain = \frac{1}{2}(3.688525 + 7.258065) = 5.4732946$$

9.2 Hitung bobot daun per kelas

9.2.1 VT (thr=12)

a. Left: $G_L = -1.5, H_L = 0.375$

$$w_L^{VT} = -\frac{-1.5}{0.375 + 1} = \frac{1.5}{1.375} = 1.090909$$

b. Right: $G_R = 4.5, H_R = 3.375$

$$w_R^{VT} = -\frac{4.5}{3.375 + 1} = -\frac{4.5}{4.375} = -1.028571$$

9.2.2 Thin (thr=16)

a. Left: $G_L = -1, H_L = 0.75$

$$w_L^{Th} = -\frac{-1}{0.75 + 1} = \frac{1}{1.75} = 0.571429$$

b. Right: $G_R = 4, H_R = 3$

$$w_R^{Th} = -\frac{4}{3 + 1} = -1.000000$$

9.2.3 Normal (thr=38)

a. Left: $G_L = -7.25, H_L = 2.8125$

$$w_L^{N} = -\frac{-7.25}{2.8125 + 1} = \frac{7.25}{3.8125} = 1.901639$$

b. Right: $G_R = 1.25, H_R = 0.9375$

$$w_R^{N} = -\frac{1.25}{0.9375 + 1} = -\frac{1.25}{1.9375} = -0.645161$$

9.2.4 Obese (thr=38)

a. Left: $G_L = 3.75,\ H_L = 2.8125$

$$w_L^{O} = -\frac{3.75}{2.8125 + 1} = -\frac{3.75}{3.8125} = -0.983607$$

b. Right: $G_R = -3.75$, $H_R = 0.9375$

$$w_R^O = -\frac{-3.75}{0.9375 + 1} = \frac{3.75}{1.9375} = 1.935484$$

10. Model Hasil Pelatihan

Karena $T = 1$, skor/logit tiap kelas:

$$z_k(x) = f_{1,k}(x)$$

Fungsi stump per kelas:

(1) Very Thin (VT)

$$f_{1,VT}(x) = \begin{cases} 1.090909, & Age \leq 12 \\ -1.028571, & Age > 12 \end{cases}$$

(2) Thin (Th)

$$f_{1,Th}(x) = \begin{cases} 0.571429, & Age \leq 16 \\ -1.000000, & Age > 16 \end{cases}$$

(3) Normal (N)

$$f_{1,N}(x) = \begin{cases} 1.901639, & Age \leq 38 \\ -0.645161, & Age > 38 \end{cases}$$

(4) Obese (O)

$$f_{1,O}(x) = \begin{cases} -0.983607, & Age \leq 38 \\ 1.935484, & Age > 38 \end{cases}$$

Vektor logit:

$$z(x) = [z_{VT}(x), z_{Th}(x), z_N(x), z_O(x)]$$

Probabilitas softmax:

$$p_k(x) = \frac{e^{z_k(x)}}{\sum_{j \in VT,Th,N,O} e^{z_j(x)}}$$

Prediksi:

$$\hat{y} = ar\ g\ ma_k x \quad p_k(x)$$

11. Prediksi Manual (TEST = 7)

11.1 Teknik softmax stabil

Agar stabil, gunakan:

a. $m = ma\,x(z_k)$
b. hitung $e^{z_k - m}$
c. $S = \sum e^{z_k - m}$
d. $p_k = \frac{e^{z_k - m}}{S}$

11.2 prediksi 1 Age=24

Age=24 → cek leaf tiap kelas:

a. VT: $Age > 12 \Rightarrow z_{VT} = -1.028571$

b. Th: $Age > 16 \Rightarrow z_{Th} = -1.000000$

c. N: $Age \leq 38 \Rightarrow z_N = 1.901639$

d. O: $Age \leq 38 \Rightarrow z_O = -0.983607$

$$z = [-1.028571, -1.000000, 1.901639, -0.983607]$$

Ambil $m = 1.901639$. Hitung:

a. $e^{z_{VT}-m} = e^{-2.930210} = 0.053386$

b. $e^{z_{Th}-m} = e^{-2.901639} = 0.054933$

c. $e^{z_N-m} = e^0 = 1$

d. $e^{z_O-m} = e^{-2.885246} = 0.055841$

Jumlah:

$$S = 0.053386 + 0.054933 + 1 + 0.055841 = 1.164160$$

Probabilitas:

a. $p(VT) = 0.053386/1.164160 = 0.045858$

b. $p(Th) = 0.054933/1.164160 = 0.047187$

c. $p(N) = 1/1.164160 = 0.858989$

d. $p(O) = 0.055841/1.164160 = 0.047967$

Prediksi: Normal.

11.3 prediksi 2 Age=48

Age=48 → leaf:

a. VT: $Age > 12 \Rightarrow z_{VT} = -1.028571$

b. Th: $Age > 16 \Rightarrow z_{Th} = -1.000000$

c. N: $Age > 38 \Rightarrow z_N = -0.645161$

d. O: $Age > 38 \Rightarrow z_O = 1.935484$

$$z = [-1.028571, -1.000000, -0.645161, 1.935484]$$

Ambil $m = 1.935484$. Hitung:

a. $e^{z_{VT}-m} = e^{-2.964055} = 0.051609$

b. $e^{z_{Th}-m} = e^{-2.935484} = 0.053105$

c. $e^{z_N-m} = e^{-2.580645} = 0.075725$

d. $e^{z_O-m} = e^0 = 1$

Jumlah:

$$S = 0.051609 + 0.053105 + 0.075725 + 1 = 1.180439$$

Probabilitas:

a. $p(VT) = 0.051609/1.180439 = 0.043720$

b. $p(Th) = 0.053105/1.180439 = 0.044988$

c. $p(N) = 0.075725/1.180439 = 0.064150$

d. $p(O) = 1/1.180439 = 0.847142$

Prediksi: Obese.

11.4 Tabel logit dan probabilitas seluruh TEST (7 data)

No	Age	z(VT)	z(Th)	z(N)	z(O)	p(VT)	p(Th)	p(N)	p(O)	Pred
1	12	1.090909	0.571429	1.901639	-0.98361	0.251889	0.149831	0.566638	0.031642	Normal
2	24	-1.02857	-1	1.901639	-0.98361	0.045858	0.047187	0.858989	0.047967	Normal
3	36	-1.02857	-1	1.901639	-0.98361	0.045858	0.047187	0.858989	0.047967	Normal
4	18	-1.02857	-1	1.901639	-0.98361	0.045858	0.047187	0.858989	0.047967	Normal
5	48	-1.02857	-1	-0.64516	1.935484	0.04372	0.044988	0.06415	0.847142	Obese

6	30	-1.02857	-1	1.901639	-0.98361	0.045858	0.047187	0.858989	0.047967	Normal
7	42	-1.02857	-1	-0.64516	1.935484	0.04372	0.044988	0.06415	0.847142	Obese

Ringkasan prediksi vs label asli:

a. Benar: No 2,3 (Normal), No 5,7 (Obese) → 4 data benar

b. Salah: No 1 (VT→Normal), No 4 (Thin→Normal), No 6 (Thin→Normal)

12. Evaluasi Multiclass

Urutan kelas (untuk confusion matrix):

$$[\mathrm{VT}, \mathrm{Th}, \mathrm{N}, \mathrm{O}]$$

12.1 Confusion Matrix

True \ Pred	VT	Th	N	O
VT	0	0	1	0
Th	0	0	2	0
N	0	0	2	0
O	0	0	0	2

12.2 Accuracy

$$Accuracy = \frac{\text{jumlah diagonal}}{N} = \frac{0+0+2+2}{7} = \frac{4}{7} = 0.5714$$

12.3 Precision, Recall, F1 (One-vs-Rest) per kelas

Definisi untuk kelas k:

a. TP_k= true kelas $k$diprediksi k

b. FP_k= prediksi $k$padahal true bukan k

c. FN_k= true kelas $k$tapi diprediksi bukan k

Rumus:

$$Precision_k = \frac{TP_k}{TP_k + FP_k}, Recall_k = \frac{TP_k}{TP_k + FN_k}, F1_k = \frac{2PR}{P + R}$$

Aturan pembagi nol: jika $TP_k + FP_k = 0$maka $Precision_k = 0$.

(1) VT

Dari confusion matrix:

a. $TP_{VT} = 0$
b. Prediksi VT tidak ada → $FP_{VT} = 0$
c. True VT ada 1 tapi masuk Normal → $FN_{VT} = 1$

$$Precision_{VT} = 0, Recall_{VT} = 0, F1_{VT} = 0$$

(2) Thin

a. $TP_{Th} = 0$
b. Prediksi Thin tidak ada → $FP_{Th} = 0$
c. True Thin = 2 semuanya diprediksi Normal → $FN_{Th} = 2$

$$Precision_{Th} = 0, Recall_{Th} = 0, F1_{Th} = 0$$

(3) Normal

a. $TP_N = 2$(Normal→Normal = 2)
b. Prediksi Normal total = 5 (VT→N 1 + Th→N 2 + N→N 2)

   → $FP_N = 5 - 2 = 3$
c. True Normal = 2 semuanya tepat → $FN_N = 0$

$$Precision_N = \frac{2}{2+3} = \frac{2}{5} = 0.4000$$

$$Recall_N = \frac{2}{2+0} = 1.0000$$

$$F1_N = \frac{2(0.4)(1)}{0.4+1} = 0.5714$$

(4) Obese

a. $TP_O = 2$(O→O = 2)

b. Prediksi Obese total = 2 → $FP_O = 0$

c. True Obese total = 2 → $FN_O = 0$

$$Precision_O = 1, Recall_O = 1, F1_O = 1$$

Ringkasan:

Kelas	TP	FP	FN	Precision	Recall	F1
VT	0	0	1	0	0	0
Th	0	0	2	0	0	0
N	2	3	0	0.4	1	0.5714
O	2	0	0	1	1	1

12.4 Macro Average

$$Precision_{macro} = \frac{0+0+0.4+1}{4} = 0.3500$$

$$Recall_{macro} = \frac{0+0+1+1}{4} = 0.5000$$

$$F1_{macro} = \frac{0+0+0.5714+1}{4} = 0.3929$$

12.5 Weighted Average

Support TEST:

VT=1, Th=2, N=2, O=2, total $N = 7$

$$Precision_{weighted} = \frac{1(0) + 2(0) + 2(0.4) + 2(1)}{7} = \frac{0 + 0 + 0.8 + 2}{7}$$

$$= 0.4000$$

$$Recall_{weighted} = \frac{1(0) + 2(0) + 2(1) + 2(1)}{7} = \frac{4}{7} = 0.5714$$

$$F1_{weighted} = \frac{1(0) + 2(0) + 2(0.5714) + 2(1)}{7} = \frac{0 + 0 + 1.1428 + 2}{7}$$

$$= 0.4490$$

13. Ringkasan Akhir

1. Inisialisasi: $z^{(0)} = 0 \Rightarrow p^{(0)} = 0.25$.
2. Gradient dan Hessian:

$$g_{ik} = 0.25 - 1(y_i = k), h_{ik} = 0.1875$$

3. Total TRAIN: $H_T = 3.75$; $G_T^{VT} = 3$, $G_T^{Th} = 3$, $G_T^N = -6$, $G_T^O = 0$.
4. Uji threshold Age menghasilkan split terbaik:
   a. VT: $Age \leq 12$
   b. Th: $Age \leq 16$
   c. N: $Age \leq 38$
   d. O: $Age \leq 38$
5. Bobot daun dihitung dengan $w = -\frac{G}{H+\lambda}$dan menghasilkan stump final pada Round-1 seperti pada Bagian 10.
6. Prediksi TEST: 5 data diprediksi Normal, 2 data diprediksi Obese.

Data Latih Height for age

a. Data latih (20 data)

1. Not Stunted → $y = 0$

2. Stunted → $y = 1$

No	Age	Weight	Height	HFA_label	y
1	12	8	72	Stunted	1
2	18	9.2	78	Not Stunted	0
3	24	10.5	85	Not Stunted	0
4	30	11	88	Not Stunted	0
5	36	12.3	95	Not Stunted	0
6	14	8.6	74	Stunted	1
7	20	9.8	80	Not Stunted	0
8	26	10.7	86	Not Stunted	0
9	32	11.8	90	Not Stunted	0
10	40	13.8	98	Not Stunted	0
11	10	7.6	70	Stunted	1
12	22	10.2	83	Not Stunted	0
13	28	10.9	87	Not Stunted	0
14	34	12	91	Not Stunted	0
15	42	14.2	100	Not Stunted	0
16	16	8.9	76	Stunted	1
17	21	9.5	79	Not Stunted	0
18	27	10.8	86	Not Stunted	0
19	33	11.6	89	Not Stunted	0
20	45	14.8	102	Not Stunted	0

Distribusi kelas train:

$\sum y = 4$(Stunted)

$n - \sum y = 16$(Not Stunted)

Data Uji (7 Data)

No	Age	Weight	Height	HFA_label	y
1	12	8.5	75	Not Stunted	0
2	24	10.2	85	Stunted	1

3	36	13.5	95	Not Stunted	0
4	18	7.8	80	Stunted	1
5	48	16	100	Not Stunted	0
6	30	11	90	Stunted	1
7	60	20	110	Not Stunted	0

Parameter yang dipakai

1. Objective: binary:logistic
2. Jumlah tree (boosting round): 1 tree (tree-1)
3. max_depth = 1 (stump: 1 split → 2 leaf)
4. learning_rate $\eta = 1$(biar tidak ada shrink tambahan)
5. Regularisasi: $\lambda = 1, \gamma = 0$

Rumus awal xgboost:

Model aditif

Prediksi (margin) data ke-i pada iterasi t:

$$\hat{y}_i^{(t)} = \sum_{k=1}^{t} f_k\,(x_i)$$

Keterangan:

a. x_i: vektor fitur (Age, Weight, Height)

b. f_k: fungsi pohon keputusan ke-k

c. $\hat{y}$: skor mentah (margin), bukan probabilitas

Fungsi objektif

XGBoost meminimalkan:

$$Obj^{(t)} = \sum_{i=1}^{n} l\left(y_i, \hat{y}_i^{(t)}\right) + \sum_{k=1}^{t} \Omega(f_k)$$

Keterangan:

a. $l(\cdot)$: loss (untuk biner: logistic loss)

b. $\Omega(\cdot)$: regularisasi kompleksitas pohon

Regularisasi pohon

$$\Omega(f) = \gamma T + \frac{1}{2}\lambda \sum_{j=1}^{T} w_j^2$$

Keterangan:

a. T: jumlah leaf pada tree

b. w_j: bobot leaf ke-j

c. γ: penalti jumlah leaf

d. λ: penalti L2 bobot leaf

Penurunan bentuk optimasi (Taylor orde-2)

Pada iterasi t, model menambah tree baru f_t:

$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + f_t(x_i)$$

Loss diaproksimasi dengan Taylor orde-2:

$$l\left(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)\right) \approx l\left(y_i, \hat{y}_i^{(t-1)}\right) + g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i)$$

dengan:

$$g_i = \frac{\partial l(y_i, \hat{y}_i)}{\partial \hat{y}_i}, h_i = \frac{\partial^2 l(y_i, \hat{y}_i)}{\partial \hat{y}_i^2}$$

Sehingga objective aproksimasi untuk mencari tree ke-t:

$$\widetilde{Obj}^{(t)} = \sum_{i=1}^{n} \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right] + \Omega(f_t)$$

Rumus khusus untuk binary logistic

Probabilitas dari margin:

$$p_i = \sigma(\hat{y}_i) = \frac{1}{1 + e^{-\hat{y}_i}}$$

Untuk logistic loss (biner), gradien dan hessian:

$$g_i = p_i - y_i$$

$$h_i = p_i(1 - p_i)$$

Rumus leaf weight optimal dan gain split

Definisi Gdan Hpada leaf

Jika leaf $j$memuat himpunan data I_j:

$$G_j = \sum_{i \in I_j} g_i \, , H_j = \sum_{i \in I_j} h_i$$

Bobot leaf optimal

$$w_j^* = -\frac{G_j}{H_j + \lambda}$$

Gain split

Untuk split node menjadi kiri (L) dan kanan (R):

$$Gain = \frac{1}{2}\left(\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{G^2}{H + \lambda}\right) - \gamma$$

Langkah perhitungan manual

Base score (probabilitas awal) dan margin awal

Proporsi positif pada data latih:

$$p_0 = \frac{4}{20} = 0.2$$

Margin awal (logit):

$$m_0 = l\,n\left(\frac{p_0}{1 - p_0}\right) = l\,n\left(\frac{0.2}{0.8}\right) = l\,n(0.25) = -1.386294$$

Artinya, sebelum tree dibentuk:

a. semua data punya margin awal m_0

b. semua data punya probabilitas awal $p_0 = 0.2$

Hitung gradien (g) dan hessian (h) untuk 20 data latih

Karena $p_0 = 0.2$, maka:

a. Jika $y = 1$: $g = 0.2 - 1 = -0.8$

b. Jika $y = 0$: $g = 0.2 - 0 = 0.2$

c. Hessian sama untuk semua: $h = 0.2(0.8) = 0.16$

Tabel per baris (train) — g dan h+ node assignment + output model (lengkap)

Split terbaik (hasil langkah 5.3) adalah Age < 17.

Age	Weight	Height	y	p0	g	h	Node	margin_after_tree1	p_after_tree1	y_pred
12	8	72	1	0.2	-0.8	0.16	Left (Age<17)	0.564925	0.637591	1
18	9.2	78	0	0.2	0.2	0.16	Right (Age≥17)	-2.285171	0.092359	0
24	10.5	85	0	0.2	0.2	0.16	Right (Age≥17)	-2.285171	0.092359	0
30	11	88	0	0.2	0.2	0.16	Right (Age≥17)	-2.285171	0.092359	0
36	12.3	95	0	0.2	0.2	0.16	Right (Age≥17)	-2.285171	0.092359	0
14	8.6	74	1	0.2	-0.8	0.16	Left (Age<17)	0.564925	0.637591	1
20	9.8	80	0	0.2	0.2	0.16	Right (Age≥17)	-2.285171	0.092359	0
26	10.7	86	0	0.2	0.2	0.16	Right (Age≥17)	-2.285171	0.092359	0
32	11.8	90	0	0.2	0.2	0.16	Right (Age≥17)	-2.285171	0.092359	0
40	13.8	98	0	0.2	0.2	0.16	Right (Age≥17)	-2.285171	0.092359	0
10	7.6	70	1	0.2	-0.8	0.16	Left (Age<17)	0.564925	0.637591	1
22	10.2	83	0	0.2	0.2	0.16	Right (Age≥17)	-2.285171	0.092359	0
28	10.9	87	0	0.2	0.2	0.16	Right (Age≥17)	-2.285171	0.092359	0
34	12	91	0	0.2	0.2	0.16	Right (Age≥17)	-2.285171	0.092359	0
42	14.2	100	0	0.2	0.2	0.16	Right (Age≥17)	-2.285171	0.092359	0
16	8.9	76	1	0.2	-0.8	0.16	Left (Age<17)	0.564925	0.637591	1
21	9.5	79	0	0.2	0.2	0.16	Right (Age≥17)	-2.285171	0.092359	0
27	10.8	86	0	0.2	0.2	0.16	Right (Age≥17)	-2.285171	0.092359	0
33	11.6	89	0	0.2	0.2	0.16	Right (Age≥17)	-2.285171	0.092359	0

45	14.8	102	0	0.2	0.2	0.16	Right (Age≥17)	-2.285171	0.092359	0

Cari split terbaik (greedy) dari fitur Age, Weight, Height

Kandidat threshold dibuat dari titik tengah nilai berurutan:

$$thr_k = \frac{v_k + v_{k+1}}{2}$$

Untuk setiap threshold dihitung:

a. G_L, H_L dari baris yang masuk kiri (x < thr)

b. G_R, H_R dari baris yang masuk kanan (x ≥ thr)

c. Gain dihitung dengan rumus XGBoost

Tabel split untuk Age

threshold	n_left	n_right	G_left	H_left	G_right	H_right	gain
11	1	19	-0.8	0.16	0.8	3.04	0.35507
13	2	18	-1.6	0.32	1.6	2.88	1.299594
15	3	17	-2.4	0.48	2.4	2.72	2.720139
17	4	16	-3.2	0.64	3.2	2.56	4.560153
19	5	15	-3	0.8	3	2.4	3.823529
20.5	6	14	-2.8	0.96	2.8	2.24	3.209877
21.5	7	13	-2.6	1.12	2.6	2.08	2.691742
23	8	12	-2.4	1.28	2.4	1.92	2.249459
25	9	11	-2.2	1.44	2.2	1.76	1.868615

26.5	10	10	-2	1.6	2	1.6	1.538462
27.5	11	9	-1.8	1.76	1.8	1.44	1.250891
29	12	8	-1.6	1.92	1.6	1.28	0.99976
31	13	7	-1.4	2.08	1.4	1.12	0.780446
32.5	14	6	-1.2	2.24	1.2	0.96	0.589569
33.5	15	5	-1	2.4	1	0.8	0.424837
35	16	4	-0.8	2.56	0.8	0.64	0.28501
38	17	3	-0.6	2.72	0.6	0.48	0.170009
41	18	2	-0.4	2.88	0.4	0.32	0.081225
43.5	19	1	-0.2	3.04	0.2	0.16	0.022192

Gain terbesar untuk Age adalah pada threshold = 17.0 dengan Gain = 4.560153.

Tabel split untuk Weight

threshold	n_left	n_right	G_left	H_left	G_right	H_right	gain
7.8	1	19	-0.8	0.16	0.8	3.04	0.35507
8.3	2	18	-1.6	0.32	1.6	2.88	1.299594
8.75	3	17	-2.4	0.48	2.4	2.72	2.720139
9.05	4	16	-3.2	0.64	3.2	2.56	4.560153
9.35	5	15	-3	0.8	3	2.4	3.823529

Tabel split untuk Height

threshold	n_left	n_right	G_left	H_left	G_right	H_right	gain
71	1	19	-0.8	0.16	0.8	3.04	0.35507
73	2	18	-1.6	0.32	1.6	2.88	1.299594
75	3	17	-2.4	0.48	2.4	2.72	2.720139
77	4	16	-3.2	0.64	3.2	2.56	4.560153
78.5	5	15	-3	0.8	3	2.4	3.823529

Statistik node untuk split terpilih (Age < 17)

Karena split terbaik adalah Age < 17, maka:

a. Node kiri (L): baris dengan Age < 17 (jumlah 4)

b. Node kanan (R): baris dengan Age ≥ 17 (jumlah 16)

Hitung Gdan H:

a. Setiap baris: $h = 0.16$

b. Node kiri berisi 4 baris (semuanya y=1), jadi:

1. $G_L = 4 \times (-0.8) = -3.2$
2. $H_L = 4 \times 0.16 = 0.64$

Node kanan berisi 16 baris (semuanya y=0), jadi:

1. $G_R = 16 \times (0.2) = 3.2$
2. $H_R = 16 \times 0.16 = 2.56$

Node	Kondisi	n	(G)	(H)
Left	Age < 17	4	-3.2	0.64

Right	Age ≥ 17	16	3.2	2.56

Hitung leaf weight (bobot leaf)

Dengan $\lambda = 1$:

$$w_L = -\frac{G_L}{H_L + \lambda} = -\frac{-3.2}{0.64 + 1} = \frac{3.2}{1.64} = 1.9512195$$

$$w_R = -\frac{G_R}{H_R + \lambda} = -\frac{3.2}{2.56 + 1} = -\frac{3.2}{3.56} = -0.8988764$$

Model hasil pelatihan

Struktur model (Tree-1)

Model akhir setelah pelatihan 1 tree (stump):

a. IF Age < 17 → leaf kiri dengan bobot $w_L = +1.9512195$

b. ELSE Age ≥ 17 → leaf kanan dengan bobot $w_R = -0.8988764$

Ditulis ringkas:

$$f_1(x) = \begin{cases} 1.9512195, & \text{jika Age} < 17 \\ -0.8988764, & \text{jika Age} \geq 17 \end{cases}$$

6.2 Update margin dan probabilitas

Margin awal: $m_0 = -1.386294$

Margin setelah tree:

a. Jika masuk kiri:

$$m_L = m_0 + w_L = -1.386294 + 1.9512195 = 0.5649255$$

$$p_L = \sigma(m_L) = 0.637591$$

b. Jika masuk kanan:

$$m_R = m_0 + w_R = -1.386294 - 0.8988764 = -2.2851704$$

$$p_R = \sigma(m_R) = 0.092359$$

6.3 Aturan klasifikasi (threshold 0.5)

$$\hat{y} = \begin{cases} 1, & \text{jika } p \geq 0.5 \\ 0, & \text{jika } p < 0.5 \end{cases}$$

Karena:

a. $p_L = 0.637591 \geq 0.5 \rightarrow$ leaf kiri selalu prediksi 1

b. $p_R = 0.092359 < 0.5 \rightarrow$ leaf kanan selalu prediksi 0

Evaluasi pada data latih

Confusion matrix

	Pred 0	Pred 1
Actual 0	16	0
Actual 1	0	4

Metrik (train)

1. Accuracy $= \frac{TP+TN}{N} = \frac{4+16}{20} = 1.00(100\%)$
2. Precision (kelas 1) $= \frac{TP}{TP+FP} = \frac{4}{4+0} = 1.00$
3. Recall (kelas 1) $= \frac{TP}{TP+FN} = \frac{4}{4+0} = 1.00$
4. F1 $= \frac{2PR}{P+R} = 1.00$

Perubahan loss (train)

Log-loss per sampel:

a. $\ell(y,p) = -(yl\,n\,p + (1-y)l\,n(1-p))$

b. Total loss awal (pakai $p_0 = 0.2$): 10.008048

c. Total loss setelah tree-1: 3.350725

d. Rata-rata loss:

   1. awal: 0.500402

   2. setelah tree: 0.167536

Ini menunjukkan tree-1 menurunkan loss cukup besar di data latih.

Prediksi data uji (7 data)

Karena threshold split sama (Age<17), maka:

a. jika Age<17 → margin m_L, prob p_L, pred=1

b. jika Age≥17 → margin m_R, prob p_R, pred=0

No	Age	Weight	Height	y (aktual)	Node	margin	prob	Y pred
1	12	8.5	75	0	Left (Age<17)	0.5649255	0.637591	1
2	24	10.2	85	1	Right (Age≥17)	-2.2851704	0.092359	0
3	36	13.5	95	0	Right (Age≥17)	-2.2851704	0.092359	0
4	18	7.8	80	1	Right (Age≥17)	-2.2851704	0.092359	0
5	48	16.0	100	0	Right (Age≥17)	-2.2851704	0.092359	0
6	30	11.0	90	1	Right (Age≥17)	-2.2851704	0.092359	0

7	60	20.0	110	0	Right (Age≥17)	-2.2851704	0.092359	0

Evaluasi pada data uji

Confusion matrix

	Pred 0	Pred 1
Actual 0	3	1
Actual 1	3	0

Metrik

a. Accuracy $= \frac{TP+TN}{N} = \frac{0+3}{7} = 0.428571 \rightarrow$ 42.86%

b. Precision (kelas 1) $= \frac{TP}{TP+FP} = \frac{0}{0+1} = 0$

c. Recall (kelas 1) $= \frac{TP}{TP+FN} = \frac{0}{0+3} = 0$

d. F1 $= 0$

Model sangat baik pada data latih karena seluruh data Stunted di train kebetulan berada pada rentang Age < 17. Namun pada data uji terdapat kasus Stunted pada umur ≥ 17 bulan.

Data Latih Weight For Age

Age_month	Weight_kg	Height_cm	Weight for Age
12	8	72	Underfed
18	9.2	78	Normal
24	10.5	85	Normal
30	11	88	Normal
36	12.3	95	Normal
14	8.6	74	Underfed

20	9.8	80	Normal
26	10.7	86	Normal
32	11.8	90	Normal
40	13.8	98	Normal
10	7.6	70	Malnutrition
22	10.2	83	Normal
28	10.9	87	Normal
34	12	91	Normal
42	14.2	100	Normal
16	8.9	76	Underfed
21	9.5	79	Normal
27	10.8	86	Normal
33	11.6	89	Normal
45	14.8	102	Overnutrition

Data Latih (n=20)

Fitur

X = (age, weight, height)

Target (multiclass, 4 kelas):

1. Malnutrition
2. Normal
3. Overnutrition
4. Underfed

Distribusi label train

1. Normal = 15
2. Underfed = 3
3. Malnutrition = 1
4. Overnutrition = 1

Data uji

Label aktual:

Normal=3, Underfed=2, Malnutrition=1, Overnutrition=1

age	height	weight	Weight for Age
12	75	8.5	Underfed

24	85	10.2	Normal
36	95	13.5	Normal
18	80	7.8	Malnutrition
48	100	16	Normal
30	90	11	Underfed
60	110	20	Overnutrition

input (fitur):

$$x = (age, weight, height)$$

Output (kelas):

$y \in$ Malnutrition, Normal, Overnutrition, Underfed

Jumlah kelas: $K = 4$

Jumlah data: data latih $n = 20$, data uji $m = 7$

Rumus dan Notasi (XGBoost Multiclass)

Skor kelas kepada iterasi t:

$$s_{i,k}^{(t)} = s_{i,k}^{(t-1)} + \eta f_{t,k}(x_i)$$

a. η: learning rate

b. $f_{t,k}(x)$: pohon keputusan (stump) untuk kelas $k$pada iterasi t

Softmax multiclass

$$p_{i,k} = \frac{e^{s_{i,k}}}{\sum_{c=1}^{K} e^{s_{i,c}}}$$

Gradien dan hessian (turunan loss multiclass)

Dengan $y_{i,k}$one-hot:

$$g_{i,k} = p_{i,k} - y_{i,k}$$

$$h_{i,k} = p_{i,k}(1 - p_{i,k})$$

Gain untuk memilih split terbaik

Pada sebuah node, definisikan:

$$G = \sum g_i, H = \sum h_i$$

Jika node dibagi menjadi kiri (L) dan kanan (R):

$$Gain = \frac{1}{2}\left(\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{G^2}{H + \lambda}\right) - \gamma$$

Bobot leaf optimal

$$w^* = -\frac{G}{H + \lambda}$$

Skor yang ditambahkan:

$$\Delta s = \eta w$$

5. Proses Pelatihan (Training)

Inisialisasi skor dan probabilitas

Karena awal model:

$$s_{i,k}^{(0)} = 0$$

Maka softmax awal uniform:

$$p_{i,k}^{(0)} = \frac{1}{4} = 0.25$$

Hessian awal (konstan):

$$h_{i,k}^{(0)} = 0.25(1 - 0.25) = 0.1875$$

Nilai gradien awal per kelas

Karena $g = p - y$dan $p = 0.25$:

a. Jika data memang kelas k: $g = 0.25 - 1 = -0.75$
b. Jika bukan kelas k: $g = 0.25 - 0 = +0.25$

Total Hdi root (untuk setiap kelas)

Jumlah data latih $n = 20$, sehingga:

$$H_{root} = 20 \times 0.1875 = 3.75$$

Total Gdi root (untuk setiap kelas)

Berdasarkan distribusi kelas latih:

Kelas Malnutrition (count=1)

$$G_M = 1(-0.75) + 19(0.25) = -0.75 + 4.75 = 4.0$$

Kelas Normal (count=15)

$$G_N = 15(-0.75) + 5(0.25) = -11.25 + 1.25 = -10.0$$

Kelas Overnutrition (count=1)

$$G_O = 1(-0.75) + 19(0.25) = 4.0$$

Kelas Underfed (count=3)

$$G_U = 3(-0.75) + 17(0.25) = -2.25 + 4.25 = 2.0$$

Tabel ringkas root:

Kelas	(G_{root})	(H_{root})
M	4.0	3.75
N	-10.0	3.75
O	4.0	3.75
U	2.0	3.75

Kandidat threshold untuk fitur age

Jika nilai age unik pada data latih adalah $v_1 < v_2 < \cdots < v_{20}$, maka kandidat threshold adalah:

$$\theta_j = \frac{v_j + v_{j+1}}{2}, j = 1..19$$

Kandidat threshold age pada data latih:

11, 13, 15, 17, 19, 20.5, 21.5, 23, 25, 26.5, 27,5, 29, 31, 32.5, 33.5, 35, 38, 41, 43

Pemilihan Split Terbaik dan Perhitungan Gain + Leaf Weight (Round-1)

masing-masing kelas menghasilkan stump terbaik berikut:

a. M: $age \leq 11$
b. N: $age \leq 17$
c. O: $age \leq 43.5$

d. U: $age \leq 17$

perhitungan setiap kelas.

Kelas Malnutrition (M) — Split $age \leq 11$

Node kiri dan kanan

a. Node kiri (L): 1 data (age=10, label Malnutrition)
b. Node kanan (R): 19 data lainnya

Hitung G_L, H_L

Karena data kiri adalah Malnutrition → $g_M = -0.75$:

$$G_{L,M} = -0.75$$
$$H_{L,M} = 1(0.1875) = 0.1875$$

Hitung G_R, H_R

$$G_{R,M} = G_M - G_{L,M} = 4.0 - (-0.75) = 4.75$$
$$H_{R,M} = H_{root} - H_{L,M} = 3.75 - 0.1875 = 3.5625$$

Hitung Gain

$$Gain_M = \frac{1}{2}\left(\frac{(-0.75)^2}{0.1875+1} + \frac{(4.75)^2}{3.5625+1} - \frac{(4.0)^2}{3.75+1}\right)$$

Komponen:

1. $(-0.75)^2 = 0.5625, \frac{05625}{1.1875} = 0.473684$
2. $(4.75)^2 = 22.5625, \frac{22.5625}{4.5625} = 4.945205$
3. $(4.0)^2 = 16, \frac{16}{4.75} = 3.368421$

$$Gain_M = \frac{1}{2}(0.473684 + 4.945205 - 3.368421) = 1.025234$$

Leaf weight dan skor ($\eta = 0.5$)

$$w_{L,M} = -\frac{G_{L,M}}{H_{L,M}+1} = -\frac{-0.75}{1.1875} = 0.631579$$

$$w_{R,M} = -\frac{G_{R,M}}{H_{R,M}+1} = -\frac{4.75}{4.5625} = -1.041096$$

Skor yang ditambahkan:

$$\Delta s_{L,M} = 0.5(0.631579) = 0.315789$$

$$\Delta s_{R,M} = 0.5(-1.041096) = -0.520548$$

Kelas Normal (N) — Split $age \leq 17$

Node kiri dan kanan

a. Node kiri (L): 4 data (age=10,12,14,16) bukan Normal

b. Node kanan (R): 16 data lainnya

Hitung G_L, H_L

Karena ke-4 data kiri bukan Normal → $g_N = 0.25$:

$$G_{L,N} = 4(0.25) = 1.0$$

$$H_{L,N} = 4(0.1875) = 0.75$$

Hitung G_R, H_R

$$G_{R,N} = -10.0 - 1.0 = -11.0$$

$$H_{R,N} = 3.75 - 0.75 = 3.0$$

Hitung Gain

$$Gain_N = \frac{1}{2}\left(\frac{1^2}{0.75+1} + \frac{(-11)^2}{3+1} - \frac{(-10)^2}{3.75+1}\right)$$

Komponen:

a. $1/1.75 = 0.5714286$

b. $121/4 = 30.25$

c. $100/4.75 = 21.0526316$

$$Gain_N = \frac{1}{2}(0.5714286 + 30.25 - 21.0526316) = 4.884398$$

Leaf weight dan skor

$$w_{L,N} = -\frac{1.0}{0.75 + 1} = -0.571429$$

$$w_{R,N} = -\frac{-11.0}{3 + 1} = 2.75$$

Skor:

$$\Delta s_{L,N} = 0.5(-0.571429) = -0.285714$$

$$\Delta s_{R,N} = 0.5(2.75) = 1.375$$

Kelas Overnutrition (O) — Split $age \leq 43.5$

Node kiri dan kanan

a. Node kiri (L): 19 data bukan Overnutrition

b. Node kanan (R): 1 data Overnutrition (age=45)

Hitung G_L, H_L

Karena 19 data kiri bukan Overnutrition → $g_O = 0.25$:

$$G_{L,O} = 19(0.25) = 4.75$$

$$H_{L,O} = 19(0.1875) = 3.5625$$

Hitung G_R, H_R

$$G_{R,O} = 4.0 - 4.75 = -0.75$$

$$H_{R,O} = 3.75 - 3.5625 = 0.1875$$

Hitung Gain

$$Gain_O = \frac{1}{2}\left(\frac{(4.75)^2}{3.5625+1} + \frac{(-0.75)^2}{0.1875+1} - \frac{(4.0)^2}{3.75+1}\right) = 1.025234$$

6.3.5 Leaf weight dan skor

$$w_{L,O} = -\frac{4.75}{3.5625+1} = -1.041096$$

$$w_{R,O} = -\frac{-0.75}{0.1875+1} = 0.631579$$

Skor:

$$\Delta s_{L,O} = 0.5(-1.041096) = -0.520548$$

$$\Delta s_{R,O} = 0.5(0.631579) = 0.315789$$

Kelas Underfed (U) — Split $age \leq 17$

Node kiri dan kanan

Node kiri (L) berisi 4 data (age=10,12,14,16):

a. Underfed = 3 data → $g_U = -0.75$
b. Malnutrition = 1 data → $g_U = 0.25$

Hitung G_L, H_L

$$G_{L,U} = 3(-0.75) + 1(0.25) = -2.25 + 0.25 = -2.0$$

$$H_{L,U} = 4(0.1875) = 0.75$$

Hitung G_R, H_R

$$G_{R,U} = 2.0 - (-2.0) = 4.0$$

$$H_{R,U} = 3.75 - 0.75 = 3.0$$

Hitung Gain

$$Gain_U = \frac{1}{2}\left(\frac{(-2)^2}{0.75+1} + \frac{(4)^2}{3+1} - \frac{(2)^2}{3.75+1}\right)$$

Komponen:

a. $4/1.75 = 2.285714$
b. $16/4 = 4.0$
c. $4/4.75 = 0.842105$

$$Gain_U = \frac{1}{2}(2.285714 + 4.0 - 0.842105) = 2.721805$$

Leaf weight dan skor

$$w_{L,U} = -\frac{-2.0}{0.75+1} = 1.142857$$

$$w_{R,U} = -\frac{4.0}{3+1} = -1.0$$

Skor:

$$\Delta s_{L,U} = 0.5(1.142857) = 0.571429$$

$$\Delta s_{R,U} = 0.5(-1.0) = -0.5$$

Model Hasil Pelatihan

Skor round-1 untuk tiap kelas (berdasarkan age):

$$s_M(x) = \begin{cases} 0.315789, & age \leq 11 \\ -0.520548, & age > 11 \end{cases}$$

$$s_N(x) = \begin{cases} -0.285714, & age \leq 17 \\ 1.375, & age > 17 \end{cases}$$

$$s_O(x) = \begin{cases} -0.520548, & age \leq 43.5 \\ 0.315789, & age > 43.5 \end{cases}$$

$$s_U(x) = \begin{cases} 0.571429, & age \leq 17 \\ -0.5, & age > 17 \end{cases}$$

Probabilitas prediksi:

$$p_k(x) = \frac{e^{s_k(x)}}{e^{s_M(x)} + e^{s_N(x)} + e^{s_O(x)} + e^{s_U(x)}}$$

Prediksi:

$$\hat{y} = arg\,max_k \quad p_k(x)$$

Proses Prediksi Data Uji (m=7)

Tabel skor untuk 7 data uji

Urutan skor: $[s_M, s_N, s_O, s_U]$

No	age	Aktual	(s_M)	(s_N)	(s_O)	(s_U)
1	12	Underfed	-0.52055	-0.28571	-0.52055	0.571429
2	24	Normal	-0.52055	1.375	-0.52055	-0.5
3	36	Normal	-0.52055	1.375	-0.52055	-0.5

4	18	Malnutrition	-0.52055	1.375	-0.52055	-0.5
5	48	Normal	-0.52055	1.375	0.315789	-0.5
6	30	Underfed	-0.52055	1.375	-0.52055	-0.5
7	60	Overnutrition	-0.52055	1.375	0.315789	-0.5

perhitungan softmax

Skor:

$$s = [-0.520548,\ -0.285714,\ -0.520548, 0.571429]$$

Eksponensial

a. $e^{-0.520548} \approx 0.594$
b. $e^{-0.285714} \approx 0.751$
c. $e^{-0.520548} \approx 0.594$
d. $e^{0.571429} \approx 1.771$

$$Z = 0.594 + 0.751 + 0.594 + 1.771 = 3.710$$

$$P(M) = 0.594/3.710 = 0.1601$$

$$P(N) = 0.751/3.710 = 0.2025$$

$$P(O) = 0.594/3.710 = 0.1601$$

$$P(U) = 1.771/3.710 = 0.4772$$

Prediksi: Underfed (probabilitas terbesar).

Hasil probabilitas dan prediksi seluruh data uji

No	Aktual	Prediksi	P(M)	P(N)	P(O)	P(U)
1	Underfed	Underfed	0.1601	0.2025	0.1601	0.4772
2	Normal	Normal	0.1033	0.6878	0.1033	0.1055
3	Normal	Normal	0.1033	0.6878	0.1033	0.1055
4	Malnutrition	Normal	0.1033	0.6878	0.1033	0.1055
5	Normal	Normal	0.0910	0.6059	0.2101	0.0929
6	Underfed	Normal	0.1033	0.6878	0.1033	0.1055
7	Overnutrition	Normal	0.0910	0.6059	0.2101	0.0929

Evaluasi Model (Multiclass)

Confusion Matrix (Multiclass)

Urutan kelas: $[M, N, O, U]$

Baris = aktual, kolom = prediksi:

$$CM = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 3 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 1 \end{bmatrix}$$

Aktual \ Prediksi	M	N	O	U	Total Aktual
M	0	1	0	0	1
N	0	3	0	0	3
O	0	1	0	0	1
U	0	1	0	1	2

Akurasi

Jumlah benar (diagonal):

$$0 + 3 + 0 + 1 = 4$$

$Accuracy = \frac{4}{7} = 0.5714$ (57.14Precision, Recall, F1-Score per kelas

$$F1_k = \frac{2 \cdot Precision_k \cdot Recall_k}{Precision_k + Recall_k}$$

Per kelas (dari confusion matrix):

Malnutrition (M)

a. $TP = 0$
b. $FP = 0$
c. $FN = 1$

$$Precision_M = 0, Recall_M = 0, F1_M = 0$$

Normal (N)

1. $TP = 3$
2. Kolom N total = 6 → $FP = 6 - 3 = 3$
3. Baris N total = 3 → $FN = 3 - 3 = 0$

$$Precision_N = \frac{3}{6} = 0.50$$

$$Recall_N = \frac{3}{3} = 1.00$$

$$F1_N = \frac{2(0.50)(1.00)}{0.50 + 1.00} = 0.6667$$

Overnutrition (O)

a. $TP = 0$
b. $FP = 0$
c. $FN = 1$

$$Precision_O = 0, Recall_O = 0, F1_O = 0$$

Underfed (U)

1. $TP = 1$
2. Kolom U total = 1 → $FP = 0$
3. Baris U total = 2 → $FN = 1$

$$Precision\ _U = \frac{1}{1} = 1.00$$

$$Recall_U = \frac{1}{2} = 0.50$$

$$F1_U = \frac{2(1.00)(0.50)}{1.00 + 0.50} = 0.6667$$

Kelas	Precision	Recall	F1
M	0.0000	0.0000	0.0000
N	0.5000	1.0000	0.6667
O	0.0000	0.0000	0.0000
U	1.0000	0.5000	0.6667

Macro-F1 dan Weighted-F1

Macro-F1:

$$MacroF1 = \frac{F1_M + F1_N + F1_O + F1_U}{4} = \frac{0 + 0.6667 + 0 + 0.6667}{4} = 0.3333$$

Weighted-F1 (berdasarkan support kelas uji: M=1, N=3, O=1, U=2):

$$Weighted\ F1 = \frac{1(0) + 3(0.6667) + 1(0) + 2(0.6667)}{7} = \frac{3.3335}{7} \approx 0.4762$$

Ringkasan keluaran prediksi

a. Prediksi benar: 4 dari 7 data uji

b. Model cenderung memprediksi Normal pada sebagian besar data uji

Metrik	Nilai
Accuracy	0.5714 (57.14%)
Macro-F1	0.3333
Weighted-F1	0.4762

Model berhasil mengenali kelas Normal dengan recall tinggi, namun performa untuk kelas Malnutrition dan Overnutrition rendah karena jumlah data latih untuk kedua kelas tersebut sangat sedikit (masing-masing 1 data), sehingga pola pembelajaran untuk kelas minor menjadi terbatas.

Lampiran 3

Bukti konsultasi ahli bersama Bidan



Gambar L3. 1 Bukti konsultasi bersama Bidan Mercu Tiana, Am. Keb

Lampiran 4

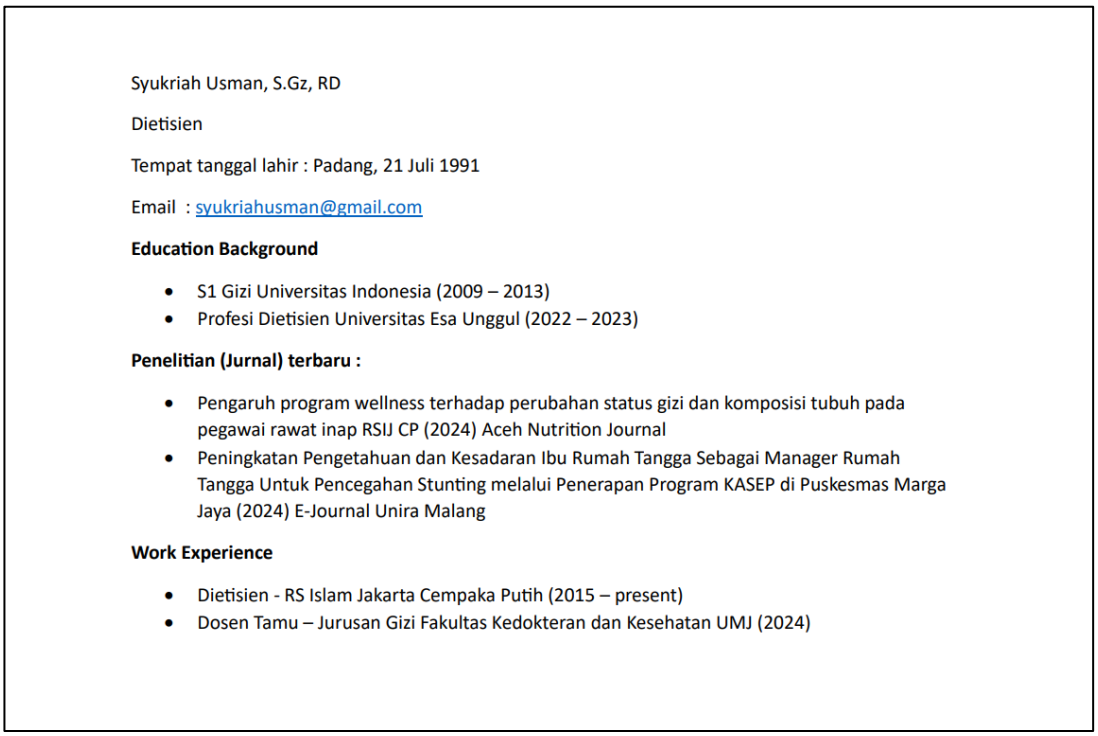
Dokumentasi Bersama Ketua Ahli Gizi



Gambar L4 1 Dokumentasi bersama Ibu Syukriah Usman, S.Gz, RD

Lampiran 5

Curriculum Vitae Ahli Gizi



Syukriah Usman, S.Gz, RD

Dietisien

Tempat tanggal lahir : Padang, 21 Juli 1991

Email : syukriahusman@gmail.com

Education Background

- S1 Gizi Universitas Indonesia (2009 – 2013)
- Profesi Dietisien Universitas Esa Unggul (2022 – 2023)

Penelitian (Jurnal) terbaru :

- Pengaruh program wellness terhadap perubahan status gizi dan komposisi tubuh pada pegawai rawat inap RSIJ CP (2024) Aceh Nutrition Journal
- Peningkatan Pengetahuan dan Kesadaran Ibu Rumah Tangga Sebagai Manager Rumah Tangga Untuk Pencegahan Stunting melalui Penerapan Program KASEP di Puskesmas Marga Jaya (2024) E-Journal Unira Malang

Work Experience

- Dietisien - RS Islam Jakarta Cempaka Putih (2015 – present)
- Dosen Tamu – Jurusan Gizi Fakultas Kedokteran dan Kesehatan UMJ (2024)

Gambar L5 1 Curriculum Vitae (CV) Ibu Syukriah Usman, S.Gz, RD

Lampiran 6

Dokumentasi Bersama Dokter Spesialis Anak



Gambar L6 1 Dokumentasi bersama Dr. dr. Wiyarni Pambudi, Sp.A, IBCLC

Lampiran 7

Curiculum Vitae Dokter Spesialis Anak

RIWAYAT HIDUP



Dr. dr. Wiyarni Pambudi, Sp.A, IBCLC

DATA DOSEN:

Alamat surel	: wiyarni@fk.untar.ac.id
NUPTK	: 2848751652230102
NIK / NIDN	: 10408005 / 0316057304
Fakultas/Prodi/Bagian	: Kedokteran / Profesi Dokter/Ilmu Kesehatan Anak
Jabatan	: Ketua Unit Penelitian dan Pengabdian kepada Masyarakat (UPPM)
SINTA ID	: 5996279
Garuda ID	: 698060
Google Scholar ID	: swSTO2kAAAAJ
ORCID ID	: 0009-0000-6991-7667
Scopus ID	: 59072881000
Web of Science ResID	: GOP-2980-2022

RIWAYAT PENDIDIKAN:

1991–1997: Dokter, Fakultas Kedokteran Universitas Airlangga
2003–2007: Spesialis Anak, Fakultas Kedokteran Universitas Airlangga
2018–2023: Doktor, Fakultas Kedokteran Universitas Indonesia
2011 : International Board-Certified Lactation Consultant (recertified 2016, 2021, 2026)
2011 : Course Director & Facilitator of WHO-UNICEF Breastfeeding Counseling Training
2020 : Course Director & Facilitator of WHO-UNICEF Baby Friendly Hospital Initiative

RIWAYAT PEKERJAAN:

2023-2024	: Coach TB Dinkes DKI Jakarta
2022–sekarang	: Sekretaris Komite Etik Penelitian Kesehatan (KEPK), Fakultas Kedokteran Universitas Tarumanagara
2021–sekarang	: Ketua Unit Penelitian dan Pengabdian Masyarakat (UPPM), Fakultas Kedokteran Universitas Tarumanagara
2015–2021	: Kepala Bagian Ilmu Kesehatan Anak, Fakultas Kedokteran Universitas Tarumanagara
2008–sekarang	: Dosen tetap Fakultas Kedokteran Universitas Tarumanagara
2022–2025	: Perwakilan Indonesia untuk WHO Guideline Development Group (GDG) for Donor Human Milk Banking
2020–2021	: Konsultan adaptasi modul Baby Friendly Hospital Initiative WHO-UNICEF
2019–2020	: Konsultan inisiatif Human Milk Bank Indonesia, Alive and Thrive

Gambar L7 1 Curiculum Vitae (CV) Dokter Spesialis Anak

2018–2019 : Focal point developer Infant and Young Child Feeding in Emergency Program NTB-Sigi Sulawesi Tengah, UNICEF
2016–2017 : Perwakilan Indonesia untuk Baby Friendly Hospital Initiative Congress, WHO-UNICEF
2012–2019 : Breastfeeding Counseling Training and Infant Friendly Hospital Initiative Course Director, Indonesia Breastfeeding Center (SELASI)
2015–2017 : Dokter spesialis anak RSUD Kembangan, Jakarta Barat
2011–sekarang : Dokter spesialis anak dan konsultas laktasi BJ Medical Center, Jakarta Barat

PENGALAMAN ORGANISASI:
2022–2025 : Member of WHO Guideline Development Group (GDG) for Donor Human Milk Banking
2021–2025 : Sekretaris Breastfeeding Taskforce Indonesia Pediatric Society (Satgas ASI IDAI)
2019–sekarang : Member of Human Milk Bank Association South East Asia (HMBASEA)
2019–sekarang : Member of Human Milk Bank Initiative of Indonesia (HMBIINA)
2016–sekarang : Member of Neuro-Behavior Pediatric Center (NBP Center)
2016–sekarang : Member of Nutrition and Metabolic Diseases Working Group (UKK NPM IDAI)
2014–2021 : Member of Breastfeeding Taskforce Indonesia Pediatric Society (Satgas ASI IDAI)
2014–2018 : Coordinator of SUN Movement CSOs Network Indonesia
2012–sekarang : Member of International Lactation Consultant Association (ILCA)
2012–sekarang : Fellow of Academy Breastfeeding Medicine (ABM)
2012–2019 : Member of Maternal and Child Health Coalition (GKIA)
2012–2019 : Chairwoman of Indonesia Breastfeeding Center (SELASI)

PELATIHAN DAN PENGEMBANGAN PROFESI:
2025 : Workshop Science of Breastfeeding, PIT IKA IDAI
2023 : Workshop Overcoming Low Milk Supply, PIT IKA IDAI
2021 : Indonesia Breastfeeding Course for Clinicians, IDAI
2020 : Baby Friendly Hospital Initiative Training for Maternity Staff, WHO-UNICEF
2020 : Workshop Early Detection and Management of Growth Faltering and Stunting, IDAI
2020 : Workshop Autism Spectrum Disorders in Children and Adolescents, IDAI
2019 : Workshop Optimal Nutrition on Preterm and Very Low Birth Weight Infant, IDAI
2018 : Workshop Breastfeeding in Preterm Infants, IDAI
2018 : Nutrition in Emergency Training, UNICEF
2018 : Workshop Advocacy Strategy to Strengthening Infant and Young Child Feeding, UNICEF
2018 : Workshop Weight Faltering in Exclusively Breastfeeding Infants, IDAI
2017 : Workshop Infant Friendly Hospital Initiative, WHO Geneva
2017 : Workshop Optimal Feeding Practices in Infancy, IDAI
2017 : IYCF Training: Children with Feeding Problems, PGPN Boston University
2016 : Workshop Advocacy Strategy to Strengthening Breastfeeding PPS, UNICEF
2016 : Intensive Training: Children with Special Needs, NBP Center,
2016 : Intensive Training: Children with Specific Learning Disabilities, NBP Center

Gambar L7 1 (Lanjutan)

2016 : International Code of Marketing of Breast Milk Substitutes Training, IBFAN
2011 : International Board-Certified Lactation Consultant, IBLCE – recertified 2016, 2022

RIWAYAT PENELITIAN:
2025 : Profil dan faktor risiko Dys-Executive Function pada Mahasiswa Kedokteran
2025 : Validasi Instrumen Feeding Aversion Screening (FAS) pada Bayi
2024 : Pengembangan Kuesioner Multidimensional: Identifikasi Faktor Risiko Stres Menyusui dan Persepsi ASI Kurang
2023 : Medical Students' Knowledge of Breastfeeding Myths
2022 : Contributing Factors for Suboptimal Breastfeeding To Identify Mother Who Need Breastfeeding Support
2021 : Online Breastfeeding Support to Conquer Altered Maternity Protocol, Practices and Perceptions of Suspected/Confirmed Covid-19 Mothers
2020 : Capaian Imunisasi Dasar/Lanjutan Sebelum dan Selama Pandemi Covid-19
2020 : Human Milk Banks in the Response to Covid-19: A Statement of The Regional Human Milk Bank Network for Southeast Asia and Beyond
2020 : Distance Learning Experience of Tarumanagara Medical Residents during Pandemic Covid-9
2019 : Academic Performance of Medical Students with an Indication of Developmental Dislexia: Positive Changes in GPA Achievement Following Self Awareness
2018 : Supporting the Most Defenceless in Central Sulawesi's Emergencies Through Training Intervention on Infant and Young Child Feeding Counselling
2018 : Woman Opinion and Knowledge about Management o Risk in Online-Based Peer-To-Peer Human Milk
2018 : Barriers to Exclusive Breastfeeding in Indonesian Hospitals: A Qualitative Study of Early Infant Feeding Practices from Three Provinces
2018 : Perception and Self Awareness of Specific Learning Disorder among Tarumanagara Medical Students

RIWAYAT PUBLIKASI:
2025 : Pemahaman Mahasiswa Kedokteran tentang Kangaroo Mother Care (KMC) untuk Bayi Berat Badan Lahir Rendah dan Prematur. Jurnal Muara Medika dan Psikologi Klinis. 2025 Sep 21;5(1):39-46.
2025 : Pengetahuan Dukungan Menyusui pada Mahasiswa Fakultas Kedokteran Universitas Tarumanagara Angkatan 2019-2022. Ebers Papyrus. 2025 Aug 20;31(1):51-7.
2025 : Analisis Faktor Sosiodemografis, Psikologis, dan Pengetahuan Terhadap Kesiapan Ibu dalam Merawat Bayi Baru Lahir. Ebers Papyrus. 2025 Aug 20;31(1):232-45.
2025 : Penyuluhan bagi Orang Tua Balita pada Pekan TB 2025: Upaya Pencegahan dan Edukasi Tuberkulosis Anak. Jurnal Serina Abdimas. 2025 Jun 30;3(2):205-10.
2025 : Hubungan Konsumsi Sugar-Sweetened Beverages dengan Berat Badan Berlebih pada Anak Usia Sekolah Dasar di Kabupaten Karawang. Tarumanagara Medical Journal. 2025 Apr 30;7(1):29-36.
2024 : Pemahaman Mahasiswa Fakultas Kedokteran tentang Obesitas pada Anak. Jurnal Serina Sains, Teknik dan Kedokteran. 2024;2(2):163-70.
2024 : Hubungan Karakteristik Ibu dengan Pola Pemberian MPASI pada Bayi di Kecamatan Cengkareng Jakarta Barat. Ebers Papyrus. 2024;30(2):130-9.

Gambar L7 1 (Lanjutan)

2024 : Hubungan riwayat ASI eksklusif dengan diare pada bayi usia 0-12 bulan. Tarumanagara Medical Journal. 2024 Oct 31;6(2):268-73.
2024 : Skrining Kesehatan dan Tumbuh Kembang Anak Usia Prasekolah di LA Preschool Jakarta Pusat. Jurnal Bakti Masyarakat Indonesia. 2024 Oct 25;7(2):216-22.
2024 : Hubungan Pengetahuan Ibu dengan Kelengkapan Imunisasi Dasar di Posyandu Kecamatan Cengkareng Jakarta Barat. Ebers Papyrus. 2024 Aug 7;30(1):74-85.
2024 : Perceptions, practices, and associated factors towards expressed breastfeeding among mothers in Jakarta, Indonesia. Paediatrica Indonesiana. 2024 Apr 23;64(2):168-75.
2023 : The Relationship Between Family Involvement and Satisfaction Level of The Family of Critical Care Patients in The Sumber Waras Hospital. Asian Journal of Social and Humanities. 2023 Aug 25;1(12):1023-30.
2023 : Pelayanan Stimulasi Deteksi Intervensi Dini Tumbuh Kembang pada Siswa Bunda Mulia School Jakarta Utara: pada Siswa Bunda Mulia School Jakarta Utara. Jurnal Bakti Masyarakat Indonesia. 2023 Aug 31;6(2).
2023 : Pengetahuan Mahasiswa Fakultas Kedokteran Universitas Tarumanagara Angkatan 2019-2022 tentang Faktor-Faktor yang Memengaruhi Keberhasilan Pemberian ASI. Ebers Papyrus. 2023 Aug 2;29(1), 85-93.
2023 : Pengetahuan Mahasiswa dan Mahasiswi Fakultas Kedokteran Universitas Tarumanagara mengenai Manfaat Pemberian ASI pada Anak Usia 0-2 Tahun. Ebers Papyrus. Vol 29(1), Aug 2023, 51-6.
2023 : Evaluasi Pengetahuan Vaksinasi pada Sasaran Vaksin Dosis-3 di Sentra Vaksinasi Covid-19 Universitas Tarumanagara FebruarI 2022. Jurnal Bakti Masyarakat Indonesia. 2023 Jul 31;6(1), 99-104.
2023 : Survei Pengukuran Status Gizi Balita dan Pola Pemberian Makanan Pendamping ASI di RPTRA Mandala Kelurahan Tomang Jakarta Barat. Jurnal Bakti Masyarakat Indonesia. 2023 Jul 7;6(1),75-82.
2023 : Hubungan Pengetahuan Mahasiswa Fakultas Kedokteran Universitas Tarumanagara tentang Keamanan Penggunaan Obat pada Ibu Menyusui. Jurnal Kesehatan dan Kedokteran Tarumanagara. 2023 Jun 28;2(1):78-83.
2023 : Pengetahuan tentang Imunisasi Dasar pada Mahasiswa Fakultas Kedokteran Universitas Tarumanagara. Jurnal Kesehatan dan Kedokteran Tarumanagara. 2023 Jun 28;2(1):90-3.
2023 : Hubungan Pengetahuan Orangtua terkait Pengaruh Pemberian Air Susu Ibu terhadap Stunting. Sari Pediatri. 2023 Apr 19;24(6):395-400.
2022 : Kejadian Infeksi Pasca Vaksinasi Covid-19 Dosis Primer pada Sasaran Vaksin Lanjutan di Sentra Vaksinasi Covid-19 Universitas Tarumanagara. Jurnal Muara Medika dan Psikologi Klinis. 2022 Nov 30;2(2):133-9.
2022 : Hubungan Pengetahuan Ibu tentang Kiat Sukses ASI Eksklusif dengan Riwayat Pemberian ASI. Jurnal Kesehatan dan Kedokteran Tarumanagara. 2022 Nov 21;1(1):46-54.
2022 : Hubungan Pengetahuan Ibu Menyusui mengenai ASI Perah dengan Ketepatan Manajemen ASI Perah. Jurnal Kesehatan dan Kedokteran Tarumanagara. 2022 Nov 21;1(1):54-62.
2022 : Hubungan Karakteristik Ibu dengan Persepsi dan Perilaku Ibu dalam Memilih Minuman Ringan untuk Anak. Prosiding 2nd Tacoham September 2022
2022 : Hubungan Pengetahuan Orangtua terhadap Intensitas Penggunaan Gawai pada Anak Usia 1-5 Tahun. Prosiding 2nd Tacoham September 2022

Gambar L7 1 (Lanjutan)

2022 : Karakteristik Pengguna Media Daring dalam Praktik Berbagi Air Susu Ibu. Sari Pediatri. 2022 Jun 29;24(1):7-15.
2022 : Contributing Factor for Suboptimal Breastfeeding Practice to Identify Mother Who Need Breastfeeding Support. 5th Indonesian Pediatric Nutrition and Metabolic Updates (Nutrimet) July 2022.
2022 : Pemenuhan Ketentuan Gula Tambahan dan Persentasi Gula terhadap Kalori pada MPASI Komersial Sesuai Peraturan BPOM. Ebers Papyrus. 2022 Jun 28;28(1):101-10.
2022 : Increased Knowledge of Maternity Staff about Postpartum Breastfeeding Support for Covid-19 Positive Mothers. Virtual Symposium Professions Scientific Series in the Management of Covid-19 in Indonesia: Lessons from RSDCWAK June 2022.
2022 : Karakteristik pendonor Air Susu Ibu (ASI) di media sosial. Tarumanagara Medical Journal. 2022 Apr 30;4(1):48-59.
2022 : Incidence Of Breakthrough Infections After Primary Covid-19 Vaccination Among Adults at The Universitas Tarumanagara Vaccine Center. Jurnal Journal of Innovation and Community Engagement (ICE) Vol. 3 No. 4 Tahun 2022.
2022 : Survei Pola Pemberian Makanan Pendamping ASI dan Pengukuran Status Gizi Balita di RPTRA Mandala Kelurahan Tomang Jakarta Barat. Madani: Jurnal Pengabdian Kepada Masyarakat Vol 8, No 2 Tahun 2022.
2022 : Empowering Teachers, Empowering the Nation: Developing an Accessible Training System for Dyslexia in Indonesia. Asia Pacific Journal of Developmental Differences Vol. 9, No. 1, January 2022, Pp. 31-41.
2021 : Pemenuhan Persyaratan Kandungan Zat Besi dan Zinc pada Label Produk Makanan Pendamping ASI (MPASI) Komersial. Tarumanagara Medical Journal. 2021 Nov 1;3(2):257-65.
2021 : Profil Iklan Susu Formula sebagai Produk Pengganti ASI yang Dimuat pada Majalah Kedokteran. Prosiding SENAPENMAS. 2021 Nov 21:1059-68.
2021 : Analisis Konten Dukungan Menyusui pada Kondisi Pandemi Covid-19 Melalui Platform Sosial Media. Prosiding SENAPENMAS. 2021 Nov 21:1163-8.
2021 : Breastfeeding Knowledge and Attitudes during Covid-19 Isolation among Mothers with Mild Cases. Proceeding 1st International Conference on Lactation Management in Covid-19 Pandemic Era September 2021.
2021 : Compliance of Breast Milk Substitutes Advertisement in Medical Journals Under the Scope Of Government Regulation. Proceeding 1st International Conference on Lactation Management in Covid-19 Pandemic Era September 2021.
2021 : Sentra Vaksin Untar: Upaya Mendukung Percepatan Pembelajaran Tatap Muka. Opini Pintar Vol 2 hlm 189 -192 September 2021.
2021 : Distance Learning on Paediatrics Clerkship: A New Experience for Medical Students at Universitas Ttarumanagara. Advances In Health Sciences Research, Proceeding 1st Tarumanagara International Conference on Medicine and Health (TICMIH) Vol 41 Agustus 2021.
2021 : Covid-19 Vaccination: Intention and Coverage to Vaccinate Among Lecturers, Education Personnel, and Students of Tarumanagara University. Advances In Health Sciences Research, Proceeding 1st Tarumanagara International Conference on Medicine and Health (TICMIH) Vol 41 Agustus 2021.
2021 : Determinan Persepsi dan Perilaku Ibu dalam Membaca Label Makanan Ringan Anak TK-SD Bumi Serpong Damai. Ebers Papyrus. 2021 Jul 7;27(1):34-44.

Gambar L7 1 (Lanjutan)

2021 : Profil Capaian Imunisasi Dasar Atau Lanjutan Pada Baduta Sebelum Dan Selama Pandemi Covid-19. Jurnal Muara Medika dan Psikologi Klinis. 2021 May 29;1(1):17-23.
2021 ; Pemenuhan Persyaratan Kandungan Zat Besi pada Label Produk Formula Bayi 0-12 Bulan. Tarumanagara Medical Journal. 2021 Apr 30;3(1):124-8.
2021 : Pemenuhan Persyaratan Kandungan Kalsium pada Label Produk Formula Bayi 0-12 Bulan. Tarumanagara Medical Journal. 2021 Apr 30;3(1):66-72.
2020 : Human Milk Banks in the response to Covid-19: A Statement of the Regional Human Milk Bank Network for Southeast Asia and Beyond. International Breastfeeding Journal. 2021 Dec;16(1):1-6.
2020 : Hubungan Pemberian ASI Eksklusif terhadap Perkembangan Kognitif Bayi Usia 3-24 Bulan di Puskesmas Grogol Petamburan Jakarta Barat tahun 2019. Tarumanagara Medical Journal. 2020 Oct 31;2(2):392-8.
2020 : Preferensi Gaya Belajar dan Hasil Prestasi Akademis Mahasiswa Fakultas Kedokteran Universitas Tarumanagara dengan Risiko Disleksia. Tarumanagara Medical Journal. 2020 May 15;2(1):141-7.
2019 : Supporting the Most Defenceless in Central Sulawesi's Emergencies through Training Intervention on Infant and Young Child Feeding Counselling. Zulfaqar Medical Journal suppl ed August 2019.
2019 : Perbandingan Hasil Prestasi Akademis Mahasiswa Fakultas Kedokteran Universitas Tarumanagara Berdasarkan Hasil Skrining Risiko Disleksia. Tarumanagara Medical Journal. 2019 Oct 29;1(3):1-6.
2019 : Hubungan Status Gizi dengan prevalensi ISPA pada Anak Usia 6–24 Bulan di Puskesmas Wilayah Kota Administratif Jakarta Barat periode Januari–April 2017. Tarumanagara Medical Journal. 2019 May 2;1(2):428-33.
2018 : Hubungan Pengetahuan Ibu dengan Pelaksanaan Inisiasi Menyusu Dini pada Tiga Puskesmas di Jakarta Barat periode Oktober 2014–Mei 2015. Tarumanagara Medical Journal. 2018 Oct 23;1(1):128-34.
2018 : Barriers to exclusive breast-feeding in Indonesian hospitals: a qualitative study of early infant feeding practices. Public Health Nutrition. 2018 Oct;21(14):2689-97.

KARYA BUKU:
2024 : EksplorASI, BP IDAI
2024 : Kita Sukses Menyusui, BP IDAI
2022 : Modul Indonesian Breastfeeding Course for Clinicians, BP IDAI
2022 : Konsensus Penggunaan Donor ASI, BP IDAI
2021 : Stunting: Pencegahan, Diagnosis dan Tata Laksana Terpadu, BP IDAI
2021 : Rampaian Perlindungan Menyusui di Masa Pandemi Sehat di Masa Pandemi, Universitas Tarumanagara Press
2018 : Modul Siaga Bencana, BP IDAI
2017 : Diagnosis dan Tata Laksana Ankyloglossia (Tongue-Tie), BP IDAI
2017 : Strategi Optimalisasi Pertumbuhan Bayi ASI Eksklusif, BP IDAI
2016 : 1001 Langkah Gerakan Kesehatan Ibu dan Anak, Puspa Swara
2016 : Anti Panik Perawatan Bayi, Wahyu Media
2013 : Pediatweet - Kicauan @dokteranakkita, Tiga Serangkai

Gambar L7 1 (Lanjutan)

PENGALAMAN MENYUSUN KEBIJAKAN PUBLIK:

2022 : Rancangan PerMenKes ASI Donor, Kemenkes RI
2021 : Naskah Akademik Rancangan PerMenKes ASI Donor, Kemenkes RI
2021 : Modul Percepatan Penurunan AKI/AKB, Kemenkes RI
2020 : Pedoman Tatalaksana Covid-19 pada Bayi dan Anak, IDAI
2020 : Panduan Pelatihan Staf Maternitas Rintisan Rumah Sakit Sayang Bayi, WHO-UNICEF
2018 : Pelayanan Kesehatan Neonatal Esensial, Kemenkes RI
2017 : Pedoman Rumah Sakit Sayang Ibu dan Bayi, Kemenkes RI

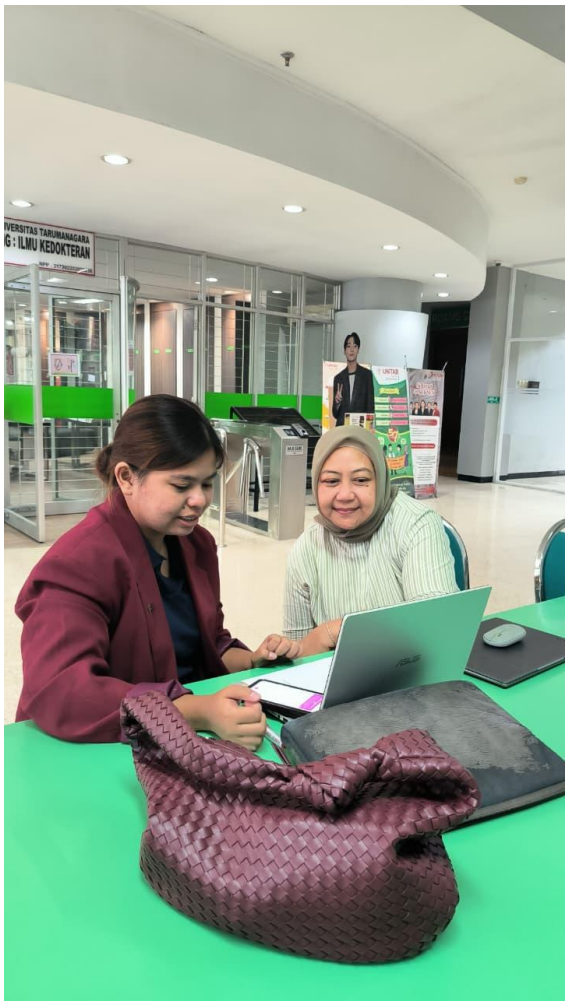
RIWAYAT PENGHARGAAN:

2022 : Juara I Oral Presentation Virtual Symposium Multi-Professions Scientific Series in the Management of Covid-19 in Indonesia: Lessons from RSDCWAK
2019 : Relawan PMBA Bencana, Kemenkes RI
2010 : Pemenang Original Article Competition Dies Natalis Fakultas Kedokteran Untar
2008 : Juara 1 Young Researcher Award 14th Indonesian Congress of Paediatrics – Asian Congress Pediatric Infectious Diseases
1995 : Juara 1 Inovative-Productive Competition Pekan Ilmiah Mahasiswa Nasional

Gambar L7 1 (Lanjutan)

Lampiran 8

Bukti Validasi Bersama Para Ahli



Gambar L8. 1 Dokumentasi Bukti UAT bersama Dr. dr. Wiyarni Pambudi, Sp.A, IBCLC

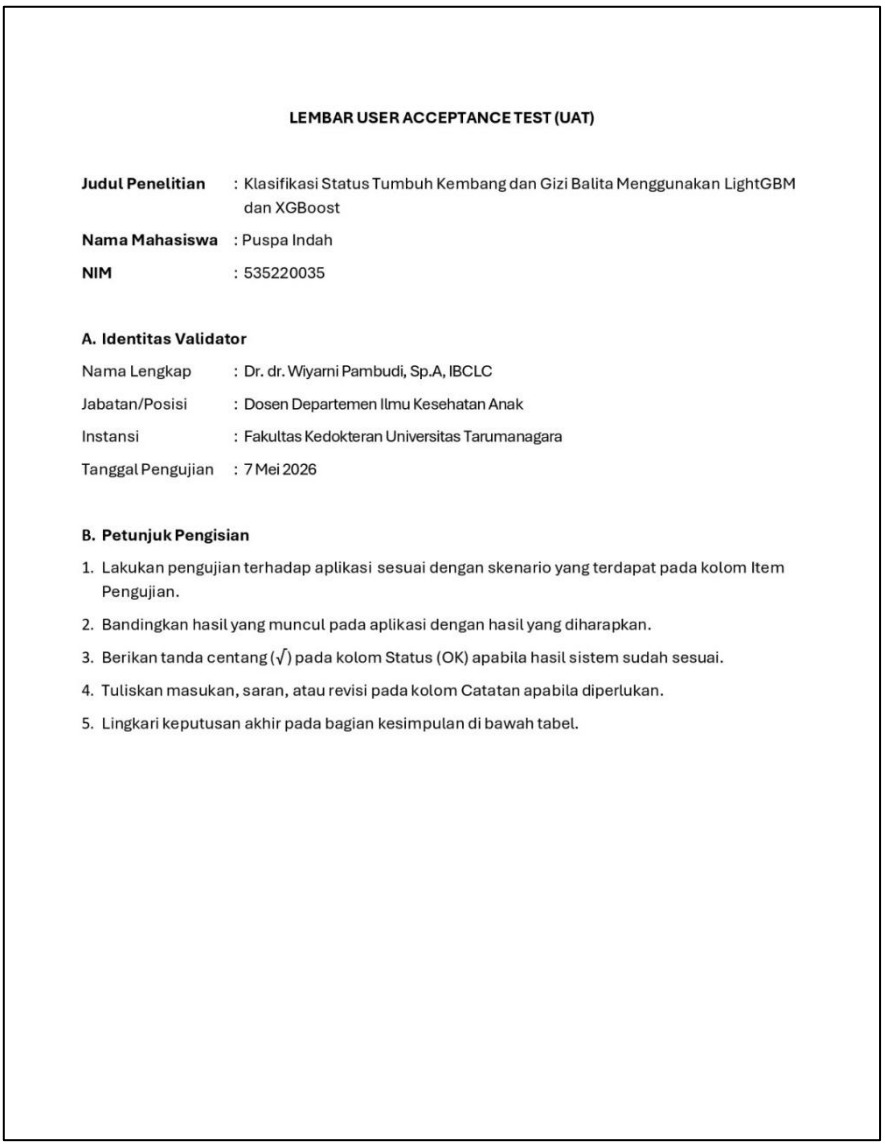


Gambar L8. 2 Dokumentasi Bukti UAT bersama Ibu Syukriah

Usman, S.Gz, RD

Lampiran 9

Hasil Lembar UAT Para Ahli



LEMBAR USER ACCEPTANCE TEST (UAT)

Judul Penelitian : Klasifikasi Status Tumbuh Kembang dan Gizi Balita Menggunakan LightGBM dan XGBoost

Nama Mahasiswa : Puspa Indah

NIM : 535220035

A. Identitas Validator

Nama Lengkap : Dr. dr. Wiyarni Pambudi, Sp.A, IBCLC

Jabatan/Posisi : Dosen Departemen Ilmu Kesehatan Anak

Instansi : Fakultas Kedokteran Universitas Tarumanagara

Tanggal Pengujian : 7 Mei 2026

B. Petunjuk Pengisian

1. Lakukan pengujian terhadap aplikasi sesuai dengan skenario yang terdapat pada kolom Item Pengujian.
2. Bandingkan hasil yang muncul pada aplikasi dengan hasil yang diharapkan.
3. Berikan tanda centang (√) pada kolom Status (OK) apabila hasil sistem sudah sesuai.
4. Tuliskan masukan, saran, atau revisi pada kolom Catatan apabila diperlukan.
5. Lingkari keputusan akhir pada bagian kesimpulan di bawah tabel.

Gambar L9. 1 Hasil Lembar UAT Bersama Dokter Anak

C. Tabel Pengujian

Tabel berikut menyajikan hasil User Acceptance Test (UAT) yang divalidasi oleh Dokter Anak. Fokus utama pengujian ini adalah untuk menilai kesesuaian alur aplikasi, input data balita, interpretasi hasil klasifikasi status pertumbuhan dan gizi, serta kejelasan informasi yang diberikan kepada pengguna.

No	Item Pengujian	Skenario / Detail Pengecekan	Hasil yang Diharapkan	Status	Catatan
1	Validasi Input Data Balita	Melakukan pengecekan pada input data seperti umur, berat badan, tinggi badan, dan jenis kelamin.	Sistem menyediakan input data yang sesuai dengan kebutuhan penilaian status pertumbuhan dan gizi balita.	[OK]	Sudah sesuai, parameter yang diukut: BB/U, TB/U, BB/TB Belum terlihat adanya validasi rentang biologis (pembatasan usia, input BB atau TB ekstrem) Belum ada validasi semantik (penting agar tidak terjadi *false diagnosis*), usia sebaiknya dihitung otomatis dari tanggal lahir dan tanggal pemeriksaan, bukan diinput manual
2	Validasi Kesesuaian Parameter	Mengecek apakah parameter umur, berat badan, dan tinggi badan sudah relevan untuk proses klasifikasi.	Parameter yang digunakan sudah sesuai sebagai dasar penilaian status pertumbuhan dan gizi balita.	[OK]	Parameter cukup baik untuk skrining entropometri dasar, namun belum memmadai untuk *pediatric nutritional assement* yang komprehensif (karena tidak ada data klinis: prematuritas/BBLR, riwayat infeksi, *intake, feeding problems*)

Gambar L9.1 (Lanjutan)

3	Validasi Hasil Weight for Age	Menguji hasil klasifikasi berat badan menurut umur.	Sistem dapat menampilkan kategori status berat badan berdasarkan umur dengan jelas dan mudah dipahami.	[OK]	Metode kalkulasi diperjelas agar kesalahan klasifikasi Z-*score* dapat dihindari
4	Validasi Hasil Height for Age	Menguji hasil klasifikasi tinggi badan menurut umur.	Sistem dapat menampilkan kategori status tinggi badan berdasarkan umur, termasuk indikasi stunting atau tidak stunting.	[OK]	Tambahkan klasifikasi 'perawakan tinggi', dan gunakan istilah 'stunted' bukan 'stunting' sesuai definisi operasional kurva pertumbuhan WHO
5	Validasi Hasil Weight for Height	Menguji hasil klasifikasi berat badan menurut tinggi badan.	Sistem dapat menampilkan kategori status gizi seperti sangat kurus, kurus, normal, atau obesitas secara jelas.	[OK]	Belum tampak deteksi overweight/obesity
6	Kejelasan Interpretasi Hasil	Mengecek apakah hasil klasifikasi mudah dipahami oleh pengguna awam.	Sistem memberikan penjelasan hasil dengan bahasa yang jelas, tidak membingungkan, dan tidak menimbulkan salah tafsir.	[OK]	Interpretasi cukup mudah dipahami, cocok untuk *user* awam, namun belum ada penjelasan sederhana terkait makna klinis indikator antropometri
7	Kesesuaian Informasi Medis	Mengecek apakah informasi yang ditampilkan tidak bertentangan dengan konsep dasar penilaian tumbuh kembang anak.	Informasi yang diberikan sistem sesuai sebagai pendukung edukasi dan tidak menggantikan diagnosis dokter.	[OK]	Sudah cukup edukatif, namun belum kuat untuk *clinical decision support*

Gambar L9.1 (Lanjutan)

8	Validasi Pesan Peringatan	Mengecek pesan peringatan atau catatan apabila hasil menunjukkan kondisi tidak normal.	Sistem memberikan saran atau peringatan secara tepat, misalnya menyarankan konsultasi lebih lanjut ke tenaga kesehatan.	[OK]	Sudah ada *disclamer* dan rekomendasi/ ajakan konsutasi
9	Kemudahan Alur Penggunaan	Menguji alur aplikasi dari input data sampai hasil keluar.	Alur penggunaan aplikasi mudah dipahami, runtut, dan tidak menyulitkan pengguna.	[OK]	Navigasi sederhana, mudah dipahami Untuk kader Puskesmas, idealnya ada *mass screening mode*
10	Kelayakan Aplikasi sebagai Media Pendukung	Menilai apakah aplikasi layak digunakan sebagai media bantu awal untuk klasifikasi status pertumbuhan dan gizi balita.	Aplikasi dinilai layak sebagai alat bantu skrining awal, dengan tetap memerlukan pemeriksaan lanjutan oleh tenaga kesehatan.	[OK]	Alat skrining yang cukup layak, namun tidak boleh berdiri sendiri tanpa validasi tenaga kesehatan

Gambar L9.1 (Lanjutan)

Catatan untuk keseluruhan :

Aplikasi ini sudah: cukup baik untuk interpretasi antropometri dasar, sebagai educational screening tool. Pengembangan aplikasi, menyesuaikan kerangka *Pediatric Nutritional Assessment* dapat dirancang lebih longitudinal, holistik, termasuk aspek *feeding* dan konteks klinis.

D. Kesimpulan & Pengesahan

Berdasarkan hasil pengujian di atas, maka aplikasi klasifikasi status pertumbuhan dan gizi balita dinyatakan:

LAYAK / ~~TIDAK LAYAK~~

Jakarta, 7 Mei 2026

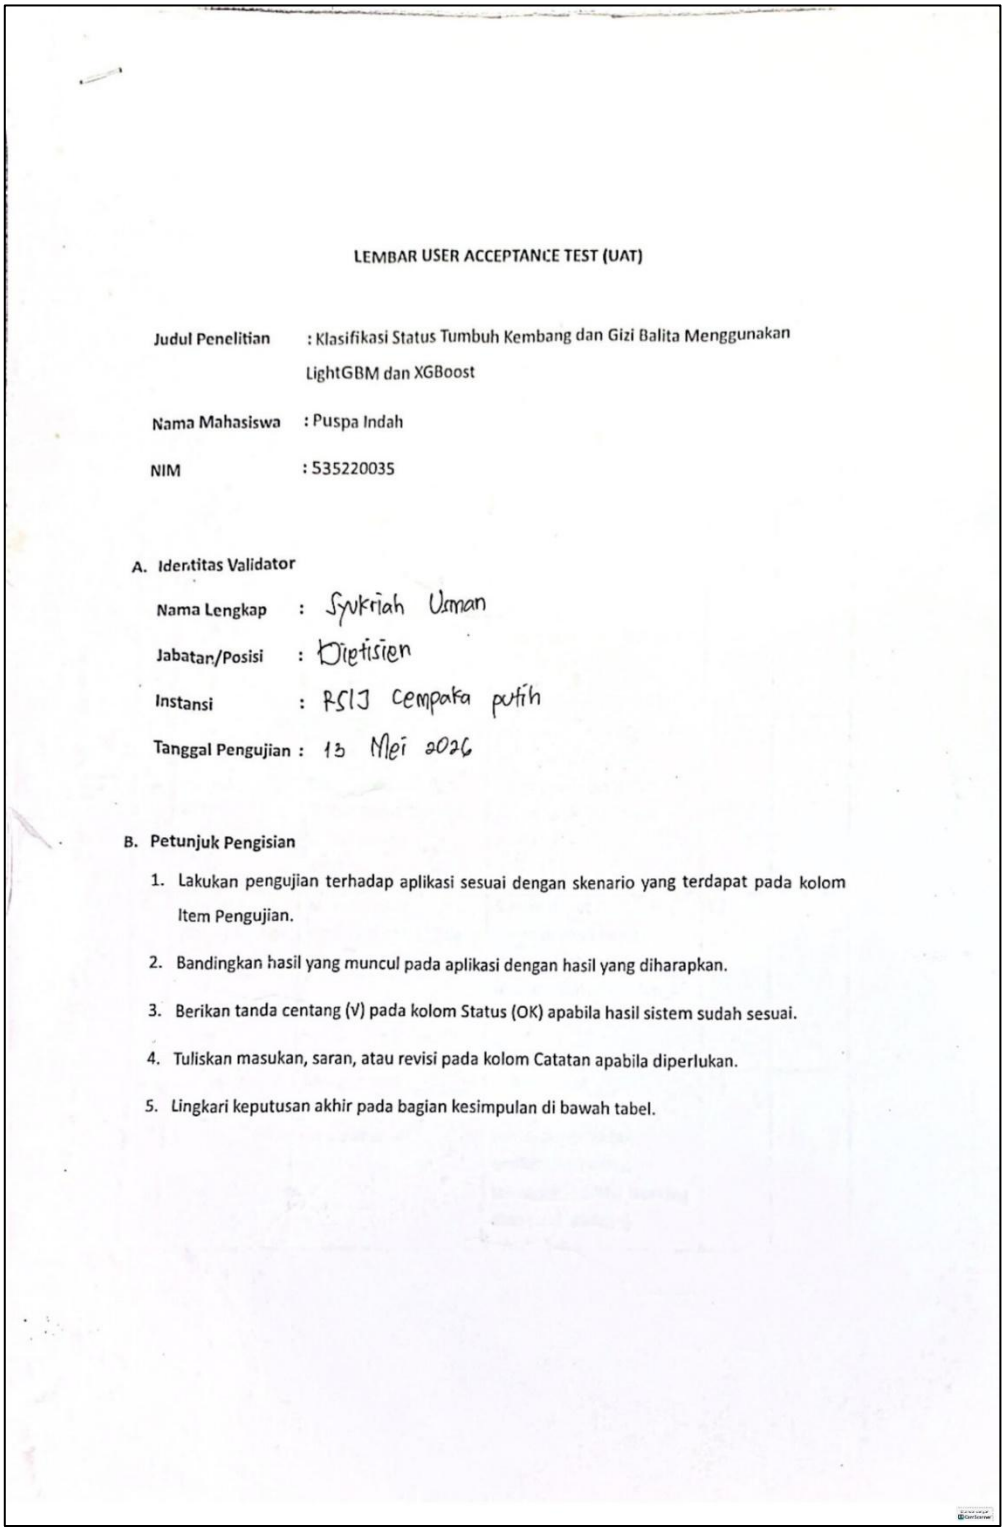


Dr. Wiyarni Pambudi, Sp.A, IBCLC

NUPTK 2848751652230102

( )

Gambar L9.1 (Lanjutan)



LEMBAR USER ACCEPTANCE TEST (UAT)

Judul Penelitian : Klasifikasi Status Tumbuh Kembang dan Gizi Balita Menggunakan LightGBM dan XGBoost

Nama Mahasiswa : Puspa Indah

NIM : 535220035

A. Identitas Validator

Nama Lengkap : Syukriah Usman

Jabatan/Posisi : Dietisien

Instansi : RSIJ cempaka putih

Tanggal Pengujian : 13 Mei 2026

B. Petunjuk Pengisian

1. Lakukan pengujian terhadap aplikasi sesuai dengan skenario yang terdapat pada kolom Item Pengujian.
2. Bandingkan hasil yang muncul pada aplikasi dengan hasil yang diharapkan.
3. Berikan tanda centang (V) pada kolom Status (OK) apabila hasil sistem sudah sesuai.
4. Tuliskan masukan, saran, atau revisi pada kolom Catatan apabila diperlukan.
5. Lingkari keputusan akhir pada bagian kesimpulan di bawah tabel.

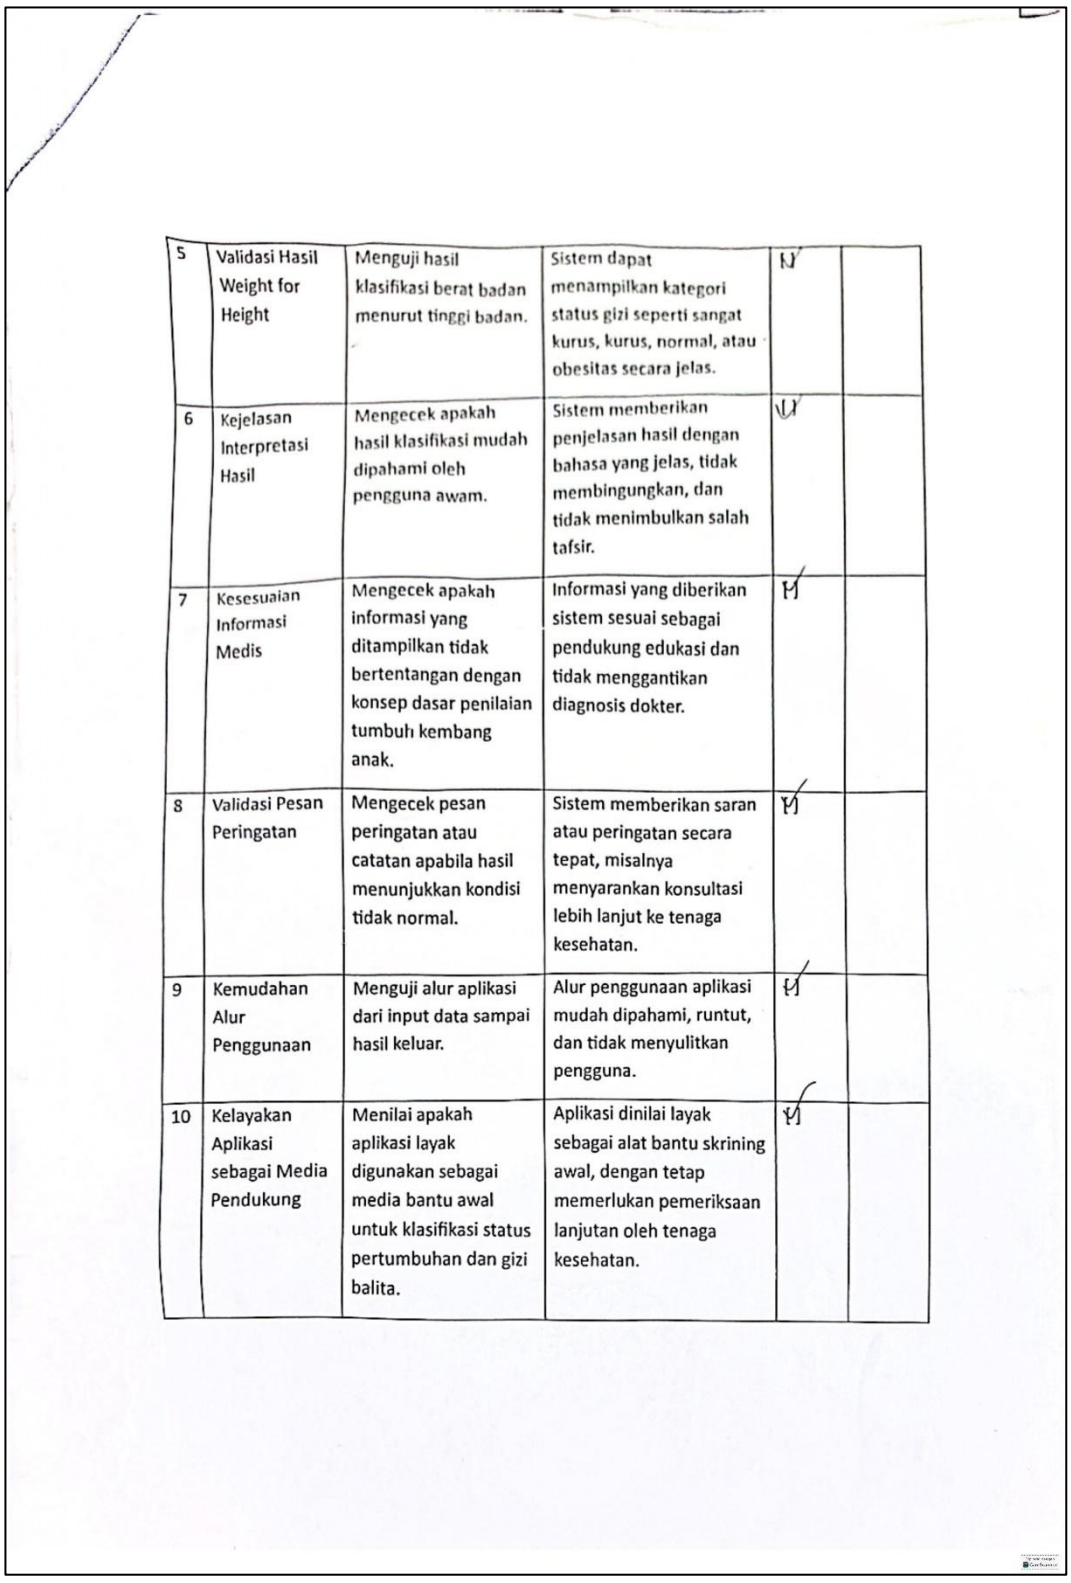
Gambar L9. 2 Hasil Lembar UAT Bersama Ahli Gizi

C. **Tabel Pengujian**

Tabel berikut menyajikan hasil User Acceptance Test (UAT) yang divalidasi oleh Dokter Anak. Fokus utama pengujian ini adalah untuk menilai kesesuaian alur aplikasi, input data balita, interpretasi hasil klasifikasi status pertumbuhan dan gizi, serta kejelasan informasi yang diberikan kepada pengguna.

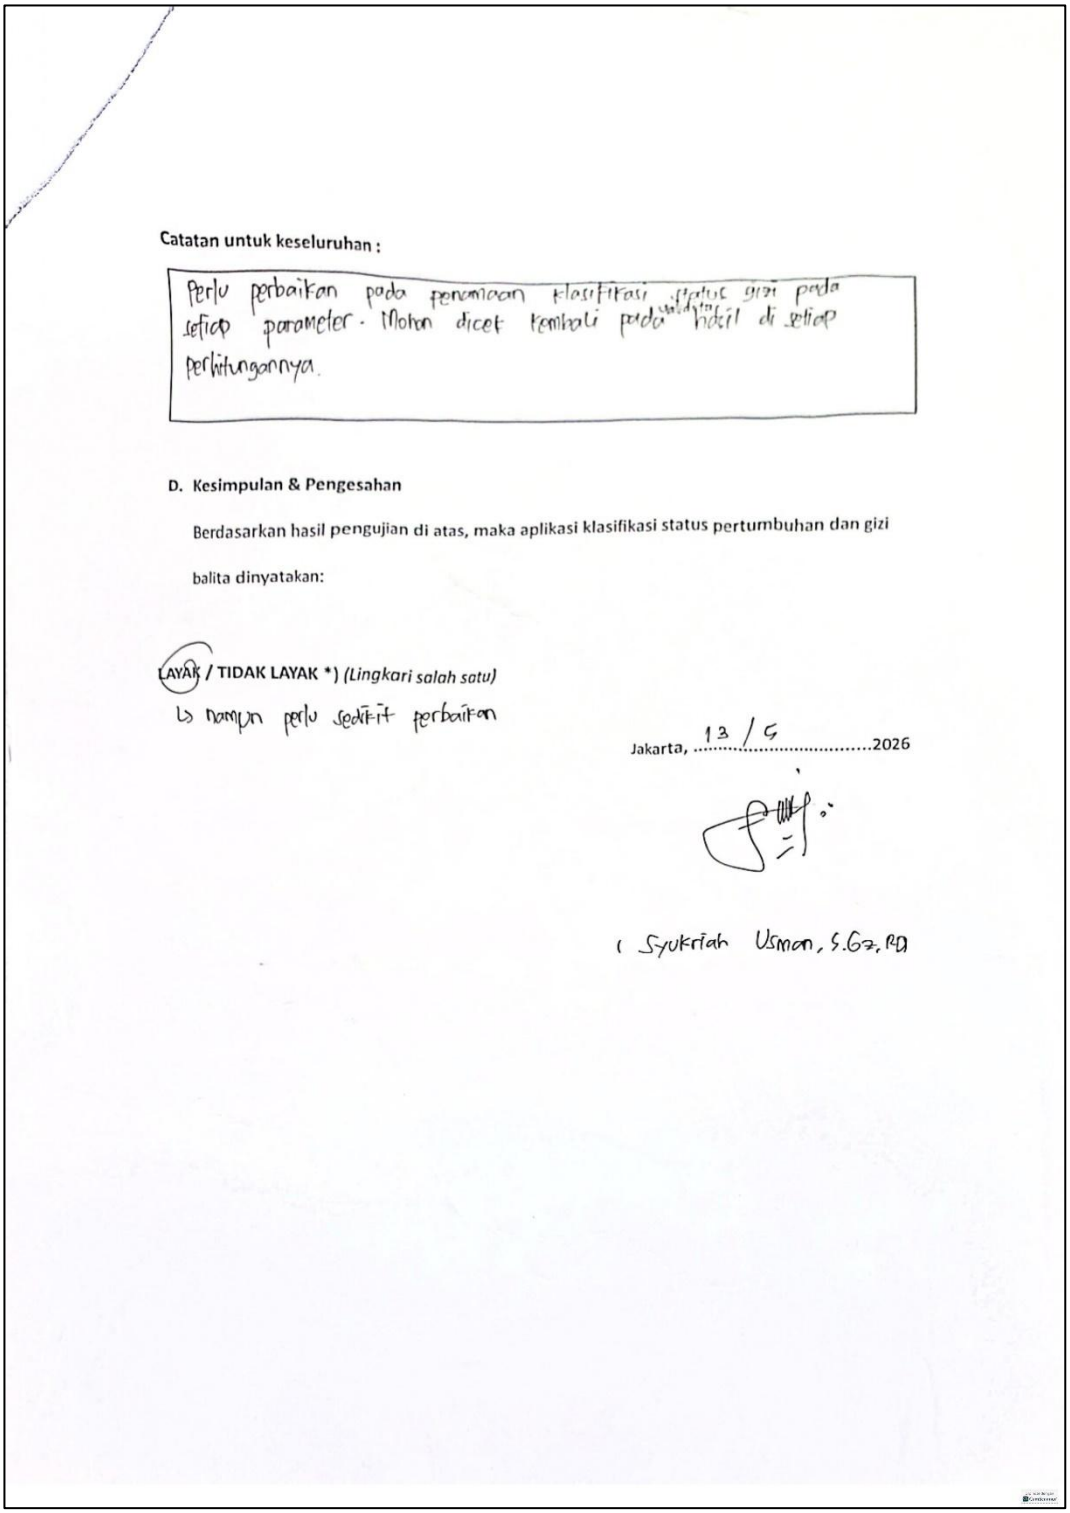
No	Item Pengujian	Skenario / Detail Pengecekan	Hasil yang Diharapkan	Status (OK)	Catatan
1	Validasi Input Data Balita	Melakukan pengecekan pada input data seperti umur, berat badan, tinggi badan, dan jenis kelamin.	Sistem menyediakan input data yang sesuai dengan kebutuhan penilaian status pertumbuhan dan gizi balita.	✓	
2	Validasi Kesesuaian Parameter	Mengecek apakah parameter umur, berat badan, dan tinggi badan sudah relevan untuk proses klasifikasi.	Parameter yang digunakan sudah sesuai sebagai dasar penilaian status pertumbuhan dan gizi balita.	✓	
3	Validasi Hasil Weight for Age	Menguji hasil klasifikasi berat badan menurut umur.	Sistem dapat menampilkan kategori status berat badan berdasarkan umur dengan jelas dan mudah dipahami.	✓	
4	Validasi Hasil Height for Age	Menguji hasil klasifikasi tinggi badan menurut umur.	Sistem dapat menampilkan kategori status tinggi badan berdasarkan umur, termasuk indikasi stunting atau tidak stunting.	✓	

Gambar L9. 2 (Lanjutan)



5	Validasi Hasil Weight for Height	Menguji hasil klasifikasi berat badan menurut tinggi badan.	Sistem dapat menampilkan kategori status gizi seperti sangat kurus, kurus, normal, atau obesitas secara jelas.	✓	
6	Kejelasan Interpretasi Hasil	Mengecek apakah hasil klasifikasi mudah dipahami oleh pengguna awam.	Sistem memberikan penjelasan hasil dengan bahasa yang jelas, tidak membingungkan, dan tidak menimbulkan salah tafsir.	✓	
7	Kesesuaian Informasi Medis	Mengecek apakah informasi yang ditampilkan tidak bertentangan dengan konsep dasar penilaian tumbuh kembang anak.	Informasi yang diberikan sistem sesuai sebagai pendukung edukasi dan tidak menggantikan diagnosis dokter.	✓	
8	Validasi Pesan Peringatan	Mengecek pesan peringatan atau catatan apabila hasil menunjukkan kondisi tidak normal.	Sistem memberikan saran atau peringatan secara tepat, misalnya menyarankan konsultasi lebih lanjut ke tenaga kesehatan.	✓	
9	Kemudahan Alur Penggunaan	Menguji alur aplikasi dari input data sampai hasil keluar.	Alur penggunaan aplikasi mudah dipahami, runtut, dan tidak menyulitkan pengguna.	✓	
10	Kelayakan Aplikasi sebagai Media Pendukung	Menilai apakah aplikasi layak digunakan sebagai media bantu awal untuk klasifikasi status pertumbuhan dan gizi balita.	Aplikasi dinilai layak sebagai alat bantu skrining awal, dengan tetap memerlukan pemeriksaan lanjutan oleh tenaga kesehatan.	✓	

Gambar L9. 2 (Lanjutan)



Catatan untuk keseluruhan :

Perlu perbaikan pada penamaan klasifikasi status gizi pada setiap parameter. Mohon dicek kembali pada hasil di setiap perhitungannya.

D. Kesimpulan & Pengesahan

Berdasarkan hasil pengujian di atas, maka aplikasi klasifikasi status pertumbuhan dan gizi balita dinyatakan:

LAYAK / TIDAK LAYAK *) *(Lingkari salah satu)*

Ya namun perlu sedikit perbaikan

Jakarta, 13 / 6 2026

(Syukriah Usman, S.Gz, RD

Gambar L9. 2 (Lanjutan)

RS ISLAM JAKARTA
CEMPAKA PUTIH

KOMKORDIK
(PENELITIAN)
Jalan Cempaka Putih Tengah I/1 – Jakarta 10510
Telp. 021-4250451 – 42801567 ext. 423-429

Perihal : Permohonan studi pendahuluan

Jakarta, 26 Maret 2026 M
7 Syawal 1447 H

Yth.
Manajer Rekam Medis
Di- Tempat

Assalamu'alaikum Wr. Wb.

Menindaklanjuti surat dari Direktur Utama RSIJCP tentang persetujuan kegiatan penelitian oleh mahasiswa Fakultas Tehnik Informatika Univ. tarumanegara atas nama dibawah ini:

No	Nama	Tema Penelitian
1	Puspa Indah	Klasifikasi status Stunting Balita menggunakan Light Gradient Boosting Machine (Light GBM)
2	Rakha Naufal Sujana	Klasifikasi Penyakit malaria menggunakan Light Gradient Boosting Machine (Light GBM)

Dengan ini, kami mohon agar yang bersangkutan dapat dibimbing untuk melakukan penelitian di unit terkait .

Atas perhatian dan kerjasama yang baik, kami mengucapkan terima kasih.

Wassalamu'alaikum Wr. Wb

dr. Ihsanil Husna , Sp.Pd, FINASIM
Ka. Komkordik

Gambar L9. 3 Hasil Bukti Penelitian Ke RS Islam Cempaka Putih

Lampiran 10

Perhitungan Manual Hasil Kuesioner Responden

Peneliti menggunakan kuesioner untuk menilai tanggapan responden terhadap aplikasi GrowSmart Health. Pengujian melibatkan 15 responden, yaitu ibu yang memiliki balita di lingkungan RT setempat. Penilaian kuesioner terdiri atas dua aspek, yaitu Pengalaman Menggunakan Aplikasi dan Relevansi Output Aplikasi.

Peneliti menggunakan skala Likert 5 poin untuk memberikan nilai pada setiap jawaban responden. Skor pada pernyataan positif mengikuti nilai jawaban responden secara langsung. Sementara itu, peneliti membalik skor pada pernyataan negatif agar skor yang lebih tinggi tetap menunjukkan penilaian yang lebih baik terhadap aplikasi.

Tabel L10. 1 Skor Pernyataan Positif

Pilihan Jawaban	Keterangan	Skor
STS	Sangat Tidak Setuju	1
TS	Tidak Setuju	2
N	Netral	3
S	Setuju	4
SS	Sangat Setuju	5

Tabel L10. 2 Konversi Skor Pernyataan Negatif

Pilihan Jawaban	Skor Awal	Skor Setelah Dibalik
Sangat Tidak Setuju (STS)	1	5
Tidak Setuju (TS)	2	4
Netral (N)	3	3
Setuju (S)	4	2
Sangat Setuju (SS)	5	1

Peneliti menggunakan rumus berikut dalam proses pengolahan data kuesioner.

1. Rumus Persentase Data Balita

$$\text{Persentase} = \frac{\text{Jumlah Data pada Kategori}}{\text{Jumlah Seluruh Data}} \times 100\%$$

2. Rumus Total Skor Setiap Pernyataan

$$\text{Total Skor} = \sum(\text{Jumlah Jawaban} \times \text{Skor})$$

3. Rumus Rata-Rata Skor Setiap Pernyataan

$$\text{Rata-Rata Skor} = \frac{\text{Total Skor Pernyataan}}{\text{Jumlah Responden}}$$

4. Rumus Skor Maksimal Setiap Aspek

$$\text{Skor Maksimal} = \text{Jumlah Responden} \times \text{Jumlah Pernyataan} \times \text{Skor Tertinggi}$$

5. Rumus Persentase Penilaian

$$\text{Persentase Penilaian} = \frac{\text{Total Skor yang Diperoleh}}{\text{Skor Maksimal}} \times 100\%$$

B. Perhitungan Karakteristik Data Balita Responden

Peneliti menyajikan data responden menggunakan nomor urut untuk menjaga kerahasiaan identitas. Peneliti juga menyamakan usia balita ke dalam satuan bulan agar sesuai dengan rentang usia yang digunakan dalam aplikasi, yaitu 0–59 bulan. Sebagai contoh, peneliti mengonversi usia 4 tahun menjadi 48 bulan.

Tabel L10. 3 Data Jenis Kelamin dan Usia Balita Responden

No. Responden	Jenis Kelamin Balita	Usia yang Dimasukkan	Usia dalam Bulan	Kelompok Usia
1	Laki-laki	3 tahun 3 bulan	39	36–47 bulan
2	Laki-laki	48 bulan	48	48–59 bulan
3	Laki-laki	12 bulan	12	12–23 bulan
4	Laki-laki	4 tahun	48	48–59 bulan

Tabel L10. 3 (Lanjutan)

No. Responden	Jenis Kelamin Balita	Usia yang Dimasukkan	Usia dalam Bulan	Kelompok Usia
5	Laki-laki	1 tahun	12	12–23 bulan
6	Perempuan	3 tahun	36	36–47 bulan
7	Perempuan	2 tahun 5 bulan	29	24–35 bulan
8	Laki-laki	36 bulan	36	36–47 bulan
9	Perempuan	41 bulan	41	36–47 bulan
10	Perempuan	0 bulan 6 hari	0	0–11 bulan
11	Perempuan	30 bulan	30	24–35 bulan
12	Perempuan	48 bulan	48	48–59 bulan
13	Perempuan	36 bulan	36	36–47 bulan
14	Laki-laki	17 bulan	17	12–23 bulan
15	Perempuan	24 bulan	24	24–35 bulan

B.1 Perhitungan Distribusi Jenis Kelamin Balita

Peneliti menghitung persentase data balita laki-laki sebagai berikut:

$$\text{Persentase Laki-laki} = \frac{7}{15} \times 100\% = 46{,}67\%$$

Peneliti menghitung persentase data balita perempuan sebagai berikut:

$$\text{Persentase Perempuan} = \frac{8}{15} \times 100\% = 53{,}33\%$$

Tabel L10. 4 Perhitungan Distribusi Jenis Kelamin Balita

Jenis Kelamin Balita	Jumlah Data	Perhitungan	Persentase
Laki-laki	7	$7/15 \times 100\%$	46,67%
Perempuan	8	$8/15 \times 100\%$	53,33%
Total	15		100,00%

B.2 Perhitungan Distribusi Kelompok Usia Balita

Peneliti menghitung persentase setiap kelompok usia sebagai berikut:

$$\text{Persentase Usia 0–11 Bulan} = \frac{1}{15} \times 100\% = 6{,}67\%$$

$$\text{Persentase Usia 12–23 Bulan} = \frac{3}{15} \times 100\% = 20{,}00\%$$

$$\text{Persentase Usia 24–35 Bulan} = \frac{3}{15} \times 100\% = 20{,}00\%$$

$$\text{Persentase Usia 36–47 Bulan} = \frac{5}{15} \times 100\% = 33{,}33\%$$

$$\text{Persentase Usia 48–59 Bulan} = \frac{3}{15} \times 100\% = 20{,}00\%$$

Tabel L10. 5 Perhitungan Distribusi Kelompok Usia Balita

Kelompok Usia Balita	Jumlah Data	Perhitungan	Persentase
0–11 bulan	1	$1/15 \times 100\%$	6,67%
12–23 bulan	3	$3/15 \times 100\%$	20,00%
24–35 bulan	3	$3/15 \times 100\%$	20,00%
36–47 bulan	5	$5/15 \times 100\%$	33,33%
48–59 bulan	3	$3/15 \times 100\%$	20,00%
Total	15		100,00%

C. Perhitungan Penilaian Pengalaman Menggunakan Aplikasi

Bagian pengalaman menggunakan aplikasi terdiri atas 11 pernyataan. Peneliti menggunakan enam pernyataan positif dan lima pernyataan negatif. Peneliti membalik skor pada pernyataan negatif sebelum menghitung total skor agar seluruh nilai memiliki arah interpretasi yang sama.

Tabel L10. 6 Daftar Pernyataan Pengalaman Menggunakan Aplikasi

No.	Pernyataan	Jenis Pernyataan
1	Saya merasa aplikasi ini mudah digunakan.	Positif
2	Saya merasa aplikasi ini terlalu rumit untuk digunakan.	Negatif
3	Saya merasa sistem ini mudah digunakan.	Positif

Tabel L10.6 (Lanjutan)

No.	Pernyataan	Jenis Pernyataan
4	Saya merasa membutuhkan bantuan orang lain untuk menggunakan aplikasi ini.	Negatif
5	Saya merasa tampilan menu, tombol, dan halaman pada aplikasi ini sudah tersusun dengan jelas.	Positif
6	Saya merasa ada banyak hal yang tidak konsisten pada sistem.	Negatif
7	Saya merasa percaya diri saat menggunakan aplikasi ini.	Positif
8	Saya merasa perlu mempelajari banyak hal terlebih dahulu sebelum dapat menggunakan aplikasi ini.	Negatif
9	Saya merasa sistem ini membingungkan.	Negatif
10	Menurut saya, aplikasi ini sudah bagus dan pantas untuk digunakan oleh orang banyak.	Positif
11	Saya bersedia menggunakan aplikasi ini kembali apabila membutuhkan informasi awal mengenai status pertumbuhan dan gizi balita.	Positif

C.1 Contoh Perhitungan Pernyataan Positif

Pernyataan nomor 1 berbunyi “Saya merasa aplikasi ini mudah digunakan.” Pernyataan tersebut termasuk pernyataan positif, sehingga peneliti menggunakan skor asli jawaban responden.

Tabel L10. 7 Perhitungan Pernyataan Nomor 1

Pilihan Jawaban	Jumlah Jawaban	Skor	Hasil Perkalian
Sangat Tidak Setuju (STS)	0	1	0
Tidak Setuju (TS)	0	2	0
Netral (N)	0	3	0

Tabel L10. 7 (Lanjutan)

Pilihan Jawaban	Jumlah Jawaban	Skor	Hasil Perkalian
Setuju (S)	1	4	4
Sangat Setuju (SS)	14	5	70
Total	15		74

Peneliti menghitung total skor pernyataan nomor 1 sebagai berikut:

Total Skor Pernyataan Nomor 1

$$= (0 \times 1) + (0 \times 2) + (0 \times 3) + (1 \times 4) + (14 \times 5)$$

Total Skor Pernyataan Nomor 1 $= 0 + 0 + 0 + 4 + 70 = 74$

Peneliti menghitung nilai rata-rata pernyataan nomor 1 sebagai berikut:

$$\text{Rata-Rata Pernyataan Nomor 1} = \frac{74}{15} = 4{,}93$$

C.2 Contoh Perhitungan Pernyataan Negatif

Pernyataan nomor 2 berbunyi “Saya merasa aplikasi ini terlalu rumit untuk digunakan.” Pernyataan tersebut termasuk pernyataan negatif, sehingga peneliti membalik skor jawaban responden sebelum melakukan perhitungan.

Tabel L10. 8 Perhitungan Pernyataan Nomor 2

Jawaban Asli Responden	Jumlah Jawaban	Skor Setelah Dibalik	Hasil Perkalian
Sangat Tidak Setuju (STS)	13	5	65
Tidak Setuju (TS)	1	4	4
Netral (N)	0	3	0
Setuju (S)	1	2	2
Sangat Setuju (SS)	0	1	0
Total	15		71

Peneliti menghitung total skor pernyataan nomor 2 setelah pembalikan sebagai berikut:

Total Skor Pernyataan Nomor 2

$$= (13 \times 5) + (1 \times 4) + (0 \times 3) + (1 \times 2) + (0 \times 1)$$

Total Skor Pernyataan Nomor 2 $= 65 + 4 + 0 + 2 + 0 = 71$

Peneliti menghitung nilai rata-rata pernyataan nomor 2 sebagai berikut:

$$\text{Rata-Rata Pernyataan Nomor 2} = \frac{71}{15} = 4{,}73$$

C.3 Rekapitulasi Perhitungan Setiap Pernyataan Pengalaman Menggunakan Aplikasi

Tabel L10. 9 Hasil Perhitungan Skor Pengalaman Menggunakan Aplikasi

No. Pernyataan	Jenis Pernyataan	Total Skor	Rata-Rata
1	Positif	74	4,93
2	Negatif, skor dibalik	71	4,73
3	Positif	72	4,80
4	Negatif, skor dibalik	61	4,07
5	Positif	73	4,87
6	Negatif, skor dibalik	71	4,73
7	Positif	74	4,93
8	Negatif, skor dibalik	55	3,67
9	Negatif, skor dibalik	66	4,40
10	Positif	72	4,80
11	Positif	71	4,73
Total		760	4,61

C.4 Rekapitulasi Skor Pengalaman Menggunakan Aplikasi per Responden

Tabel L10. 10 Skor Pengalaman Menggunakan Aplikasi per Responden

No. Responden	1	2*	3	4*	5	6*	7	8*	9*	10	11	Total Skor
1	5	2	4	2	4	2	5	2	2	4	5	37
2	5	5	5	4	5	5	5	1	1	5	5	46
3	5	5	5	4	5	5	5	5	5	5	5	54
4	5	5	5	3	5	5	5	1	5	5	5	49
5	5	5	5	3	5	5	5	3	4	4	4	48
6	4	5	3	2	4	4	4	2	4	4	2	38
7	5	4	5	3	5	5	5	3	5	5	5	50
8	5	5	5	5	5	5	5	5	5	5	5	55
9	5	5	5	5	5	5	5	5	5	5	5	55
10	5	5	5	5	5	5	5	3	5	5	5	53
11	5	5	5	5	5	5	5	5	5	5	5	55
12	5	5	5	5	5	5	5	5	5	5	5	55
13	5	5	5	5	5	5	5	5	5	5	5	55
14	5	5	5	5	5	5	5	5	5	5	5	55
15	5	5	5	5	5	5	5	5	5	5	5	55
Total	74	71	72	61	73	71	74	55	66	72	71	760

C.5 Perhitungan Persentase Pengalaman Menggunakan Aplikasi

Jumlah responden pada pengujian kuesioner adalah 15 orang. Jumlah pernyataan pada aspek pengalaman menggunakan aplikasi adalah 11 pernyataan. Skor tertinggi pada setiap pernyataan adalah 5. Peneliti menghitung skor maksimal sebagai berikut:

$$\text{Skor Maksimal} = 15 \times 11 \times 5 = 825$$

Peneliti memperoleh total skor pengalaman menggunakan aplikasi sebesar 760. Peneliti menghitung persentase penilaian sebagai berikut:

$$\text{Persentase Pengalaman Menggunakan Aplikasi} = \frac{760}{825} \times 100\% = 92{,}12\%$$

Peneliti menghitung nilai rata-rata aspek pengalaman menggunakan aplikasi sebagai berikut:

$$\text{Rata-Rata} = \frac{760}{15 \times 11} = \frac{760}{165} = 4{,}61$$

Berdasarkan perhitungan tersebut, aspek pengalaman menggunakan aplikasi memperoleh total skor sebesar 760 dari skor maksimal 825, dengan nilai rata-rata sebesar 4,61 dan persentase sebesar 92,12%.

D. Perhitungan Relevansi Output Aplikasi

Bagian relevansi output aplikasi terdiri atas sembilan pernyataan positif. Peneliti menggunakan skor asli pada setiap jawaban responden karena seluruh pernyataan pada bagian ini memiliki arah penilaian positif.

Tabel L.10.11 Daftar Pernyataan Relevansi Output Aplikasi

No.	Pernyataan
1	Hasil klasifikasi status tumbuh kembang dan gizi balita yang ditampilkan aplikasi mudah dipahami.
2	Hasil klasifikasi pada indikator Weight-for-Age (W/A) atau berat badan menurut umur ditampilkan dengan jelas.
3	Hasil klasifikasi pada indikator Height-for-Age (H/A) atau tinggi badan menurut umur ditampilkan dengan jelas.
4	Hasil klasifikasi pada indikator Weight-for-Height (W/H) atau berat badan menurut tinggi badan ditampilkan dengan jelas.
5	Rekomendasi atau informasi pendukung yang diberikan aplikasi sesuai dengan hasil klasifikasi yang muncul.
6	Rekomendasi yang ditampilkan aplikasi membantu pengguna memahami kondisi awal tumbuh kembang dan gizi balita.
7	Informasi hasil aplikasi membantu pengguna mengetahui langkah awal yang dapat dilakukan setelah melihat hasil klasifikasi.
8	Hasil dan rekomendasi aplikasi tidak menimbulkan kesan sebagai diagnosis akhir.
9	Secara keseluruhan, output aplikasi sudah relevan dan bermanfaat sebagai alat bantu skrining awal status tumbuh kembang dan gizi balita.

D.1 Contoh Perhitungan Pernyataan Relevansi Output

Pernyataan nomor 6 berbunyi “Rekomendasi yang ditampilkan aplikasi membantu pengguna memahami kondisi awal tumbuh kembang dan gizi balita.” Peneliti menggunakan skor asli karena pernyataan tersebut termasuk pernyataan positif

Tabel L10. 11 Perhitungan Pernyataan Nomor 6 pada

Relevansi Output Aplikasi

Pilihan Jawaban	Jumlah Jawaban	Skor	Hasil Perkalian
Sangat Tidak Setuju (STS)	0	1	0
Tidak Setuju (TS)	0	2	0
Netral (N)	0	3	0
Setuju (S)	1	4	4
Sangat Setuju (SS)	14	5	70
Total	15		74

Peneliti menghitung total skor pernyataan nomor 6 sebagai berikut:

Total Skor Pernyataan Nomor 6

$$= (0 \times 1) + (0 \times 2) + (0 \times 3) + (1 \times 4) + (14 \times 5)$$

Total Skor Pernyataan Nomor 6 $= 0 + 0 + 0 + 4 + 70 = 74$

Peneliti menghitung nilai rata-rata pernyataan nomor 6 sebagai berikut:

$$\text{Rata-Rata Pernyataan Nomor 6} = \frac{74}{15} = 4{,}93$$

D.2 Perhitungan Setiap Pernyataan Relevansi Output Aplikasi

Tabel L.10.13 Hasil Perhitungan Relevansi Output Aplikasi

No. Pernyataan	STS (1)	TS (2)	N (3)	S (4)	SS (5)	Total Skor	Rata-Rata
1	0	0	1	2	12	71	4,73
2	0	0	0	3	12	72	4,80
3	0	0	0	3	12	72	4,80
4	0	0	0	3	12	72	4,80
5	0	0	0	3	12	72	4,80
6	0	0	0	1	14	74	4,93
7	0	0	0	2	13	73	4,87
8	1	1	2	1	10	63	4,20
9	0	0	0	2	13	73	4,87
Total	1	1	3	20	110	642	4,76

D.3 Rekapitulasi Skor Relevansi Output Aplikasi per Responden

Tabel L10. 12 Skor Relevansi Output Aplikasi per Responden

No. Responden	1	2	3	4	5	6	7	8	9	Total Skor
1	4	4	4	4	4	5	5	5	5	40
2	5	5	5	5	5	5	5	5	5	45
3	5	5	5	5	5	5	5	1	5	41
4	5	5	5	5	5	5	5	3	5	43
5	3	4	4	4	4	4	4	4	4	35

Tabel L10. 12 (Lanjutan)

No. Responden	1	2	3	4	5	6	7	8	9	Total Skor
6	4	5	5	5	5	5	5	2	5	41
7	5	4	4	4	4	5	4	3	4	37
8	5	5	5	5	5	5	5	5	5	45
9	5	5	5	5	5	5	5	5	5	45
10	5	5	5	5	5	5	5	5	5	45
11	5	5	5	5	5	5	5	5	5	45
12	5	5	5	5	5	5	5	5	5	45
13	5	5	5	5	5	5	5	5	5	45
14	5	5	5	5	5	5	5	5	5	45
15	5	5	5	5	5	5	5	5	5	45
Total	71	72	72	72	72	74	73	63	73	642

D.4 Perhitungan Persentase Relevansi Output Aplikasi

Jumlah responden adalah 15 orang. Jumlah pernyataan pada aspek relevansi output aplikasi adalah sembilan pernyataan. Skor tertinggi pada setiap pernyataan adalah 5. Peneliti menghitung skor maksimal sebagai berikut:

$$\text{Skor Maksimal} = 15 \times 9 \times 5 = 675$$

Peneliti memperoleh total skor relevansi output aplikasi sebesar 642. Peneliti menghitung persentase penilaian sebagai berikut:

$$\text{Persentase Relevansi Output Aplikasi} = \frac{642}{675} \times 100\% = 95{,}11\%$$

Peneliti menghitung nilai rata-rata relevansi output aplikasi sebagai berikut:

$$\text{Rata-Rata} = \frac{642}{15 \times 9} = \frac{642}{135} = 4{,}76$$

Berdasarkan perhitungan tersebut, aspek relevansi output aplikasi memperoleh total skor sebesar 642 dari skor maksimal 675, dengan nilai rata-rata sebesar 4,76 dan persentase sebesar 95,11%.

E. Perhitungan Keseluruhan Hasil Kuesioner Responden

Peneliti menghitung hasil keseluruhan kuesioner dengan menjumlahkan total skor pada aspek pengalaman menggunakan aplikasi dan aspek relevansi output aplikasi.

Tabel L10. 13 Ringkasan Perhitungan Hasil Kuesioner Responden

Aspek Penilaian	Jumlah Pernyataan	Total Skor	Skor Maksimal	Perhitungan Persentase	Persentase
Pengalaman Menggunakan Aplikasi	11	760	825	$760/825 \times 100\%$	92,12%
Relevansi Output Aplikasi	9	642	675	$642/675 \times 100\%$	95,11%
Keseluruhan Penilaian	20	1.402	1.500	$1.402/1.500 \times 100\%$	93,47%

Peneliti menghitung total skor keseluruhan sebagai berikut:

$$\text{Total Skor Keseluruhan} = 760 + 642 = 1.402$$

Peneliti menghitung skor maksimal keseluruhan sebagai berikut:

$$\text{Skor Maksimal Keseluruhan} = 825 + 675 = 1.500$$

Peneliti menghitung persentase keseluruhan sebagai berikut:

$$\text{Persentase Keseluruhan} = \frac{1.402}{1.500} \times 100\% = 93{,}47\%$$

Berdasarkan hasil perhitungan tersebut, aplikasi GrowSmart Health memperoleh persentase penilaian keseluruhan sebesar 93,47%. Nilai tersebut berasal dari aspek pengalaman menggunakan aplikasi sebesar 92,12% dan aspek relevansi output aplikasi sebesar 95,11%.

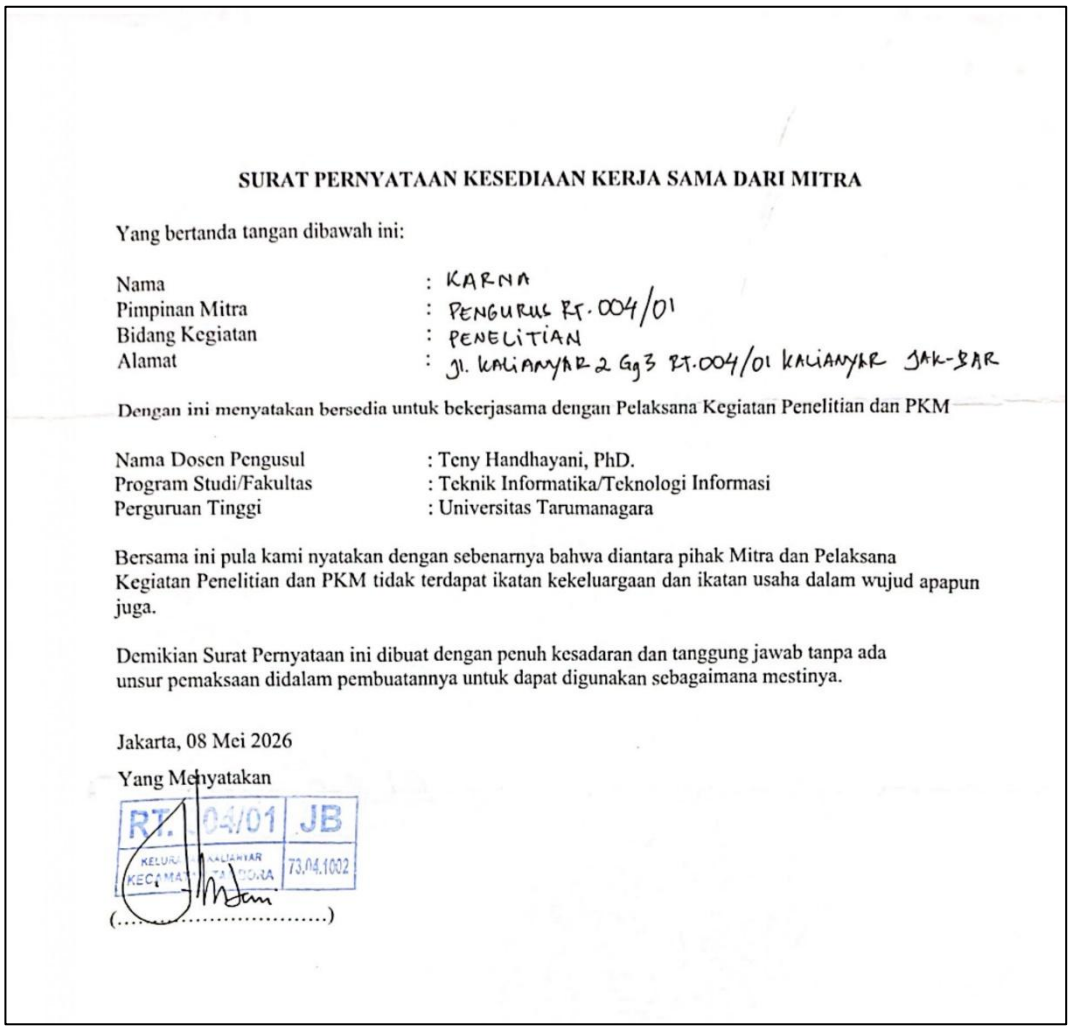
F. Kesimpulan Perhitungan Manual Kuesioner

Berdasarkan perhitungan manual terhadap jawaban 15 responden, aspek pengalaman menggunakan aplikasi memperoleh total skor sebesar 760 dari skor maksimal 825 atau sebesar 92,12%. Aspek relevansi output aplikasi memperoleh total skor sebesar 642 dari skor maksimal 675 atau sebesar 95,11%. Secara keseluruhan, hasil kuesioner memperoleh total skor sebesar 1.402 dari skor maksimal 1.500 atau sebesar 93,47%.

Hasil perhitungan tersebut menunjukkan bahwa responden memberikan penilaian yang sangat baik terhadap aplikasi GrowSmart Health. Responden menilai bahwa aplikasi mudah digunakan dan mampu menampilkan informasi hasil analisis yang relevan untuk membantu memperoleh gambaran awal mengenai status pertumbuhan dan gizi balita. Meskipun demikian, aplikasi tetap perlu memberikan penegasan bahwa hasil analisis hanya digunakan sebagai alat bantu skrining awal dan tidak menggantikan pemeriksaan langsung oleh tenaga kesehatan.

Lampiran 11

Dokumentasi Bersama Responden



SURAT PERNYATAAN KESEDIAAN KERJA SAMA DARI MITRA

Yang bertanda tangan dibawah ini:

Nama : KARNA
Pimpinan Mitra : PENGURUS RT. 004/01
Bidang Kegiatan : PENELITIAN
Alamat : Jl. KALIANYAR 2 Gg 3 RT.004/01 KALIANYAR JAK-BAR

Dengan ini menyatakan bersedia untuk bekerjasama dengan Pelaksana Kegiatan Penelitian dan PKM

Nama Dosen Pengusul : Teny Handhayani, PhD.
Program Studi/Fakultas : Teknik Informatika/Teknologi Informasi
Perguruan Tinggi : Universitas Tarumanagara

Bersama ini pula kami nyatakan dengan sebenarnya bahwa diantara pihak Mitra dan Pelaksana Kegiatan Penelitian dan PKM tidak terdapat ikatan kekeluargaan dan ikatan usaha dalam wujud apapun juga.

Demikian Surat Pernyataan ini dibuat dengan penuh kesadaran dan tanggung jawab tanpa ada unsur pemaksaan didalam pembuatannya untuk dapat digunakan sebagaimana mestinya.

Jakarta, 08 Mei 2026

Yang Menyatakan

RT. 04/01 JB

(.....)

Gambar L11. 1 Surat Pernyataan Kesediaan Kerja Sama kepada RT Setempat



Gambar L11. 2 Dokumentasi Bersama RT



Gambar L11. 3 Dokumentasi Bersama Responden 1



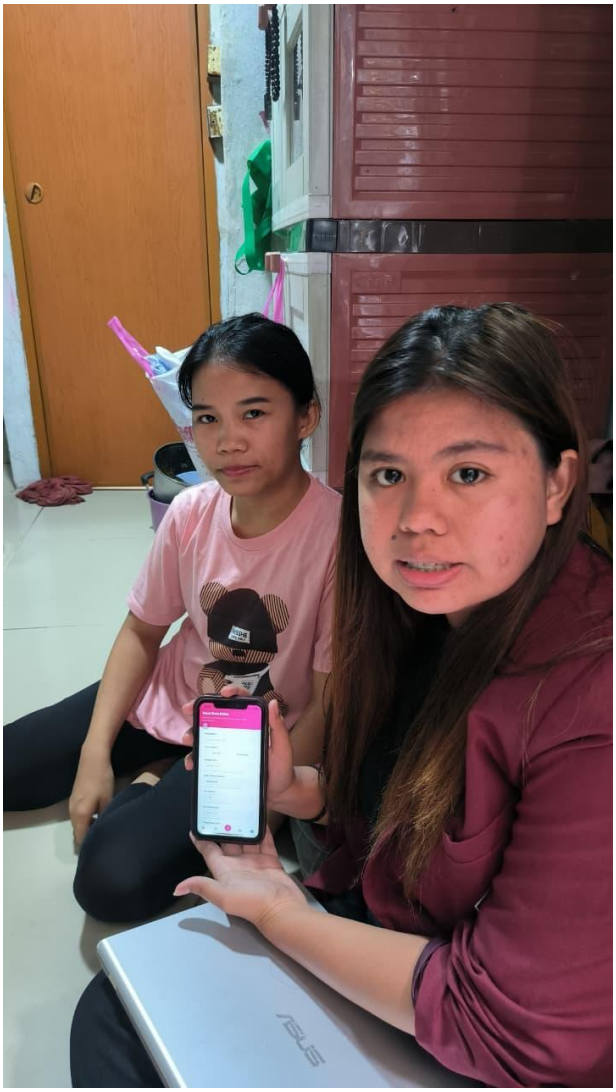
Gambar L11. 4 Dokumentasi Bersama Responden 2



Gambar L11. 5 Dokumentasi Bersama Responden 3



Gambar L11. 6 Dokumentasi Bersama Responden 4



Gambar L11. 7 Dokumentasi Bersama Responden 5



Gambar L11. 8 Dokumentasi Bersama Responden 6



Gambar L11. 9 Dokumentasi Bersama Responden 7



Gambar L11. 10 Dokumentasi Bersama Responden 8



Gambar L11. 11 Dokumentasi Bersama Responden 9



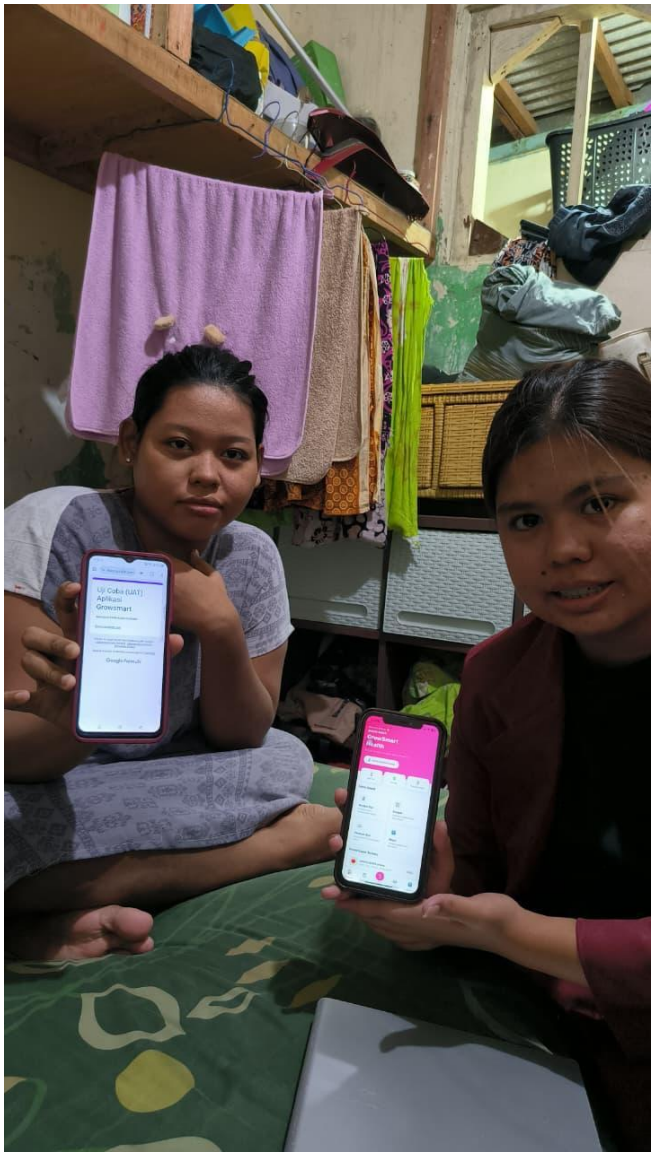
Gambar L11. 12 Dokumentasi Bersama Responden 10



Gambar L11. 13 Dokumentasi Bersama Responden 11



Gambar L11. 14 Dokumentasi Bersama Responden 12



Gambar L11. 15 Dokumentasi Bersama Responden 13



Gambar L11. 16 Dokumentasi Bersama Responden 14



Gambar L11. 17 Dokumentasi Bersama Responden 15

Lampiran 12

Black Box Testing

ANGKET BLACK BOX TESTING APLIKASI GROWSMART HEALTH

SISTEM KLASIFIKASI STATUS TUMBUH KEMBANG DAN GIZI BALITA MENGGUNAKAN LIGHTGBM

Identitas Tester

Nama : Alfiah Yuli

Gender : Perempuan

Umur : 38 Tahun

Alamat : Jl Kalianyar III RT004 / RW 001 No. 28 Tambora Jakarta Barat

Petunjuk Pengisian

1. Lakukan pengujian pada aplikasi sesuai dengan skenario yang ada.
2. Bandingkan hasil pengujian dengan hasil yang diharapkan untuk mengetahui kesesuaiannya.
3. Deskripsikan hasil pengujiannya pada kolom **"Hasil Pengujian"**.
4. Berikan tanda **(V)** pada salah satu kolom kesimpulan. Pilih **Diterima** apabila hasil pengujian sudah sesuai dengan yang diharapkan, sedangkan **Perbaikan** berarti fitur perlu diperbaiki agar sesuai dengan harapan.

Fitur	Skenario Uji	Hasil yang Diharapkan	Hasil Pengujian	Kesimpulan Diterima	Kesimpulan Perbaikan
	Pengguna membuka aplikasi.	Sistem menampilkan halaman awal atau halaman login aplikasi GrowSmart Health.	Sesuai	**(V)**	
	Pengguna memilih menu	Akun baru berhasil dibuat.	Sesuai	**(V)**	

Gambar L12. 1 Hasil Black Box Testing

Autentikasi dan Navigasi Dasar	**Register**, mengisi nama, email, dan password, lalu menekan tombol **Daftar**.	Sistem menampilkan notifikasi bahwa pendaftaran berhasil dan mengarahkan pengguna ke halaman login.			
	Pengguna mengisi form register dengan data yang belum lengkap.	Sistem menampilkan peringatan bahwa seluruh data wajib diisi.	Sesuai	**(V)**	
	Pengguna melakukan register menggunakan email yang sudah terdaftar.	Sistem menampilkan pesan bahwa email sudah digunakan atau akun sudah terdaftar.	Sesuai	**(V)**	
	Pengguna memasukkan email dan password yang valid, lalu menekan tombol **Login**.	Login berhasil. Sistem menampilkan halaman utama aplikasi.	Sesuai	**(V)**	
	Pengguna memasukkan email atau password yang salah.	Login gagal. Sistem menampilkan pesan bahwa email atau password tidak sesuai.	Sesuai	**(V)**	

Gambar L12. 1 (Lanjutan)

	dalam satuan bulan.	data tersebut untuk proses klasifikasi.			
	Pengguna memasukkan berat badan balita dalam satuan kilogram.	Sistem menerima input berat badan dan menggunakan data tersebut untuk proses klasifikasi.	Sesuai	**(V)**	
	Pengguna memasukkan tinggi badan balita dalam satuan sentimeter.	Sistem menerima input tinggi badan dan menggunakan data tersebut untuk proses klasifikasi.	Sesuai	**(V)**	
Validasi Input Pemeriksaan	Pengguna menekan tombol **Proses** atau **Klasifikasi** tanpa mengisi salah satu data wajib.	Sistem menampilkan peringatan bahwa seluruh data wajib diisi.	Sesuai	**(V)**	
	Pengguna memasukkan huruf pada kolom usia, berat badan, atau tinggi badan.	Sistem menolak input dan meminta pengguna memasukkan data dalam bentuk angka.	Sesuai	**(V)**	
	Pengguna memasukkan nilai usia, berat badan, atau	Sistem menampilkan peringatan bahwa	Sesuai	**(V)**	

Gambar L12. 1 (Lanjutan)

	tinggi badan dengan angka nol.	nilai input tidak valid.			
	Pengguna memasukkan nilai berat badan atau tinggi badan yang tidak wajar.	Sistem menampilkan peringatan bahwa data yang dimasukkan perlu diperiksa kembali.	Sesuai	**(V)**	
Proses Klasifikasi	Pengguna mengisi seluruh data balita dengan benar dan menekan tombol **Proses** atau **Klasifikasi**.	Sistem memproses data dan menampilkan hasil klasifikasi status tumbuh kembang balita.	Sesuai	**(V)**	
Proses Klasifikasi BB/U	Sistem memproses data balita untuk indikator berat badan menurut umur.	Sistem menampilkan hasil klasifikasi **Weight for Age / BB/U** sesuai data yang dimasukkan.	Sesuai	**(V)**	
Proses Klasifikasi TB/U	Sistem memproses data balita untuk indikator tinggi badan menurut umur.	Sistem menampilkan hasil klasifikasi **Height for Age / TB/U** sesuai data yang dimasukkan.	Sesuai	**(V)**	
Proses Klasifikasi BB/TB	Sistem memproses data balita untuk indikator berat badan	Sistem menampilkan hasil klasifikasi **Weight for Height / BB/TB** sesuai	Sesuai	**(V)**	

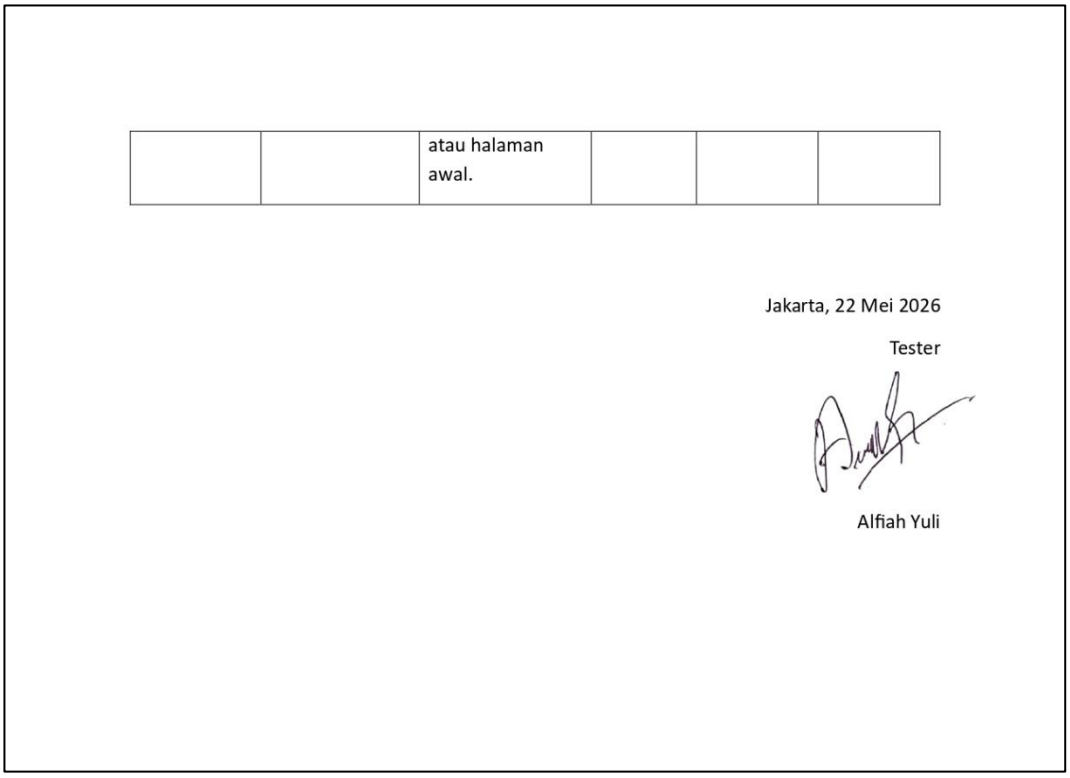
Gambar L12. 1 (Lanjutan)

	menurut tinggi badan.	data yang dimasukkan.			
Halaman Hasil Pemeriksaan	Pengguna melihat halaman hasil setelah proses klasifikasi selesai.	Sistem menampilkan hasil pemeriksaan secara jelas, meliputi BB/U, TB/U, dan BB/TB.	Sesuai	**(V)**	
	Pengguna membaca interpretasi hasil klasifikasi.	Sistem menampilkan keterangan hasil yang mudah dipahami, seperti normal, underweight, stunted, thin, very thin, obese, atau kategori lain sesuai hasil model.	Sesuai	**(V)**	
	Pengguna menekan tombol **Simpan Hasil Pemeriksaan**.	Sistem menyimpan data balita dan hasil klasifikasi ke dalam riwayat pemeriksaan.	Sesuai	**(V)**	
Panduan Gizi	Pengguna menekan menu **Panduan Gizi** pada aplikasi.	Sistem menampilkan halaman **Panduan Gizi**.	Sesuai	**(V)**	
	Pengguna membuka halaman **Panduan Gizi**.	Sistem menampilkan informasi panduan gizi balita dengan	Sesuai	**(V)**	

Gambar L12. 1 (Lanjutan)

		jelas dan mudah dipahami.			
Riwayat Pemeriksaan	Pengguna membuka halaman **Riwayat** setelah melakukan pemeriksaan.	Sistem menampilkan daftar hasil pemeriksaan yang telah disimpan.	Sesuai	**(V)**	
	Pengguna memilih salah satu data riwayat pemeriksaan.	Sistem menampilkan detail data balita dan hasil klasifikasi dari riwayat yang dipilih.	Sesuai	**(V)**	
	Pengguna menghapus salah satu data riwayat pemeriksaan.	Sistem menghapus data riwayat yang dipilih dan menampilkan perubahan pada daftar riwayat.	Sesuai	**(V)**	
Respons Tampilan	Pengguna membuka aplikasi melalui perangkat dengan ukuran layar berbeda.	Tampilan aplikasi tetap dapat digunakan dengan baik dan komponen halaman tidak berantakan.	Sesuai	**(V)**	
Logout	Pengguna menekan tombol **Logout**.	Pengguna berhasil keluar dari akun dan sistem kembali menampilkan halaman login	Sesuai	**(V)**	

Gambar L12. 1 (Lanjutan)



		atau halaman awal.			

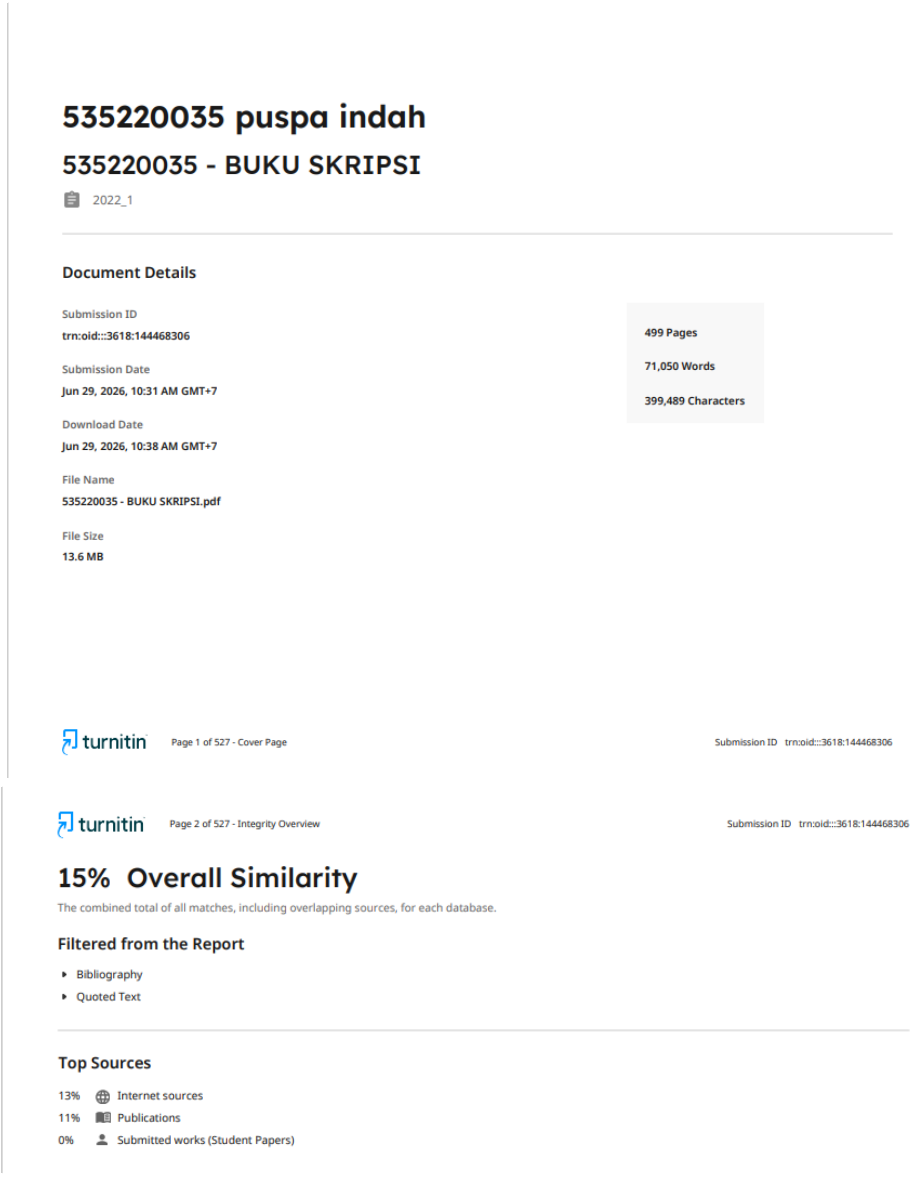
Jakarta, 22 Mei 2026

Tester

Alfiah Yuli

Gambar L12. 1 (Lanjutan)

Lampiran 13 Turnitin



535220035 puspa indah

535220035 - BUKU SKRIPSI

2022_1

Document Details

Submission ID
trn:oid:::3618:144468306

Submission Date
Jun 29, 2026, 10:31 AM GMT+7

Download Date
Jun 29, 2026, 10:38 AM GMT+7

File Name
535220035 - BUKU SKRIPSI.pdf

File Size
13.6 MB

499 Pages

71,050 Words

399,489 Characters

turnitin Page 1 of 527 - Cover Page Submission ID trn:oid:::3618:144468306

turnitin Page 2 of 527 - Integrity Overview Submission ID trn:oid:::3618:144468306

15% Overall Similarity

The combined total of all matches, including overlapping sources, for each database.

Filtered from the Report

- Bibliography
- Quoted Text

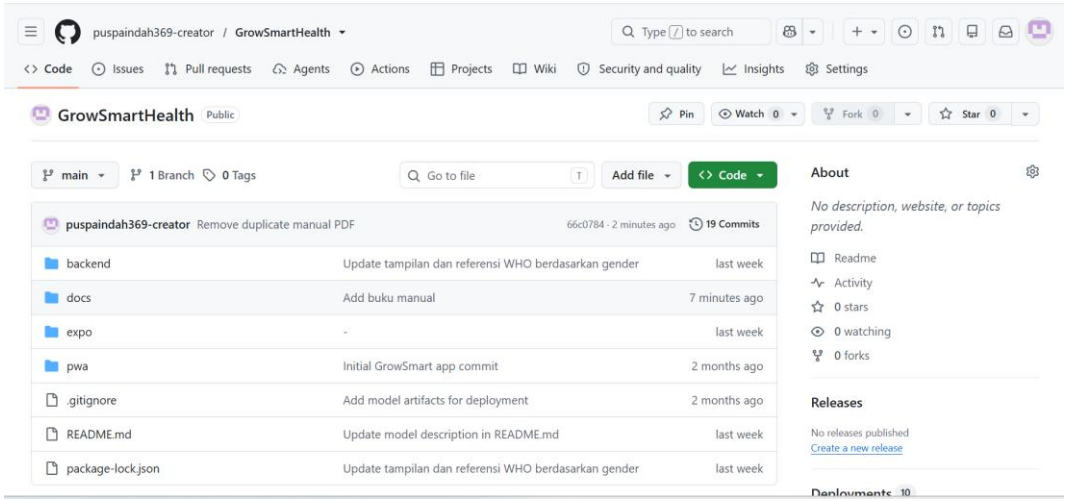
Top Sources

13% Internet sources
11% Publications
0% Submitted works (Student Papers)

Gambar L13. 1 Hasil Cek Plagiasi Turnitin

Lampiran 14 Github

Program Skripsi dapat dilihat pada Link Github berikut : **LINK GUTHUB**



Gambar L14. 1 Tampilan Github

Daftar Riwayat Hidup

Nama : Puspa Indah

NPM : 535220035

Tempat/tanggal lahir : Jakarta, 28 Juli 2003

Alamat : Jl. Kalianyar II RT004/RW 01 NO.21 Tambora, Jakarta Barat 11310

No. Telepon/HP : 085775379165

Alamat email : puspaindah0707@gmail.com

Riwayat Pendidikan :

- SDN Kalianyar 02, Jl. Kalianyar Raya No.11 5, RT.5/RW.3, Kali Anyar, Kec. Tambora, Kota Jakarta Barat, Daerah Khusus Ibukota Jakarta 11310, 2011 – 2016
- SMPN 159 JAKARTA, Jl. Jembatan Besi Raya No.24, RT.1/RW.5, Jemb. Besi, Kec. Tambora, Kota Jakarta Barat, Daerah Khusus Ibukota Jakarta 11320, 2016 – 2019
- SMK FARMASI CANDRA NAYA, Jl. Jemb. Besi II No.26, RT.8/RW.3, Jemb. Besi, Kec. Tambora, DKI Jakarta, Daerah Khusus Ibukota Jakarta 11320, 2019 – 2022
- Program Studi Teknik Informatika Fakultas Teknologi Informasi Universitas Tarumanagara, 2022 – 2026

Riwayat Pekerjaan :

- IT Support, Rumah Sakit Bhakti Mulia, Jl. K.S. Tubun No.79 9, RT.9/RW.5, Slipi, Kec. Palmerah, Kota Jakarta Barat, Daerah Khusus Ibukota Jakarta 11410, 27 Januari – 27 Juni 2025